گزارش مدل KG-GT v2:
پیش‌بینی پوش EMG از سینماتیک و EEG با تفسیرپذیری در همه‌ی لایه‌ها

تیم ۶، مدرسه‌ی بین‌رشته‌ای علوم اعصاب محاسباتی

مهر ۱۴۰۵

چکیده

این گزارش دو مدل را برای پیش‌بینی پوش فعالیت پنج عضله‌ی دست و بازو در داده‌ی WAY-EEG-GAL مقایسه می‌کند. مدل پایه (KG-GT، دفترچه‌ی main_1stage در شاخه‌ی KG-GT-CUDA) یک encoder Transformer روی EEG و یک muscle graph با هدایت سینماتیک دارد و یک خروجی می‌دهد. روی سری‌های آزمون ۱۲ شرکت‌کننده به VAF برابر ۷۲٫۲ درصد و ضریب همبستگی ۰٫۸۵۱ رسید، اما آزمون‌های حذف ورودی نشان دادند که تقریباً همه‌ی این دقت از سینماتیک می‌آید و نمی‌توان سهم EEG را از سهم سینماتیک جدا کرد. مدل v2 سه خروجی جدا می‌دهد: K از سینماتیک و تاریخچه‌ی بلندکردن‌ها، E فقط از EEG و F که K را با یک اصلاحِ gated از EEG ترکیب می‌کند. K با VAF برابر ۷۵٫۸ درصد و r برابر ۰٫۸۷۲ در هر ۱۲ شرکت‌کننده از مدل پایه بهتر شد. E به‌تنهایی به r برابر ۰٫۶۴۵ رسید و در هر ۱۲ نفر از null test گذشت. F عملاً برابر K ماند. residual test نشان داد EEG اطلاعات کمی درباره‌ی خطای K دارد (r حدود ۰٫۰۷، معنادار در ۱۰ نفر از ۱۲) که کمتر از نیم واحد درصد به VAF اضافه می‌کند. مدل v2 از ابتدا طوری ساخته شد که هر خروجی را بتوان در همه‌ی لایه‌ها با rollout توجه، attention flow، gradient-weighted rollout و gradient × input ردیابی کرد؛ این روش‌ها با deletion check و weight-shuffle check سنجیده شدند.

فهرست مطالب

۱ داده و هدف پیش‌بینی **۴**

۲ مدل پایه: KG-GT در شاخه‌ی KG-GT-CUDA **۴**

۱.۲ ورودی‌ها و خروجی ۴

۲.۲ معماری ۴

۳.۲ loss function ۵

۴.۲ آموزش ۷

۵.۲ نتایج مدل پایه ۷

۳ کاستی‌های مدل پایه **۱۲**

۴ چرا v2 **۱۳**

۵ مدل v2 **۱۳**

۱.۵ ورودی‌ها، tokens و خروجی‌ها . . . ۱۳

۲.۵ بلوک یکسان توجه . . . ۱۴

۳.۵ جریان سینماتیک . . . ۱۴

۴.۵ جریان EEG . . . ۱۶

۵.۵ fusion . . . ۱۶

۶.۵ loss function . . . ۱۶

۷.۵ آموزش . . . ۱۶

۸.۵ پیش‌بینی روی یک سری کامل . . . ۱۷

۶ نتایج ارزیابی v2 **۱۸**

۱.۶ دقت E ،K و F . . . ۱۸

۲.۶ هر عضله و سقف داده . . . ۱۹

۳.۶ دامنه در هر وزن . . . ۲۰

۴.۶ triptych figures . . . ۲۰

۷ تفسیرپذیری در v2 **۲۹**

۱.۷ چه چیزی توضیح داده می‌شود . . . ۲۹

۲.۷ attention rollout و attention flow . . . ۲۹

۳.۷ gradient-weighted rollout . . . ۳۰

۴.۷ نمای هر لایه . . . ۳۰

۵.۷ gradient × input . . . ۳۰

۶.۷ میانگین روی رخدادها و مقایسه با استراحت . . . ۳۰

۷.۷ سنجش خودِ نقشه‌ها . . . ۳۱

۸.۷ نتایج برای همه‌ی شرکت‌کننده‌ها . . . ۳۲

۹.۷ نتایج P1 و P2 . . . ۳۳

۸ attention rollout و attention flow **۳۹**

۱.۸ نمادگذاری و layered graph . . . ۳۹

۲.۸ attention rollout . . . ۳۹

۳.۸ attention flow . . . ۴۱

۴.۸ پیاده‌سازی . . . ۴۳

۵.۸ چرا attention flow در این مدل اشباع می‌شود . . . ۴۳

۶.۸ نتایج . . . ۴۶

۹ residual test: آیا EEG چیزی بیش از سینماتیک دارد؟ **۴۶**

۱.۹ پرسش ۴۶
۲.۹ روش ۴۷
۳.۹ یک دام: موقعیت درون پنجره ۴۷
۴.۹ نتایج ۴۸
۵.۹ بحث ۴۹

۱۰ جمع‌بندی و محدودیت‌ها **۴۹**

۱ داده و هدف پیش‌بینی

داده‌ی WAY-EEG-GAL [۱] ثبت هم‌زمان EEG، الکترومیوگرافی (EMG)، سینماتیک دست و نیروهای جسم را در آزمایش «گرفتن و بلندکردن» دارد. ۱۲ شرکت‌کننده جسمی را با دست راست می‌گیرند، بلند می‌کنند، چند ثانیه نگه می‌دارند و سر جایش می‌گذارند. وزن جسم (سبک، متوسط، سنگین) و جنس سطح تماس آن بین سری‌ها و گاهی بین بلندکردن‌ها تغییر می‌کند. هر سری چند ده بلندکردن پشت سر هم است.

هدف در هر دو مدل این گزارش، پوش EMG پنج عضله است: دلتوئید قدامی (AD)، براکیورادیالیس (BR)، فلکسور انگشتان (FD)، اکستنسور انگشتان (ED) و اولین بین‌استخوانی پشتی (FDI). پوش با این مراحل ساخته می‌شود: فیلتر band-pass ۳۰ تا ۳۰۰ هرتز روی سیگنال خام ۴۰۰۰ هرتز، عملگر انرژی TKEO، low-pass علّی ۸ هرتز و کاهش نرخ به ۵۰۰ هرتز. EMG فقط هدف است و هیچ‌جا ورودی مدل نیست.

سری‌های هر شرکت‌کننده به سه دسته‌ی آموزش، validation و آزمون تقسیم می‌شوند؛ تقسیم برای هر شرکت‌کننده جداگانه و لایه‌بندی‌شده بر اساس شرایط سری است و هر دو مدل از همین تقسیم استفاده می‌کنند. همه‌ی اعداد این گزارش روی سری‌های آزمون است (برای هر شرکت‌کننده دو سری).

معیارها برای هر عضله جدا حساب می‌شوند. اگر y هدف و $\hat{y}$ پیش‌بینی باشد:

$$\mathrm{VAF} = ۱۰۰\left(۱ - \frac{\mathrm{Var}(y-\hat{y})}{\mathrm{Var}(y)}\right), \qquad \mathrm{CCC} = \frac{۲\,\mathrm{Cov}(y,\hat{y})}{\mathrm{Var}(y)+\mathrm{Var}(\hat{y})+(\bar{y}-\bar{\hat{y}})^{۲}}, \tag{۱}$$

و r Pearson correlation است. VAF هم شکل و هم دامنه را می‌سنجد و r فقط شکل را. «height ratio» میانگین پیش‌بینی به میانگین هدف در مرحله‌ی نگه‌داشتن جسم است و مقدار مطلوبش ۱ است.

۲ مدل پایه: KG-GT در شاخه‌ی KG-GT-CUDA

مدل پایه همان مدلی است که دفترچه‌ی main_1stage.ipynb در شاخه‌ی KG-GT-CUDA آموزش می‌دهد. نام آن از «Transformer گراف با هدایت سینماتیک» (Kinematics-Guided Graph Transformer) آمده است. کل مدل در یک مرحله و یک‌جا آموزش می‌بیند.

۱.۲ ورودی‌ها و خروجی

EEG: ۳۲ کانال با نرخ ۵۰۰ هرتز، پس از فیلتر band-pass ۰٫۵ تا ۴۰ هرتز، فیلتر ناچ ۵۰ هرتز و حذف خودکار artifact با ICA. سیگنال در حوزه‌ی زمان (نه band power) به مدل داده می‌شود.

سینماتیک: ۲۴ ویژگی با نرخ ۵۰۰ هرتز: ۱۰ ویژگی وضعیت دست، نیروی بار (F_L) و نیروی گرفتن (F_G) که در یک «gate نزدیکی دست به جسم» ضرب شده‌اند، ۱۰ سرعت وضعیت دست و سرعت دو نیروی gated. gate وقتی انگشت اشاره تا ۱۲ سانتی‌متری جسم است ۱ است و تا ۲۰ سانتی‌متر به‌تدریج به صفر می‌رسد؛ با آن، نیرویی که دیگران هنگام آماده‌سازی جسم وارد می‌کنند وارد مدل نمی‌شود. سرعت‌ها با فیلتر ساویتزکی‌گولای (پنجره‌ی ۵۱ نمونه) حساب می‌شوند و همه‌ی ویژگی‌ها با آماره‌های سری‌های آموزش استاندارد می‌شوند.

پنجره: یک ثانیه (۵۰۰ نمونه) بدون هم‌پوشانی. هدف در هر پنجره پوش EMG استانداردشده (z-score) است و خروجی مدل در پایان به واحد اصلی برمی‌گردد.

۲.۲ معماری

شکل ۱ مسیر داده را نشان می‌دهد. با نماد $X^e \in \mathbb{R}^{T\times ۳۲}$ برای EEG و $X^k \in \mathbb{R}^{T\times ۲۴}$ برای سینماتیک ($T = ۵۰۰$):

۱. **temporal encoder:** Transformer با ۴ لایه، ۸ سر، عرض $d = ۱۲۸$ و شبکه‌ی feed-forward ۵۱۲، با توجهِ تکه‌تکه (تکه‌های ۵۰۰ نمونه‌ای) و sinusoidal positional encoding: $H = \mathrm{Enc}(X^e) \in \mathbb{R}^{T\times ۱۲۸}$.

۲. **تصویر به گره‌های عضله:** یک لایه‌ی خطی H را به پنج گره با عرض ۶۴ می‌برد: $N_t \in \mathbb{R}^{۵\times ۶۴}$.

۳. **muscle graph با هدایت سینماتیک:** graph attention (GAT [۳]) با ۴ سر بین پنج گره. امتیاز یال $j \to i$ در سر h و زمان t سه جزء دارد:

$$s^h_{ij}(t) = \frac{q^h_i(t)\cdot k^h_j(t)}{\sqrt{d_k}} + B^h_{ij} + \big[W x^g(t) + b\big]^h_{ij}, \tag{۲}$$

که B bias ایستای یال‌هاست (مقداردهی اولیه از همبستگی EMG آموزش) و $x^g(t)$ دوازده ویژگی اول سینماتیک (وضعیت دست و دو نیروی gated) است که با یک لایه‌ی خطی به bias پویای یال‌ها تبدیل می‌شود.

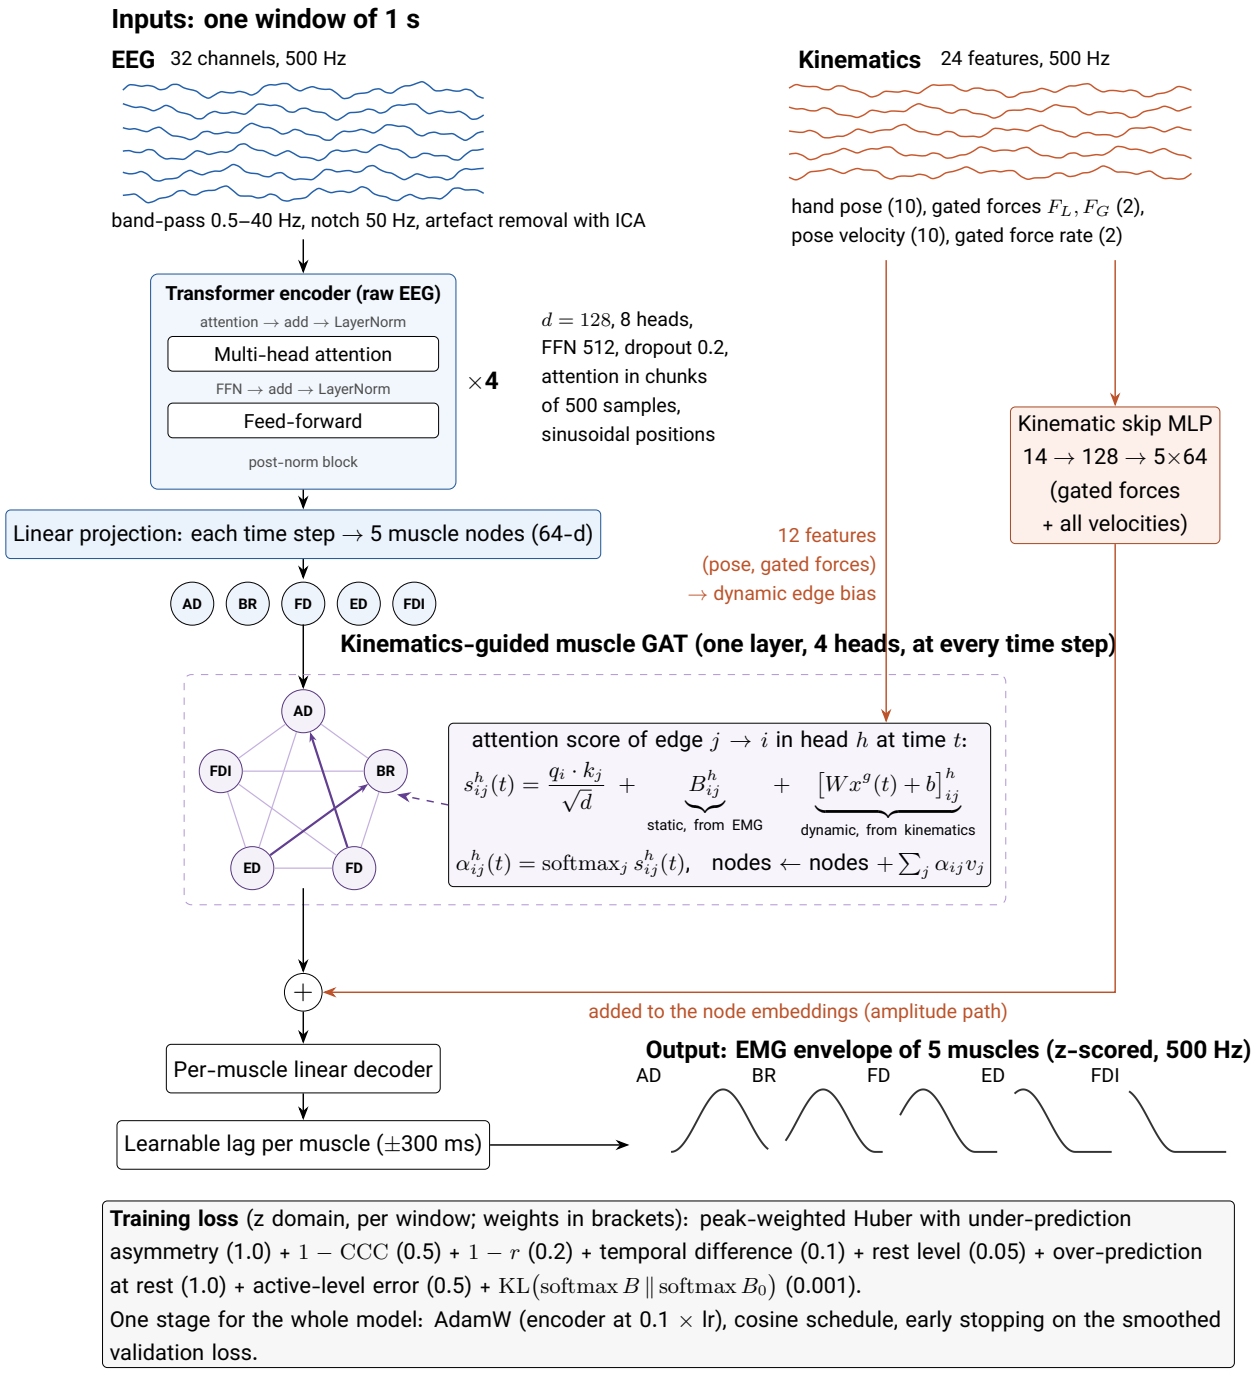
۴. **kinematic skip highway:** ۱۴ ویژگی (دو نیروی gated و ۱۲ سرعت) از یک شبکه‌ی کوچک (خطی، LayerNorm، GELU، خطی) می‌گذرند و مستقیم به بردار گره‌ها اضافه می‌شوند: $Z_t = \mathrm{GAT}(N_t, x^g_t) + \mathrm{MLP}(x^s_t)$.

۵. **decoder و هم‌ترازی تأخیر:** یک لایه‌ی خطی برای هر عضله Z_t را به یک عدد تبدیل می‌کند و یک تأخیر آموختنی برای هر عضله (تا ± ۳۰۰ میلی‌ثانیه) خروجی را در زمان جابه‌جا می‌کند.

۳.۲ loss function

هزینه در حوزه‌ی استانداردشده (z) و روی هر پنجره حساب می‌شود و هشت جزء دارد. با y_{tc} هدف و $\hat{y}_{tc}$ پیش‌بینی در زمان t و عضله‌ی c، و $u_{tc} = (y_{tc} - \min_t y)/(\max_t y - \min_t y)$ سطح نسبی فعالیت در همان پنجره:

- **خطای وزن‌دار قله‌ها** (وزن ۱٫۰): $L_{peak} = \mathrm{mean}\left[w_c\,(۱+\alpha u^۲)\,(۱+(a-۱)\,\mathbb{I}[\hat{y}<y]\,u)\,\rho_\delta(\hat{y}-y)\right]$ با $\alpha = ۳$، ضریب عدم‌تقارن $a = ۱٫۵$ (کم‌برآوردی در قله‌ها گران‌تر است)، ρ_δ دو برابر تابع هوبر با $\delta = ۲٫۵$ و w_c وزن هر عضله (عکس صدک ۹۵ هدف، با میانگین ۱).
- **concordance correlation (CCC)** (وزن ۰٫۵): $L_{ccc} = ۱ - \mathrm{CCC}$ برای هر پنجره و عضله.
- **Pearson correlation** (وزن ۰٫۲): $L_r = ۱ - r$.
- **تفاضل زمانی** (وزن ۰٫۱): اختلاف تفاضل‌های مرتبه‌ی اول پیش‌بینی و هدف.
- **استراحت** (وزن ۰٫۰۵): $L_{rest} = \mathrm{mean}\left[m\,|\hat{y} - \min_t y|\right]$ که m نقاطی است که هدف در ۱۵ درصد پایینیِ بازه‌ی پنجره است.
- **بیش‌برآوردی در استراحت** (وزن ۱٫۰): $\mathrm{mean}\left[m\,w_c\,\mathrm{relu}(\hat{y}-y)^۲\right]$.
- **سطح فعالیت** (وزن ۰٫۵): خطای نسبی میانگین سطح فعالیت (بالاتر از کمینه‌ی پنجره) در نقاط غیراستراحت، با هوبر هموار و همان عدم‌تقارن a.
- **تنظیم گراف** (وزن ۰٫۰۰۱): واگرایی $\mathrm{KL}\big(\,\mathrm{softmax}(B)\,\|\,\mathrm{softmax}(B_۰)\big)$ که bias ایستای یال‌ها را نزدیک مقدار اولیه‌ی برگرفته از همبستگی EMG نگه می‌دارد.



شکل ۱: نمای کلی مدل پایه KG-GT از ورودی تا خروجی. پنجره‌ی یک‌ثانیه‌ای EEG از Transformer encoder (چهار بلوک توجه و feed-forward) می‌گذرد، هر گام زمانی به پنج گره‌ی عضله تصویر می‌شود و یک لایه‌ی graph attention بین عضله‌ها پیام جابه‌جا می‌کند. سینماتیک از دو راه وارد می‌شود: دوازده ویژگی امتیاز یال‌های گراف را تغییر می‌دهند (خط نارنجی) و چهارده ویژگی از یک بزرگراه مستقیم به بردار گره‌ها اضافه می‌شوند. رمزگشای هر عضله و تأخیر آموختنی پوش EMG را می‌سازند. کادر پایین هشت جزء loss function را با وزن‌هایشان نشان می‌دهد.

۴.۲ آموزش

AdamW optimizer با learning rate $۱۰^{-۳}$ برای گراف و decoder و یک‌دهم آن برای encoder، weight decay ۰٫۰۱، ۵ دوره warm-up و سپس cosine decay، batch size ۳۲ با انباشت دو گام، mixed precision و حداکثر ۲۰۰ دوره. early stopping وقتی است که میانگین پنج‌دوره‌ای خطای validation ۲۰ دوره بهتر نشود.

۵.۲ نتایج مدل پایه

جدول ۱ نتیجه‌ی هر شرکت‌کننده و جدول ۲ نتیجه‌ی هر عضله را نشان می‌دهد. میانگین VAF برابر ۷۲٫۲ درصد و میانگین r برابر ۰٫۸۵۱ است. سه عضله‌ی AD، BR و ED خوب پیش‌بینی می‌شوند و FD و FDI ضعیف‌ترند. میانگین height ratio ۰٫۹۷۳ است؛ یعنی دامنه به‌طور کلی درست است، اما سطح بیش‌برآورد (۰٫۱۳۸) از سطح کم‌برآورد (۰٫۰۸۹) بیشتر است.

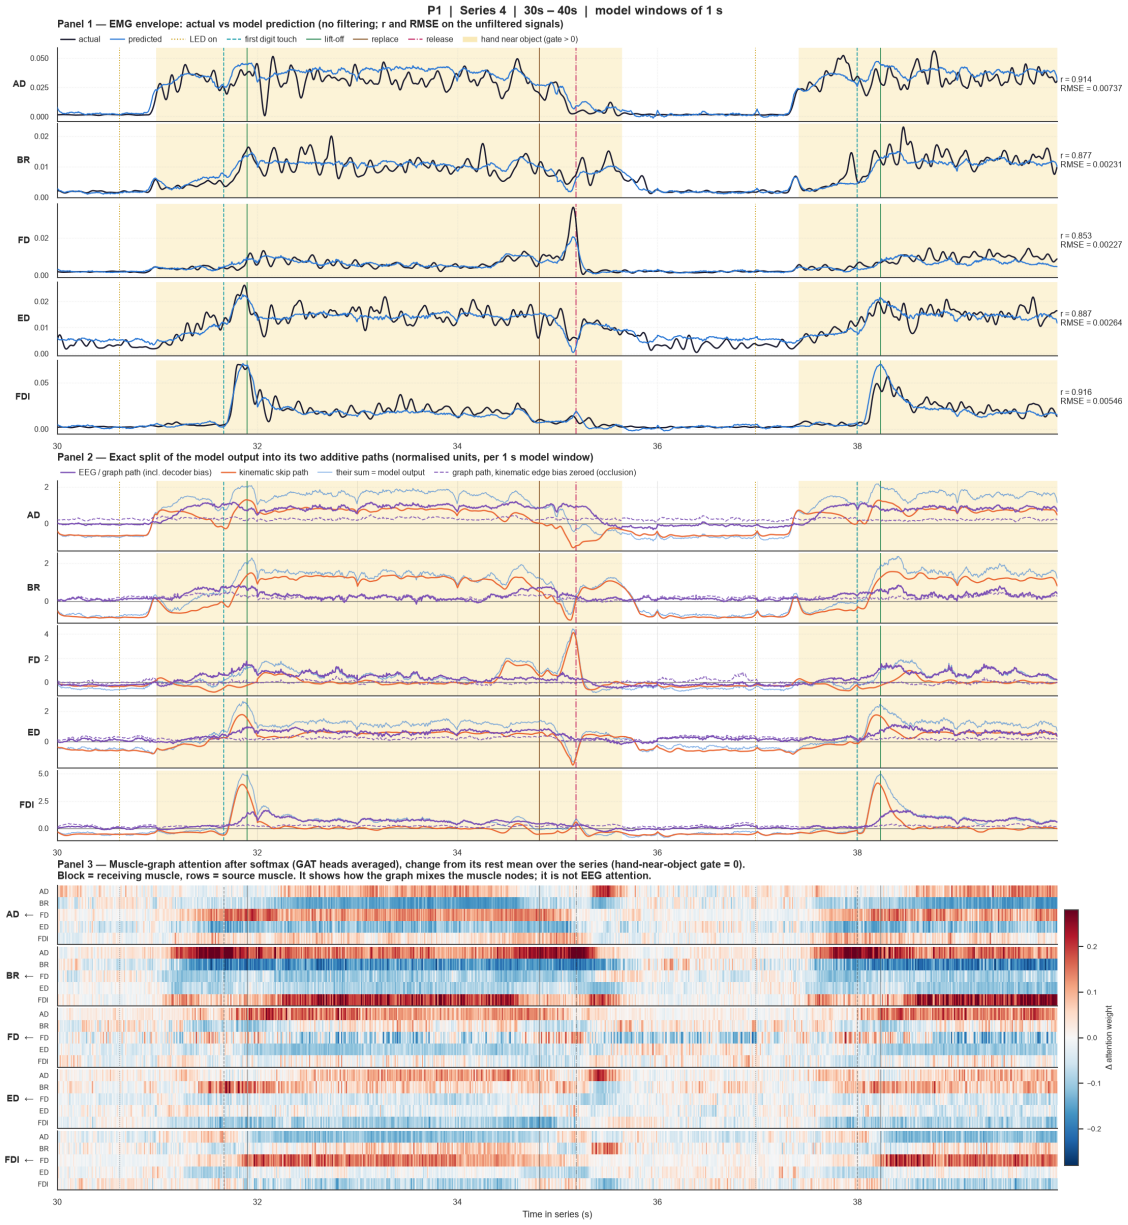
جدول ۱: مدل پایه KG-GT (main_1stage)، سری‌های آزمون: میانگین روی پنج عضله برای هر شرکت‌کننده.

شرکت‌کننده	r	CCC	VAF (%)	height ratio
P1	۰٫۸۹۱	۰٫۸۶۹	۷۹٫۰	۰٫۹۲۲
P2	۰٫۸۷۲	۰٫۸۶۸	۷۵٫۲	۰٫۹۷۷
P3	۰٫۸۱۱	۰٫۷۸۲	۶۷٫۵	۰٫۹۹۴
P4	۰٫۸۸۰	۰٫۸۷۱	۷۶٫۰	۱٫۰۳۱
P5	۰٫۷۷۷	۰٫۷۳۶	۶۳٫۵	۰٫۹۲۷
P6	۰٫۸۶۵	۰٫۸۳۱	۷۴٫۷	۰٫۹۹۴
P7	۰٫۸۹۹	۰٫۸۷۰	۷۹٫۱	۰٫۸۹۸
P8	۰٫۷۶۴	۰٫۷۴۲	۵۴٫۳	۱٫۰۴۷
P9	۰٫۸۹۷	۰٫۸۹۲	۷۹٫۳	۰٫۹۹۳
P10	۰٫۸۷۱	۰٫۸۶۵	۷۴٫۹	۰٫۹۹۱
P11	۰٫۸۵۸	۰٫۸۴۸	۷۳٫۶	۰٫۹۵۴
P12	۰٫۸۳۲	۰٫۸۱۴	۶۹٫۸	۰٫۹۴۹
میانگین	۰٫۸۵۱	۰٫۸۳۲	۷۲٫۲	۰٫۹۷۳

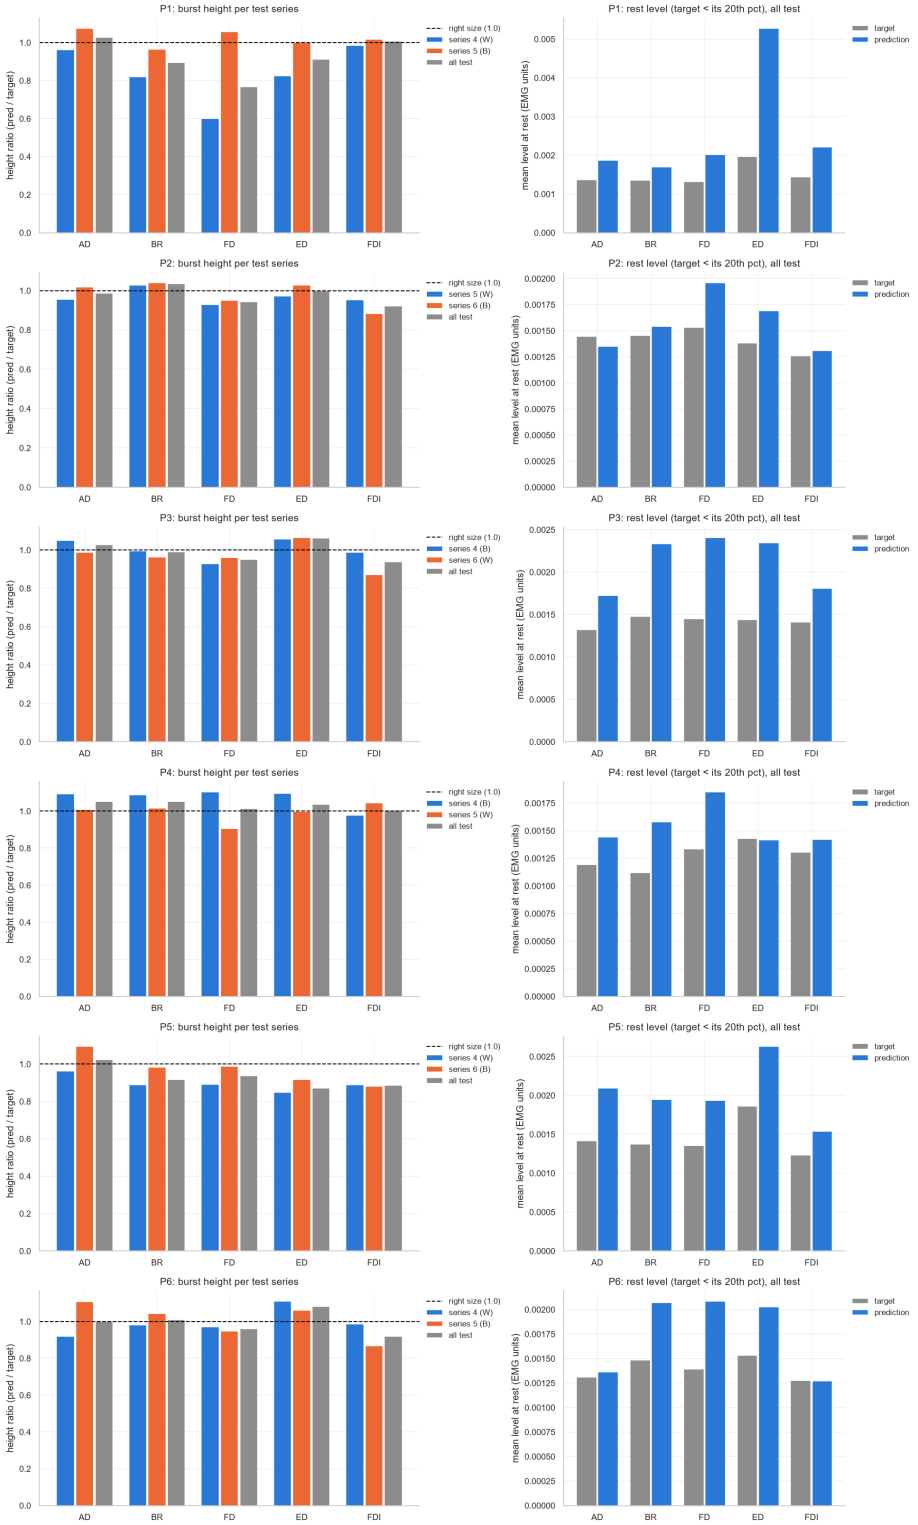
جدول ۲: مدل پایه، میانگین روی ۱۲ شرکت‌کننده برای هر عضله.

عضله	r	VAF (%)	سطح بیش‌برآورد	سطح کم‌برآورد
AD	۰٫۹۳۴	۸۵٫۹	۰٫۱۵۴	۰٫۰۷۴
BR	۰٫۸۹۷	۷۹٫۶	۰٫۱۱۸	۰٫۰۶۸
FD	۰٫۷۰۴	۴۹٫۵	۰٫۱۳۲	۰٫۰۸۰
ED	۰٫۹۱۶	۸۲٫۴	۰٫۱۳۷	۰٫۰۸۵
FDI	۰٫۸۰۶	۶۳٫۷	۰٫۱۴۸	۰٫۱۳۸

شکل ۲ نمونه‌ای از شکل تفسیری مدل پایه است: پیش‌بینی در برابر هدف، تفکیک دقیق خروجی به مسیر گراف و مسیر kinematic skip highway، و تغییر توجه muscle graph نسبت به حالت استراحت. در این شکل دیده می‌شود که شکل و زمان‌بندی جهش‌ها تقریباً همه از kinematic skip highway (منحنی نارنجی پنل ۲) می‌آیند.



شکل ۲: مدل پایه، شرکت‌کننده‌ی P1، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰. پنل ۱: پوش واقعی و پیش‌بینی. پنل ۲: تفکیک دقیق خروجی به مسیر EEG و گراف (بنفش) و مسیر kinematic skip highway (نارنجی). پنل ۳: تغییر توجه muscle graph نسبت به میانگین استراحت.



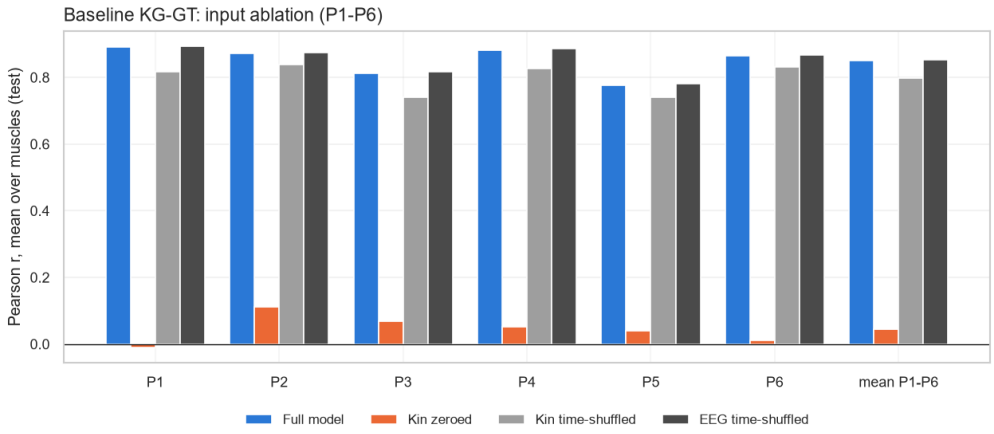
شکل ۳: گزارش دامنه‌ی مدل پایه برای شرکت‌کننده‌های P1 تا P6. چپ: height ratio فعالیت برای هر عضله، یک ستون برای هر سری آزمون و یک ستون خاکستری برای همه‌ی سری‌ها (خط‌چین = ۱). راست: سطح استراحت پیش‌بینی در برابر هدف. جدول ۱ همین اعداد را برای هر ۱۲ نفر دارد.

سهم EEG در مدل پایه

جدول ۳ نتیجه‌ی حذف ورودی را نشان می‌دهد. اگر سینماتیک صفر شود، r از ۰٫۸۵۱ به ۰٫۰۳۵ می‌افتد؛ اگر EEG بین پنجره‌ها جابه‌جا شود، r حتی کمی بالا می‌رود (۰٫۸۵۵). یعنی پیش‌بینی مدل پایه تقریباً تماماً از سینماتیک است و EEG در عمل یک ورودیِ بی‌اثر است.

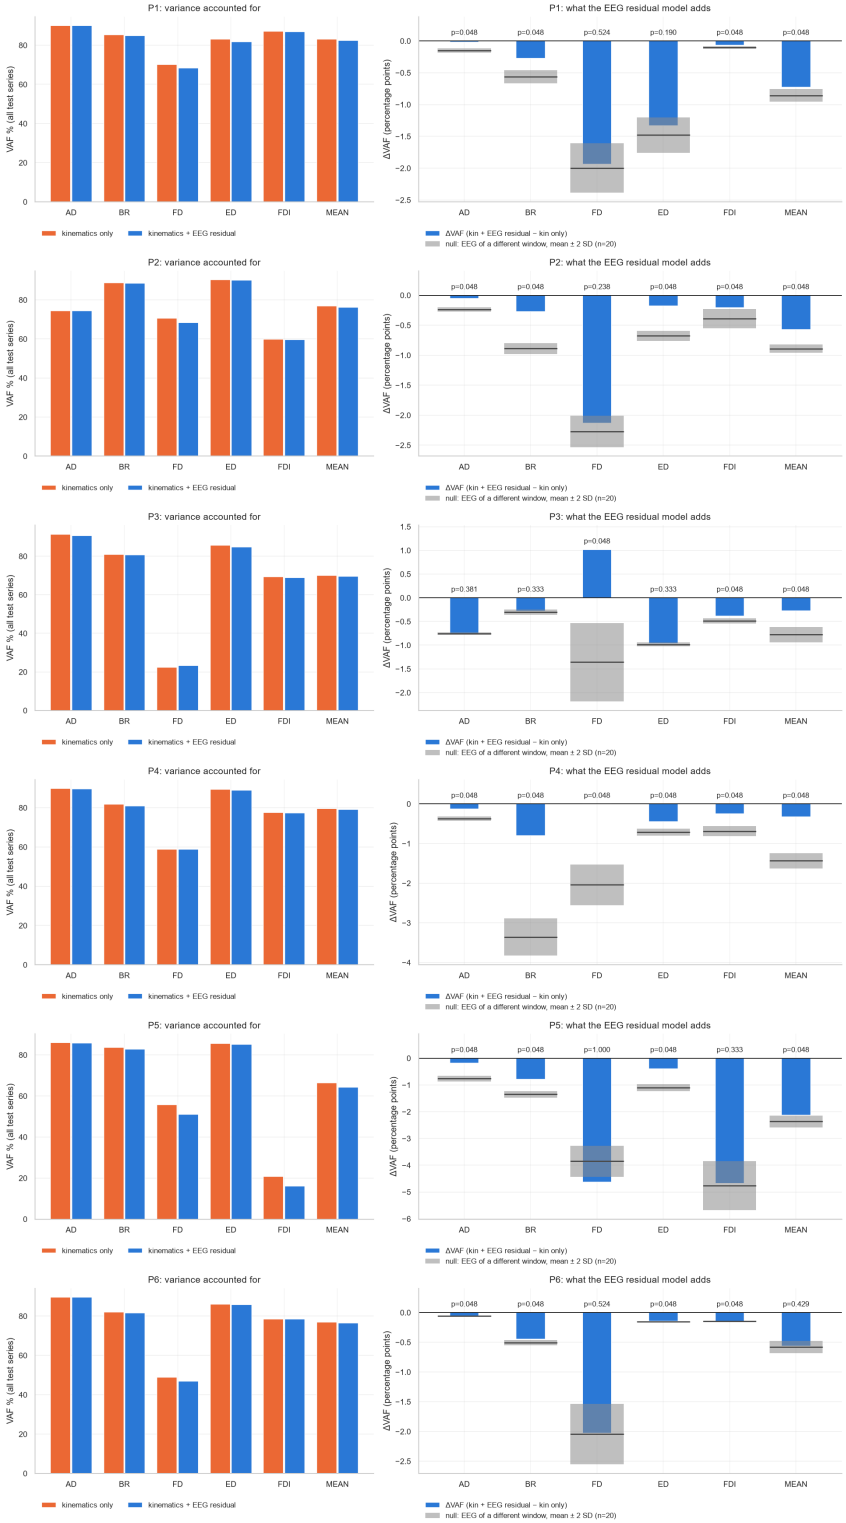
جدول ۳: input ablation در مدل پایه: ضریب همبستگی r وقتی یک ورودی صفر یا جابه‌جا می‌شود.

شرکت‌کننده	کامل	سینماتیک صفر	سینماتیک جابه‌جا	EEG جابه‌جا
P1	۰٫۸۹۱	-۰٫۰۱۰	۰٫۸۱۶	۰٫۸۹۴
P2	۰٫۸۷۲	۰٫۱۱۱	۰٫۸۳۸	۰٫۸۷۴
P3	۰٫۸۱۱	۰٫۰۶۸	۰٫۷۴۰	۰٫۸۱۶
P4	۰٫۸۸۰	۰٫۰۵۱	۰٫۸۲۶	۰٫۸۸۵
P5	۰٫۷۷۷	۰٫۰۳۹	۰٫۷۴۰	۰٫۷۸۰
P6	۰٫۸۶۵	۰٫۰۱۱	۰٫۸۳۲	۰٫۸۶۸
P7	۰٫۸۹۹	۰٫۱۶۹	۰٫۸۷۲	۰٫۹۰۲
P8	۰٫۷۶۴	۰٫۰۳۵	۰٫۶۶۳	۰٫۷۷۱
P9	۰٫۸۹۷	۰٫۰۰۶	۰٫۸۶۴	۰٫۸۹۹
P10	۰٫۸۷۱	-۰٫۰۹۶	۰٫۸۱۲	۰٫۸۷۷
P11	۰٫۸۵۸	۰٫۰۱۵	۰٫۸۳۰	۰٫۸۶۵
P12	۰٫۸۳۲	۰٫۰۱۹	۰٫۷۸۴	۰٫۸۳۴
میانگین	۰٫۸۵۱	۰٫۰۳۵	۰٫۸۰۱	۰٫۸۵۵



شکل ۴: input ablation در مدل پایه برای P1 تا P6: میانگین r روی پنج عضله برای مدل کامل، سینماتیک صفر، سینماتیک جابه‌جاشده در زمان و EEG جابه‌جاشده در زمان. جدول ۳ هر ۱۲ نفر را دارد.

برای اینکه این نتیجه به ساختار مدل پایه وابسته نباشد، آزمایش جداگانه‌ای انجام شد (جدول ۴): ابتدا مدلی فقط با سینماتیک آموزش دید و سپس EEG فقط برای پیش‌بینی باقی‌مانده‌ی آن به کار رفت. مدل فقط‌سینماتیک به VAF برابر ۷۵٫۵ درصد رسید (بیشتر از مدل پایه‌ی کامل) و افزودن EEG آن را به‌طور متوسط ۰٫۷۴ واحد بدتر کرد. فقط ۴ خانه از ۶۰ خانه (شرکت‌کننده × عضله) بهبود معنادار داشتند که نزدیک به عددی است که از شانس انتظار می‌رود (۳ خانه).



شکل ۵: residual experiment روی مدل پایه برای P1 تا P6. چپ: VAF هر عضله برای مدل فقط‌سینماتیک (نارنجی) و همان مدل به‌علاوه‌ی EEG روی باقی‌مانده (آبی). راست: تغییر VAF (ستون آبی) روی null distribution با EEG پنجره‌ای دیگر (نوار خاکستری، میانگین $\pm$ دو انحراف معیار) و p تجربی. جدول ۴ هر ۱۲ نفر را دارد.

جدول ۴: residual experiment روی مدل پایه (شاخه KG-GT-CUDA): مدل فقط‌سینماتیک در برابر مدلی که EEG را روی باقی‌مانده‌ی آن آموزش می‌دهد. ستون آخر: تعداد خانه‌های (سری × عضله) با p آزمون جابه‌جایی کمتر از ۰٫۰۵.

شرکت‌کننده	VAF فقط سینماتیک	VAF کامل	ΔVAF	r باقی‌مانده	خانه‌های معنادار
P1	۸۳٫۲	۸۲٫۴	-۰٫۷۳	۰٫۰۲۵	۰ از ۵
P2	۷۶٫۸	۷۶٫۳	-۰٫۵۷	۰٫۰۵۳	۰ از ۵
P3	۷۰٫۰	۶۹٫۷	-۰٫۲۸	۰٫۰۲۰	۱ از ۵
P4	۷۹٫۵	۷۹٫۲	-۰٫۳۳	۰٫۰۸۸	۰ از ۵
P5	۶۶٫۳	۶۴٫۲	-۲٫۱۴	۰٫۰۴۳	۰ از ۵
P6	۷۷٫۰	۷۶٫۵	-۰٫۵۶	۰٫۰۰۳	۰ از ۵
P7	۸۳٫۴	۸۳٫۱	-۰٫۲۸	۰٫۰۵۸	۱ از ۵
P8	۶۱٫۸	۶۰٫۷	-۱٫۱۱	۰٫۰۴۶	۱ از ۵
P9	۸۰٫۷	۸۰٫۱	-۰٫۶۸	۰٫۰۳۲	۰ از ۵
P10	۷۸٫۰	۷۷٫۹	-۰٫۱۳	۰٫۰۹۸	۱ از ۵
P11	۷۷٫۳	۷۵٫۷	-۱٫۵۹	۰٫۰۱۸	۰ از ۵
P12	۷۱٫۷	۷۱٫۲	-۰٫۴۹	۰٫۰۰۰	۰ از ۵
میانگین	۷۵٫۵	۷۴٫۷	-۰٫۷۴	۰٫۰۴۰	۴ از ۶۰

۳ کاستی‌های مدل پایه

سهم EEG قابل‌سنجش نیست. مدل پایه یک خروجی دارد و EEG و سینماتیک درون یک گراف با هم ترکیب می‌شوند. وقتی سینماتیک این‌قدر قوی است، بهینه‌سازی راه کوتاه را انتخاب می‌کند و EEG کنار می‌رود. با یک خروجی نمی‌توان هم دقت را گزارش کرد و هم ادعای علوم اعصاب («EEG حرکت را رمز می‌کند») را آزمود.

بافت زمانی کوتاه. پنجره‌ی یک‌ثانیه‌ای از یک بلندکردن کامل (چند ثانیه) کوتاه‌تر است. مدل نمی‌بیند جسم چند ثانیه است نگه داشته شده یا بلندکردن قبلی چقدر سنگین بود.

خطاهای دامنه وابسته به وزن جسم. height ratio میانگین درست است، اما وزن‌های سبک و متوسط ۴ تا ۱۱ درصد بیش‌برآورد می‌شوند و همبستگی سطح فعالیت بین بلندکردن‌ها در یک وزن ثابت ضعیف است (برای AD حدود ۰٫۰۷). ضریب ثابت بهترینِ هر سری فقط ۱٫۳ واحد به VAF اضافه می‌کند، پس مشکل یک مقیاس کلی نیست. مدل اطلاعاتی از تاریخچه‌ی بلندکردن‌ها ندارد.

هزینه‌ی پیچیده و جهت‌دار. وزن‌دهی قله‌ها، عدم‌تقارن و ماسک استراحت در حوزه‌ی z مدل را به سمت بیش‌برآوردی هل می‌دهند (سطح بیش‌برآورد بزرگ‌تر از کم‌برآورد). هشت جزء با هشت وزن، اثر هر کدام را سخت قابل‌ردیابی می‌کند.

سقف داده. پیش‌بین هموار ایدئال (خودِ هدف با low-pass ۲ هرتز) برای FD فقط به ۷۴ درصد می‌رسد؛ بخشی از خطا در خود ثبت‌هاست و هیچ مدلی آن را جبران نمی‌کند (بخش ۶).

تفسیرپذیری محدود. اطلاعات در مدل پایه از چند راه بین موقعیت‌ها جابه‌جا می‌شود: توجه تکه‌تکه، تأخیر آموختنی (یک کانولوشن)، kinematic skip highway و گراف. لایه‌های گراف پس‌نرمال‌اند و encoder هیچ recorder توجهی ندارد. بنابراین rollout یا attention flow از ورودی تا خروجی تعریف‌پذیر نیست. شکل تفسیری مدل پایه (شکل ۲) فقط توجه muscle graph را نشان می‌دهد که توجه EEG نیست.

۴ چرا v2

v2 پاسخ مستقیم به کاستی‌های بخش ۳ است. جدول ۵ هر کاستی را کنار تصمیمی که در v2 گرفته شد می‌گذارد.

جدول ۵: کاستی‌های مدل پایه و پاسخ v2 به هر کدام.

کاستی مدل پایه	تصمیم در v2
یک خروجی؛ سهم EEG جداشدنی نیست	سه خروجی جدا: K (سینماتیک)، E (فقط EEG)، F (K به‌علاوه‌ی اصلاح gated از EEG)؛ پارامترهای K هیچ گرادیانی از E و F نمی‌گیرند
پنجره‌ی یک‌ثانیه‌ای	۵۰ tokens هرتز و پنجره‌ی ۸ ثانیه‌ای (۴۰۰ tokens)
بی‌اطلاعی از بلندکردن‌های قبلی	هشت ویژگی تاریخچه از نیروهای gated، فقط از گذشته و بدون EMG
هزینه‌ی هشت‌جزئی در حوزه‌ی z با عدم‌تقارن	حوزه‌ی جذر دامنه و هزینه‌ی چهارجزئی بدون عدم‌تقارن و ماسک
EEG خام در حوزه‌ی زمان	band power در چهار باند برای هر الکترود، به‌صورت گرافی از الکترودها
اطلاعات از چند نوع لایه جابه‌جا می‌شود؛ rollout تعریف‌پذیر نیست	«یک مخلوط‌کننده»: فقط ماژول توجه و attention pooling بین موقعیت‌ها اطلاعات جابه‌جا می‌کنند؛ همه ثبت می‌شوند
آموزش یک‌جا با یک early stopping	یک optimizer و یک توقف برای هر جریان؛ جریانی که بهتر نمی‌شود در بهترین نقطه‌اش منجمد می‌شود

v2 از سه نظر بهتر از مدل پایه است. اول، دقت: K در هر ۱۲ شرکت‌کننده VAF بالاتری از مدل پایه دارد (بخش ۶). دوم، صداقت علمی: پرسش «آیا EEG چیزی بیش از سینماتیک دارد؟» با مقایسه‌ی F و K و residual test جواب روشن می‌گیرد و پرسش «آیا EEG به‌تنهایی حرکت را رمز می‌کند؟» با E. سوم، تفسیرپذیری: هر عدد خروجی را می‌توان از خروجی تا ورودی در همه‌ی لایه‌ها دنبال کرد.

۵ مدل v2

۱.۵ ورودی‌ها، tokens و خروجی‌ها

نرخ token. همه‌ی سیگنال‌ها پس از بارگذاری، یک بار برای هر سری با فیلتر ضدتداخل بدون تأخیر فاز از ۵۰۰ به ۵۰ هرتز کاهش می‌یابند (ضریب ۱۰). دو سر سری با بازتاب فرد ادامه داده می‌شوند تا اولین و آخرین token به سمت صفر کشیده نشوند. هر token ۲۰ میلی‌ثانیه است.

سینماتیک $X^k \in \mathbb{R}^{T\times ۲۴}$: همان ۲۴ ویژگی مدل پایه، استانداردشده با آماره‌های آموزش.

تاریخچه $X^h \in \mathbb{R}^{T\times ۸}$: هر «نگه‌داشتن» بازه‌ای است که نیروی بار gated دست‌کم ۰٫۵ ثانیه از ۱ نیوتن بیشتر بماند. یک نگه‌داشتن فقط پس از پایانش برای مدل شناخته می‌شود، پس هر ویژگی در زمان t فقط به گذشته بستگی دارد. هشت ویژگی: پرچم «تاریخچه وجود دارد»، شمار نگه‌داشتن‌های تا اینجا، زمان از شروع سری، زمان از

پایان آخرین نگه‌داشتن، میانگین نیروی بار و گرفتن در نگه‌داشتن قبلی، و میانگین جاری نیروی بار و گرفتن در همه‌ی نگه‌داشتن‌های قبلی.

EEG $X^e \in \mathbb{R}^{T\times ۳۲\times ۴}$: لگاریتم توان در چهار باند تتا (۴ تا ۸ هرتز)، آلفا (۸ تا ۱۳)، بتا (۱۳ تا ۳۰) و گامای پایین (۳۰ تا ۴۰) برای هر الکترود. توان لحظه‌ای با low-pass ۵ هرتز هموار، استاندارد و در ± ۵ بریده می‌شود.

هدف در حوزه‌ی مدل. برای هر عضله s_c صدک ۹۵ پوش آموزش است. مدل در حوزه‌ی جذر کار می‌کند:

$$u = \sqrt{y/s_c}, \qquad \hat{y} = s_c\,\hat{u}^{۲}. \tag{۳}$$

جذر، قله‌ها را فشرده و سطوح پایین را باز می‌کند؛ به همین دلیل دیگر به وزن‌دهی قله و ماسک استراحت نیازی نیست.

خروجی‌ها. مدل برای هر token و هر عضله سه خروجی و سه جزء دقیق برمی‌گرداند:

$$K = K_{base} \odot g(X^h), \qquad E = \text{E-stream}(X^e), \qquad F = \text{relu}\big(K + F_{eeg}\big). \tag{۴}$$

۲.۵ بلوک یکسان توجه

همه‌ی لایه‌های توجه v2، چه روی زمان، چه روی الکترودها و چه روی عضله‌ها، یک شکل دارند: بلوک باقی‌مانده با pre-norm. برای ورودی x و ماتریس توجه سر h:

(۵)

$$A^h = \text{softmax}\Big(\frac{Q^h K^{h\top}}{\sqrt{d_h}} + M^h\Big), \qquad x \leftarrow x + W_o\big[A^{۱}V^{۱} \,\|\, \ldots \,\|\, A^H V^H\big], \qquad x \leftarrow x + \text{FFN}(\text{LN}(x)),$$

که Q, K, V از $\text{LN}(x)$ ساخته می‌شوند. در توجه زمانی $M = ۰$ است؛ در لایه‌های گرافی $M^h = B^h + \lambda P$ که B^h bias آموختنی هر یال در هر سر، P یک ماتریس پیش‌فرض ثابت و λ یک ضریب آموختنی است. سطر i ماتریس A گیرنده و ستون j فرستنده است. pooling الکترودها و residual connection fusion cross-attention ندارند.

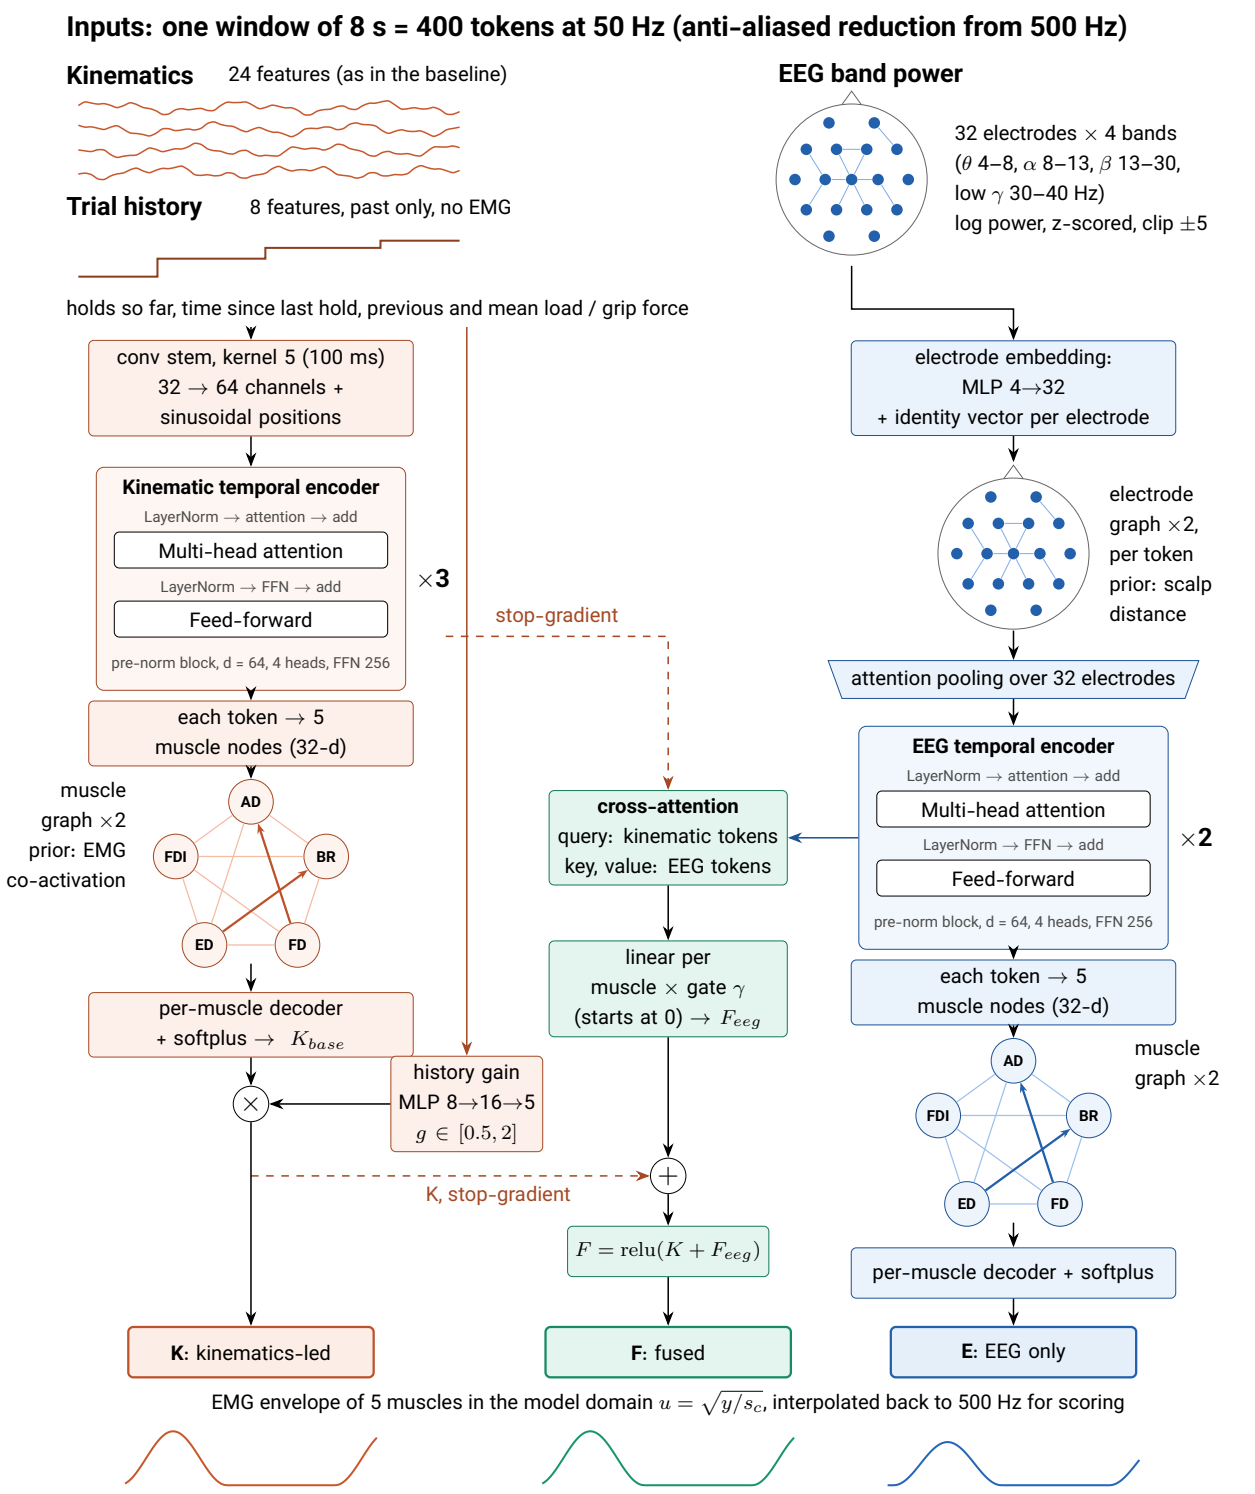
قاعده‌ی «یک مخلوط‌کننده». اطلاعات فقط از راه این ماژول توجه و ماژول attention pooling بین موقعیت‌ها (زمان، الکترود، عضله، جریان) جابه‌جا می‌شود. تنها استثنا کانولوشن ۵ضربه‌ای stem سینماتیک است که ردپایش با ماتریس S (سطرها با جمع ۱، وزن هر جابه‌جایی برابر انرژی هسته در آن جابه‌جایی) صادر می‌شود. همه‌ی لایه‌های دیگر روی یک موقعیت در یک زمان کار می‌کنند. ثبت‌کننده‌ای بیرون از مدل (model) as recording with) tape) توجه هر سر را پس از softmax و پیش از dropout برمی‌دارد و در صورت نیاز گراف گرادیان را نگه می‌دارد. ثبت، خروجی را تغییر نمی‌دهد و هیچ forward آرگومان تفسیری ندارد. فهرست لایه‌های ثبت‌شده (۱۳ ماژول) از model.attention_layers() می‌آید.

۳.۵ جریان سینماتیک

۱. **stem:** کانولوشن یک‌بعدی با هسته‌ی ۵ روی $[X^k \,\|\, X^h]$ (۳۲ ویژگی) به ۶۴ کانال، به‌علاوه‌ی sinusoidal positional encoding.

۲. **temporal encoder:** ۳ بلوک توجه کامل روی ۴۰۰ tokens، ۴ سر، ۲۵۶ feed-forward، dropout برابر ۰٫۲.

۳. **سر عضله:** تصویر هر token به ۵ گره با عرض ۳۲، دو بلوک توجه بین گره‌ها که پیش‌فرض P آن‌ها از هم‌فعالی عضلات در EMG آموزش ساخته می‌شود، و یک رمزگشای خطی برای هر عضله با خروجی softplus (نامنفی): K_{base}.



Loss $L = L_K + L_E + L_F$, for each output: Huber ($\delta = 0.5$) + 0.3 $(1 - \mathrm{CCC})$ + 0.5 level error per detected hold + 0.1 temporal difference.
Training: one AdamW for the kinematic stream, one for the EEG stream and fusion (gate without weight decay); a stream with no improvement for 30 epochs returns to its best weights and is frozen, the other one goes on.
Attention recorder (outside the model): all 13 attention layers, per head and with gradients → rollout, attention flow, gradient-weighted rollout.

شکل ۶: نمای کلی v2 از ورودی تا سه خروجی. چپ: جریان سینماتیک (stem کانولوشنی، سه بلوک Transformer زمانی، گراف پنج عضله، decoder و history gain) که K را می‌سازد. راست: جریان EEG (embedding الکترودها، گراف ۳۲ الکترود روی سر، pooling توجهی، دو بلوک Transformer زمانی، muscle graph) که E را می‌سازد. وسط: fusion با cross-attention و دروازه‌ای که از صفر شروع می‌شود و F را می‌سازد. خط‌چین‌ها جاهایی‌اند که گرادیان قطع می‌شود: K fusion و tokens سینماتیک را می‌خواند اما به آن‌ها گرادیان نمی‌فرستد، پس K فقط با هزینه‌ی خودش آموزش می‌بیند. کادر پایین هزینه، آموزش و attention recorder را خلاصه می‌کند.

۴. **history gain:** شبکه‌ی کوچک ۵ $\to$ ۱۶ $\to$ ۸ روی X^h: $g = ۲^{\tanh(\cdot)} \in [۰٫۵, ۲]$، با مقداردهی اولیه‌ای که $g = ۱$ می‌دهد. $K = K_{base} \odot g$.

۴.۵ جریان EEG

۱. **embedding الکترود:** یک MLP مشترک چهار band power هر الکترود را به ۳۲ بعد می‌برد و یک بردار هویت آموختنی برای هر الکترود اضافه می‌شود. در آموزش هر الکترود با احتمال ۰٫۲ کنار گذاشته می‌شود.

۲. **electrode graph:** دو بلوک توجه بین ۳۲ الکترود، برای هر token جداگانه، با پیش‌فرض $P_{ij} = -d_{ij}/\operatorname{median}(d)$ که d_{ij} فاصله‌ی دو الکترود در مختصات استاندارد ۱۰-۰۵ است؛ الکترودهای نزدیک به هم bias بزرگ‌تری دارند.

۳. **attention pooling:** یک پرسش آموختنی روی ۳۲ الکترود توجه می‌کند و یک بردار برای هر token می‌سازد: $p_t = \sum_e \pi_{t,e}\, n_{t,e}$.

۴. **temporal encoder:** ۲ بلوک توجه روی ۴۰۰ tokens.

۵. **سر عضله:** مانند جریان سینماتیک با وزن‌های جدا، خروجی E.

۵.۵ fusion

tokens سینماتیک (با stop-gradient) به‌عنوان پرسش روی EEG tokens توجه می‌کنند و یک لایه‌ی خطی برای هر عضله یک اصلاح می‌دهد:

$$F_{eeg} = \gamma \odot W\,\mathrm{CrossAttn}\big(\mathrm{sg}[Z^k],\, Z^e\big), \qquad F = \mathrm{relu}\big(\mathrm{sg}[K] + F_{eeg}\big), \tag{۶}$$

که sg stop-gradient و $\gamma \in \mathbb{R}^۵$ gate هر عضله است که از صفر شروع می‌شود و weight decay ندارد. اگر EEG چیزی به K اضافه نکند، γ نزدیک صفر می‌ماند و $F = K$. تعداد کل پارامترها ۷۱۲٬۳۳۷ است.

۶.۵ loss function

هر سه خروجی هزینه‌ی یکسان چهارجزئی در حوزه‌ی جذر دارند و هزینه‌ی کل $L = L_K + L_E + L_F$ است:

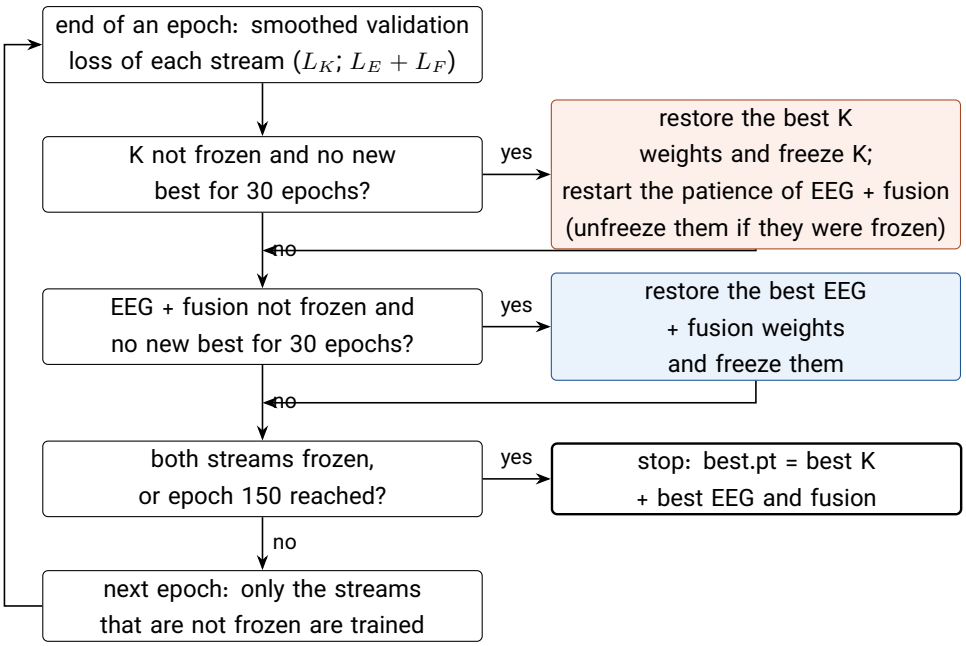
$$L_o = \underbrace{\mathrm{Huber}_{۰٫۵}(\hat{u}_o, u)}_{\text{main},\,۱٫۰} + ۰٫۳\underbrace{\big(۱ - \mathrm{CCC}(\hat{u}_o, u)\big)}_{\text{ccc}} + ۰٫۵\underbrace{\frac{۱}{|\mathcal{H}|}\sum_{k\in\mathcal{H}}\left|\overline{\hat{u}_{ok}} - \overline{u}_k\right|}_{\text{lift}} + ۰٫۱\underbrace{\mathrm{mean}\,\big|\Delta\hat{u}_o - \Delta u\big|}_{\text{diff}}, \tag{۷}$$

که $\mathcal{H}$ نگه‌داشتن‌های درون پنجره (با دست‌کم ۵ tokens) و $\overline{\cdot}_k$ میانگین روی نگه‌داشتن k است. جزء سطح نگه‌داشتن، خطای سطح فعالیت هر بلندکردن را مستقیم می‌سنجد؛ همان خطایی که در مدل پایه به وزن جسم وابسته بود. عدم‌تقارن، وزن‌دهی قله و ماسک استراحت عمداً حذف شدند.

۷.۵ آموزش

هر جریان optimizer خود را دارد: یک AdamW برای پارامترهای *.kin و یکی برای *.eeg و *.fusion (gate بدون weight decay)، با نرخ $۱۰^{-۳}$، weight decay ۰٫۰۱، ۵ دوره warm-up و cosine decay، gradient clipping ۱٫۰ برای هر جریان جداگانه، batch size ۳۲ و حداکثر ۱۵۰ دوره. پنجره‌های آموزش ۸ ثانیه با گام ۲ ثانیه‌اند و آغاز آن‌ها در هر دوره به‌طور تصادفی جابه‌جا می‌شود. پیش از آموزش یک آزمون بودجه چند گام را با و بدون mixed precision اندازه می‌گیرد و سریع‌تر را انتخاب می‌کند؛ روی GTX 1660 Ti mixed precision حدود سه برابر کندتر بود و دقت کامل انتخاب شد.

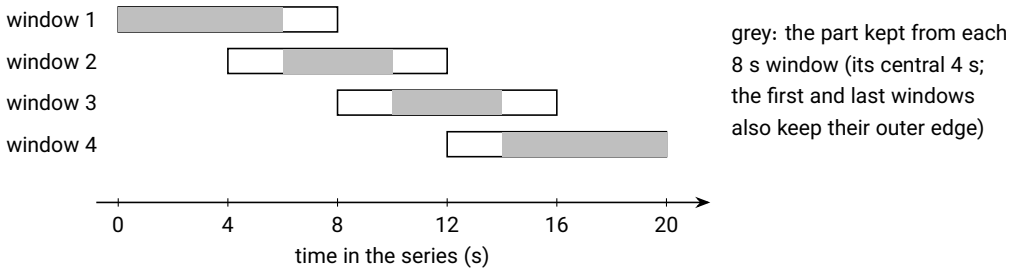
freezing هر جریان. خطای validation هر جریان با میانگین سه‌دوره‌ای هموار می‌شود: L_K برای سینماتیک و $L_E + L_F$ برای EEG و fusion. شکل ۷ قاعده را نشان می‌دهد. جریانی که ۳۰ دوره بهتر نشود به وزن‌های بهترین دوره‌اش برمی‌گردد و دیگر به‌روز نمی‌شود (بدون هزینه، بدون گام optimizer و در حالت ارزیابی)، و جریان دیگر ادامه می‌دهد. چون F روی K ساخته می‌شود، وقتی K منجمد شد شمارش صبر EEG و fusion از نو آغاز می‌شود تا بهترین دوره‌ی آن‌ها با همان K ذخیره‌شده سنجیده شده باشد. آموزش وقتی تمام می‌شود که هر دو جریان منجمد شده باشند یا به ۱۵۰ دوره برسد.



شکل ۷: قاعده‌ی freezing در پایان هر دوره. وضعیت freezing در last.pt ذخیره می‌شود و با ادامه‌ی آموزش حفظ می‌شود.

۸.۵ پیش‌بینی روی یک سری کامل

یک سری با پنجره‌های ۸ ثانیه‌ای و گام ۴ ثانیه‌ای پیموده می‌شود و از هر پنجره فقط ۴ ثانیه‌ی میانی نگه داشته می‌شود (اولین و آخرین پنجره لبه‌ی بیرونی خود را هم نگه می‌دارند). ۵۰ tokens هرتز با درون‌یابی اسپلاین مکعبی به ۵۰۰ هرتز برمی‌گردند و با هدف اصلی ۵۰۰ هرتز سنجیده می‌شوند. همین تابع در ارزیابی، تفسیر و triptych figures به کار می‌رود.



شکل ۸: پیش‌بینی پیوسته روی یک سری: پنجره‌های ۸ ثانیه‌ای با گام ۴ ثانیه و نگه‌داشتن ۴ ثانیه‌ی میانی هر پنجره.

۶ نتایج ارزیابی v2

همه‌ی اعداد این بخش روی همان سری‌های آزمون مدل پایه و با نرخ ۵۰۰ هرتز حساب شده‌اند. آموزش هر شرکت‌کننده ۱۷ تا ۳۱ دقیقه روی GTX 1660 Ti طول کشید (جدول ۸).

۱.۶ دقت K، E و F

جدول ۶ خلاصه‌ی اصلی است. K با میانگین VAF برابر ۷۵٫۸ درصد و r برابر ۰٫۸۷۲، در هر ۱۲ شرکت‌کننده از مدل پایه (۷۲٫۲ درصد و ۰٫۸۵۱) بهتر است و از مدل فقط‌سینماتیکِ residual experiment (۷۵٫۵ درصد و ۰٫۸۶۹) هم کمی جلوتر است؛ بنابراین معیار پذیرش اول طرح v2 برآورده شد. بهبود VAF نسبت به مدل پایه از ۰٫۳ واحد (P5) تا ۵٫۵ واحد (P4) است و میانه‌ی آن حدود ۴ واحد.

جدول ۶: نتایج v2 روی سری‌های آزمون در برابر مدل پایه. چهار ستون اول VAF (درصد) و چهار ستون بعد r، هر دو میانگین روی پنج عضله.

شرکت‌کننده	پایه	K	E	F	پایه	K	E	F
P1	۷۹٫۰	۸۳٫۶	۳۳٫۹	۸۳٫۸	۰٫۸۹۱	۰٫۹۱۴	۰٫۵۹۷	۰٫۹۱۵
P2	۷۵٫۲	۷۸٫۸	۵۸٫۳	۷۸٫۸	۰٫۸۷۲	۰٫۸۸۸	۰٫۷۶۶	۰٫۸۸۸
P3	۶۷٫۵	۶۹٫۸	۳۰٫۷	۷۰٫۲	۰٫۸۱۱	۰٫۸۳۷	۰٫۵۹۲	۰٫۸۳۶
P4	۷۶٫۰	۸۱٫۵	۵۷٫۷	۸۱٫۸	۰٫۸۸۰	۰٫۹۰۵	۰٫۷۵۹	۰٫۹۰۵
P5	۶۳٫۵	۶۳٫۸	۳۴٫۴	۶۴٫۰	۰٫۷۷۷	۰٫۷۹۵	۰٫۶۰۳	۰٫۷۹۳
P6	۷۴٫۷	۷۶٫۷	۳۵٫۸	۷۷٫۰	۰٫۸۶۵	۰٫۸۷۷	۰٫۶۲۶	۰٫۸۷۷
P7	۷۹٫۱	۸۲٫۶	۵۷٫۷	۸۲٫۵	۰٫۸۹۹	۰٫۹۱۰	۰٫۷۵۶	۰٫۹۱۱
P8	۵۴٫۳	۵۸٫۴	۳۲٫۷	۵۸٫۰	۰٫۷۶۴	۰٫۷۹۲	۰٫۵۸۲	۰٫۷۹۹
P9	۷۹٫۳	۸۳٫۵	۴٫۵	۸۳٫۵	۰٫۸۹۷	۰٫۹۱۸	۰٫۴۷۸	۰٫۹۱۸
P10	۷۴٫۹	۸۰٫۲	۵۳٫۶	۸۰٫۳	۰٫۸۷۱	۰٫۸۹۸	۰٫۷۲۵	۰٫۸۹۸
P11	۷۳٫۶	۷۸٫۱	۳۶٫۰	۷۸٫۱	۰٫۸۵۸	۰٫۸۸۴	۰٫۶۴۹	۰٫۸۸۴
P12	۶۹٫۸	۷۲٫۵	۳۴٫۴	۷۲٫۳	۰٫۸۳۲	۰٫۸۴۵	۰٫۶۰۴	۰٫۸۴۵
میانگین	۷۲٫۲	۷۵٫۸	۳۹٫۱	۷۵٫۹	۰٫۸۵۱	۰٫۸۷۲	۰٫۶۴۵	۰٫۸۷۲

E که فقط EEG می‌بیند به r برابر ۰٫۶۴۵ و VAF برابر ۳۹٫۱ درصد رسید. این عدد از خروجی فقطEEG آزمایش‌های قبلی (r حدود ۰٫۴۷) بالاتر است و در هر ۱۲ شرکت‌کننده از null test جابه‌جایی بلوک‌های EEG گذشت (جدول ۷). یعنی EEG به‌تنهایی حالت حرکت را به‌خوبی رمز می‌کند.

F عملاً با K برابر است: میانگین VAF برابر ۷۵٫۹ در برابر ۷۵٫۸. بزرگ‌ترین قدرمطلق gate در هر شرکت‌کننده بین ۰٫۰۱ و ۰٫۰۴ ماند و اصلاح EEG حدود ۰٫۲ تا ۲ درصد اندازه‌ی K است (جدول ۱۳). فقط در یک شرکت‌کننده (P4) بهره‌ی F نسبت به K در برابر null test معنادار شد که با یک مورد از ۱۲ در حد انتظار شانس است. بخش ۹ نشان می‌دهد این نتیجه خطای fusion نیست.

قاعده‌ی تفسیرپذیری F. دفترچه‌ی آموزش بررسی می‌کند که آیا fusion ذخیره‌شده با همان K ذخیره‌شده آموزش دیده است یا نه. با قاعده‌ی freezing، بهترین دوره‌ی EEG و fusion همیشه بعد از freezing K است (جدول ۸)، پس این شرط در هر ۱۲ نفر برقرار است. جدول حکم‌های ذخیره‌شده‌ی این گزارش پیش از اصلاح این قاعده ساخته شده و برای ۹ نفر برچسب «غیرقابل‌تفسیر» دارد؛ اعداد آن تغییری نمی‌کنند و با اجرای دوباره‌ی سلول ارزیابی، برچسب‌ها

جدول ۷: null tests: E در برابر EEG جابه‌جاشده بین بلوک‌ها، و بهره‌ی F نسبت به K. p هیچ‌گاه کمتر از یک‌تقسیم‌برتعداد بلوک‌ها گزارش نمی‌شود. ستون آخر بزرگ‌ترین قدرمطلق fusion gate بین پنج عضله است.

شرکت‌کننده	r خروجی E	p (جابه‌جایی)	ΔVAF (K−F)	p (جابه‌جایی)	بیشینه‌ی $\lvert g \rvert$
P1	۰٫۵۹۷	۰٫۰۱۲	+۰٫۱۹	۰٫۱۹	۰٫۰۱۵
P2	۰٫۷۶۶	۰٫۰۱۱	−۰٫۰۲	۰٫۸۵	۰٫۰۱۴
P3	۰٫۵۹۲	۰٫۰۱۳	+۰٫۳۷	۰٫۹۵	۰٫۰۱۷
P4	۰٫۷۵۹	۰٫۰۱۲	+۰٫۳۲	۰٫۰۱	۰٫۰۲۶
P5	۰٫۶۰۳	۰٫۰۱۱	+۰٫۲۵	۰٫۱۸	۰٫۰۲۶
P6	۰٫۶۲۶	۰٫۰۱۱	+۰٫۳۵	۰٫۲۶	۰٫۰۲۴
P7	۰٫۷۵۶	۰٫۰۱۱	−۰٫۰۲	۰٫۷۸	۰٫۰۱۸
P8	۰٫۵۸۲	۰٫۰۱۳	−۰٫۳۵	۰٫۳۴	۰٫۰۴۲
P9	۰٫۴۷۸	۰٫۰۱۲	+۰٫۰۳	۰٫۳۴	۰٫۰۱۲
P10	۰٫۷۲۵	۰٫۰۱۲	+۰٫۰۶	۰٫۴۰	۰٫۰۱۰
P11	۰٫۶۴۹	۰٫۰۱۱	+۰٫۰۱	۰٫۴۵	۰٫۰۱۵
P12	۰٫۶۰۴	۰٫۰۱۰	−۰٫۲۲	۰٫۸۲	۰٫۰۲۱

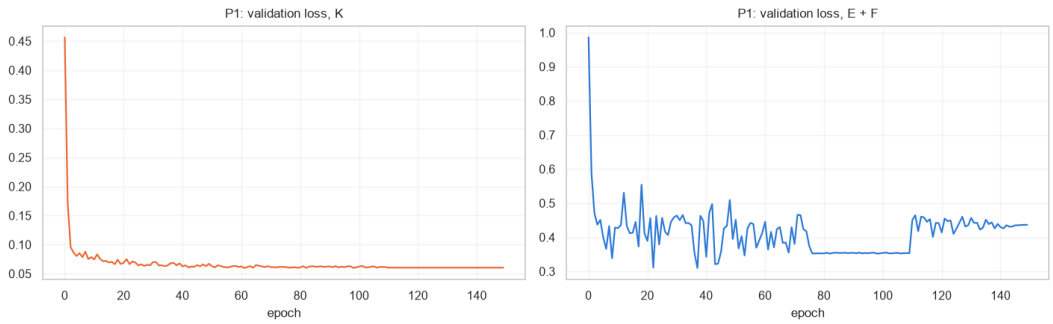
به «EEG چیزی به سینماتیک اضافه نمی‌کند» تبدیل می‌شوند (به‌جز P4).

جدول ۸: روند آموزش v2: شماره‌ی بهترین دوره و دوره‌ی freezing هر جریان. خط تیره یعنی جریان تا پایان (۱۵۰ دوره) منجمد نشد.

شرکت‌کننده	دوره‌ها	بهترین K	K freezing	بهترین E	E freezing	زمان (دقیقه)
P1	۱۵۰	۸۰	۱۱۰	۱۲۷	–	۲۴٫۱
P2	۱۵۰	۱۱۶	۱۴۶	۱۴۷	–	۳۰٫۸
P3	۱۰۵	۳۱	۶۱	۷۵	۱۰۵	۱۷٫۲
P4	۱۳۸	۵۵	۸۵	۱۰۸	۱۳۸	۲۳٫۹
P5	۱۵۰	۵۵	۸۵	۱۲۵	–	۲۷٫۹
P6	۱۲۲	۴۹	۷۹	۹۲	۱۲۲	۲۳٫۱
P7	۱۰۵	۳۸	۶۸	۷۵	۱۰۵	۲۱٫۹
P8	۱۳۸	۲۷	۵۷	۱۰۸	۱۳۸	۲۲٫۹
P9	۱۵۰	۷۳	۱۰۳	۱۲۰	۱۵۰	۲۴٫۶
P10	۱۱۰	۴۹	۷۹	۸۰	۱۱۰	۱۹٫۳
P11	۹۵	۳۳	۶۳	۶۵	۹۵	۱۷٫۸
P12	۹۰	۱۹	۴۹	۶۰	۹۰	۱۷٫۳

۲.۶ هر عضله و سقف داده

جدول ۹ نشان می‌دهد بهبود K در همه‌ی عضله‌ها هست. ستون سقف، VAF خودِ هدف پس از low-pass ۲ هرتز است؛ یعنی بهترین عددی که یک پیش‌بین هموار می‌تواند بگیرد. FD با سقف ۷۴ درصد و modulation depth کم (نسبت صدک ۸۰ به ۲۰ حدود ۲) محدودترین عضله است؛ فاصله‌ی K تا سقف برای AD، BR و ED حدود ۸ تا ۱۱ واحد است.



شکل ۹: منحنی خطای validation P1: چپ K، راست F+E. K در دوره‌ی ۸۰ بهترین بود و در دوره‌ی ۱۱۰ منجمد شد؛ EEG و fusion تا دوره‌ی ۱۵۰ ادامه دادند.

جدول ۹: VAF (درصد) برای هر عضله، میانگین روی ۱۲ شرکت‌کننده؛ VAF = smooth ceiling خودِ هدفِ هموارشده با low-pass ۲ هرتز؛ modulation depth = نسبت صدک ۸۰ به صدک ۲۰ هدف.

عضله	پایه	K	E	F	smooth ceiling	modulation depth
AD	۸۵٫۹	۸۸٫۶	۵۸٫۰	۸۸٫۷	۹۳٫۷	۱۲٫۲
BR	۷۹٫۶	۸۲٫۵	۴۴٫۴	۸۲٫۹	۹۰٫۵	۳٫۲
FD	۴۹٫۵	۵۳٫۰	۱۸٫۱	۵۲٫۷	۷۴٫۲	۲٫۰
ED	۸۲٫۴	۸۶٫۱	۵۲٫۴	۸۶٫۴	۹۳٫۳	۵٫۰
FDI	۶۳٫۷	۶۸٫۶	۲۲٫۷	۶۸٫۵	۸۷٫۱	۳٫۵

۳.۶ دامنه در هر وزن

جدول ۱۰ height ratio در مرحله‌ی نگه‌داشتن را برای سه وزن جسم و همبستگی سطح فعالیت بین بلندکردن‌ها را مقایسه می‌کند. جزء سطح نگه‌داشتن در هزینه و ویژگی‌های تاریخچه برای همین خطا طراحی شده بودند و اثرشان روشن است: مدل پایه وزن‌های سبک و متوسط را ۴٫۵ و ۵٫۵ درصد بیش‌برآورد می‌کرد، در حالی که height ratio K در هر سه وزن بین ۱٫۰۰۴ و ۱٫۰۰۹ است (معیار پذیرش دوم: بین ۰٫۹۵ و ۱٫۰۵). همبستگی سطح فعالیت بین بلندکردن‌ها در یک وزن ثابت هم در هر سه وزن بالا رفته است (برای نمونه از ۰٫۳۹ به ۰٫۵۳ در وزن سبک).

جدول ۱۰: سطح فعالیت در مرحله‌ی نگه‌داشتن، برای هر وزن جسم (میانگین روی شرکت‌کننده‌ها، سری‌ها و عضله‌ها). height ratio = میانگین پیش‌بینی به میانگین هدف؛ مقدار مطلوب ۱.

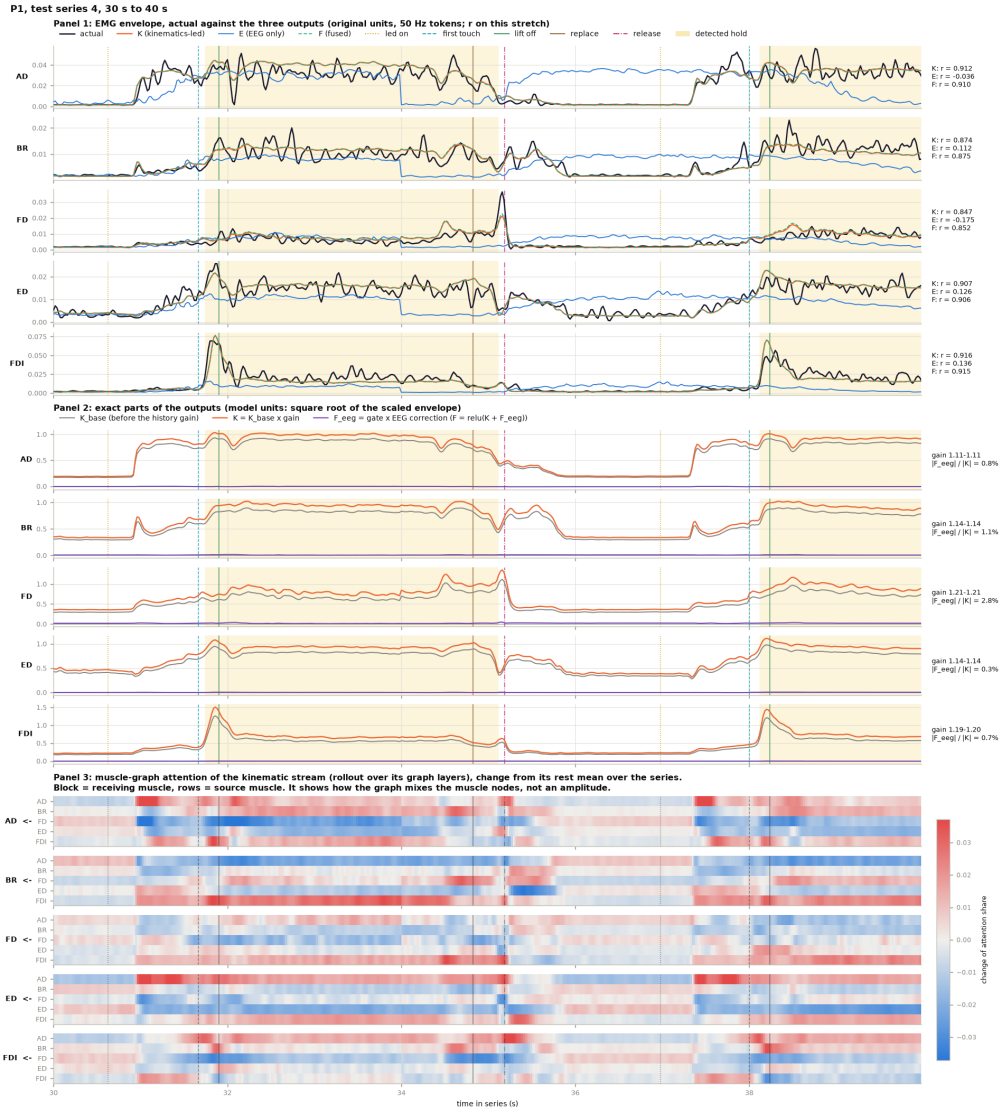
وزن جسم	height ratio پایه	K height ratio	r بین بلندکردن‌ها پایه	r بین بلندکردن‌ها K
سبک	۱٫۰۴۵	۱٫۰۰۵	۰٫۳۹۱	۰٫۵۲۹
متوسط	۱٫۰۵۵	۱٫۰۰۴	۰٫۵۰۱	۰٫۵۷۰
سنگین	۱٫۰۲۴	۱٫۰۰۹	۰٫۳۹۴	۰٫۴۶۱

۴.۶ triptych figures

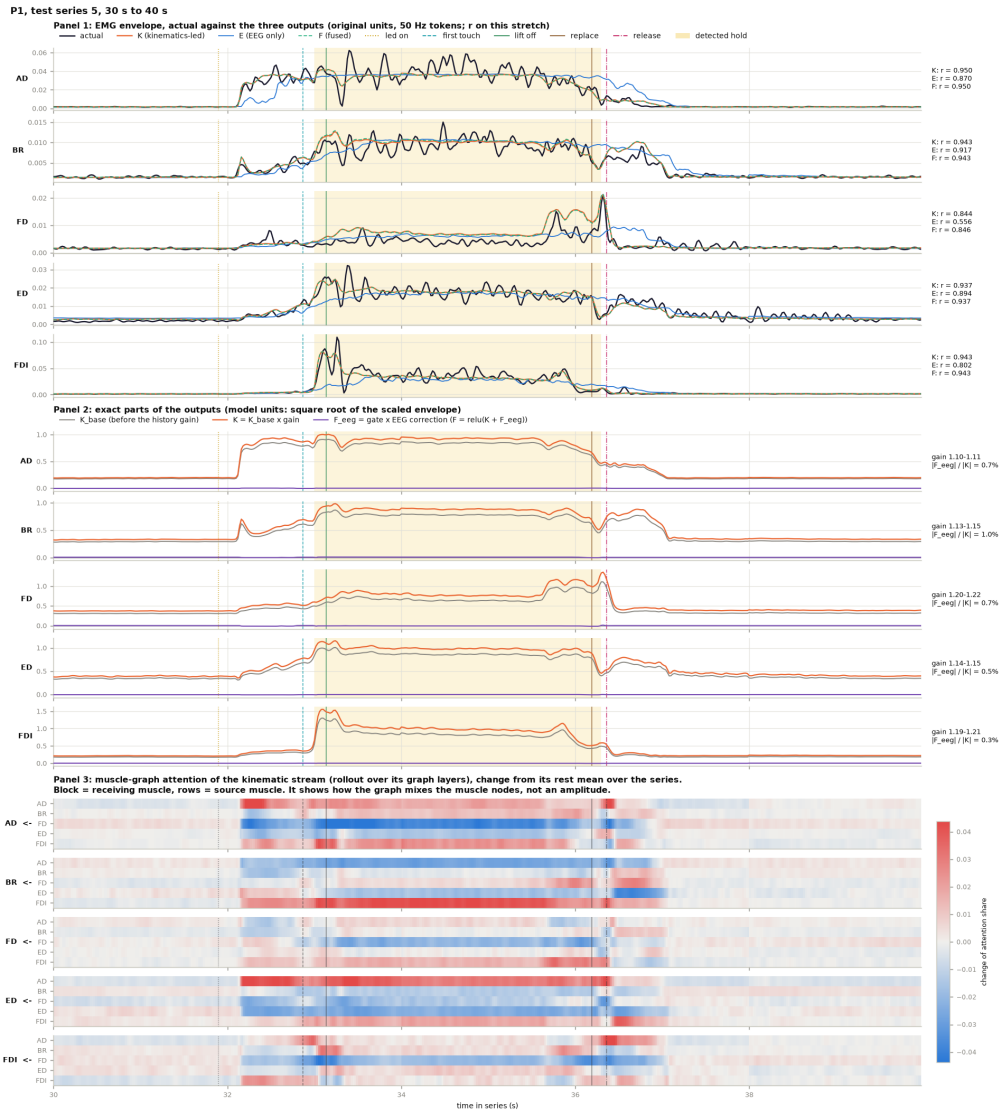
برای هر سری آزمون، کل سری به بازه‌های ۱۰ ثانیه‌ای پشت سر هم بریده و برای هر بازه یک شکل ساخته شد. در ادامه برای شرکت‌کننده‌های ۱ تا ۴ و هر سری آزمون یک شکل آمده است (ثانیه‌ی ۳۰ تا ۴۰ هر سری). سه پنل هر شکل:

- **پنل ۱:** پوش واقعی (سیاه) در برابر K (نارنجی)، E (آبی) و F (سبز خط‌چین)، با واحد اصلی. خطوط عمودی رخدادهای آزمایش‌اند (روشن‌شدن چراغ، اولین تماس، جداشدن از سطح، گذاشتن و رها کردن) و ناحیه‌ی زرد نگه‌داشتن تشخیص‌داده‌شده است. ستون راست r همین بازه است.
- **پنل ۲:** اجزای دقیق در حوزه‌ی مدل: K_{base} (خاکستری)، $K = K_{base} \cdot g$ (نارنجی) و F_{eeg} (بنفش). ستون راست بازه‌ی history gain و نسبت $|F_{eeg}|/|K|$ را می‌دهد.
- **پنل ۳:** muscle graph attention rollout جریان سینماتیک، به‌صورت تغییر نسبت به میانگین استراحت همان سری. هر بلوک یک عضله‌ی گیرنده و هر سطر یک عضله‌ی فرستنده است.

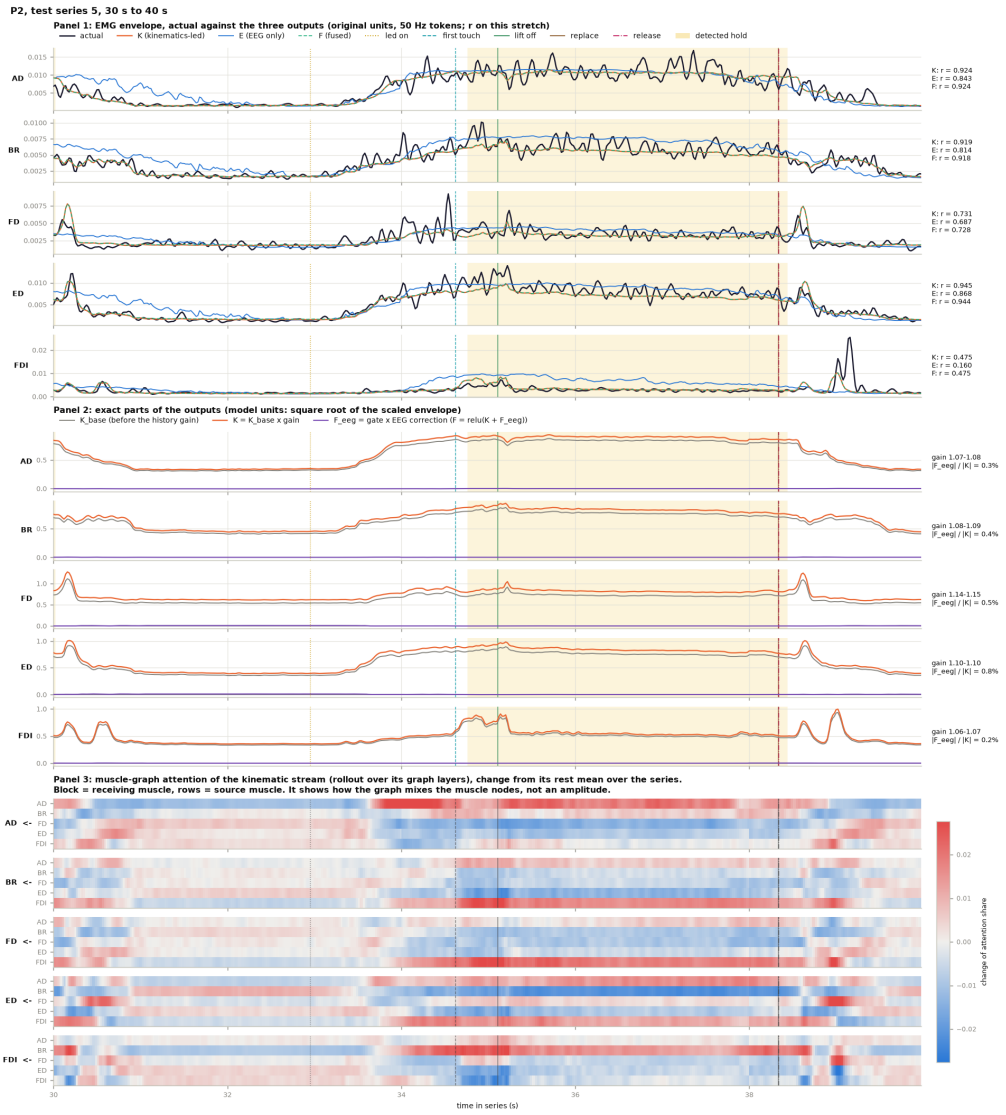
در همه‌ی شکل‌ها F روی K افتاده و F_{eeg} نزدیک صفر است؛ E زمان‌بندی کلی بلندکردن را دنبال می‌کند اما جهش‌های کوتاه را ندارد.



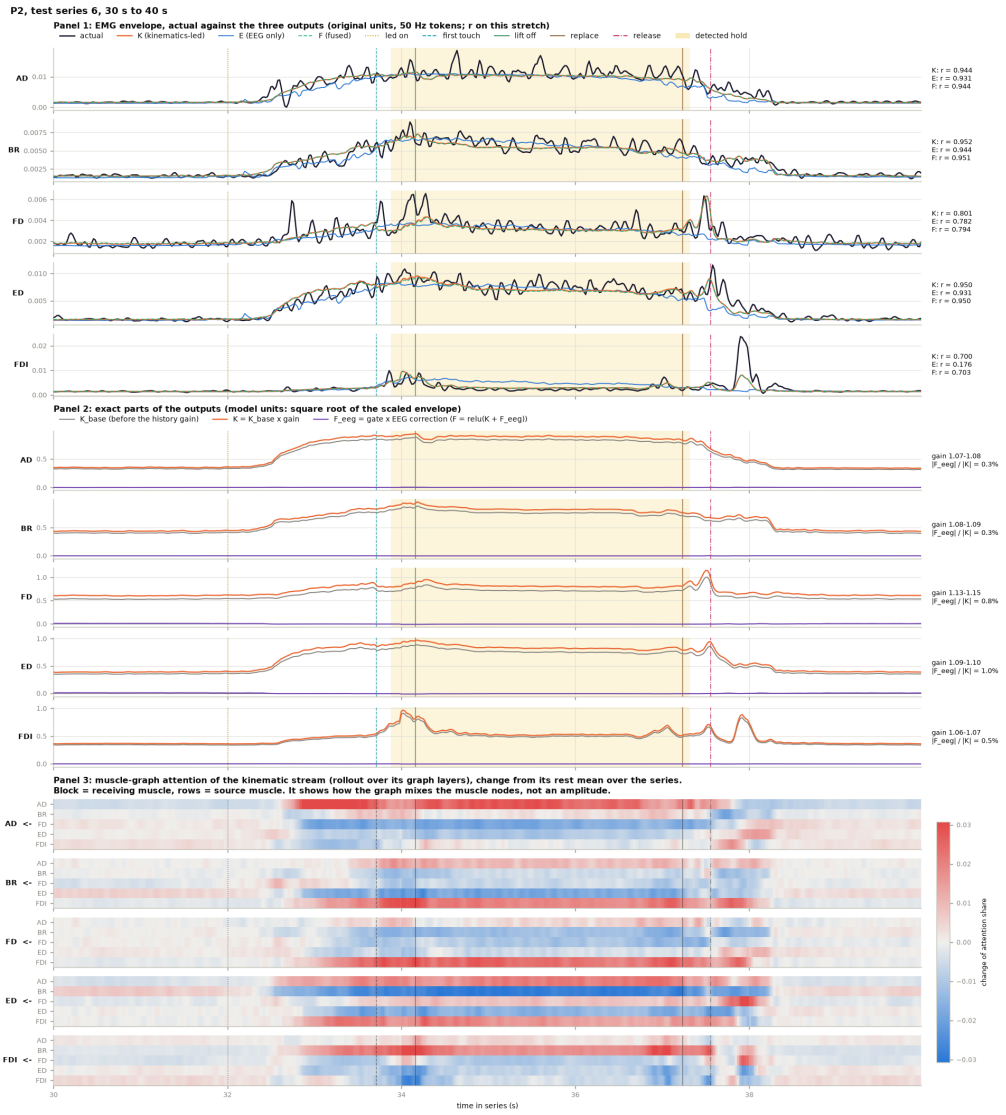
شکل ۱۰: P1، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰.



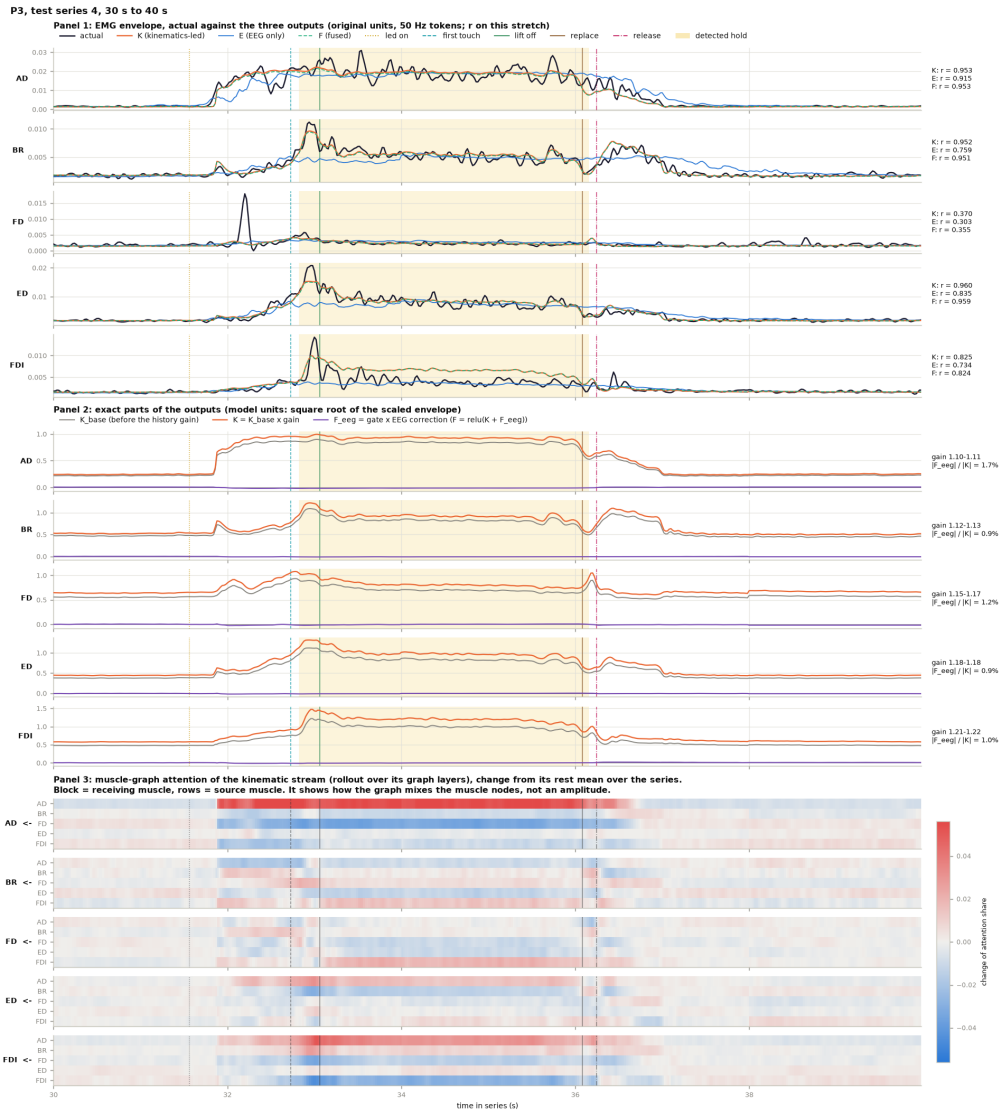
شکل ۱۱: P1، سری آزمون ۵، ثانیه‌ی ۳۰ تا ۴۰.



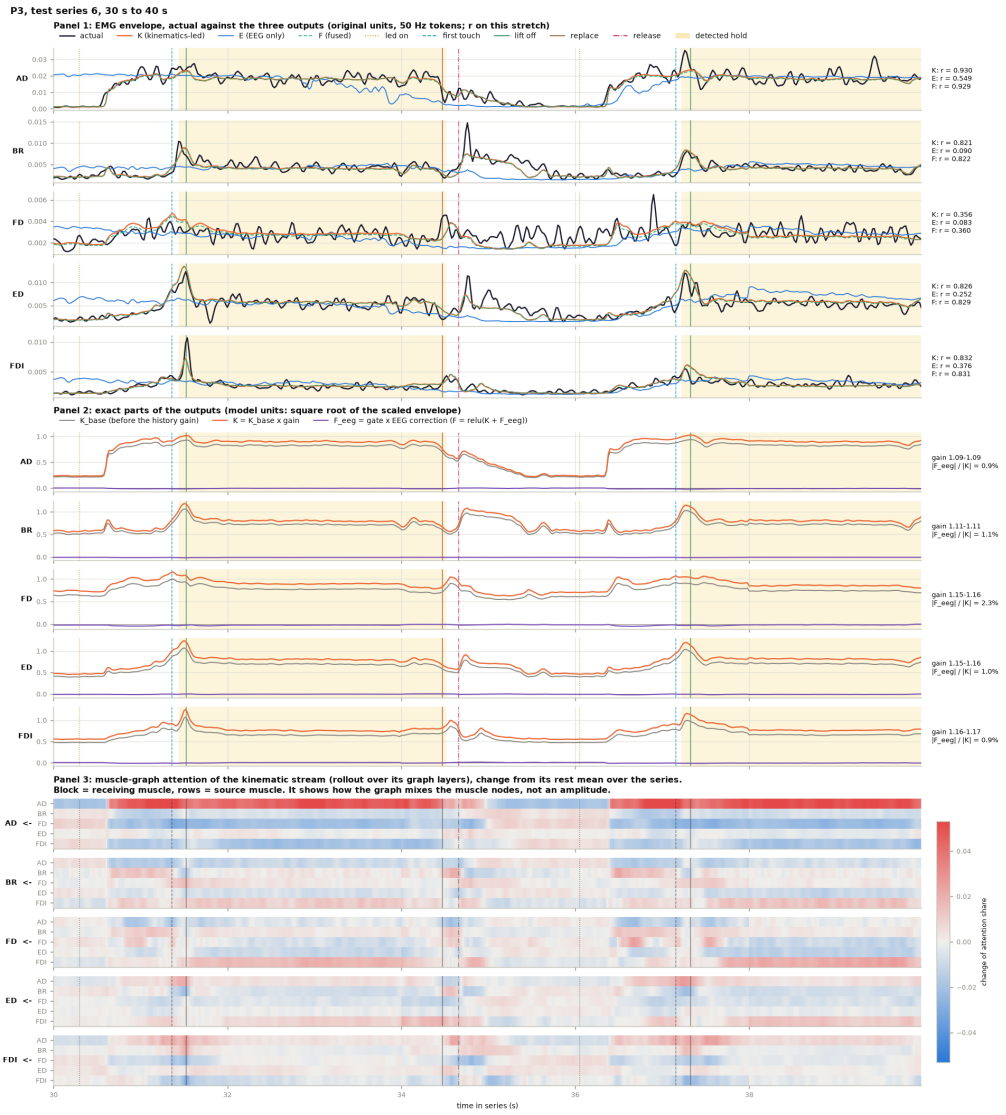
شکل ۱۲: P2، سری آزمون ۵، ثانیه‌ی ۳۰ تا ۴۰.



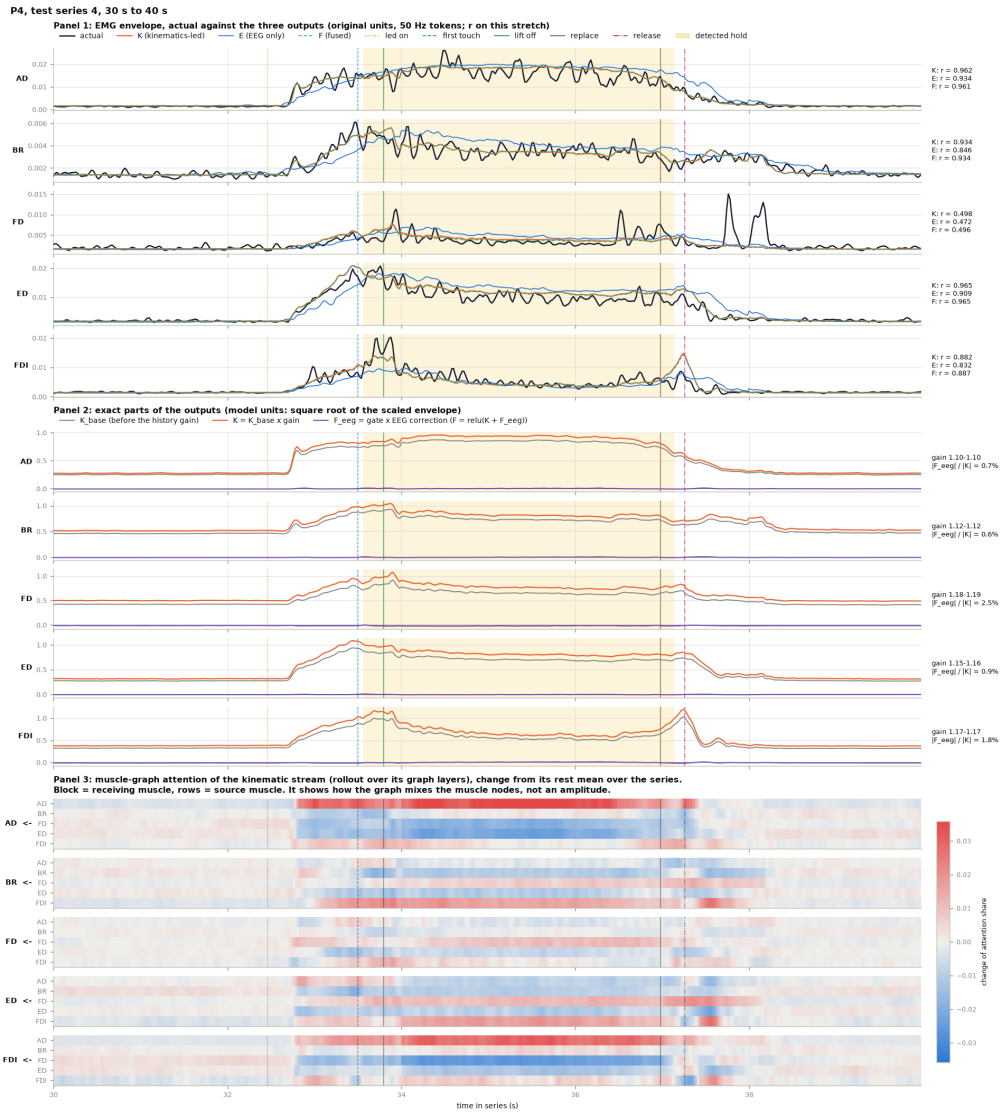
شکل ۱۳: P2، سری آزمون ۶، ثانیه‌ی ۳۰ تا ۴۰.



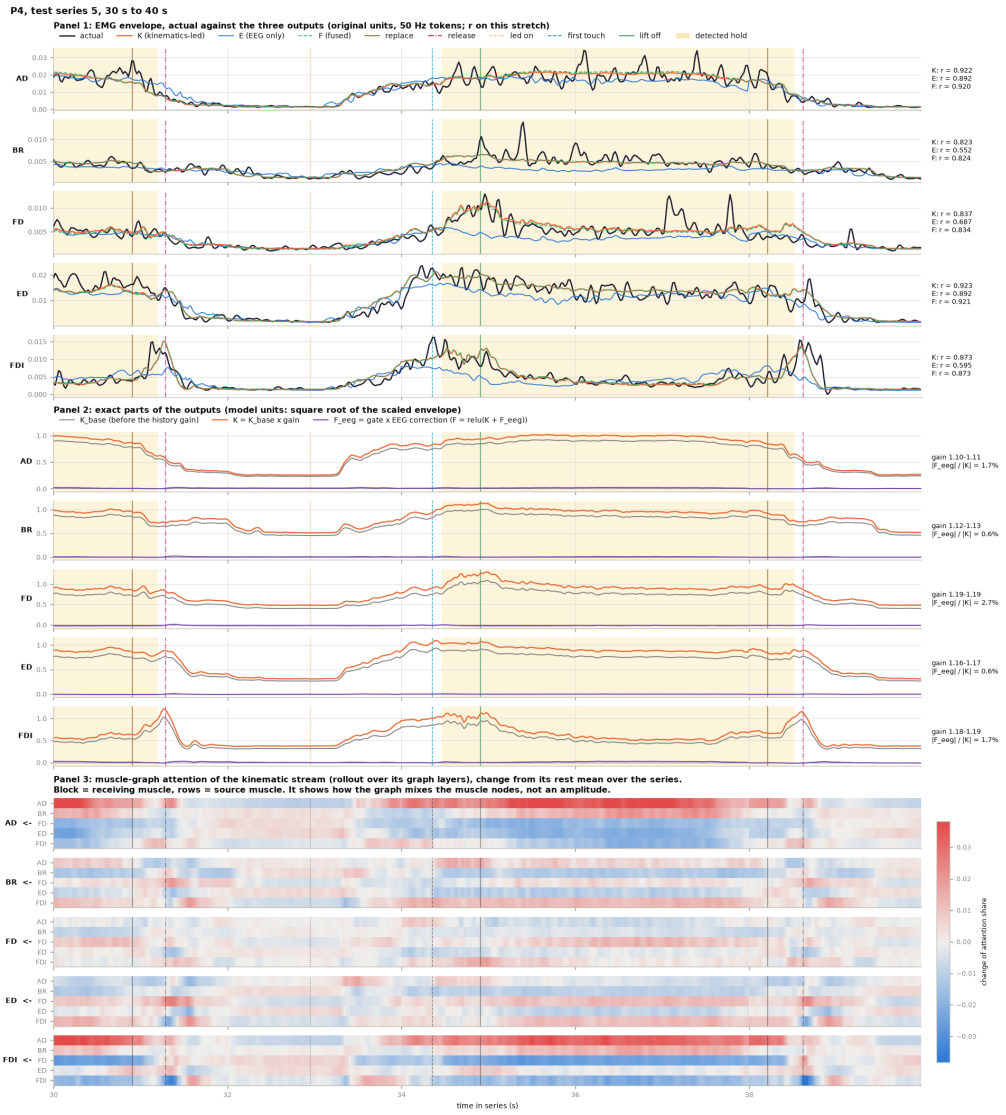
شکل ۱۴: P3، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰.



شکل ۱۵: P3، سری آزمون ۶، ثانیه‌ی ۳۰ تا ۴۰.



شکل ۱۶: P4، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰.



شکل ۱۷: P4، سری آزمون ۵، ثانیه‌ی ۳۰ تا ۴۰.

۷ تفسیرپذیری در v2

۱.۷ چه چیزی توضیح داده می‌شود

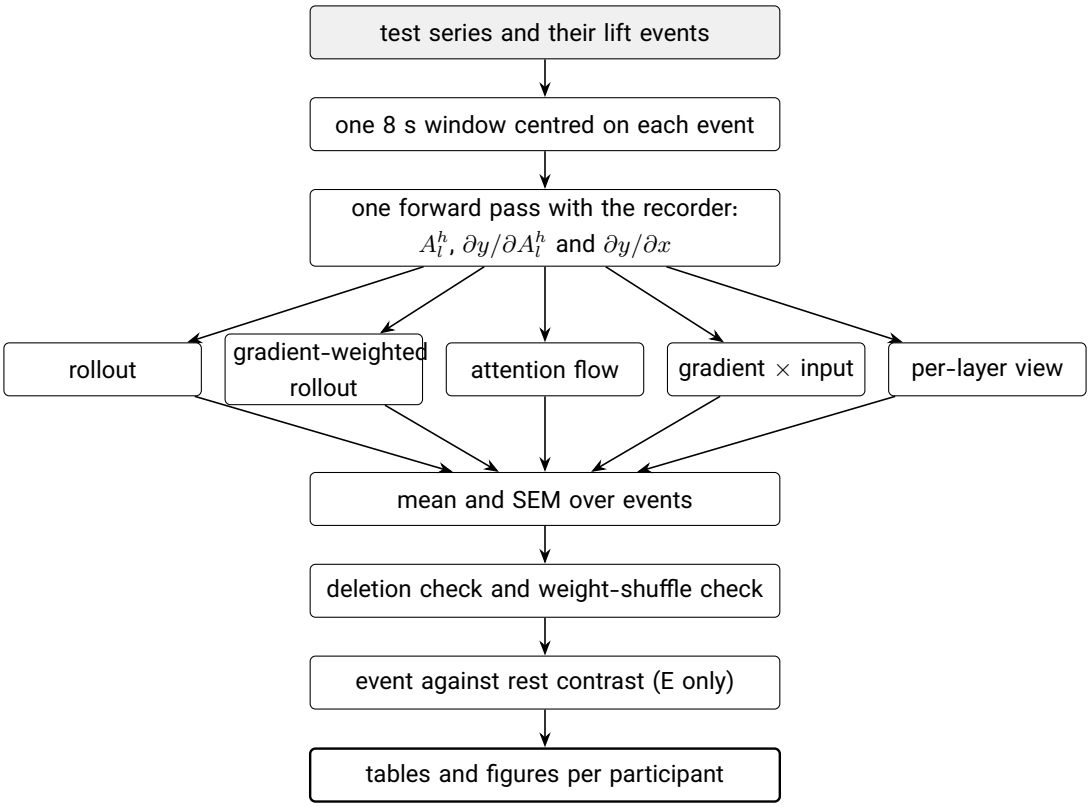
هر توضیح درباره‌ی یک عدد است: یک خروجی $o \in \{K, E, F_{eeg}\}$، یک عضله‌ی c و یک token t از یک پنجره‌ی ۸ ثانیه‌ای:

$$y = \mathrm{out}_o[t, c]. \tag{۸}$$

پنجره‌ها حول رخدادهای آزمایش (اولین تماس و جداشدن جسم از سطح) در سری‌های آزمون چیده می‌شوند و t مرکز پنجره است، یعنی خودِ لحظه‌ی رخداد. مسیر هر خروجی:

- K: stem، سه لایه‌ی زمانی سینماتیک، دو لایه‌ی muscle graph؛
- E: دو لایه‌ی electrode graph، pooling، دو لایه‌ی زمانی EEG، دو لایه‌ی muscle graph؛
- F_{eeg}: electrode graph، pooling، لایه‌های زمانی EEG و cross-attention.

recorder در یک گذر رو به جلو ماتریس توجه همه‌ی این لایه‌ها را برمی‌دارد: $A_l^h \in \mathbb{R}^{n \times n}$ برای لایه‌ی l و سر h. هر روش زیر از همین ماتریس‌ها یا از گرادیان y نسبت به آن‌ها ساخته می‌شود. شکل ۱۸ کل مسیر را نشان می‌دهد.



شکل ۱۸: مسیر تفسیر در v2: هر روش از یک گذر ثبت‌شده ساخته می‌شود، روی رخدادها میانگین گرفته می‌شود و پیش از هر ادعا سنجیده می‌شود.

۲.۷ attention rollout و attention flow

این دو روش هر لایه‌ی توجه را از خروجی تا ورودی دنبال می‌کنند و برای همه‌ی مسیرهای مدل به کار می‌روند. تعریف ریاضی آن‌ها، فرایند کامل هر کدام در یک شکل، پیاده‌سازی و نتایجشان در بخش جداگانه‌ی ۸ آمده است.

برای ادامه‌ی این بخش کافی است بدانیم rollout با ماتریس‌های $\hat{A}_l = \frac{1}{2}\overline{A}_l + \frac{1}{2}I$ (میانگین سرها به‌علاوه‌ی residual connection) و حاصل‌ضرب $R = \hat{A}_L \cdots \hat{A}_1$ ساخته می‌شود، برای هر token ورودی سهمی بین ۰ و ۱ می‌دهد که جمعشان ۱ است، و برای پنج عضله‌ی یک جریان یکسان است.

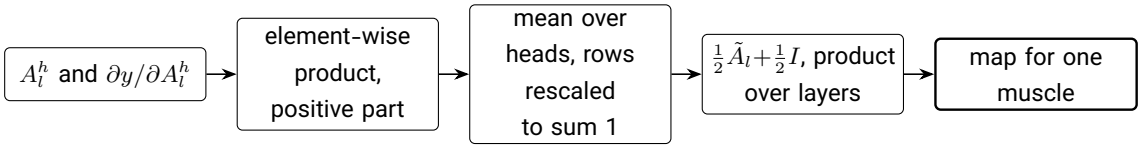
۳.۷ gradient-weighted rollout

مفهوم. plain rollout نمی‌داند کدام توجه برای عضله‌ی موردنظر مهم است. این روش [۵] هر وزن توجه را در گرادیان خروجی نسبت به همان وزن ضرب می‌کند و فقط بخش مثبت را نگه می‌دارد، پس نقشه برای هر عضله جداست.

ریاضی.

$$G_l = \frac{1}{H}\sum_h \left(A_l^h \odot \frac{\partial y}{\partial A_l^h}\right)^+, \qquad \tilde{A}_l = \frac{G_l}{G_l \mathbf{1}}, \qquad R^{\nabla} = \prod_{l=L}^{1}\left(\tfrac{1}{2}\tilde{A}_l + \tfrac{1}{2}I\right), \tag{۹}$$

که تقسیم سطری است (هر سطر دوباره جمع ۱ می‌گیرد) و سطری که همه‌ی آن صفر است همان I می‌ماند. گرادیان‌ها با recorder در حالت grad=True گرفته می‌شوند.



شکل ۱۹: gradient-weighted rollout.

۴.۷ نمای هر لایه

توجه هر لایه و هر سر در token رخداد، بدون ترکیب لایه‌ها: سطر t از A_l^h برای لایه‌های زمانی، و کل ماتریس برای electrode graph و muscle graph. این نما نشان می‌دهد ترکیب rollout از کدام لایه‌ها آمده است.

۵.۷ gradient × input

مفهوم. لایه‌هایی که توجه ندارند (embedding، feed-forward، decoder) در rollout دیده نمی‌شوند. gradient × input [۶] اثر موضعی خطیِ هر ورودی را از کل مدل می‌گیرد.

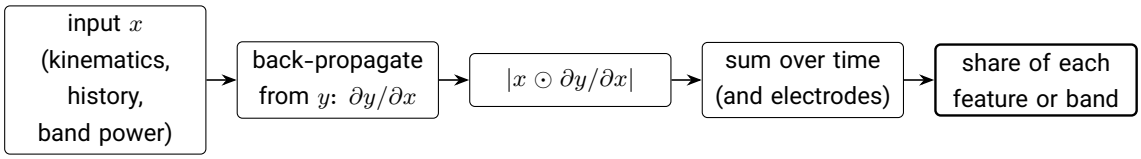
ریاضی. برای ورودی x (سینماتیک، تاریخچه یا EEG band power):

$$s_i = \left| x_i \frac{\partial y}{\partial x_i} \right|, \tag{۱۰}$$

که برای هر ویژگی سینماتیک روی زمان، و برای هر باند EEG روی زمان و الکترودها جمع زده و سپس به سهم (جمع ۱) تبدیل می‌شود.

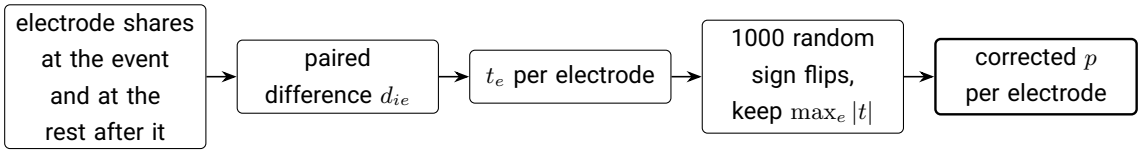
۶.۷ میانگین روی رخدادها و مقایسه با استراحت

میانگین روی رخدادها. هیچ نقشه‌ای از یک پنجره گزارش نمی‌شود. برای هر رخداد یک پنجره ساخته می‌شود و نقشه‌ها به سهم (جمع ۱) تبدیل و سپس میانگین و SEM ($\mathrm{SEM} = \sigma/\sqrt{n}$) روی رخدادها گرفته می‌شود. رخدادی که پنجره‌اش در سری جا نشود کنار می‌رود.



شکل ۲۰: input × gradient.

مقایسه با استراحت (فقط E). هر بلندکردن با پنجره‌ی استراحتِ پس از آن (وسط فاصله‌ی دو بلندکردن) جفت می‌شود. برای هر الکترود e تفاوت جفت‌شده‌ی سهم‌ها $d_{ie} = a_{ie} - b_{ie}$ و آماره‌ی $t_e = \bar{d}_e/(s_e/\sqrt{n})$ حساب می‌شود. null distribution با برگرداندن تصادفی علامت هر جفت ساخته می‌شود (۱۰۰۰ بار)؛ هر بار بیشینه‌ی $|t|$ روی همه‌ی الکترودها نگه داشته می‌شود و p هر الکترود از مقایسه با این بیشینه‌ها به دست می‌آید [۹]. این کار خطای آزمودن ۳۲ الکترود را کنترل می‌کند و هر چه دو عضو جفت در آن مشترک‌اند (خودِ پنجره‌ی سیگنال) حذف می‌شود.



شکل ۲۱: مقایسه‌ی رخداد با استراحت.

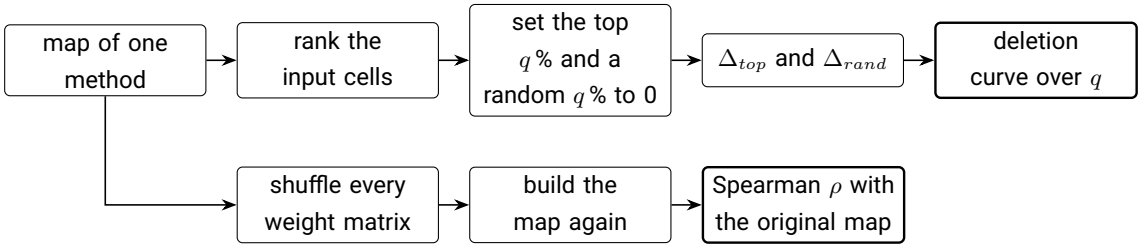
۷.۷ سنجش خودِ نقشه‌ها

deletion check [۷]. خانه‌هایی از ورودی که یک روش مهم‌تر می‌داند به صفر (یعنی میانگین آموزش) تغییر داده می‌شوند و جابه‌جایی y اندازه گرفته می‌شود. برای EEG هر خانه یک الکترود در یک token است (هر چهار باند) و برای سینماتیک همه‌ی ویژگی‌های یک token. کسرهای ۵، ۱۰، ۲۰ و ۴۰ درصد آزموده می‌شوند و با حذف همان تعداد خانه‌ی تصادفی (میانگین ۱۰ بار) مقایسه می‌شوند:

$$\Delta_{top}(q) = \big|\, y(x) - y(x_{\setminus \mathrm{top}(q)}) \,\big|, \qquad \Delta_{rand}(q) = \mathrm{mean}_{10} \,\big|\, y(x) - y(x_{\setminus \mathrm{rand}(q)}) \,\big|, \tag{11}$$

که $x_{\setminus \mathrm{top}(q)}$ ورودی بدون q درصد خانه‌های برتر و $x_{\setminus \mathrm{rand}(q)}$ ورودی بدون همان تعداد خانه‌ی تصادفی است. روشی که Δ_{top} آن بزرگ‌تر است، ورودی‌های واقعاً اثرگذار را بهتر پیدا می‌کند.

weight-shuffle check [۸]. در یک نسخه از مدل، درایه‌های هر ماتریس وزن (دو بعد یا بیشتر) به‌هم ریخته می‌شوند و نقشه‌ها دوباره ساخته می‌شوند. Spearman correlation نقشه‌ی مدل آموزش‌دیده و مدل به‌هم‌ریخته باید نزدیک صفر باشد؛ نقشه‌ای که برای مدل به‌هم‌ریخته هم همان شکل را دارد به آموخته‌های مدل بستگی ندارد.



شکل ۲۲: deletion check (بالا) و weight-shuffle check (پایین).

۸.۷ نتایج برای همه‌ی شرکت‌کننده‌ها

جدول ۱۱ مهم‌ترین نتیجه‌ی سنجش است. برای E gradient-weighted rollout با فاصله‌ی زیاد بهترین روش است (۰٫۲۰۵ در برابر حدود ۰٫۰۹ برای روش‌های دیگر و ۰٫۰۲۱ برای حذف تصادفی) و در هر ۱۲ شرکت‌کننده اول است (جدول ۱۳). برای K rollout، gradient-weighted rollout و gradient × input هم‌ترازند و attention flow ضعیف‌تر است. همه‌ی روش‌ها از حذف تصادفی بهترند.

جدول ۱۱: deletion check، میانگین روی ۱۲ شرکت‌کننده، پنج عضله و چهار کسر حذف (۵، ۱۰، ۲۰ و ۴۰ درصد): تغییر خروجی (واحد مدل) وقتی ورودی‌هایی که هر روش مهم‌تر می‌داند حذف می‌شوند. بزرگ‌تر بهتر است.

خروجی	حذف تصادفی	rollout	attention flow	gradient-weighted rollout	gradient × input
E	۰٫۰۲۱	۰٫۰۹۸	۰٫۰۹۳	۰٫۲۰۵	۰٫۰۹۲
K	۰٫۰۳۷	۰٫۲۱۲	۰٫۱۱۸	۰٫۲۱۳	۰٫۲۱۱

جدول ۱۲ یک هشدار دارد: K plain rollout برای مدل با وزن‌های به‌هم‌ریخته هم شکل مشابهی دارد (اسپیرمن ۰٫۴۷). علت آن ساختار است، نه یادگیری: residual connection و ردپای stem بیشترین سهم را همیشه به token خودِ رخداد و همسایه‌هایش می‌دهند. برای E gradient × input کمترین وابستگی به یادگیری را دارد (۰٫۲۷). gradient-weighted rollout در هر دو خروجی نزدیک صفر است؛ پس برای ادعاهای این گزارش gradient-weighted rollout روش اصلی است.

جدول ۱۲: weight-shuffle check: Spearman correlation بین نقشه‌ی مدل آموزش‌دیده و نقشه‌ی مدلی با ماتریس‌های وزنِ به‌هم‌ریخته (میانگین روی ۱۲ شرکت‌کننده). نزدیک صفر بهتر است: یعنی نقشه به آموخته‌های مدل وابسته است.

خروجی	rollout	attention flow	gradient-weighted rollout	gradient × input
E	۰٫۰۳۶	۰٫۰۷۵	۰٫۰۱۲	۰٫۲۷۱
K	۰٫۴۷۳	-۰٫۰۰۸	۰٫۰۷۰	۰٫۰۷۶

جدول ۱۳: اجزای دقیق خروجی در پنجره‌های رخداد و بهترین روش تفسیر برای E در هر شرکت‌کننده.

شرکت‌کننده	بازه‌ی history gain	$\lvert F_{eeg}\rvert/K$ (%)	بیشینه‌ی $\lvert g\rvert$	بهترین روش در deletion check (E)
P1	۱٫۰۹–۱٫۲۰	۰٫۶۹	۰٫۰۱۵	gradient-weighted rollout
P2	۱٫۰۶–۱٫۱۳	۰٫۱۵	۰٫۰۱۴	gradient-weighted rollout
P3	۱٫۱۰–۱٫۱۸	۱٫۰۱	۰٫۰۱۷	gradient-weighted rollout
P4	۱٫۱۰–۱٫۱۹	۰٫۶۰	۰٫۰۲۶	gradient-weighted rollout
P5	۱٫۰۴–۱٫۱۱	۰٫۵۷	۰٫۰۲۶	gradient-weighted rollout
P6	۱٫۰۸–۱٫۱۵	۱٫۱۴	۰٫۰۲۴	gradient-weighted rollout
P7	۱٫۱۱–۱٫۱۸	۰٫۹۱	۰٫۰۱۸	gradient-weighted rollout
P8	۱٫۰۸–۱٫۱۸	۲٫۲۲	۰٫۰۴۲	gradient-weighted rollout
P9	۱٫۰۸–۱٫۱۸	۰٫۶۵	۰٫۰۱۲	gradient-weighted rollout
P10	۱٫۰۹–۱٫۲۶	۰٫۸۳	۰٫۰۱۰	gradient-weighted rollout
P11	۱٫۰۸–۱٫۱۴	۱٫۰۹	۰٫۰۱۵	gradient-weighted rollout
P12	۱٫۰۹–۱٫۱۷	۱٫۰۶	۰٫۰۲۱	gradient-weighted rollout

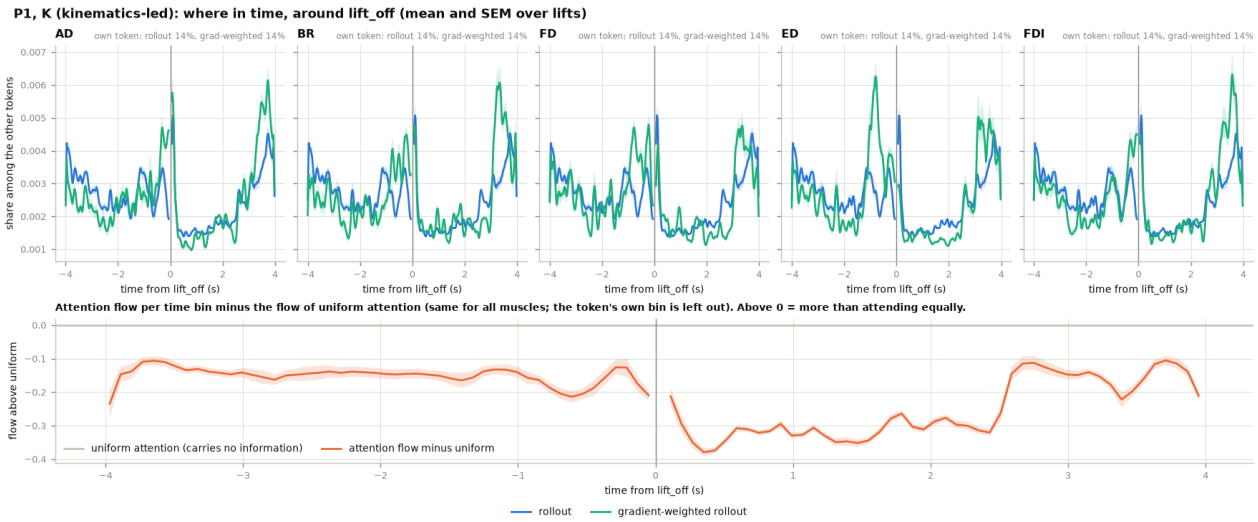
۹.۷ نتایج P1 و P2

شکل‌های این بخش برای رخداد «جداشدن جسم از سطح» (lift_off) و میانگین روی همه‌ی بلندکردن‌های سری‌های آزمون است. شکل‌های زمانی از جدول‌های ذخیره‌شده با نسخه‌ی تازه‌ی رسم دوباره ساخته شده‌اند: سهم token خودِ رخداد (که همیشه بزرگ‌ترین است) جداگانه نوشته شده و منحنی‌ها سهم tokens دیگر را نشان می‌دهند.

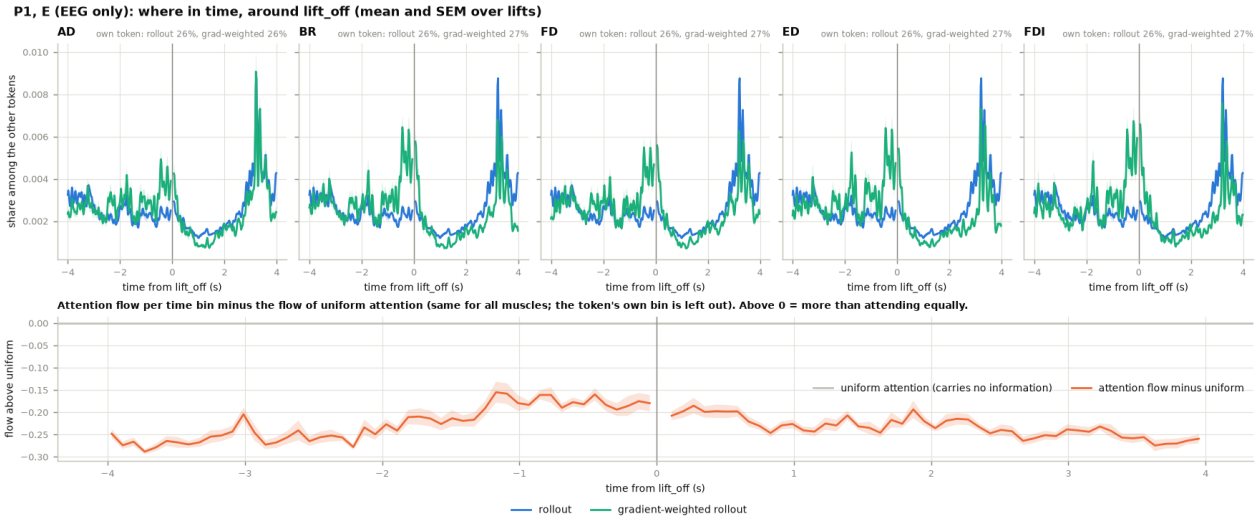
زمان. برای K در P1، هر دو rollout در یک ثانیه‌ی پیش از جداشدن بالا می‌روند، در دو ثانیه‌ی پس از آن کمترین سهم را دارند و دوباره حدود ۳ تا ۴ ثانیه بعد بالا می‌روند. gradient-weighted rollout برای هر عضله قله‌های متفاوتی دارد (برای نمونه ED و FD حدود ۰٫۸ ثانیه پیش از رخداد). برای E الگو در P1 شبیه K است، اما در P2 سهم تقریباً یکنواخت است و فقط در لبه‌ی پایانی پنجره (۴+ ثانیه) جهش دارد که بیشتر به اثر لبه‌ی پنجره می‌ماند تا به رویداد حرکتی.

الکترودها. در هر دو شرکت‌کننده یکی از کانون‌های سهم E روی الکترودهای چپِ مرکزی (C3، FC5، CP5) است، یعنی بالای قشر حرکتی نیمکره‌ی مقابل دست راست، و لایه‌ی اول electrode graph در P1 بیشتر از همین الکترودها می‌خواند. اما سهم قابل‌توجهی هم روی الکترودهای پس‌سری و (در P2) پیشانی راست است؛ بنابراین بخشی از اطلاعات E ممکن است از artifact حرکت چشم یا عضلات سر و گردن باشد، نه فقط از قشر حرکتی.

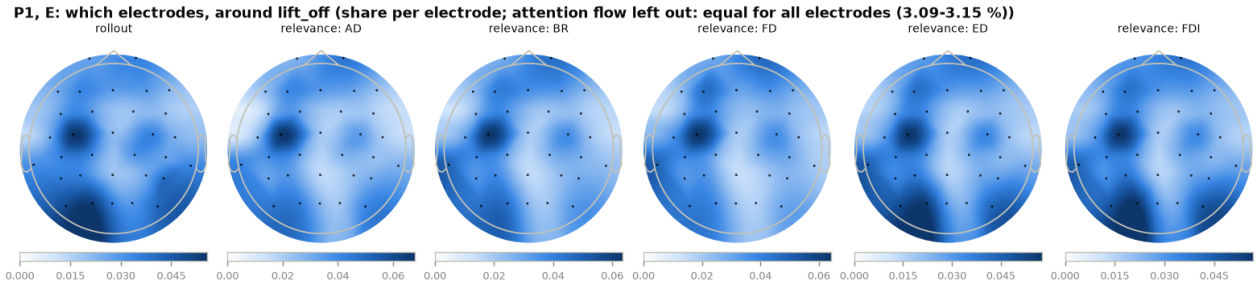
muscle graph. قطر ماتریس‌ها قوی است (هر عضله بیشتر از خودش می‌خواند) و روابط بین عضلات بیشتر در gradient-weighted rollout دیده می‌شوند.



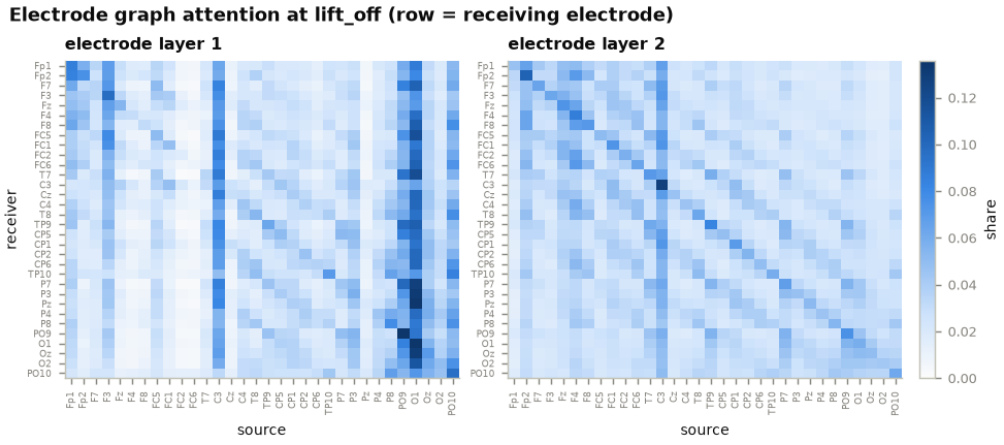
شکل ۲۳: P1، خروجی K: سهم هر token زمانی حول جداشدن جسم (بالا) و attention flow منهای uniform-attention flow (پایین).



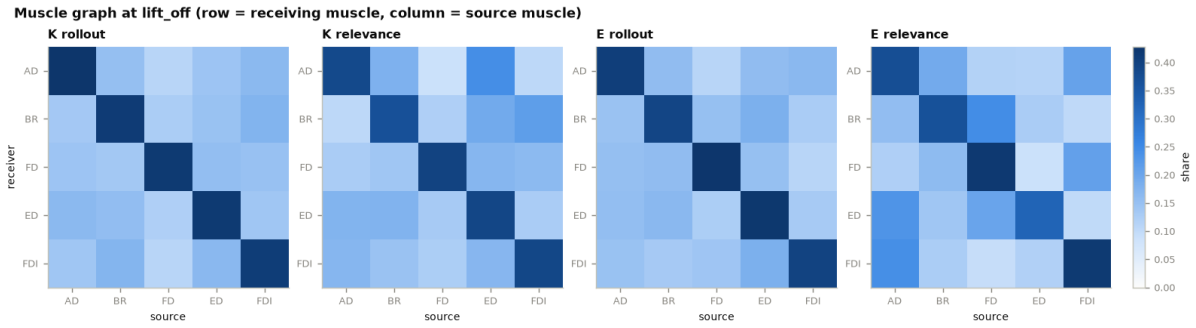
شکل ۲۴: P1، خروجی E: سهم زمانی و attention flow منهای خط پایه.



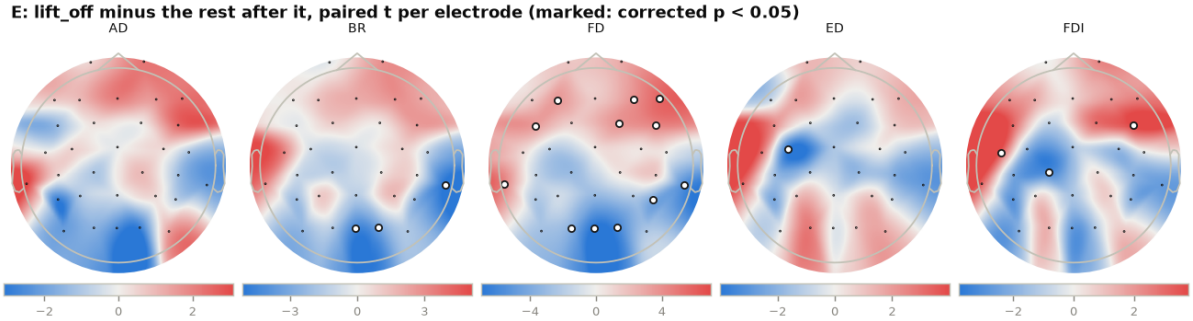
شکل ۲۵: P1، خروجی E: سهم هر الکترود در rollout و gradient-weighted rollout برای هر عضله. نقشه‌ی attention flow حذف شده چون برای همه‌ی الکترودها برابر است.



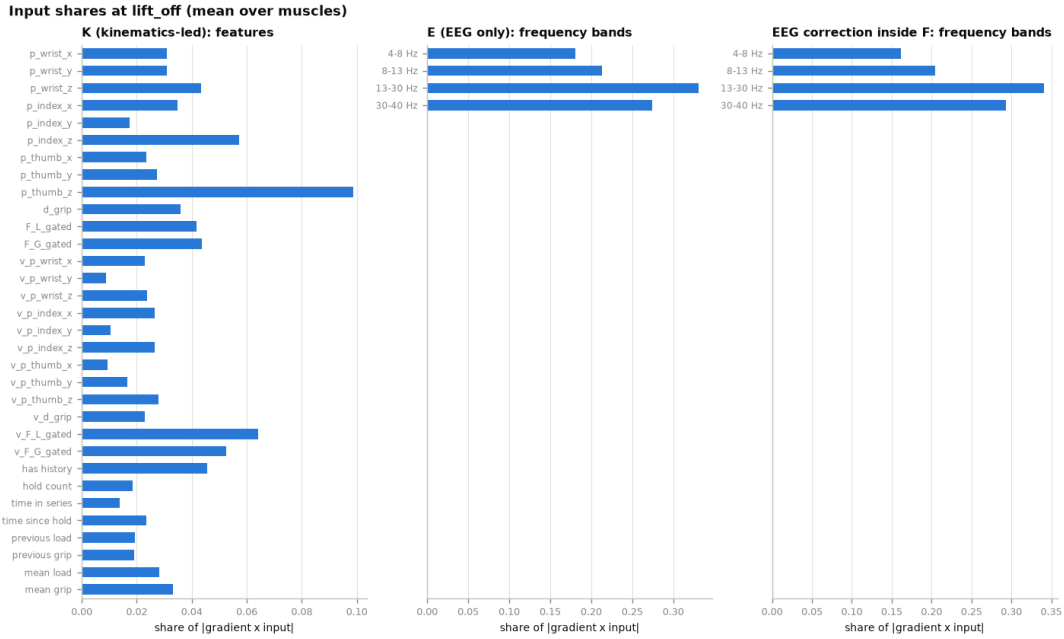
شکل ۲۶: P1: توجه دو لایه‌ی electrode graph در لحظه‌ی جداشدن (سطر = الکترود گیرنده).



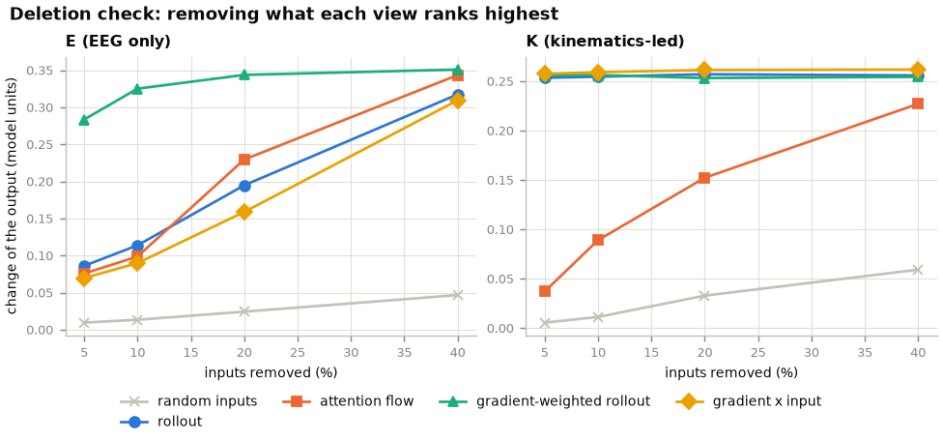
شکل ۲۷: P1 muscle graph در لحظه‌ی جداشدن برای K و E، rollout و gradient-weighted rollout.



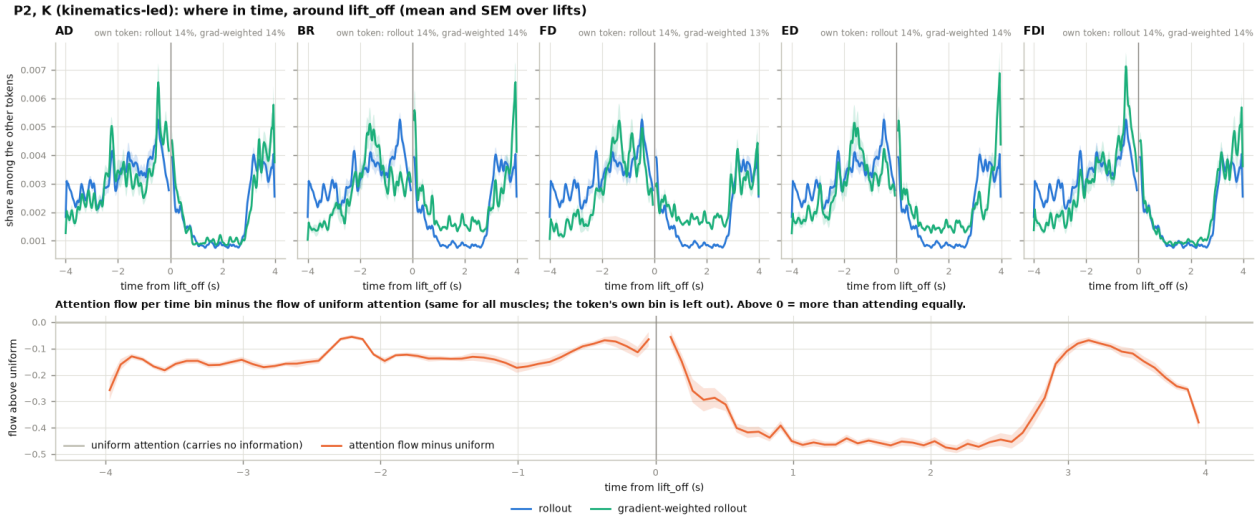
شکل ۲۸: P1 سهم الکترودها در E هنگام جداشدن منهای استراحت پس از آن؛ آماره‌ی t جفت‌شده، دایره‌ها p تصحیح‌شده کمتر از ۰٫۰۵.



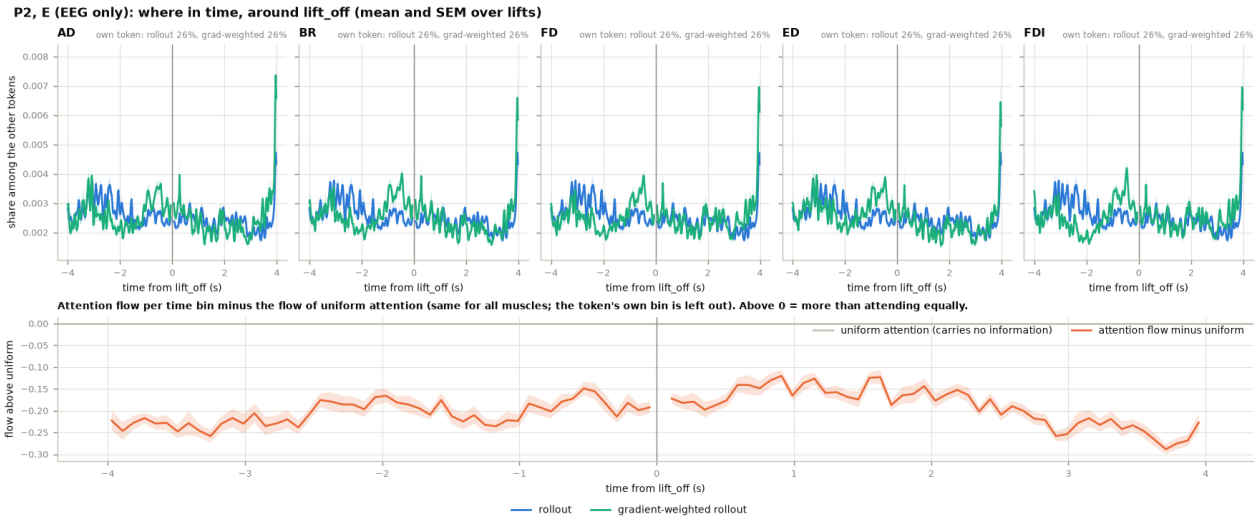
شکل ۲۹: P1 سهم ویژگی‌های سینماتیک و تاریخچه در K و سهم باندهای EEG در E (gradient × input).



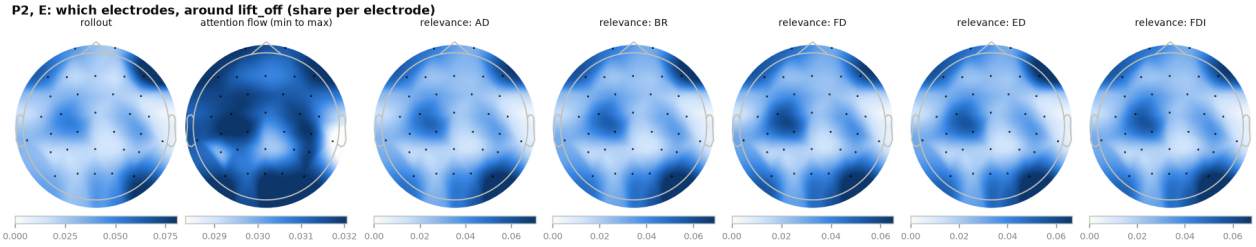
شکل ۳۰: P1: منحنی‌های deletion check.



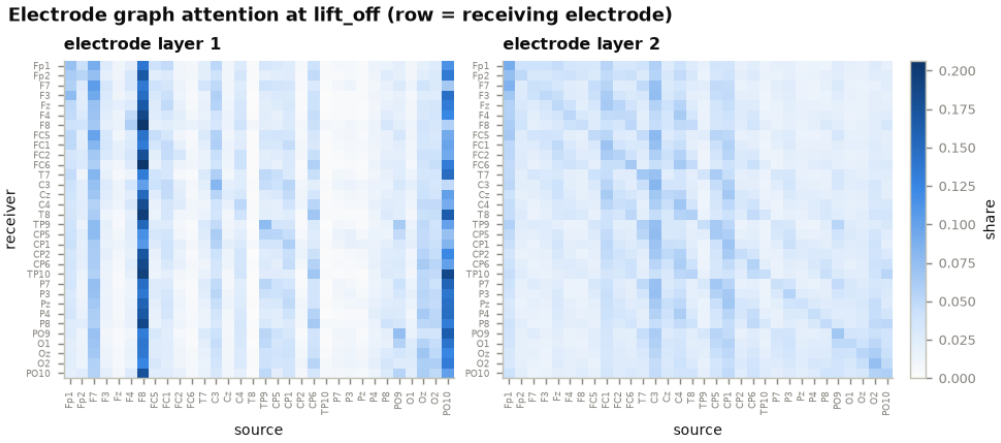
شکل ۳۱: P2، خروجی K: سهم زمانی و attention flow منهای خط پایه.



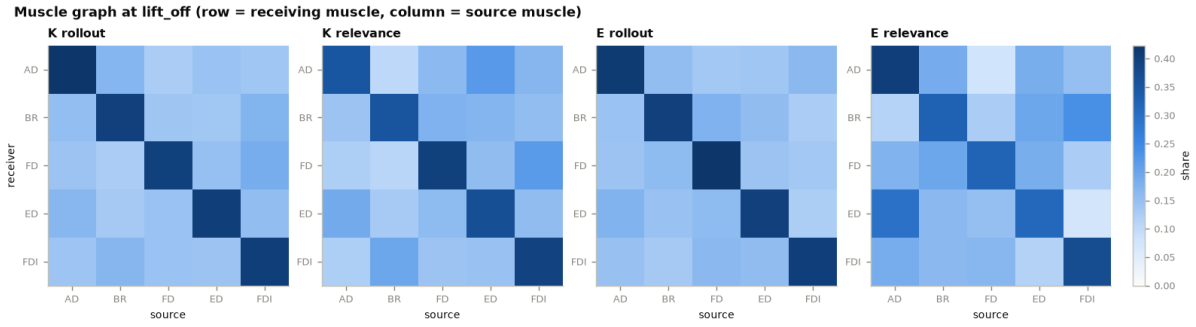
شکل ۳۲: P2، خروجی E: سهم زمانی و attention flow منهای خط پایه.



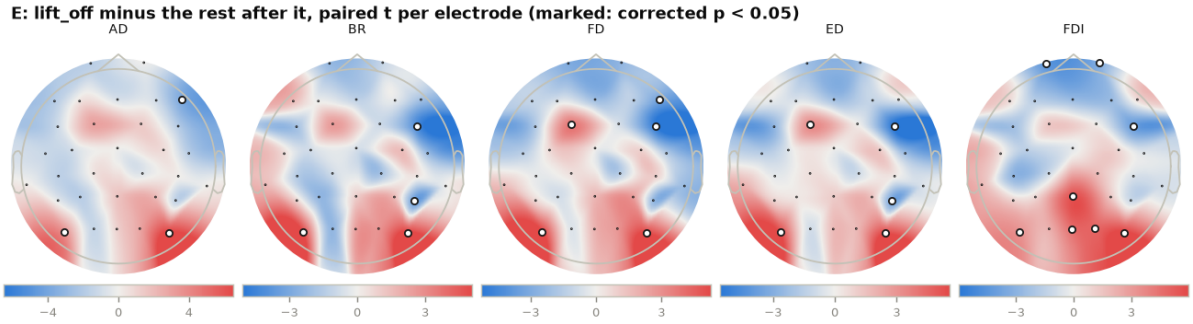
شکل ۳۳: P2، خروجی E: سهم هر الکترود. در این شرکت‌کننده جریان الکترودها کمی پراکندگی دارد (۱۱٫۵ درصد) و نقشه‌اش با رنگ از کمینه تا بیشینه رسم شده است.



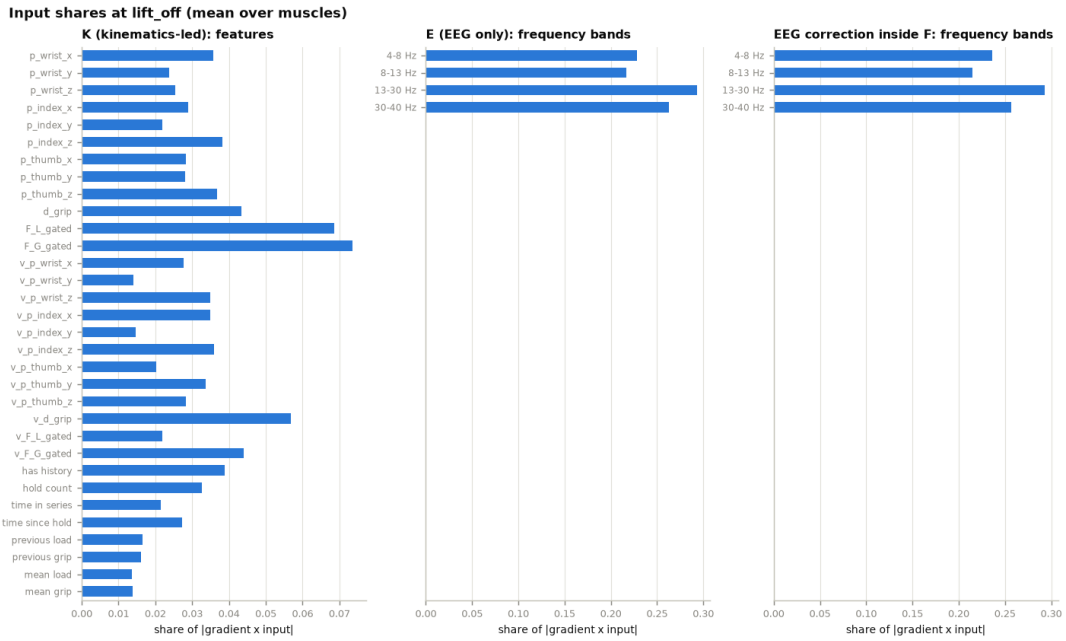
شکل ۳۴: P2: توجه دو لایه‌ی electrode graph در لحظه‌ی جداشدن.



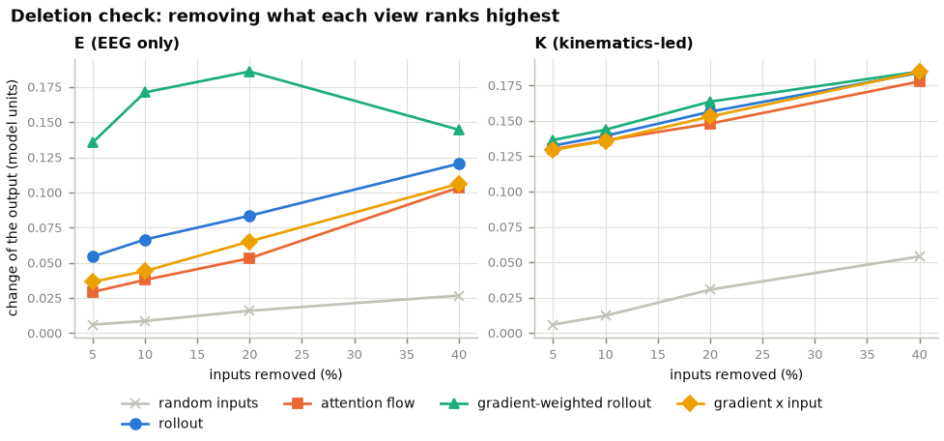
شکل ۳۵: P2: muscle graph در لحظه‌ی جداشدن.



شکل ۳۶: P2: مقایسه‌ی رخداد با استراحت برای E.



شکل ۳۷: P2: سهم ورودی‌ها (gradient × input).



شکل ۳۸: P2: منحنی‌های deletion check.

۸ attention rollout و attention flow

attention rollout و attention flow [۴] هر دو یک پرسش را پاسخ می‌دهند: یک عدد خروجی از کدام ورودی‌ها آمده است، وقتی اطلاعات در هر لایه فقط از راه توجه و residual connection بین موقعیت‌ها جابه‌جا می‌شود. هر دو روی همان ماتریس‌های ثبت‌شده کار می‌کنند و فقط در قاعده‌ی ترکیب لایه‌ها فرق دارند: rollout در طول هر مسیر وزن‌ها را ضرب و مسیرها را جمع می‌کند، و attention flow وزن‌ها را ظرفیت لوله می‌گیرد و بیشینه‌ی جریانی را که از یک ورودی به خروجی می‌رسد حساب می‌کند. قاعده‌ی «یک مخلوط‌کننده» در v2 (بخش ۵) شرط لازم هر دو است: چون اطلاعات جز از راه توجه (و stem معلوم K) بین موقعیت‌ها جابه‌جا نمی‌شود، این گراف کل مسیر اطلاعات را می‌پوشاند.

۱.۸ نمادگذاری و layered graph

برای لایه‌ی l از L لایه‌ی توجه، recorder ماتریس $A_l^h \in \mathbb{R}^{n\times n}$ را برای هر سر $h = ۱,\dots,H$ پس از softmax برمی‌دارد؛ سطر i گیرنده (پرسش) و ستون j فرستنده است و هر سطر جمع ۱ دارد. میانگین سرها و residual connection:

$$\overline{A}_l = \frac{۱}{H}\sum_{h=۱}^{H} A_l^h, \qquad \hat{A}_l = \tfrac{۱}{۲}\,\overline{A}_l + \tfrac{۱}{۲} I. \tag{۱۲}$$

وزن $\frac{۱}{۲}$ برای residual connection یک قرارداد است: بلوک $x + \mathrm{Attn}(\mathrm{LN}(x))$ نیمی از اطلاعات را از مسیر توجه و نیمی را از مسیر مستقیم فرض می‌کند. layered graph $L+۱$ ردیف گره دارد (ردیف ۰ ورودی‌ها، ردیف L خروجی‌ها) و از گره j در ردیف $l-۱$ به گره i در ردیف l یک یال با وزن $\hat{A}_l[i,j]$ می‌رود. یال‌های $j \to j$ مسیر اتصال باقی‌مانده‌اند و بقیه مسیر توجه (شکل ۳۹).

۲.۸ attention rollout

تعریف

rollout حاصل‌ضرب ماتریس‌های لایه‌ها از آخر به اول است، و این حاصل‌ضرب دقیقاً جمع روی همه‌ی مسیرهای layered graph است:

$$R = \hat{A}_L \hat{A}_{L-۱} \cdots \hat{A}_۱, \qquad R[t,\tau] = \sum_{\tau=i_۰\to i_۱\to\cdots\to i_L=t} \prod_{l=۱}^{L} \hat{A}_l[i_l, i_{l-۱}]. \tag{۱۳}$$

هر مسیر به اندازه‌ی حاصل‌ضرب وزن‌هایش سهم می‌گیرد، پس یک یال ضعیف کل مسیر را تضعیف می‌کند. چون همه‌ی $\hat{A}_l$ سطرهایی با جمع ۱ و درایه‌های نامنفی دارند، حاصل‌ضرب آن‌ها هم همین‌طور است:

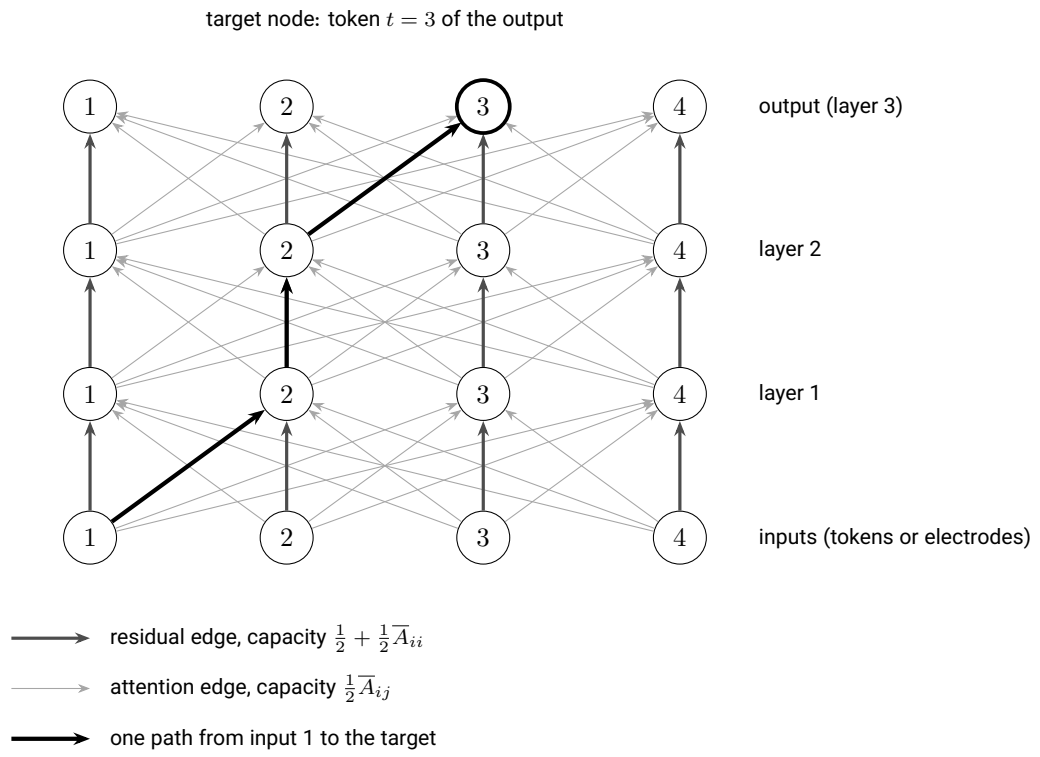
$$\hat{A}_l \mathbf{۱} = \mathbf{۱}\ \forall l \quad\Longrightarrow\quad R\mathbf{۱} = \hat{A}_L \cdots \hat{A}_۱ \mathbf{۱} = \mathbf{۱}, \qquad \sum_{\tau} R[t,\tau] = ۱, \tag{۱۴}$$

و سطر t از R یک توزیع روی ورودی‌هاست: سهم هر ورودی در خروجی token t.

rollout در هر مسیر مدل

همین حاصل‌ضرب، مرحله به مرحله، برای هر خروجی:

- **K، زمان** (سه لایه‌ی زمانی سینماتیک و stem): $R_K = \hat{A}_۳^{(k)} \hat{A}_۲^{(k)} \hat{A}_۱^{(k)}\, S$



شکل ۳۹: rollout layered graph و attention flow. وزن هر یال همان $\hat{A}_l[i,j]$ است. rollout روی همه‌ی مسیرها از ورودی به هدف حاصل‌ضرب وزن‌ها را جمع می‌زند؛ attention flow وزن‌ها را ظرفیت لوله می‌داند و بیشینه‌ی جریانی را که از یک ورودی به هدف می‌رسد حساب می‌کند.

- **E، زمان** (دو لایه‌ی زمانی EEG): $R_E = \hat{A}_{۲}^{(t)} \hat{A}_{۱}^{(t)}$
- **E، الکترودها در token** τ (دو لایه‌ی گراف الکترود و pooling): $e_\tau = \pi_\tau \, \hat{A}_{۲}^{(e)}(\tau) \, \hat{A}_{۱}^{(e)}(\tau) \in \mathbb{R}^{۳۲}$
- **E، زمان در الکترود**: $M_E[\tau, e] = R_E[t, \tau] \; e_\tau[e]$
- F_{eeg}: $R_F = c_t \, R_E$، که c_t سطر t cross-attention است (بدون residual connection)
- **muscle graph** (دو لایه): $R_M = \hat{A}_{۲}^{(m)} \hat{A}_{۱}^{(m)} \in \mathbb{R}^{۵\times۵}$

S ردپای K convolutional stem است: ماتریسی نواری با پهنای ۵ که وزن هر جابه‌جایی برابر انرژی هسته در آن جابه‌جایی است و سطرهایش جمع ۱ دارند. π_τ وزن‌های pooling الکترودها در token τ است (جمع ۱). چون همه‌ی عامل‌ها جمع سطری ۱ دارند، $\sum_{\tau,e} M_E[\tau, e] = ۱$ هم برقرار است.

نمایش

token خود رخداد و همسایه‌هایش (ردپای ۵ توکنی stem) همیشه بیشترین سهم را از مسیر مستقیم می‌گیرند و بقیه‌ی نقشه را پنهان می‌کنند. شکل‌ها سهم آن‌ها را جداگانه می‌نویسند و منحنی سهم بقیه‌ی tokens را نشان می‌دهند:

$$\text{own} = \sum_{\tau \in \mathcal{O}} R[t, \tau], \qquad s(\tau) = \frac{R[t, \tau]}{۱ - \text{own}} \quad (\tau \notin \mathcal{O}), \tag{۱۵}$$

که $\mathcal{O}$ پنج token اطراف t است. نقشه‌ی هر رخداد جداگانه ساخته و سپس روی رخدادها میانگین و SEM گرفته می‌شود.

نسخه‌ی وزن‌دار با گرادیان

در gradient-weighted rollout (بخش ۷) فقط $\overline{A}_l$ در رابطه‌ی (۱۲) با $\tilde{A}_l = \mathrm{rownorm}\big(\frac{1}{H}\sum_h (A_l^h \odot \partial y/\partial A_l^h)^+\big)$ عوض می‌شود و بقیه‌ی مراحل همین است؛ نتیجه برای هر عضله جداست.

محدودیت‌ها

rollout فقط وزن‌های توجه را می‌بیند و آنچه بردارهای مقدار حمل می‌کنند در آن نیست. لایه‌های بدون توجه (embedding، feed-forward، decoder) در آن وارد نمی‌شوند، و وزن ۰٫۵ residual connection انتخاب ماست، نه چیزی که مدل آموخته باشد.

۳.۸ attention flow

تعریف

در attention flow هر یال layered graph یک لوله با ظرفیت $c_e = \hat{A}_l[i,j]$ است. برای ورودی (منبع) τ و گره هدف t، جریان یک تابع f روی یال‌هاست و بیشینه‌ی مقدار آن جواب است:

(۱۶)

$$\mathrm{flow}(\tau \to t) = \max_{f} \sum_{e\,\in\,\mathrm{out}(\tau)} f_e \quad \text{که} \quad 0 \le f_e \le c_e, \qquad \sum_{e\,\in\,\mathrm{in}(v)} f_e = \sum_{e\,\in\,\mathrm{out}(v)} f_e \;\; \text{برای هر گره میانی } v.$$

طبق قضیه‌ی maximum flow و minimum cut، این مقدار برابر ظرفیت کم‌هزینه‌ترین برشی است که τ را از t جدا می‌کند:

$$\mathrm{flow}(\tau \to t) = \min_{(\mathcal{S},\mathcal{T}):\ \tau\in\mathcal{S},\ t\in\mathcal{T}} \ \sum_{e:\,\mathcal{S}\to\mathcal{T}} c_e. \tag{۱۷}$$

فرق با rollout: rollout در طول هر مسیر ضرب می‌کند، اما جریان مسیرهای موازی را جمع می‌کند و هر مسیر فقط با باریک‌ترین لوله‌اش محدود می‌شود. به همین دلیل جریان هیچ‌گاه از سهم rollout کمتر نیست و وقتی توجه پخش است، زود به سقف می‌رسد.

بازه‌بندی زمان

حل رابطه‌ی (۱۶) روی ۴۰۰ tokens برای هر منبع بسیار پرهزینه است. زمان به بازه‌های ۴ توکنی (۸۰ میلی‌ثانیه) تقسیم می‌شود: سطرهای گیرنده‌ی هر بازه میانگین و ستون‌های فرستنده جمع می‌شوند،

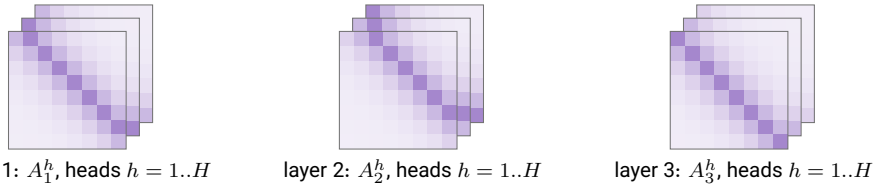
$$\hat{A}_l^{bin}[a,b] = \frac{1}{|a|}\sum_{i\in a}\sum_{j\in b}\hat{A}_l[i,j], \tag{۱۸}$$

که سطرها را همچنان با جمع ۱ نگه می‌دارد. برای K ماتریس stem S هم با همین قاعده بازه‌بندی و پیش از لایه‌ی اول گذاشته می‌شود؛ برای F_{eeg} سطر cross-attention لایه‌ی آخر است.

جریان الکترودها

برای E و F_{eeg}، در هر بازه‌ی زمانی τ گراف دیگری هست: دو لایه‌ی electrode graph (۳۲ $\to$ ۳۲ $\to$ ۳۲، با residual connection) و ردیف pooling (۱ $\to$ ۳۲ با ظرفیت $\pi_\tau[e]$ و بدون residual connection). $\mathrm{flow}_{elec}(\tau, e)$

1 Record every attention layer in one forward pass (after softmax, per head)



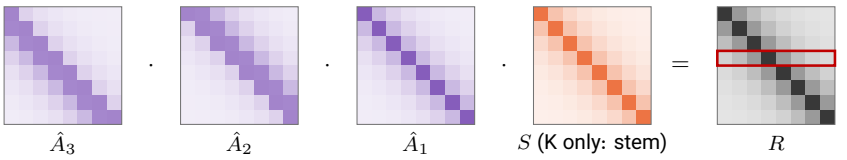
row i = receiving token (query), column j = source

2 Average the heads and add the residual path



$\overline{A}_l = \frac{1}{H}\sum_h A_l^h$
rows still sum to 1
I: the skip connection

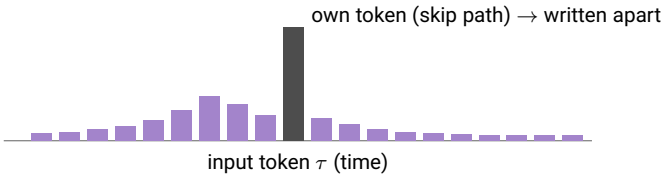
3 Multiply the layers from the last to the first



row t = the explained token

$R[t,\tau] = \sum_{\text{paths } \tau \to t} \prod_l \hat{A}_l$
$\sum_\tau R[t,\tau] = 1$

4 Read row t: the share of every input in the explained output

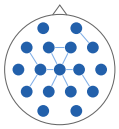


5 The same product, stage by stage, for every output

K: $R_K = \hat{A}_3\hat{A}_2\hat{A}_1 S$
time map, 400 tokens

E, time: $R_E = \hat{A}_2\hat{A}_1$
(EEG temporal layers)

E, electrodes at token τ:
$e_\tau = \pi_\tau \hat{A}_2^{(e)} \hat{A}_1^{(e)}$, π = pooling row

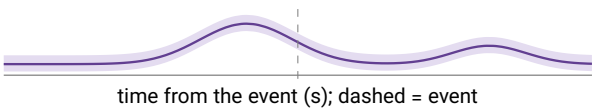


E, time × electrode:
$M_E[\tau, e] = R_E[t,\tau]\, e_\tau[e]$

F$_{eeg}$: cross-attention C last, no residual: $C\,R_E$

muscle graph: $\hat{A}_2^{(m)} \hat{A}_1^{(m)}$
5×5, row = receiving muscle

6 One map per lift event, then mean ± SEM over events (never a single window)



gradient-weighted variant: replace $\overline{A}_l$ by $\tilde{A}_l = \text{rownorm}\left(\frac{1}{H}\sum_h \left(A_l^h \odot \frac{\partial y}{\partial A_l^h}\right)^+\right)$ and run steps 2–6 unchanged: one map per muscle.

شکل ۴۰: فرایند کامل attention rollout. (۱) recorder توجه هر لایه و هر سر را در یک گذر برمی‌دارد. (۲) سرها میانگین گرفته و residual connection به‌صورت $\frac{1}{2}I$ اضافه می‌شود. (۳) ماتریس‌ها از لایه‌ی آخر به اول ضرب می‌شوند (برای K ردپای stem S هم). (۴) سطر token توضیح‌داده‌شده سهم هر ورودی است؛ سهم token خود رخداد جداگانه نوشته می‌شود. (۵) همین حاصل‌ضرب برای زمان، الکترودها، زمان در الکترود، اصلاح EEG و muscle graph. (۶) نقشه‌ی هر رخداد ساخته و روی رخدادها میانگین گرفته می‌شود. کادر پایین: نسخه‌ی وزن‌دار با گرادیان.

maximum flow از الکترود e تا token پول‌شده است. چون token پول‌شده تنها راه خروج اطلاعات الکترودهای یک گام زمانی است، جریان یک الکترود در یک زمان تا خروجی کمینه‌ی دو مرحله است:

$$\mathrm{flow}(\tau, e) = \min\big(\mathrm{flow}_{time}(\tau),\ \mathrm{flow}_{elec}(\tau, e)\big). \tag{۱۹}$$

خط پایه‌ی توجه یکنواخت

همان محاسبه برای مدلی تکرار می‌شود که در هر لایه به همه‌ی n موقعیت برابر توجه می‌کند، با همان residual connection و همان stem:

$$\hat{A}^u = \tfrac{۱}{۲} \cdot \tfrac{۱}{n} J + \tfrac{۱}{۲} I, \qquad \mathrm{excess}(\tau) = \mathrm{flow}(\tau) - \mathrm{flow}^u(\tau), \tag{۲۰}$$

که J ماتریس تمام‌یک است. فقط excess به الگوی توجه آموخته‌شده مربوط است؛ flow^u چیزی است که حتی یک مدل آموزش‌ندیده هم می‌دهد.

۴.۸ پیاده‌سازی

تابع trace مدل را یک بار با recorder اجرا می‌کند و برای هر لایه تنسور (B, H, n, n) را برمی‌دارد. layer_matrix رابطه‌ی (۱۲) را می‌سازد و rollout ماتریس‌ها را به ترتیب از لایه‌ی آخر به اول ضرب می‌کند. rollout با تابع rollout مدل پایه روی ماتریس‌های دست‌ساز آزموده شده است.

برای جریان، bin_matrix بازه‌بندی را انجام می‌دهد و attention_flow برای هر منبع یک مسئله‌ی maximum flow با SciPy حل می‌کند. این الگوریتم ظرفیت صحیح می‌خواهد، پس ظرفیت‌ها در $۱۰^۶$ ضرب و گرد می‌شوند و جواب دوباره بر $۱۰^۶$ تقسیم می‌شود. هر پنجره ۱۰۰ مسئله دارد، پس جریان برای هر خروجی و هر نوع رخداد فقط روی حداکثر ۶ رخداد حساب می‌شود. جریان با maximum flow دست‌حساب‌شده روی گلوگاه‌های ساده آزموده شده و هیچ‌گاه کمتر از rollout نیست.

۵.۸ چرا attention flow در این مدل اشباع می‌شود

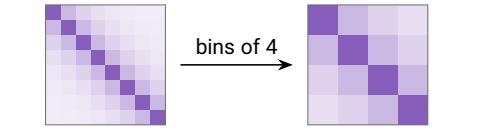
مثال دو لایه با توجه یکنواخت روی n موقعیت را در نظر بگیرید (مسیر زمانی E). ظرفیت یال از ورودی j به گره میانی i برابر $\frac{۱}{۲n} + \frac{۱}{۲}\delta_{ij}$ و از i به هدف t برابر $\frac{۱}{۲n} + \frac{۱}{۲}\delta_{it}$ است. برای $j \neq t$ مسیرها از گره‌های میانی جدا می‌گذرند و هر کدام با کوچک‌ترین یال خود محدود می‌شوند:

$$\mathrm{flow}(j \to t) = \sum_{i=۱}^{n} \min\Big(\tfrac{۱}{۲n} + \tfrac{۱}{۲}\delta_{ij},\ \tfrac{۱}{۲n} + \tfrac{۱}{۲}\delta_{it}\Big) = n \cdot \tfrac{۱}{۲n} = \tfrac{۱}{۲}, \tag{۲۱}$$

و برای خود هدف ($j = t$) نزدیک به ۱. پس در مدلی که هیچ چیز نیاموخته، همه‌ی ورودی‌ها جریان ۰٫۵ دارند و جریان در token خود رخداد به ۱ می‌پرد. با stem و سه لایه (مسیر K) این عدد برای همه‌ی ورودی‌ها حدود ۱ است. وقتی توجه پخش است، تعداد زیاد مسیرهای موازی کوچک جمع می‌شود و جریان به «پخش بودن توجه» حساس است، نه به اینکه اطلاعات از کجا آمده است.

در الکترودها وضع بدتر است. جریان هر الکترود باید از ردیف pooling بگذرد که ظرفیت کل آن ۱ است، و ظرفیت خروجی هر الکترود در لایه‌ی اول دست‌کم ۰٫۵ است. با توجه نسبتاً پخش در لایه‌ی دوم، تقریباً همه‌ی الکترودها به یک سقف می‌رسند: در P1 سهم جریان همه‌ی ۳۲ الکترود بین ۳٫۰۹ و ۳٫۱۵ درصد است (سهم یکنواخت ۳٫۱۲۵ درصد است). شکل‌ها در این حالت نقشه‌ی جریان الکترود را رسم نمی‌کنند و دلیلش را در عنوان می‌نویسند.

1 **Start from the same layer matrices $\hat{A}_l = \frac{1}{2}\overline{A}_l + \frac{1}{2}I$ and bin the time axis**

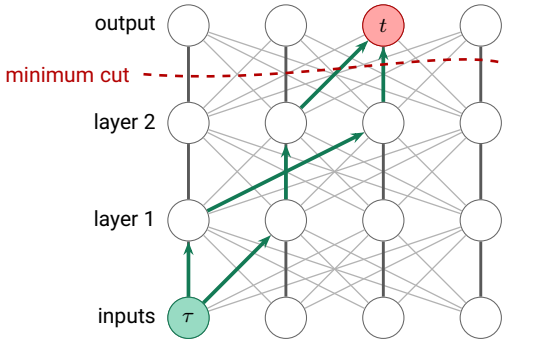


$\hat{A}_l$: 400 × 400 tokens — 100 × 100 bins (80 ms)

$$\hat{A}^{bin}[a,b] = \frac{1}{|a|}\sum_{i\in a}\sum_{j\in b}\hat{A}[i,j]$$

queries averaged, sources summed: rows still sum to 1, and the graph shrinks from $L \cdot 400^2$ to $L \cdot 100^2$ edges.

2 **Read the layers as a flow network: every edge is a pipe with capacity $\hat{A}_l[i,j]$**



source: input bin τ (one problem per source)

maximum flow from source τ to target t:

$$\text{flow}(\tau \to t) = \max_f \sum_{e \text{ out of } \tau} f_e$$

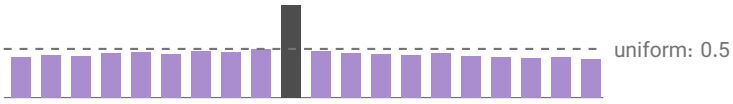
subject to $0 \le f_e \le c_e$ (capacity $c_e = \hat{A}_l[i,j]$) and inflow = outflow at every inner node.

max-flow = min-cut: the value equals the capacity of the cheapest set of pipes that separates τ from t.

Rollout multiplies along each path; flow adds parallel paths, each limited by its narrowest pipe.

3 **Solve one maximum-flow problem per source bin (100 per window)**

capacities $\times 10^6$, rounded to integers
`scipy...csgraph.maximum_flow`
result divided by 10^6



source bin τ (time); dark bar = the target's own bin

4 **Subtract the flow of a model that attends to everything equally**

uniform layers $\frac{1}{2}\frac{1}{n}J + \frac{1}{2}I$ (same residual, same stem)

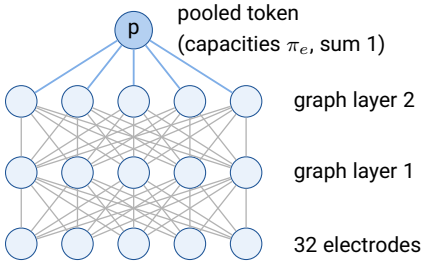
$$\text{excess}(\tau) = \text{flow}(\tau) - \text{flow}_{uniform}(\tau)$$

two uniform layers: every source gets exactly $\frac{1}{2}$



excess below 0: the learned attention is more concentrated than uniform

5 **Electrode flow (E and F_{eeg}): per time bin, through both electrode layers into the pooled token**

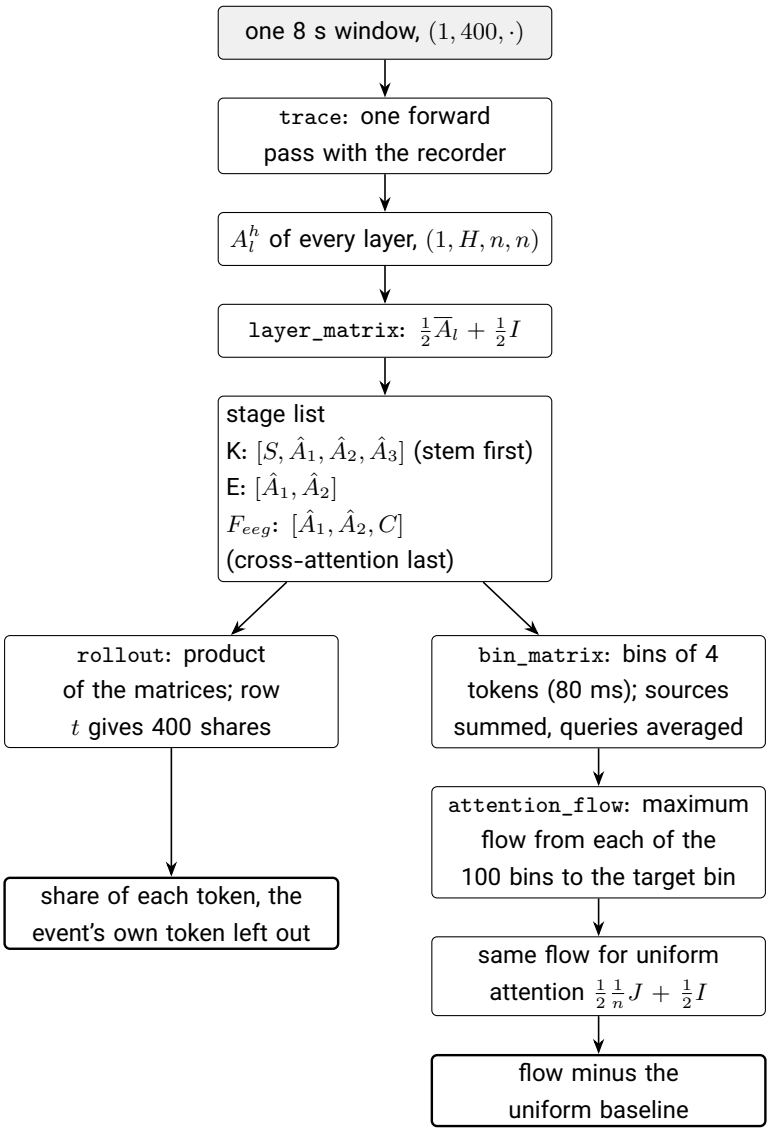


$\text{flow}_{elec}(\tau, e)$: maximum flow from electrode e to the pooled token of bin τ.

The pooled token is the only exit of a time step, so the input flow is $\text{flow}(\tau, e) = \min\left(\text{flow}_{time}(\tau),\ \text{flow}_{elec}(\tau, e)\right)$.

If $\max_e - \min_e < 10\,\%$ of the mean, every electrode reaches the same cap: the map carries no spatial information and is not drawn.

شکل ۴۱: فرایند کامل attention flow. (۱) همان ماتریس‌های لایه‌ها، با بازه‌بندی زمان به ۱۰۰ بازه‌ی ۸۰ میلی‌ثانیه‌ای. (۲) لایه‌ها به‌صورت شبکه‌ی جریان خوانده می‌شوند: هر یال لوله‌ای با ظرفیت $\hat{A}_l[i,j]$ است؛ maximum flow از منبع τ تا هدف t برابر ظرفیت minimum cut است. (۳) برای هر بازه‌ی منبع یک مسئله‌ی maximum flow با ظرفیت‌های صحیح حل می‌شود. (۴) جریان یک مدل با توجه یکنواخت کم می‌شود؛ مقدار زیر صفر یعنی توجه آموخته‌شده متمرکزتر از یکنواخت است. (۵) جریان الکترودها از دو لایه‌ی گراف الکترود و pooling عبور می‌کند و جریان ورودی کمینه‌ی جریان زمانی و جریان الکترود است.



شکل ۴۲: پیاده‌سازی rollout (چپ) و attention flow (راست) برای مسیر زمانی.

۶.۸ نتایج

جدول ۱۴ و شکل ۴۳ جریان را در برابر خط پایه برای هر ۱۲ شرکت‌کننده نشان می‌دهند. سه نتیجه:

۱. جریان واقعی همه‌جا **کمتر** از uniform-attention flow است (میانگین ۰٫۱۵- برای K، ۰٫۲۱- برای E و ۰٫۲۴- برای F_{eeg}). یعنی توجه آموخته‌شده متمرکزتر از یکنواخت است و راه بسیاری از ورودی‌ها را می‌بندد.

۲. برای K الگوی زمانی در همه‌ی شرکت‌کننده‌ها یکسان است: ورودی‌های ۰ تا ۳ ثانیه پس از جداشدن کمترین جریان را دارند و ورودی‌های پیش از رخداد بیشترین. این با rollout سازگار است: K برای سطح فعالیت در لحظه‌ی جداشدن، به حرکت پیش از آن نگاه می‌کند.

۳. پراکندگی جریان الکترودها در ۱۰ نفر از ۱۲ کمتر از ۱۰ درصد میانگین است؛ فقط P2 (۱۲ درصد) از این مرز می‌گذرد. جریان الکترود در این مدل تقریباً هیچ اطلاعات مکانی ندارد.

در deletion check (جدول ۱۱) جریان برای K ضعیف‌ترین روش است (۰٫۱۱۸ در برابر حدود ۰٫۲۱) و برای E هم‌تراز plain rollout و بسیار ضعیف‌تر از gradient-weighted rollout. نتیجه‌ی عملی: attention flow در این معماری درست محاسبه می‌شود اما برای مکان‌یابی اطلاعات به کار نمی‌آید؛ gradient-weighted rollout روش اصلی است و جریان فقط به‌صورت «فاصله از خط پایه‌ی یکنواخت» گزارش می‌شود.

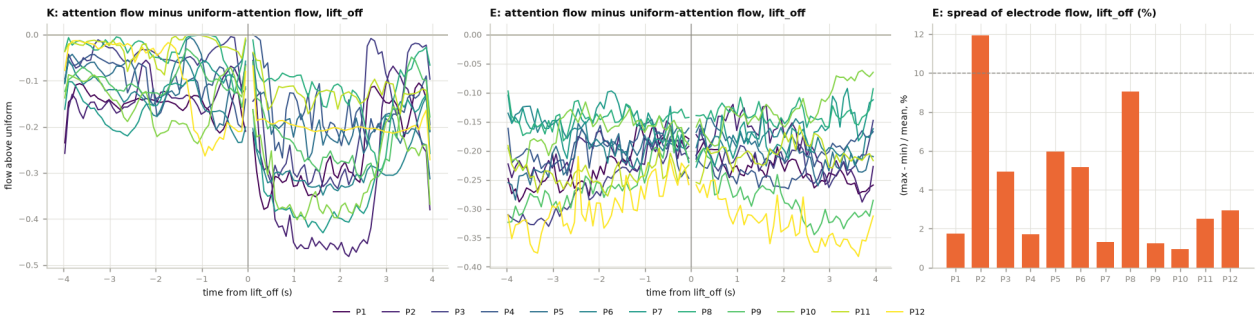
جدول ۱۴: attention flow در برابر خط پایه‌ی توجه یکنواخت: میانگین «جریان منهای جریانِ توجه یکنواخت» روی همه‌ی بازه‌های زمانی، و پراکندگی جریان بین الکترودها (بیشینه منهای کمینه، تقسیم بر میانگین). منفی یعنی جریان از حالت یکنواخت کمتر است.

شرکت‌کننده	جریان اضافه K	جریان اضافه E	جریان اضافه F_eeg	پراکندگی جریان الکترودها (%)
P1	۰٫۱۵۷-	۰٫۲۲۸-	۰٫۲۴۶-	۱٫۷
P2	۰٫۲۴۰-	۰٫۲۰۳-	۰٫۲۰۴-	۱۱٫۵
P3	۰٫۱۱۶-	۰٫۲۴۲-	۰٫۲۰۲-	۴٫۵
P4	۰٫۱۳۲-	۰٫۲۱۶-	۰٫۲۱۷-	۱٫۶
P5	۰٫۱۴۱-	۰٫۱۹۵-	۰٫۱۸۶-	۶٫۳
P6	۰٫۱۸۳-	۰٫۱۷۹-	۰٫۱۹۱-	۵٫۶
P7	۰٫۱۸۸-	۰٫۱۶۸-	۰٫۲۱۶-	۱٫۴
P8	۰٫۰۷۶-	۰٫۱۴۸-	۰٫۲۷۵-	۸٫۸
P9	۰٫۱۲۱-	۰٫۲۷۰-	۰٫۲۴۳-	۱٫۳
P10	۰٫۲۰۶-	۰٫۱۵۶-	۰٫۳۹۱-	۰٫۹
P11	۰٫۰۷۷-	۰٫۲۲۳-	۰٫۲۴۰-	۲٫۴
P12	۰٫۱۲۸-	۰٫۳۰۰-	۰٫۲۵۸-	۲٫۸

۹ residual test: آیا EEG چیزی بیش از سینماتیک دارد؟

۱.۹ پرسش

F برابر K ماند و gate نزدیک صفر. دو توضیح ممکن است: یا EEG واقعاً اطلاعاتی درباره‌ی خطای K ندارد، یا دارد و ماژول fusion نتوانسته آن را یاد بگیرد. residual test این دو را بدون ماژول fusion از هم جدا می‌کند: مستقیم می‌پرسد آیا از EEG می‌توان باقی‌مانده‌ی K را پیش‌بینی کرد.



شکل ۴۳: attention flow منهای uniform-attention flow برای K (چپ) و E (وسط) حول جداشدن جسم، هر خط یک شرکت‌کننده؛ بازه‌ی token خود رخداد حذف شده است. راست: پراکندگی جریان الکترودها برای E؛ خط‌چین مرز ۱۰ درصد که زیر آن نقشه‌ی جریان رسم نمی‌شود.

۲.۹ روش

باقی‌مانده. در حوزه‌ی مدل و با نرخ token: $\varepsilon = u - \hat{u}_K$ که $u = \sqrt{y / s_c}$ هدف و $\hat{u}_K$ خروجی K است.

ویژگی‌ها. دو مجموعه، هر کدام برای هر token:

- **tokens:** خروجی temporal encoder جریان EEG (۶۴ بعد)، یعنی همان چیزی که ماژول fusion می‌خواند؛
- **band power:** ۱۲۸ ویژگی (۳۲ الکترود × ۴ باند) ورودی مدل، با moving average یک‌ثانیه‌ای. این مجموعه به جریان EEG آموزش‌دیده وابسته نیست.

برازش. ridge regression با ورودی استانداردشده و عرض از مبدأ:

$$\hat{W} = \arg\min_{W} \; \|\varepsilon - Z W\|^{۲} + \alpha\, N\, \|W\|^{۲}, \tag{۲۲}$$

روی **سری‌های validation** برازش می‌شود؛ K روی این سری‌ها آموزش ندیده است، پس باقی‌مانده‌ی آن‌ها شبیه باقی‌مانده‌ی سری‌های آزمون است. در سری‌های آموزش، K داده را تا حدی حفظ کرده و باقی‌مانده کوچک‌تر از واقع است. α از میان $۱۰^{-۲}, \dots, ۱۰^{۴}$ با cross-validation روی پنج بلوک پیوسته‌ی زمانی انتخاب می‌شود.

سنجش روی سری‌های آزمون. برای هر عضله:

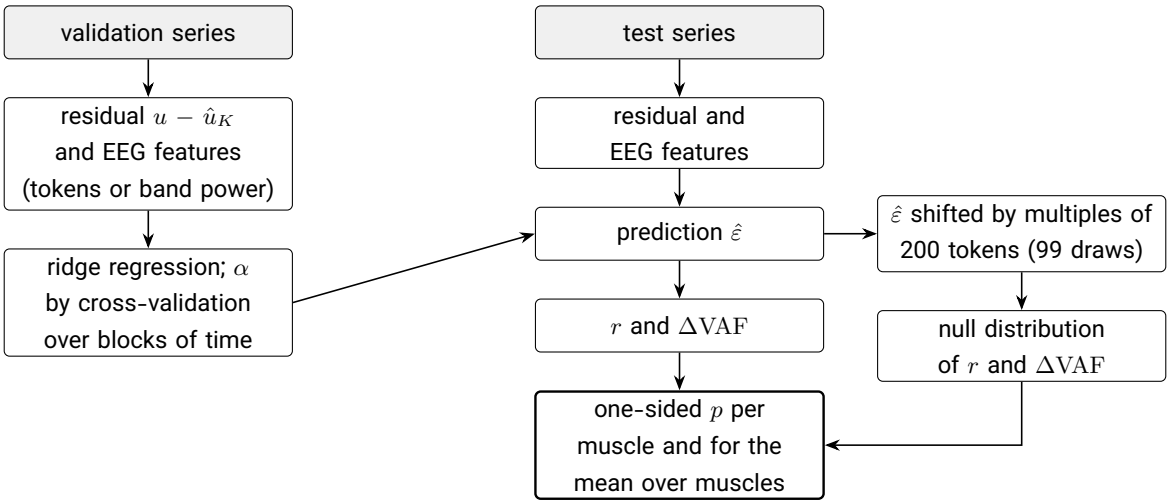
$$r = \mathrm{corr}(\hat{\varepsilon}, \varepsilon), \qquad \Delta\mathrm{VAF} = \mathrm{VAF}\big(s_c\, \mathrm{relu}(\hat{u}_K + \hat{\varepsilon})^{۲},\; y\big) - \mathrm{VAF}\big(s_c\, \hat{u}_K^{۲},\; y\big). \tag{۲۳}$$

null distribution. همان پیش‌بینی $\hat{\varepsilon}$ به‌طور دایره‌ای در زمان جابه‌جا می‌شود و دوباره سنجیده می‌شود (۹۹ بار). جابه‌جایی همیشه مضربی از گام پیش‌بینی (۲۰۰ tokens، یعنی ۴ ثانیه) و دست‌کم یک پنجره است. دلیل این قید در بخش بعد آمده است. p یک‌طرفه است و هیچ‌گاه کمتر از یک‌تقسیم‌برتعداد جابه‌جایی‌های ممکن گزارش نمی‌شود (۱۵۲ تا ۱۹۰ جابه‌جایی در شرکت‌کننده‌های مختلف). آزمون اصلی میانگین روی پنج عضله است.

مقایسه با مدل. همبستگی اصلاحی که خود مدل ساخته $(F - K)$ با باقی‌مانده هم گزارش می‌شود: r_{model}.

۳.۹ یک دام: موقعیت درون پنجره

encoders زمانی به هر token sinusoidal positional encoding اضافه می‌کنند، پس EEG tokens «جای خود در پنجره‌ی ۸ ثانیه‌ای» را می‌دانند. پیش‌بینی پیوسته‌ی K هم ممکن است خطای کوچکی با همین دوره داشته باشد (هر ۴ ثانیه یک پنجره‌ی تازه آغاز می‌شود). یک ridge روی tokens می‌تواند این دو را به هم ربط دهد بی آنکه



شکل ۴۴: residual test.

EEG اطلاعاتی داشته باشد. در آزمون روی داده‌ی کاملاً تصادفی این اتفاق افتاد: با جابه‌جایی‌های دلخواه، r حدود ۰٫۱ و «معنادار» بود. جابه‌جایی به اندازه‌ی مضرب گام پیش‌بینی، فاز این دوره را حفظ می‌کند؛ پس این اثر در null distribution هم هست و فقط اطلاعاتی که به زمان واقعی بسته است شمرده می‌شود. ویژگی‌های band power اصلاً موقعیت ندارند و بررسی تمیزتری هستند.

۴.۹ نتایج

جدول ۱۵: residual test، ردیف میانگین روی پنج عضله برای هر شرکت‌کننده. r: همبستگی باقی‌مانده‌ی پیش‌بینی‌شده و واقعی روی سری‌های آزمون؛ p: در برابر همان پیش‌بینی با جابه‌جایی زمانی؛ VAF∆: بهره‌ی K به‌علاوه‌ی باقی‌مانده‌ی پیش‌بینی‌شده نسبت به K (واحد درصد)؛ ستون آخر همبستگی اصلاحِ خودِ مدل (F_{eeg}) با باقی‌مانده.

شرکت‌کننده	tokens r	p	VAF∆	band power r	p	VAF∆	r اصلاح مدل
P1	۰٫۰۵۵	۰٫۰۱	-۰٫۰۳	۰٫۰۴۱	۰٫۰۳	-۰٫۰۶	۰٫۰۹۲
P2	۰٫۰۸۵	۰٫۰۱	+۰٫۰۳	۰٫۰۸۳	۰٫۰۱	-۰٫۰۰	۰٫۰۰۴
P3	۰٫۱۴۱	۰٫۰۱	+۰٫۲۴	۰٫۱۰۴	۰٫۰۱	-۰٫۴۸	۰٫۰۸۴
P4	۰٫۰۸۸	۰٫۰۱	+۰٫۰۶	۰٫۰۰۶	۰٫۳۶	-۰٫۱۹	۰٫۰۶۴
P5	۰٫۰۶۵	۰٫۰۱	+۰٫۱۹	۰٫۰۳۰	۰٫۲۴	-۰٫۲۳	۰٫۰۸۸
P6	۰٫۰۵۹	۰٫۰۱	-۰٫۹۷	۰٫۰۶۲	۰٫۰۳	-۰٫۶۳	۰٫۱۲۲
P7	۰٫۰۰۱	۰٫۶۰	-۰٫۰۸	-۰٫۰۴۶	۱٫۰۰	-۰٫۰۸	۰٫۱۲۲
P8	۰٫۲۲۶	۰٫۰۱	+۲٫۳۷	۰٫۱۲۲	۰٫۰۱	+۰٫۴۷	۰٫۱۵۲
P9	۰٫۰۷۸	۰٫۰۱	+۰٫۱۶	۰٫۰۴۲	۰٫۰۱	+۰٫۲۳	۰٫۱۴۷
P10	-۰٫۰۵۵	۱٫۰۰	-۰٫۸۶	-۰٫۰۱۲	۰٫۸۱	-۰٫۵۹	-۰٫۰۰۱
P11	۰٫۰۳۹	۰٫۰۱	-۰٫۱۰	۰٫۰۱۷	۰٫۱۸	+۰٫۰۳	-۰٫۰۰۴
P12	۰٫۱۰۱	۰٫۰۱	+۰٫۱۵	۰٫۰۳۶	۰٫۰۸	-۰٫۰۴	۰٫۰۳۷
میانگین	۰٫۰۷۳		+۰٫۱۰	۰٫۰۴۰		-۰٫۱۳	۰٫۰۷۶

- **اثر واقعی است.** با tokens میانگین r برابر ۰٫۰۷۳ و در null distribution ۰٫۰۰۱- است؛ در ۱۰ شرکت‌کننده از

جدول ۱۶: residual test برای هر عضله، میانگین روی ۱۲ شرکت‌کننده؛ ستون‌های تعداد از ۱۲ شمرده شده‌اند.

عضله	tokens r	تعداد p≤۰۵/۰	VAFΔ	band power r	تعداد p≤۰۵/۰	VAFΔ
AD	۰/۰۵۶	۷	+۰/۰۴	۰/۰۳۵	۴	+۰/۰۲
BR	۰/۰۷۹	۷	+۰/۱۶	۰/۰۲۱	۶	-۰/۱۳
FD	۰/۱۱۸	۸	+۰/۱۴	۰/۰۵۲	۷	-۰/۴۶
ED	۰/۰۷۸	۷	+۰/۰۸	۰/۰۵۱	۴	-۰/۰۳
FDI	۰/۰۳۶	۵	+۰/۰۷	۰/۰۴۲	۴	-۰/۰۵

۱۲، ۰/۰۵ $p \le$ (از شانس کمتر از یک مورد انتظار می‌رود). با band power میانگین r برابر ۰/۰۴۰ و در ۶ نفر معنادار است.

- **اثر بسیار کوچک است.** ۰/۰۷ $r =$ یعنی حدود ۰/۵ درصد واریانس باقی‌مانده. افزودن پیش‌بینی به K به‌طور متوسط ۰/۱۰ واحد (با tokens) و ۰/۱۳- واحد (با band power) به VAF اضافه می‌کند. فقط در ۷ نفر (tokens) و ۲ نفر (band power) بهره‌ی VAF هم مثبت و هم معنادار است.
- **استثنا: P8.** با tokens ۲/۴ واحد بهره و r تا ۰/۲۹ برای BR، FD و ED. P8 ضعیف‌ترین K را دارد (VAF برابر ۵۸ درصد)، پس جای بیشتری برای توضیح دادن هست.
- **ماژول fusion همان را یاد گرفته که هست.** r_{model} (اصلاح خودِ مدل در برابر باقی‌مانده) به‌طور متوسط ۰/۰۷۶ است، هم‌اندازه‌ی ridge. fusion جهت درست را پیدا کرده، اما چون اطلاعات این‌قدر کم است، بهینه‌سازی gate را نزدیک صفر نگه داشته است.

۵.۹ بحث

EEG در این داده سیگنال کوچک ولی سازگاری درباره‌ی آنچه سینماتیک توضیح نمی‌دهد دارد، اما ارزش پیش‌بینی آن کمتر از نیم واحد VAF است. بنابراین $F \approx K$ نتیجه‌ی درست این داده است، نه نقص ماژول fusion. حتی یک مرحله‌ی آموزش جداگانه فقط برای fusion (با هر دو جریان منجمد و انتخاب بر اساس خطای F) در بهترین حالت حدود ۰/۱ واحد به میانگین و حدود ۲ واحد به P8 اضافه می‌کرد؛ این هزینه‌ی آموزش دوباره‌ی ۱۲ نفر را توجیه نمی‌کند.

یک احتیاط: tokens از band power بهتر عمل کردند و tokens برای پیش‌بینی EMG آموزش دیده‌اند، پس مرحله‌ی کار را می‌دانند. بخشی از این سیگنال کوچک ممکن است زمان‌بندی حرکت یا artifact حرکت در EEG باشد و نه فرمان قشر حرکتی. r معنادار در اینجا اطلاعات عصبی فراتر از سینماتیک را **اثبات نمی‌کند**. آزمون بعدی می‌تواند همین ridge روی باندها یا الکترودهایی باشد که کمتر در معرض artifact حرکت‌اند.

۱۰ جمع‌بندی و محدودیت‌ها

آنچه به دست آمد. v2 سه پرسش را که مدل پایه در یک خروجی با هم مخلوط می‌کرد جدا کرد.

۱. **دقت از سینماتیک:** K با VAF برابر ۷۵/۸ درصد و r برابر ۰/۸۷۲ در هر ۱۲ شرکت‌کننده از مدل پایه بهتر است و دامنه را در هر سه وزن جسم با خطای کمتر از یک درصد پیش‌بینی می‌کند. بافت ۸ ثانیه‌ای، تاریخچه‌ی بلندکردن‌ها، حوزه‌ی جذر و جزء سطح نگه‌داشتن در هزینه پشت این بهبودند.

۲. **EEG به‌تنهایی:** E با r برابر ۰/۶۴۵ در هر ۱۲ نفر از null test گذشت؛ EEG حالت حرکت را رمز می‌کند.

۳. **EEG فراتر از سینماتیک:** F برابر K است. residual test سیگنالی واقعی اما بسیار کوچک یافت (r حدود ۰٫۰۷، کمتر از نیم واحد VAF) که ماژول fusion هم همان را یافته بود.

تفسیرپذیری. قاعده‌ی «یک مخلوط‌کننده» و recorder بیرونی، rollout، جریان، gradient-weighted rollout و نمای هر لایه را برای هر خروجی و در همه‌ی لایه‌ها بدون حالت خاص ممکن کرد. سنجش نقشه‌ها نشان داد gradient-weighted rollout قابل‌اعتمادترین روش است (بهترین در deletion check، کمترین شباهت با مدل به‌هم‌ریخته). attention flow در این معماری اشباع می‌شود و فقط در برابر خط پایه‌ی توجه یکنواخت معنا دارد. نقشه‌های الکترود E کانونی بالای قشر حرکتی چپ دارند، اما سهم الکترودهای پیشانی و پس‌سری هشدار می‌دهد که بخشی از اطلاعات ممکن است artifact باشد.

محدودیت‌ها.

- rollout و جریان فقط وزن‌های توجه را می‌بینند؛ وزن ۰٫۵ residual connection یک قرارداد است. روش‌های گرادیانی موضعی و مرتبه‌ی اول‌اند.
- K plain rollout در weight-shuffle check شباهت بالایی دارد (۰٫۴۷)؛ شکل آن بیشتر از ساختار مدل می‌آید تا از یادگیری.
- پنجره‌های رخدادهای نزدیک هم‌پوشانی دارند، پس p مقایسه‌ی رخداد با استراحت تقریبی است.
- همه‌ی نتایج برای هر شرکت‌کننده جداگانه است؛ تعمیم به شرکت‌کننده‌ی تازه آزموده نشده است.
- پیش‌بینی برون‌خط است: هر token از کل پنجره‌ی ۸ ثانیه‌ای، از جمله آینده، استفاده می‌کند.
- سقف داده (به‌ویژه برای FD) هر بهبود دیگری را محدود می‌کند.

بازتولید. کد در شاخه‌ی KG-GT-v2 (بسته‌ی v2/ و دفترچه‌ی main_v2.ipynb) است. جدول‌ها و شکل‌های این گزارش را اسکریپت v2-report/build_assets.py از نتایج ذخیره‌شده می‌سازد و هیچ مدلی را اجرا نمی‌کند.

مراجع

[۱] M. D. Luciw, E. Jarocka, B. B. Edin. Multi-channel EEG recordings during 3,936 grasp and lift trials with varying weight and friction. Scientific Data, 1:140047, 2014.

[۲] A. Vaswani et al. Attention is all you need. NeurIPS, 2017.

[۳] P. Veličković et al. Graph attention networks. ICLR, 2018.

[۴] S. Abnar, W. Zuidema. Quantifying attention flow in transformers. ACL, 2020.

[۵] H. Chefer, S. Gur, L. Wolf. Generic attention-model explainability for interpreting bi-modal and encoder-decoder transformers. ICCV, 2021.

[۶] A. Shrikumar, P. Greenside, A. Shcherbina, A. Kundaje. Not just a black box: learning important features through propagating activation differences. arXiv:1605.01713, 2016.

W. Samek, A. Binder, G. Montavon, S. Lapuschkin, K.-R. Müller. Evaluating the visualization of what a deep neural network has learned. IEEE TNNLS, 28(11), 2017. [۷]

J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, B. Kim. Sanity checks for saliency maps. NeurIPS, 2018. [۸]

T. E. Nichols, A. P. Holmes. Nonparametric permutation tests for functional neuroimaging: a primer with examples. Human Brain Mapping, 15(1), 2002. [۹]

L. I. Lin. A concordance correlation coefficient to evaluate reproducibility. Biometrics, 45(1), 1989. [۱۰]