گزارش مدل KG-GT v2:
پیش‌بینی پوش EMG از سینماتیک و EEG با تفسیرپذیری در همه‌ی لایه‌ها

تیم ۶، مدرسه‌ی بین‌رشته‌ای علوم اعصاب محاسباتی

مهر ۱۴۰۵

چکیده

این گزارش دو مدل را مقایسه می‌کند که فعالیت پنج عضله‌ی دست و بازو (پوش EMG) را در داده‌ی WAY-EEG-GAL پیش‌بینی می‌کنند. در این داده ۱۲ نفر بارها جسمی را گرفته و بلند کرده‌اند.

مدل پایه (KG-GT، دفترچه‌ی main_1stage در شاخه‌ی KG-GT-CUDA) یک Transformer روی EEG و یک muscle graph دارد که سینماتیک دست آن را هدایت می‌کند، و فقط یک خروجی می‌دهد. روی سری‌های آزمون به VAF ۷۲٫۲ درصد و همبستگی ۰٫۸۵۱ رسید. اما آزمون‌های حذف ورودی نشان دادند تقریباً همه‌ی این دقت از سینماتیک می‌آید، و با یک خروجی نمی‌توان سهم EEG را جدا کرد.

مدل v2 سه خروجی جدا دارد: K فقط از سینماتیک و تاریخچه‌ی بلندکردن‌ها، E فقط از EEG، و F که K را با یک اصلاح کوچک از EEG جمع می‌کند. K با VAF ۷۵٫۸ درصد و r ۰٫۸۷۲ در هر ۱۲ نفر از مدل پایه بهتر شد. E به‌تنهایی به r ۰٫۶۴۵ رسید و در هر ۱۲ نفر از null test گذشت. F عملاً با K برابر ماند. residual test نشان داد EEG فقط اطلاعات بسیار کمی درباره‌ی خطای K دارد (r حدود ۰٫۰۷، معنادار در ۱۰ نفر از ۱۲) که کمتر از نیم واحد به VAF اضافه می‌کند.

v2 طوری ساخته شد که بتوان هر خروجی را از طریق همه‌ی لایه‌ها تا ورودی دنبال کرد: با attention rollout، attention flow، gradient-weighted rollout و gradient × input. خود این روش‌ها با deletion check و weight-shuffle check سنجیده شدند، یکسانی نقشه‌ها بین ۱۲ نفر اندازه گرفته شد و نتایج با پژوهش‌های پیشین مقایسه شد. نقشه‌ی گروهی EEG کانونی تکرارپذیر روی C3 و CP1 دارد و باند بتا را ترجیح می‌دهد.

فهرست مطالب

۱ داده و هدف پیش‌بینی **۴**

۲ پیش‌پردازش **۴**

۱.۲ داده‌ی خام و تقسیم سری‌ها ۵

۲.۲ مرحله‌ی مشترک: EEG ۵

۳.۲ مرحله‌ی مشترک: EMG و ساختن پوش ۷

۴.۲ مرحله‌ی مشترک: سینماتیک و نیروها ۷

۵.۲ مرحله‌ی ویژه‌ی v2: از cache تا tokens ۸

۶.۲ مقایسه‌ی دو پیش‌پردازش ۱۲

۳ مدل پایه: KG-GT در شاخه‌ی KG-GT-CUDA ۱۲

۱.۳ ورودی‌ها و خروجی . . . ۱۲

۲.۳ معماری . . . ۱۳

۳.۳ loss function . . . ۱۳

۴.۳ آموزش . . . ۱۵

۵.۳ نتایج مدل پایه . . . ۱۵

۴ کاستی‌های مدل پایه ۲۲

۵ چرا v2 ۲۲

۶ مدل v2 ۲۳

۱.۶ ورودی‌ها، tokens و خروجی‌ها . . . ۲۳

۲.۶ بلوک توجه یکسان . . . ۲۴

۳.۶ جریان سینماتیک . . . ۲۶

۴.۶ جریان EEG . . . ۲۶

۵.۶ fusion . . . ۲۷

۶.۶ loss function . . . ۲۷

۷.۶ آموزش . . . ۲۷

۸.۶ پیش‌بینی روی یک سری کامل . . . ۲۸

۷ نتایج ارزیابی v2 ۲۹

۱.۷ دقت K، E و F . . . ۲۹

۲.۷ هر عضله و سقف داده . . . ۳۰

۳.۷ دامنه در هر وزن جسم . . . ۳۲

۴.۷ triptych figures . . . ۳۲

۸ تفسیرپذیری در v2 ۴۱

۱.۸ چه چیزی توضیح داده می‌شود . . . ۴۱

۲.۸ attention rollout و attention flow . . . ۴۱

۳.۸ gradient-weighted rollout . . . ۴۱

۴.۸ نمای هر لایه . . . ۴۲

۵.۸ gradient × input . . . ۴۳

۶.۸ میانگین روی رخدادها و مقایسه با استراحت . . . ۴۳

۷.۸ سنجش خودِ روش‌ها . . . ۴۴

۸.۸ نتایج برای همه‌ی شرکت‌کننده‌ها . . . ۴۴

۹.۸ نتایج P1 و P2: هر شکل چه می‌گوید . . . ۴۵

۹ attention rollout و attention flow ۵۶
۱.۹ نمادها و layered graph . . . ۵۶
۲.۹ attention rollout . . . ۵۶
۳.۹ attention flow . . . ۵۸
۴.۹ پیاده‌سازی . . . ۶۲
۵.۹ چرا attention flow در این مدل به سقف می‌رسد . . . ۶۲
۶.۹ نتایج . . . ۶۳

۱۰ یکسانی نتایج rollout و attention flow بین شرکت‌کننده‌ها ۶۵
۱.۱۰ معیارها . . . ۶۵
۲.۱۰ نقشه‌ی الکترودها . . . ۶۶
۳.۱۰ منحنی‌های زمانی . . . ۶۹
۴.۱۰ muscle graph، باندهای EEG و مقایسه با استراحت . . . ۷۱
۵.۱۰ جمع‌بندی . . . ۷۲

۱۱ مقایسه‌ی نقشه‌های rollout با پژوهش‌های پیشین ۷۳
۱.۱۱ مکان: کدام الکترودها . . . ۷۳
۲.۱۱ فرکانس: کدام باندها . . . ۷۴
۳.۱۱ زمان: پیش یا پس از رخداد . . . ۷۴
۴.۱۱ عضله: کدام عضله‌ها . . . ۷۴
۵.۱۱ تفاوت بین افراد . . . ۷۵
۶.۱۱ مقایسه با Pinto Neto (2026) روی همین داده . . . ۷۵
۷.۱۱ جمع‌بندی و محدودیت‌ها . . . ۷۶

۱۲ residual test: آیا EEG چیزی بیش از سینماتیک دارد؟ ۷۷
۱.۱۲ پرسش . . . ۷۷
۲.۱۲ روش . . . ۷۷
۳.۱۲ یک دام: موقعیت درون پنجره . . . ۷۸
۴.۱۲ نتایج . . . ۷۸
۵.۱۲ بحث . . . ۸۰

۱۳ جمع‌بندی و محدودیت‌ها ۸۰

۱ داده و هدف پیش‌بینی

آزمایش. داده‌ی WAY-EEG-GAL [۱] از یک آزمایش ساده می‌آید. شرکت‌کننده جسمی را با دست راست می‌گیرد، بلند می‌کند، چند ثانیه در هوا نگه می‌دارد و دوباره سر جایش می‌گذارد. این کار چند ده بار پشت سر هم تکرار می‌شود و هر مجموعه از این تکرارها یک «سری» است. وزن جسم (سبک، متوسط یا سنگین) و جنس سطحی که انگشت‌ها لمس می‌کنند بین سری‌ها و گاهی بین دو بلندکردن عوض می‌شود. ۱۲ نفر در آزمایش شرکت کرده‌اند.

در همین مدت چهار نوع سیگنال هم‌زمان ثبت شده است: EEG از سطح سر، EMG از عضله‌های دست و بازو، سینماتیک (وضعیت و حرکت دست) و نیروهایی که به جسم وارد می‌شود.

چه چیزی را پیش‌بینی می‌کنیم. هدف هر دو مدل این گزارش «پوش EMG» پنج عضله است. پوش، منحنی هموار شدت فعالیت عضله است؛ یعنی اینکه عضله در هر لحظه چقدر فعال است، بدون نوسان‌های سریع سیگنال خام. پنج عضله این‌ها هستند: دلتوئید قدامی (AD، جلوی شانه)، براکیورادیالیس (BR، ساعد)، فلکسور انگشتان (FD، بستن انگشت‌ها)، اکستنسور انگشتان (ED، باز کردن انگشت‌ها) و اولین بین‌استخوانی پشتی (FDI، بین شست و اشاره).

پوش از سیگنال خام ۴۰۰۰ هرتز ساخته و به ۵۰۰ هرتز برده می‌شود (بخش ۲). EMG فقط هدف است و هیچ‌جا به‌عنوان ورودی به مدل داده نمی‌شود.

تقسیم داده. سری‌های هر شرکت‌کننده به سه دسته تقسیم می‌شوند: ۶ سری آموزش، ۱ سری validation و ۲ سری آزمون. قاعده‌ی تقسیم در بخش ۲ آمده است. هر دو مدل دقیقاً همین تقسیم را به کار می‌برند. همه‌ی اعداد این گزارش روی سری‌های آزمون است که مدل هرگز در آموزش ندیده.

معیارها. دقت برای هر عضله جدا حساب می‌شود. اگر y پوش واقعی و $\hat{y}$ پیش‌بینی باشد:

$$\mathrm{VAF} = ۱۰۰\left(۱ - \frac{\mathrm{Var}(y-\hat{y})}{\mathrm{Var}(y)}\right), \qquad \mathrm{CCC} = \frac{۲\,\mathrm{Cov}(y,\hat{y})}{\mathrm{Var}(y)+\mathrm{Var}(\hat{y})+(\bar{y}-\bar{\hat{y}})^{۲}}. \tag{۱}$$

VAF می‌گوید چند درصد از تغییرات پوش واقعی را پیش‌بینی توضیح می‌دهد. اگر پیش‌بینی هم در شکل و هم در اندازه درست باشد ۱۰۰ می‌شود. r (Pearson correlation) فقط شکل را می‌سنجد: پیش‌بینی‌ای که دو برابر بزرگ‌تر از واقع باشد ولی هم‌زمان بالا و پایین برود، r برابر ۱ دارد اما VAF پایینی می‌گیرد. CCC مثل r است ولی اختلاف میانگین و اندازه را هم جریمه می‌کند.

«height ratio» یک معیار ساده‌ی دامنه است: میانگین پیش‌بینی تقسیم بر میانگین پوش واقعی، در بازه‌ای که جسم در هوا نگه داشته شده است. عدد ۱ یعنی سطح فعالیت درست پیش‌بینی شده، بیشتر از ۱ یعنی بیش‌برآورد و کمتر از ۱ یعنی کم‌برآورد.

۲ پیش‌پردازش

سیگنال‌های خام را نمی‌توان مستقیم به مدل داد. EEG پر از نویز برق شهر و حرکت چشم است، EMG خام نوسانی سریع حول صفر است و نه شدت فعالیت، و حسگرهای نیرو گاهی نیرویی را ثبت می‌کنند که از دست شرکت‌کننده نیست. پیش‌پردازش این مشکل‌ها را رفع می‌کند و همه‌ی سیگنال‌ها را به شکلی درمی‌آورد که مدل بتواند از آن‌ها یاد بگیرد.

پیش‌پردازش دو مرحله دارد:

۱. **مرحله‌ی مشترک** (شکل ۱): از فایل‌های خام تا سیگنال‌های تمیز ۵۰۰ هرتز. هر دو مدل از خروجی همین مرحله استفاده می‌کنند. نتیجه برای هر سری یک بار ساخته و در یک cache ذخیره می‌شود.

۲. **مرحله‌ی ویژه‌ی v2** (شکل ۲): از cache تا ورودی‌ها و هدف ۵۰ هرتز مدل v2. این مرحله هر بار که v2 داده را بارگذاری می‌کند اجرا می‌شود و چیزی روی دیسک نمی‌نویسد.

۱.۲ داده‌ی خام و تقسیم سری‌ها

برای هر شرکت‌کننده ۹ سری اصلی وجود دارد (فایل‌های HS_P{p}_S{s}.mat). یک سری دیگر هم هست (ST) که در هیچ‌کدام از دو مدل استفاده نمی‌شود. در هر فایل سه نوع سیگنال هست:

- EEG: ۳۲ کانال با ۵۰۰ هرتز؛
- EMG: ۵ عضله با ۴۰۰۰ هرتز؛
- سینماتیک: ۳۶ ستون با ۵۰۰ هرتز، شامل مکان چهار حسگر (جسم، نوک انگشت اشاره، نوک شست و مچ، به سانتی‌متر) و نیروها و گشتاورهای دو صفحه‌ی نیروسنج روی جسم.

سری‌ها سه نوع‌اند: ۵ سری که فقط وزن جسم در آن‌ها عوض می‌شود (W)، ۲ سری که فقط جنس سطح عوض می‌شود (S) و ۲ سری که هر دو عوض می‌شوند (B). سری‌های ۷ تا ۹ همیشه از نوع W هستند. تقسیم برای هر شرکت‌کننده با یک قاعده‌ی ثابت انجام می‌شود:

- **آزمون (۲ سری):** دومین سری W از میان سری‌های ۱ تا ۶ و دومین سری B؛
- **validation (۱ سری):** سری ۹؛
- **آموزش (۶ سری):** بقیه، یعنی اولین W از ۱ تا ۶، سری‌های ۷ و ۸، هر دو سری S و اولین B.

با این قاعده، آزمون هم سری‌ای دارد که فقط وزن در آن عوض می‌شود و هم سری‌ای که وزن و سطح هر دو عوض می‌شوند، و آموزش از هر سه نوع نمونه دارد. یک قاعده‌ی مهم در همه‌ی مراحل: هر آماره‌ای که برای نرمال کردن لازم است (میانگین، انحراف معیار، صدک ۹۵) فقط از سری‌های آموزش حساب می‌شود. اگر از سری‌های آزمون هم استفاده می‌شد، اطلاعات آزمون به آموزش نشت می‌کرد.

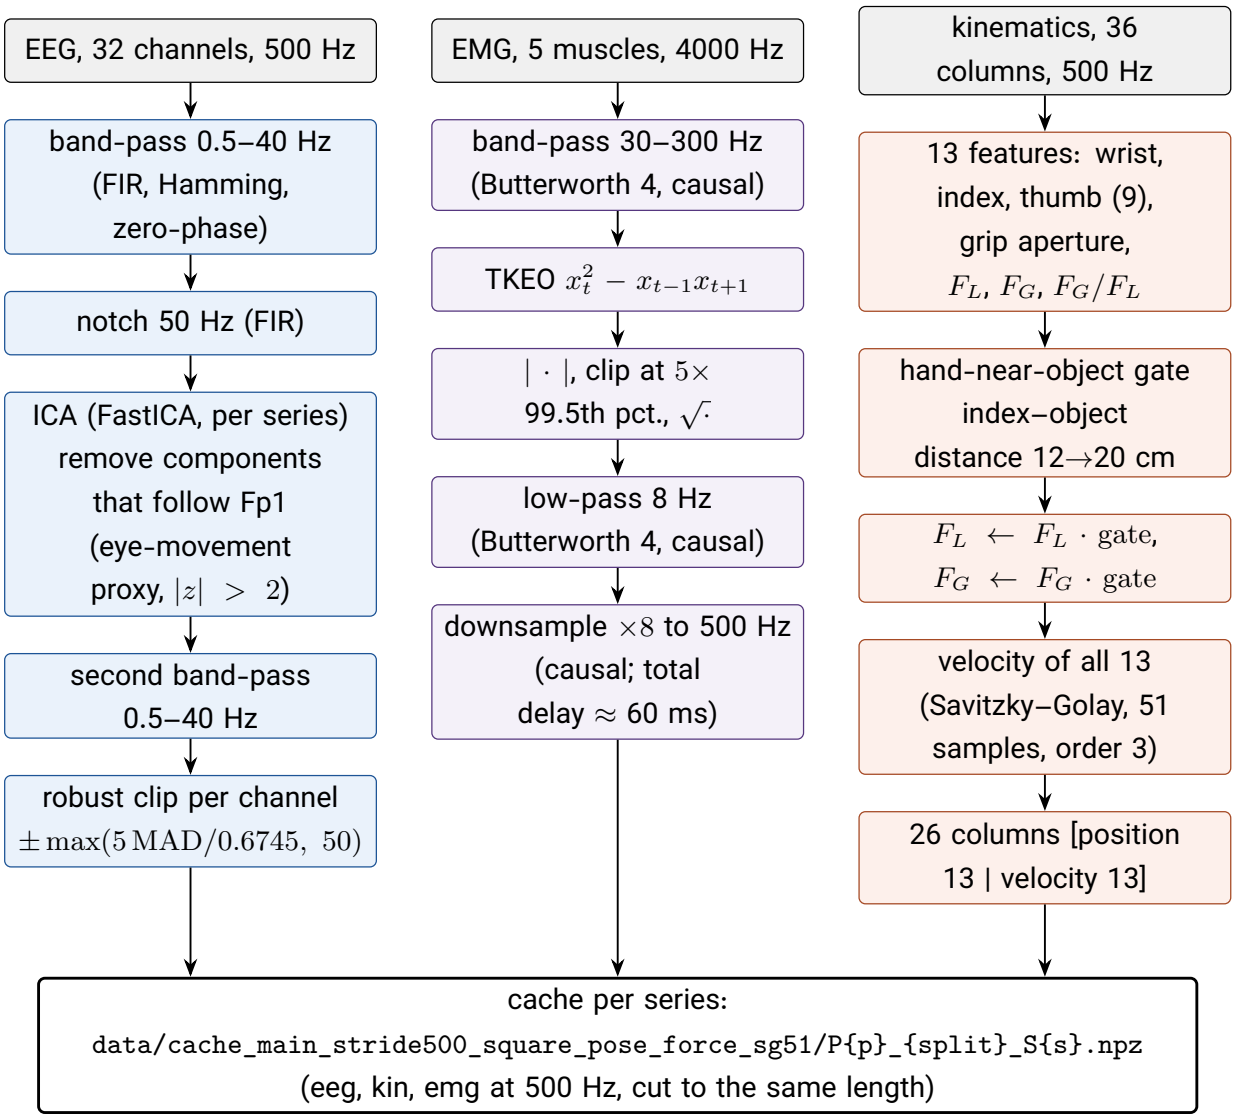
۲.۲ مرحله‌ی مشترک: EEG

پنج گام، به همین ترتیب، روی کل سری:

۱. **band-pass ۰٫۵ تا ۴۰ هرتز** (فیلتر FIR با پنجره‌ی همینگ، بدون جابه‌جایی زمانی). زیر ۰٫۵ هرتز بیشتر رانش آرام الکترودها و تعریق است و بالای ۴۰ هرتز بیشتر فعالیت عضلات سر و نویز. فعالیت مغزی مرتبط با حرکت (تتا تا گامای پایین) در همین بازه است.

۲. **notch ۵۰ هرتز** (FIR) برای حذف برق شهر.

۳. **حذف artifact با ICA.** ICA سیگنال ۳۲ کانال را به مؤلفه‌هایی تجزیه می‌کند که از نظر آماری مستقل‌اند. مؤلفه‌هایی که از منبع غیرمغزی می‌آیند حذف و سیگنال دوباره ساخته می‌شود. روش FastICA است، برای هر سری جداگانه، با seed ثابت ۴۲ و حداکثر ۲۰۰ تکرار. این داده کانال جداگانه‌ای برای حرکت چشم (EOG) ندارد. برای همین Fp1، که بالای چشم چپ است و پلک زدن را بیشتر از همه ثبت می‌کند، جای کانال چشم را می‌گیرد. هر مؤلفه‌ای که همبستگی‌اش با Fp1 به‌طور غیرعادی بالا باشد (z-score بیشتر از ۲) حذف می‌شود.



شکل ۱: مرحله‌ی مشترک پیش‌پردازش، از فایل خام تا cache ۵۰۰ هرتز. چپ: EEG. وسط: EMG که پوش آن هدف پیش‌بینی است. راست: سینماتیک و نیروها. همه‌ی گام‌ها روی کل سری انجام می‌شوند، نه روی پنجره‌ها.

۴. **band-pass دوم ۰٫۵ تا ۴۰ هرتز.** همان فیلتر گام ۱ یک بار دیگر اجرا می‌شود (در کد نامش «delta» است، اما بازه‌اش ۰٫۵ تا ۴۰ هرتز تنظیم شده). این کار هر چیزی را که ICA بیرون از این بازه به سیگنال برگردانده پاک می‌کند.

۵. **بریدن مقادیر بسیار بزرگ.** برای هر کانال یک آستانه حساب می‌شود: $\max(۵\,\mathrm{MAD}/۰٫۶۷۴۵,\ ۵۰\,\mu V)$. MAD میانه‌ی قدرمطلق فاصله از میانه است و $\mathrm{MAD}/۰٫۶۷۴۵$ تخمینی از انحراف معیار است که پرت‌ها رویش اثر ندارند. هر مقداری بیرون از $\pm$ آستانه به خود آستانه بریده می‌شود. این کار جهش‌های کوتاه و بزرگ (مثلاً از حرکت سیم) را محدود می‌کند، بدون اینکه بقیه‌ی سیگنال تغییر کند.

مرجع مشترک (CAR) اعمال نمی‌شود و سیگنال با همان مرجع ثبت باقی می‌ماند.

چه چیزی ممکن است باقی بماند. ICA با این روش بیشتر پلک و حرکت چشم را حذف می‌کند. فعالیت عضلات سر و گردن که در فرکانس‌های بالاتر است، و حرکت چشمی که با Fp1 همبستگی کمی دارد، ممکن است باقی بمانند. این همان هشداری است که در فصل‌های تفسیر درباره‌ی سهم الکترودهای پیشانی و پس‌سری و باند گامای پایین آمده است.

۳.۲ مرحله‌ی مشترک: EMG و ساختن پوش

هدف هر دو مدل پوش EMG است: منحنی آرامی که نشان می‌دهد عضله در هر لحظه چقدر فعال است. پنج گام:

۱. **band-pass ۳۰ تا ۳۰۰ هرتز** (Butterworth مرتبه‌ی ۴). زیر ۳۰ هرتز بیشتر artifact حرکت کابل و پوست است و بالای ۳۰۰ هرتز نویز.

۲. **TKEO:** $\psi_t = x_t^۲ - x_{t-۱}x_{t+۱}$. این عملگر «انرژی» لحظه‌ای سیگنال را می‌دهد. برای نوسان‌های سریع و بزرگ (فعالیت عضله) بزرگ است و برای نویز آرام کوچک؛ برای همین شروع فعالیت را تیزتر از یکسوسازی ساده نشان می‌دهد.

۳. **قدرمطلق، بریدن و جذر.** قدرمطلق گرفته می‌شود و هر مقدار بیشتر از ۵ برابر صدک ۹۹٫۵ همان کانال به این حد بریده می‌شود، تا چند جهش نادر بقیه‌ی سیگنال را کوچک نکنند. سپس جذر گرفته می‌شود، چون TKEO واحد توان دارد و جذر آن را به واحد دامنه برمی‌گرداند.

۴. **low-pass ۸ هرتز** (Butterworth مرتبه‌ی ۴). نوسان‌های سریع حذف می‌شوند و فقط پوش آرام می‌ماند.

۵. **کاهش نرخ از ۴۰۰۰ به ۵۰۰ هرتز** (ضریب ۸، با فیلتر ضدتداخل)، تا با EEG و سینماتیک هم‌نرخ شود.

تأخیر پوش. همه‌ی فیلترهای EMG علّی‌اند؛ یعنی فقط از گذشته استفاده می‌کنند و هیچ‌وقت از آینده‌ی سیگنال خبر ندارند. بهای این کار تأخیر است: پوش حدود ۶۰ میلی‌ثانیه دیرتر از فعالیت واقعی عضله بالا و پایین می‌رود. بیشتر این تأخیر از low-pass است (۵۲ تا ۶۵ میلی‌ثانیه، بسته به فرکانس) و حدود ۵ میلی‌ثانیه از کاهش نرخ. در مقابل، فیلترهای EEG و سینماتیک بدون تأخیرند. پس هدف کمی عقب‌تر از ورودی‌هاست. مدل پایه این را با تأخیر آموختنی خودش جبران می‌کند، و v2 با دیدن ۸ ثانیه بافت می‌تواند ورودی‌های کمی قبل‌تر را هم به کار ببرد.

۴.۲ مرحله‌ی مشترک: سینماتیک و نیروها

سیزده ویژگی. از ۳۶ ستون خام، ۱۳ ویژگی ساخته می‌شود:

- مکان سه‌بعدی مچ، نوک انگشت اشاره و نوک شست (۹ ویژگی، سانتی‌متر)؛
- دهانه‌ی گرفتن: فاصله‌ی نوک اشاره تا نوک شست (۱ ویژگی)؛
- نیروی بار F_L: اندازه‌ی بردار نیروی سه‌بعدی صفحه‌ی اول، $\sqrt{F_x^2 + F_y^2 + F_z^2}$؛
- نیروی گرفتن F_G: میانگین قدرمطلق نیروی عمودی بر دو صفحه، $(|F_{z1}| + |F_{z2}|)/2$؛
- نسبت $F_G/(F_L + 1)$.

ده ویژگی اول «وضعیت دست» را توصیف می‌کنند و سه ویژگی آخر نیروها را.

gate نزدیکی دست به جسم. بین دو بلندکردن، آزمایشگر جسم را جابه‌جا یا سطح آن را عوض می‌کند و صفحه‌های نیروسنج این را هم ثبت می‌کنند. در P1، در سری‌هایی که سطح عوض می‌شود، صفحه‌ها در حدود ۱۹ درصد زمان سری بار ۲ تا ۵ نیوتنی دارند، در حالی که دست شرکت‌کننده حدود ۲۸ سانتی‌متر دورتر است و عضله‌ها در استراحت‌اند. اگر این نیرو به مدل داده شود، مدل در استراحت جهش EMG پیش‌بینی می‌کند.

راه حل یک gate است که از فاصله‌ی نوک انگشت اشاره تا جسم ساخته می‌شود. این فاصله دو حالت روشن دارد: حدود ۱۰٫۵ سانتی‌متر وقتی جسم در دست است و حدود ۲۸ سانتی‌متر وقتی دست کنار است. gate تا فاصله‌ی ۱۲ سانتی‌متر برابر ۱ است، تا ۲۰ سانتی‌متر به‌طور خطی به صفر می‌رسد و بعد از آن صفر است. اگر حسگر مکان را گم کرده باشد، gate صفر در نظر گرفته می‌شود. سپس gate با پنجره‌ی ۰٫۱ ثانیه نرم می‌شود: اول بیشینه‌ی متحرک، بعد میانگین متحرک، هر دو متقارن. ترتیب این دو مهم است: بیشینه‌ی متحرک تضمین می‌کند که نرم کردن هیچ‌وقت gate را در ناحیه‌ی نزدیک کمتر از ۱ نکند، حتی وقتی دست سریع به جسم می‌رسد. در آخر F_L و F_G در gate ضرب می‌شوند.

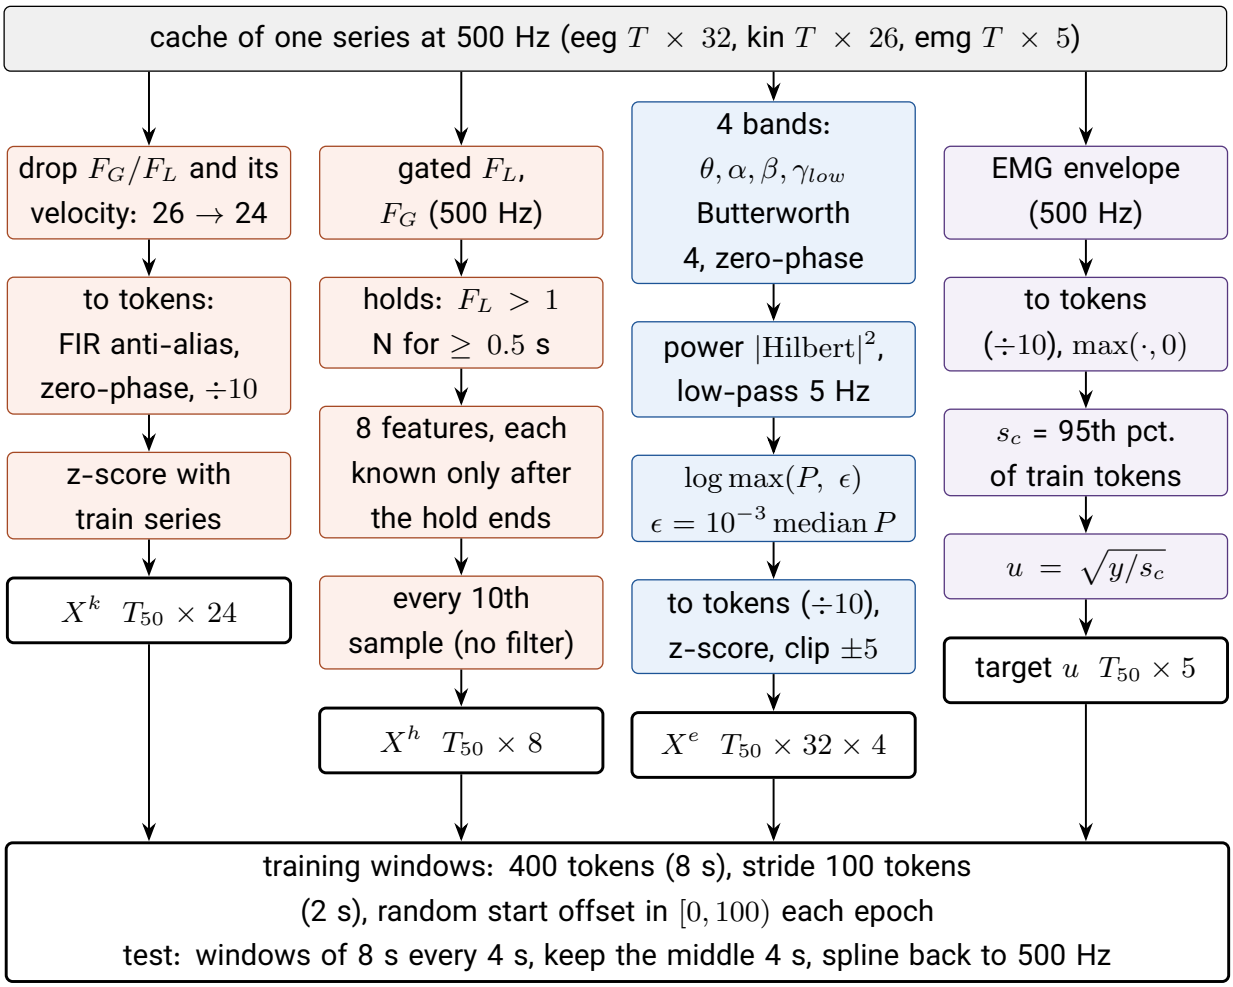
سرعت. سرعت هر ۱۳ ویژگی با مشتق اول فیلتر Savitzky-Golay حساب می‌شود (پنجره‌ی ۵۱ نمونه یعنی ۱۰۲ میلی‌ثانیه، چندجمله‌ای مرتبه‌ی ۳). این فیلتر در هر پنجره یک چندجمله‌ای برازش می‌کند و مشتق آن را می‌گیرد، که بسیار کم‌نویزتر از تفاضل ساده‌ی دو نمونه است. پنجره‌ی ۵۱ نمونه‌ای لرزش حسگر را در زمان استراحت کم می‌کند. سرعت نیروها بعد از اعمال gate حساب می‌شود، پس وقتی دست دور است سرعت نیرو هم صفر است. شتاب حساب نمی‌شود، چون مشتق دوم لرزش حسگر را بسیار بزرگ می‌کند.

نتیجه ۲۶ ستون است: ۱۳ ویژگی و ۱۳ سرعت. هر دو مدل نسبت نیروها و سرعتش را کنار می‌گذارند و ۲۴ ویژگی باقی می‌ماند: وضعیت دست (۱۰)، دو نیروی gated، سرعت وضعیت دست (۱۰) و سرعت دو نیرو.

cache. برای هر سری، سه سیگنال ۵۰۰ هرتز به طول کوتاه‌ترینشان بریده و در پوشه‌ی cache ذخیره می‌شوند (data/cache_main_stride500_square_pose_force_sg51). v2 فقط این فایل‌ها را می‌خواند و خودش هیچ‌کدام از گام‌های بالا را دوباره اجرا نمی‌کند. پس دو مدل دقیقاً از یک داده‌ی تمیزشده شروع می‌کنند و تفاوت نتایج از مدل‌هاست، نه از پیش‌پردازش.

۵.۲ مرحله‌ی ویژه‌ی v2: از cache تا tokens

شکل ۲ این مرحله را نشان می‌دهد. یک اصل در همه‌ی گام‌ها رعایت می‌شود: هر فیلتری اول روی کل سری با ۵۰۰ هرتز اجرا می‌شود و بعد نرخ کم می‌شود. فیلترها برای کار درست به سیگنال طولانی نیاز دارند؛ اگر روی پنجره‌های کوتاه اجرا شوند، لبه‌های هر پنجره خراب می‌شود.



شکل ۲: مرحله‌ی ویژه‌ی v2، از cache ۵۰۰ هرتز تا ورودی‌ها و هدف ۵۰ هرتز. از چپ: سینماتیک، تاریخچه‌ی بلندکردن‌ها (فقط از نیروهای gated)، EEG band power و هدف EMG. کادر پایین: ساختن پنجره‌های آموزش و پیش‌بینی روی سری آزمون.

۱. تبدیل به tokens (کاهش نرخ از ۵۰۰ به ۵۰ هرتز)

اگر فقط هر دهمین نمونه را برداریم، نوسان‌های بالای ۲۵ هرتز (نصف نرخ جدید) از بین نمی‌روند و به شکل نوسان‌های آرام جعلی در سیگنال جدید ظاهر می‌شوند (aliasing). برای همین اول یک فیلتر ضدتداخل اجرا می‌شود: فیلتر FIR با ۲۰۱ ضریب (scipy.signal.decimate)، رفت و برگشتی تا سیگنال در زمان جابه‌جا نشود. token شماره‌ی k دقیقاً روی نمونه‌ی $10k$ قرار می‌گیرد.

یک مشکل در لبه‌ها هست: این فیلتر بیرون سری را صفر فرض می‌کند، پس اولین و آخرین tokens تا حدود نصف مقدار واقعی‌شان به سمت صفر کشیده می‌شوند. برای رفع آن، سری پیش از فیلتر در هر دو سر ۱۰۰ نمونه با «بازتاب فرد» ادامه داده می‌شود: $x_{-i} = 2x_0 - x_i$. با این بازتاب، سیگنال ثابت ثابت می‌ماند و سیگنالی که خطی بالا می‌رود همچنان خطی ادامه پیدا می‌کند. پس از فیلتر، بخش اضافه دوباره بریده می‌شود. سری باید دست‌کم ۷۰۰ نمونه داشته باشد تا این فیلتر کار کند.

۲. سینماتیک

۲۴ ستون سینماتیک (بعد از کنار گذاشتن نسبت نیروها) به tokens تبدیل می‌شوند. سپس هر ویژگی با میانگین و انحراف معیار tokens سری‌های آموزش استاندارد می‌شود (z-score). این ویژگی‌ها بریده نمی‌شوند، چون gate و فیلترهای مرحله‌ی مشترک مقادیر پرت آن‌ها را از قبل گرفته‌اند. نتیجه $X^k \in \mathbb{R}^{T\times 24}$ است.

۳. تاریخچه‌ی بلندکردن‌ها

این ویژگی‌ها فقط از دو نیروی gated و با نرخ ۵۰۰ هرتز ساخته می‌شوند؛ EMG هیچ نقشی در آن‌ها ندارد.

پیدا کردن نگه‌داشتن‌ها. یک «نگه‌داشتن» بازه‌ای پیوسته است که در آن F_L بیشتر از ۱ نیوتن است و دست‌کم ۰٫۵ ثانیه طول می‌کشد. چون F_L gated است، نیرویی که آزمایشگر وارد می‌کند نگه‌داشتن حساب نمی‌شود.

بدون نگاه به آینده. مدل فقط وقتی از یک نگه‌داشتن خبردار می‌شود که آن نگه‌داشتن تمام شده باشد. همه‌ی ویژگی‌های مربوط به نگه‌داشتن k از نمونه‌ی پایان آن به بعد مقدار می‌گیرند. پس مقدار هر ویژگی در زمان t فقط به نمونه‌های تا t بستگی دارد.

هشت ویژگی. ویژگی‌ها با عددهای ثابت مقیاس می‌شوند، نه با z-score، تا معنای هر عدد روشن بماند و مقدارها تقریباً بین ۰ و ۱ باشند:

	ویژگی	مقیاس
۱	آیا تا اینجا نگه‌داشتنی بوده است	۰ یا ۱
۲	تعداد نگه‌داشتن‌ها تا اینجا	تقسیم بر ۴۰
۳	زمان از شروع سری	تقسیم بر ۳۰۰ ثانیه
۴	زمان از پایان آخرین نگه‌داشتن	حداکثر ۳۰ ثانیه، تقسیم بر ۳۰
۵ و ۶	میانگین F_L و F_G در آخرین نگه‌داشتن	تقسیم بر ۱۰ نیوتن
۷ و ۸	میانگین F_L و F_G در همه‌ی نگه‌داشتن‌های قبلی	تقسیم بر ۱۰ نیوتن

ویژگی ۳ از ابتدای سری مقدار دارد و بقیه تا پایان اولین نگه‌داشتن صفرند.

تبدیل به tokens بدون فیلتر. این ویژگی‌ها پله‌ای‌اند: تا پایان یک نگه‌داشتن ثابت می‌مانند و ناگهان عوض می‌شوند. برای همین از هر ۱۰ نمونه فقط یکی برداشته می‌شود و فیلتر ضدتداخل اجرا نمی‌شود. فیلتر رفت و برگشتی، پله را در هر دو طرف پخش می‌کند و تغییر را چند token زودتر از پایان واقعی نگه‌داشتن نشان می‌دهد؛ یعنی کمی از آینده به مدل خبر می‌دهد. نتیجه $X^h \in \mathbb{R}^{T\times 8}$ است.

همین شماره‌گذاری نگه‌داشتن‌ها برای هر نمونه هم نگه داشته و به همین روش به tokens تبدیل می‌شود. جزء lift در loss function از آن استفاده می‌کند تا میانگین پیش‌بینی و هدف را در هر نگه‌داشتن مقایسه کند.

۴. EEG band power

v2 به‌جای موج خام EEG، توان آن را در چهار باند می‌بیند. موج خام ۰٫۵ تا ۴۰ هرتز تقریباً هیچ اطلاعات خطی درباره‌ی پوش EMG ندارد، اما تغییرهای آرام توان باندها دارد؛ مثلاً کاهش توان بتا روی قشر حرکتی پیش از حرکت (ERD). برای هر باند تتا (۴ تا ۸)، آلفا (۸ تا ۱۳)، بتا (۱۳ تا ۳۰) و گامای پایین (۳۰ تا ۴۰ هرتز)، و برای هر الکترود، روی کل سری:

۱. **جدا کردن باند:** Butterworth band-pass مرتبه‌ی ۴، رفت و برگشتی.

۲. **توان لحظه‌ای:** مجذور دامنه‌ی سیگنال تحلیلی، $P_t = |\mathcal{H}(x)_t|^2$ (تبدیل هیلبرت). این عدد اندازه‌ی نوسان را در هر لحظه می‌دهد، مستقل از اینکه موج در آن لحظه در قله باشد یا در صفر.

۳. **نرم کردن:** low-pass ۵ هرتز. فیلتر مرتبه‌ی ۱ است و رفت و برگشتی اجرا می‌شود، طوری طراحی شده که کل فیلتر دقیقاً در ۵ هرتز ۳- دسی‌بل کاهش بدهد. مرتبه‌ی ۱ عمداً انتخاب شده: پاسخ ضربه‌ی آن همیشه مثبت است، پس توان نرم‌شده هیچ‌وقت منفی نمی‌شود. با مرتبه‌ی ۴، توان نرم‌شده در ۰٫۳ تا ۲٫۴ درصد نمونه‌ها منفی می‌شد و بعد از log جهش‌های بزرگ می‌ساخت.

۴. **لگاریتم با کف:** $\log \max(P,\ 10^{-3} \cdot \operatorname{median} P)$، که میانه برای هر الکترود و باند جداگانه روی کل سری حساب می‌شود. توان توزیع بسیار کجی دارد و لگاریتم آن را متقارن‌تر می‌کند؛ علاوه بر این، تغییر نسبی توان (مثلاً «۲۰ درصد کاهش») در لگاریتم به یک اختلاف ثابت تبدیل می‌شود. کف نمی‌گذارد یک لحظه‌ی تقریباً بی‌سیگنال، بعد از لگاریتم به عدد منفی بسیار بزرگ تبدیل شود.

نتیجه برای هر لحظه یک جدول 4×32 است. این جدول به tokens تبدیل می‌شود، هر یک از ۱۲۸ خانه‌ی آن با آماره‌های tokens آموزش استاندارد می‌شود و مقادیر بیرون از ± 5 انحراف معیار بریده می‌شوند. بریدن جلوی اثر چند لحظه‌ی artifact باقی‌مانده را می‌گیرد. نتیجه $X^e \in \mathbb{R}^{T \times 32 \times 4}$ است و الکترودها به همان ترتیب hs.eeg.names می‌مانند تا electrode graph بتواند فاصله‌ی آن‌ها روی سر را بداند.

۵. هدف

پوش ۵۰۰ هرتز EMG با همان روش به tokens تبدیل می‌شود. فیلتر ضدتداخل گاهی کنار جهش‌های تیز مقدار کمی زیر صفر می‌سازد؛ این مقادیر صفر می‌شوند، چون شدت فعالیت نمی‌تواند منفی باشد. برای هر عضله s_c برابر صدک ۹۵ tokens آموزش است، و هدف مدل $u = \sqrt{y / s_c}$ است (بخش ۶). تقسیم بر s_c پنج عضله را هم‌مقیاس می‌کند، چون دامنه‌ی خام EMG از عضله‌ای به عضله‌ی دیگر بسیار فرق دارد.

ارزیابی روی این هدف ۵۰ هرتز انجام نمی‌شود. پیش‌بینی با درون‌یابی اسپلاین به ۵۰۰ هرتز برمی‌گردد، به واحد اصلی تبدیل می‌شود ($\hat{y} = s_c \hat{u}^2$) و با پوش اصلی ۵۰۰ هرتز مقایسه می‌شود. پس هر خطایی که کاهش نرخ ایجاد کند در اعداد گزارش‌شده هم دیده می‌شود.

۶. پنجره‌ها

ورودی‌ها برای هر سری یک بار و کامل نرمال می‌شوند و بعد پنجره‌ها از آن بریده می‌شوند. پس همه‌ی پنجره‌های یک سری با یک مقیاس نرمال شده‌اند.

- **آموزش:** پنجره‌های ۴۰۰ token (۸ ثانیه) با فاصله‌ی ۱۰۰ token (۲ ثانیه)، که هر دو پنجره‌ی پشت سر هم ۶ ثانیه هم‌پوشانی دارند. در هر دوره، نقطه‌ی شروع اولین پنجره به‌طور تصادفی بین ۰ و ۹۹ token انتخاب می‌شود. بنابراین مدل در هر دوره برش‌های کمی متفاوتی از داده می‌بیند و لبه‌ی پنجره‌ها همیشه روی یک لحظه‌ی ثابت از سری نمی‌افتد.
- **validation و آزمون:** پنجره‌های ۸ ثانیه‌ای هر ۴ ثانیه، با نگه داشتن ۴ ثانیه‌ی وسط هر پنجره (شکل ۱۰).

۶.۲ مقایسه‌ی دو پیش‌پردازش

جدول ۱: تفاوت پیش‌پردازش مدل پایه و v2. مرحله‌ی مشترک (تا cache) در هر دو یکسان است.

	مدل پایه	v2
نرخ ورودی مدل	۵۰۰ هرتز	۵۰ هرتز (tokens، با فیلتر ضدتداخل)
طول پنجره	۱ ثانیه، بدون هم‌پوشانی	۸ ثانیه، با فاصله‌ی ۲ ثانیه و شروع تصادفی
EEG	موج زمانی ۰٫۵ تا ۴۰ هرتز، ۳۲ کانال، بدون نرمال‌سازی بیشتر	لگاریتم band power در ۴ باند، ۴×۳۲
سینماتیک	۲۴ ویژگی، z-score	همان ۲۴ ویژگی، z-score پس از کاهش نرخ
تاریخچه	ندارد	۸ ویژگی از نیروهای gated، بدون نگاه به آینده
هدف	پوش، z-score با میانگین و انحراف معیار آموزش	$\sqrt{y/s_c}$ با s_c صدک ۹۵ آموزش
بریدن	–	EEG در ± ۵؛ هدف در صفر از پایین
ارزیابی	روی پنجره‌های ۱ ثانیه‌ای	روی کل سری، پس از برگرداندن به ۵۰۰ هرتز

جدول ۱ تفاوت‌ها را خلاصه می‌کند. همه‌ی تصمیم‌های v2 در این مرحله یکی از سه هدف را دنبال می‌کنند: دیدن بافت طولانی‌تر با هزینه‌ی کم (۵۰ tokens هرتز)، دادن اطلاعاتی به مدل که سینماتیک لحظه‌ای ندارد (تاریخچه و band power)، و جلوگیری از نشت اطلاعات (آماره‌ها فقط از آموزش، تاریخچه فقط از گذشته، تاریخچه بدون فیلتر).

۳ مدل پایه: KG-GT در شاخه‌ی KG-GT-CUDA

مدل پایه همان مدلی است که دفترچه‌ی main_1stage.ipynb در شاخه‌ی KG-GT-CUDA آموزش می‌دهد. نامش کوتاه‌شده‌ی Kinematics-Guided Graph Transformer است: یک Transformer روی EEG و یک گراف بین عضله‌ها که سینماتیک آن را هدایت می‌کند. همه‌ی اجزای مدل با هم و در یک مرحله آموزش می‌بینند.

۱.۳ ورودی‌ها و خروجی

EEG. ۳۲ کانال با نرخ ۵۰۰ هرتز، پس از پیش‌پردازش مشترک (band-pass ۰٫۵ تا ۴۰ هرتز، notch ۵۰ هرتز، ICA؛ بخش ۲). خودِ موج در حوزه‌ی زمان به مدل داده می‌شود، نه band power آن.

سینماتیک. ۲۴ ویژگی با نرخ ۵۰۰ هرتز:

- ۱۰ ویژگی وضعیت دست؛
- نیروی بار (F_L، نیروی رو به بالا) و نیروی گرفتن (F_G، فشار انگشت‌ها)؛
- سرعت همه‌ی این ۱۲ ویژگی.

دو نیرو پیش از ورود در یک «gate نزدیکی» ضرب می‌شوند تا نیرویی که آزمایشگر بین دو بلندکردن وارد می‌کند به مدل نرسد. سرعت‌ها با فیلتر Savitzky-Golay حساب می‌شوند. جزئیات هر دو در بخش ۲ آمده است. همه‌ی ویژگی‌ها با میانگین و انحراف معیار سری‌های آموزش استاندارد می‌شوند.

پنجره. مدل هر بار یک ثانیه (۵۰۰ نمونه) را می‌بیند و پنجره‌ها هم‌پوشانی ندارند. هدف پوش EMG است که با میانگین و انحراف معیار آموزش استاندارد شده (z-score)، و خروجی در پایان به واحد اصلی برمی‌گردد.

۲.۳ معماری

شکل ۳ مسیر داده را نشان می‌دهد. به زبان ساده: EEG از یک Transformer می‌گذرد، نتیجه به پنج «گره» (یکی برای هر عضله) تبدیل می‌شود، گره‌ها در یک گراف با هم پیام رد و بدل می‌کنند و در آخر هر گره به پوش عضله‌ی خودش تبدیل می‌شود. سینماتیک از دو راه وارد می‌شود: یکی تعیین می‌کند کدام عضله‌ها در گراف بیشتر به هم گوش دهند، و دیگری مستقیم به گره‌ها اضافه می‌شود.

با نماد $X^e \in \mathbb{R}^{T\times ۳۲}$ برای EEG و $X^k \in \mathbb{R}^{T\times ۲۴}$ برای سینماتیک ($T = ۵۰۰$ نمونه) گام‌ها این‌هاست:

۱. **temporal encoder.** یک Transformer با ۴ لایه، ۸ سر توجه، عرض $d = ۱۲۸$ و شبکه‌ی feed-forward ۵۱۲. توجه درون تکه‌های ۵۰۰ نمونه‌ای انجام می‌شود و sinusoidal positional encoding جای هر نمونه را به مدل می‌گوید. خروجی: $H = \mathrm{Enc}(X^e) \in \mathbb{R}^{T\times ۱۲۸}$.

۲. **ساختن گره‌های عضله.** یک لایه‌ی خطی، H را در هر لحظه به پنج بردار ۶۴ بعدی تبدیل می‌کند، یکی برای هر عضله: $N_t \in \mathbb{R}^{۵\times ۶۴}$.

۳. **muscle graph با هدایت سینماتیک.** یک لایه‌ی graph attention (GAT [۳]) با ۴ سر بین پنج گره. هر گره تصمیم می‌گیرد از گره‌های دیگر چقدر اطلاعات بگیرد. امتیاز یال $j \to i$ در سر h و زمان t از سه بخش ساخته می‌شود:

$$s^h_{ij}(t) = \underbrace{\frac{q^h_i(t)\cdot k^h_j(t)}{\sqrt{d_k}}}_{\text{content}} + \underbrace{B^h_{ij}}_{\text{static}} + \underbrace{\big[Wx^g(t)+b\big]^h_{ij}}_{\text{kinematics}}. \qquad (۲)$$

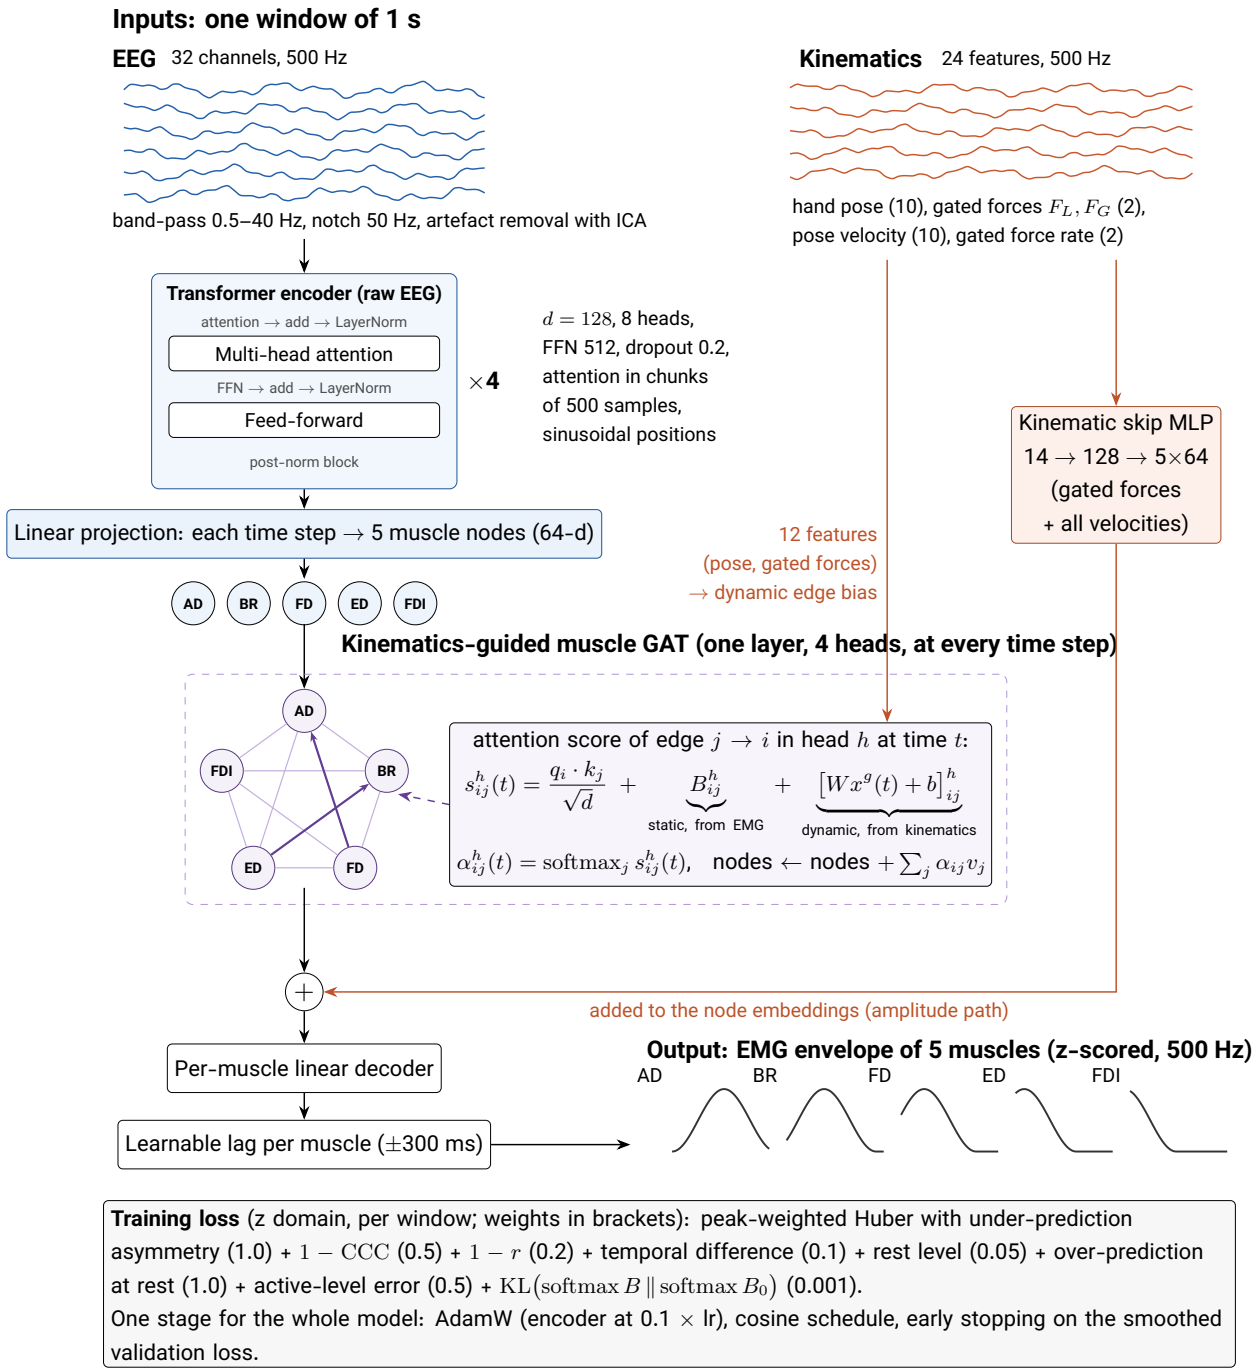
بخش اول توجه معمولی است و به محتوای دو گره بستگی دارد. بخش دوم، B، یک bias ثابت برای هر یال است که مقدار اولیه‌اش از همبستگی EMG عضله‌ها در داده‌ی آموزش می‌آید. بخش سوم از سینماتیک می‌آید: دوازده ویژگی اول (x^g، یعنی وضعیت دست و دو نیرو) با یک لایه‌ی خطی به یک bias تبدیل می‌شوند که در هر لحظه عوض می‌شود.

۴. **kinematic skip highway.** ۱۴ ویژگی سینماتیک (دو نیرو و ۱۲ سرعت) از یک شبکه‌ی کوچک (خطی، LayerNorm، GELU، خطی) می‌گذرند و مستقیم به گره‌ها اضافه می‌شوند: $Z_t = \mathrm{GAT}(N_t, x^g_t) + \mathrm{MLP}(x^s_t)$. این «میان‌بر» به سینماتیک اجازه می‌دهد بدون گذشتن از گراف به خروجی برسد.

۵. **decoder و تأخیر.** یک لایه‌ی خطی برای هر عضله، Z_t را به یک عدد تبدیل می‌کند. سپس یک تأخیر آموختنی برای هر عضله (تا ± ۳۰۰ میلی‌ثانیه) خروجی را در زمان جابه‌جا می‌کند، چون فعالیت عضله کمی با حرکت فاصله‌ی زمانی دارد.

۳.۳ loss function

loss function عددی است که آموزش سعی می‌کند کوچکش کند؛ هر جزء آن یک نوع خطا را جریمه می‌کند. در مدل پایه این عدد هشت جزء دارد و روی هر پنجره در حوزه‌ی استانداردشده (z) حساب می‌شود. نمادها: y_{tc} هدف



شکل ۳: نمای کلی مدل پایه KG-GT از ورودی تا خروجی. پنجره‌ی یک‌ثانیه‌ای EEG از Transformer encoder (چهار بلوک توجه و feed-forward) می‌گذرد، هر لحظه به پنج گره‌ی عضله تبدیل می‌شود و یک لایه‌ی graph attention بین عضله‌ها پیام جابه‌جا می‌کند. سینماتیک از دو راه وارد می‌شود: دوازده ویژگی امتیاز یال‌های گراف را تغییر می‌دهند (خط نارنجی) و چهارده ویژگی از یک میان‌بر مستقیم به گره‌ها اضافه می‌شوند. decoder هر عضله و تأخیر آموختنی پوش EMG را می‌سازند. کادر پایین هشت جزء loss function را با وزن‌هایشان نشان می‌دهد.

و $\hat{y}_{tc}$ پیش‌بینی در زمان t برای عضله‌ی c، و $u_{tc} = (y_{tc} - \min_t y)/(\max_t y - \min_t y)$ که می‌گوید هر نقطه در آن پنجره چقدر به قله نزدیک است (۰ در کمینه، ۱ در قله).

- **خطای قله‌ها** (وزن ۱٫۰). خطای اصلی، با این تفاوت که نزدیک قله‌ها گران‌تر است و کم‌برآوردی در قله از بیش‌برآوردی گران‌تر: $L_{peak} = \text{mean}\left[w_c\,(1+\alpha u^2)\,(1+(a-1)\,\mathbb{I}[\hat{y}<y]\,u)\,\rho_\delta(\hat{y}-y)\right]$. اینجا $\alpha = 3$ وزن اضافه‌ی قله است، $a = 1.5$ ضریب گرانیِ کم‌برآوردی، ρ_δ دو برابر تابع هوبر با $\delta = 2.5$ و w_c وزن هر عضله (عکس صدک ۹۵ هدف، با میانگین ۱).
- **CCC** (وزن ۰٫۵): $L_{ccc} = 1 - \text{CCC}$ برای هر پنجره و عضله.
- **Pearson correlation** (وزن ۰٫۲): $L_r = 1 - r$.
- **شیب** (وزن ۰٫۱): اختلاف تغییر لحظه‌به‌لحظه‌ی پیش‌بینی و هدف، تا بالا و پایین رفتن‌ها هم‌زمان باشند.
- **استراحت** (وزن ۰٫۰۵): $L_{rest} = \text{mean}\left[m\,|\hat{y} - \min_t y|\right]$. m نقاطی را نشان می‌دهد که عضله تقریباً در استراحت است (۱۵ درصد پایینی بازه‌ی همان پنجره).
- **بیش‌برآوردی در استراحت** (وزن ۱٫۰): $\text{mean}\left[m\,w_c\,\text{relu}(\hat{y}-y)^2\right]$؛ فقط وقتی جریمه می‌کند که مدل در استراحت بیش از واقع پیش‌بینی کند.
- **سطح فعالیت** (وزن ۰٫۵): خطای نسبی میانگین سطح فعالیت در نقاطی که عضله فعال است، با هوبر هموار و همان ضریب a.
- **تنظیم گراف** (وزن ۰٫۰۰۱): $\text{KL}\big(\,\text{softmax}(B)\,\|\,\text{softmax}(B_0)\big)$؛ نمی‌گذارد bias ثابت یال‌ها از مقدار اولیه‌شان (همبستگی EMG) خیلی دور شوند.

۴.۳ آموزش

optimizer از نوع AdamW است. learning rate برای گراف و decoder برابر 10^{-3} و برای encoder یک‌دهم آن است. بقیه‌ی تنظیم‌ها: weight decay ۰٫۰۱، ۵ دوره warm-up و سپس cosine decay، batch size ۳۲ با انباشت گرادیان دو گام، mixed precision و حداکثر ۲۰۰ دوره. آموزش وقتی متوقف می‌شود (early stopping) که میانگین پنج‌دوره‌ای خطای validation در ۲۰ دوره‌ی پشت سر هم بهتر نشود.

۵.۳ نتایج مدل پایه

جدول ۲ نتیجه‌ی هر شرکت‌کننده و جدول ۳ نتیجه‌ی هر عضله را نشان می‌دهد. میانگین VAF ۷۲٫۲ درصد و میانگین r ۰٫۸۵۱ است. سه عضله‌ی AD، BR و ED خوب پیش‌بینی می‌شوند و دو عضله‌ی انگشت، FD و FDI، ضعیف‌ترند.

میانگین height ratio ۰٫۹۷۳ است، پس اندازه‌ی کلی فعالیت تقریباً درست است. ولی خطای سطح در دو جهت برابر نیست: در جاهایی که مدل بیش‌برآورد می‌کند، اندازه‌ی خطا (۰٫۱۳۸) بزرگ‌تر از جاهایی است که کم‌برآورد می‌کند (۰٫۰۸۹).

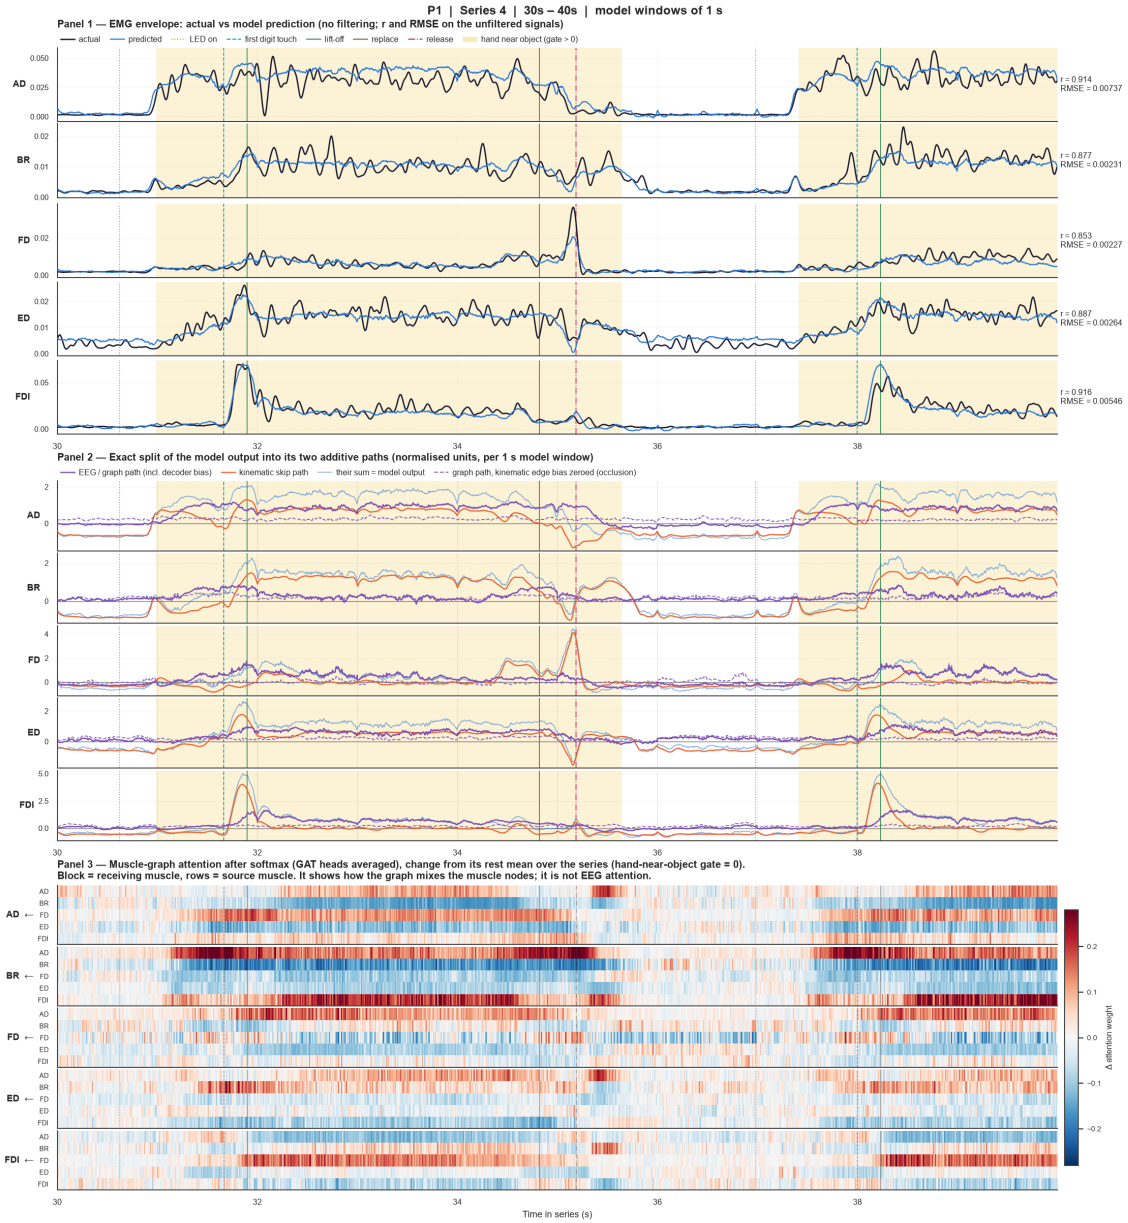
شکل ۴ نمونه‌ای از شکل تفسیری مدل پایه است. پنل اول پیش‌بینی را کنار پوش واقعی می‌گذارد. پنل دوم خروجی را به دو بخش تقسیم می‌کند: بخشی که از مسیر EEG و گراف آمده و بخشی که از kinematic skip highway آمده. پنل سوم نشان می‌دهد توجه muscle graph نسبت به حالت استراحت چقدر تغییر کرده است. نکته‌ی اصلی شکل در پنل دوم است: شکل و زمان‌بندی جهش‌های پوش تقریباً همه از میان‌بر سینماتیک (منحنی نارنجی) می‌آید.

جدول ۲: مدل پایه KG-GT (main_1stage)، سری‌های آزمون: میانگین روی پنج عضله برای هر شرکت‌کننده.

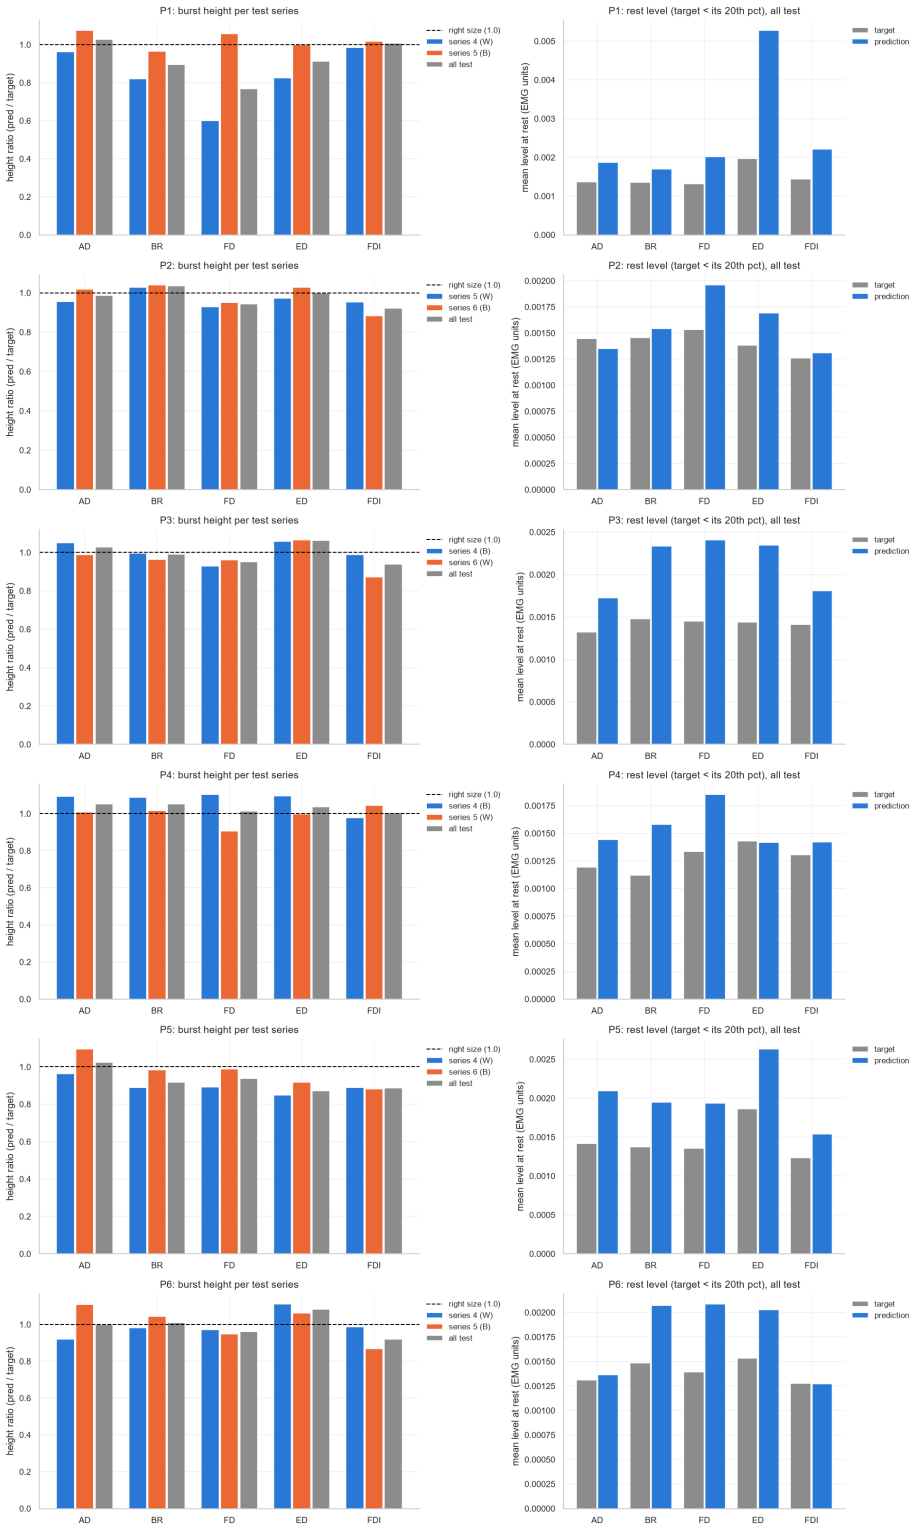
شرکت‌کننده	r	CCC	VAF (%)	height ratio
P1	۰٫۸۹۱	۰٫۸۶۹	۷۹٫۰	۰٫۹۲۲
P2	۰٫۸۷۲	۰٫۸۶۸	۷۵٫۲	۰٫۹۷۷
P3	۰٫۸۱۱	۰٫۷۸۲	۶۷٫۵	۰٫۹۹۴
P4	۰٫۸۸۰	۰٫۸۷۱	۷۶٫۰	۱٫۰۳۱
P5	۰٫۷۷۷	۰٫۷۳۶	۶۳٫۵	۰٫۹۲۷
P6	۰٫۸۶۵	۰٫۸۳۱	۷۴٫۷	۰٫۹۹۴
P7	۰٫۸۹۹	۰٫۸۷۰	۷۹٫۱	۰٫۸۹۸
P8	۰٫۷۶۴	۰٫۷۴۲	۵۴٫۳	۱٫۰۴۷
P9	۰٫۸۹۷	۰٫۸۹۲	۷۹٫۳	۰٫۹۹۳
P10	۰٫۸۷۱	۰٫۸۶۵	۷۴٫۹	۰٫۹۹۱
P11	۰٫۸۵۸	۰٫۸۴۸	۷۳٫۶	۰٫۹۵۴
P12	۰٫۸۳۲	۰٫۸۱۴	۶۹٫۸	۰٫۹۴۹
میانگین	۰٫۸۵۱	۰٫۸۳۲	۷۲٫۲	۰٫۹۷۳

جدول ۳: مدل پایه، میانگین روی ۱۲ شرکت‌کننده برای هر عضله.

عضله	r	VAF (%)	سطح بیش‌برآورد	سطح کم‌برآورد
AD	۰٫۹۳۴	۸۵٫۹	۰٫۱۵۴	۰٫۰۷۴
BR	۰٫۸۹۷	۷۹٫۶	۰٫۱۱۸	۰٫۰۶۸
FD	۰٫۷۰۴	۴۹٫۵	۰٫۱۳۲	۰٫۰۸۰
ED	۰٫۹۱۶	۸۲٫۴	۰٫۱۳۷	۰٫۰۸۵
FDI	۰٫۸۰۶	۶۳٫۷	۰٫۱۴۸	۰٫۱۳۸



شکل ۴: مدل پایه، شرکت‌کننده‌ی P1، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰. پنل ۱: پوش واقعی و پیش‌بینی. پنل ۲: سهم مسیر EEG و گراف (بنفش) و سهم kinematic skip highway (نارنجی) در خروجی. پنل ۳: تغییر توجه muscle graph نسبت به میانگین استراحت.



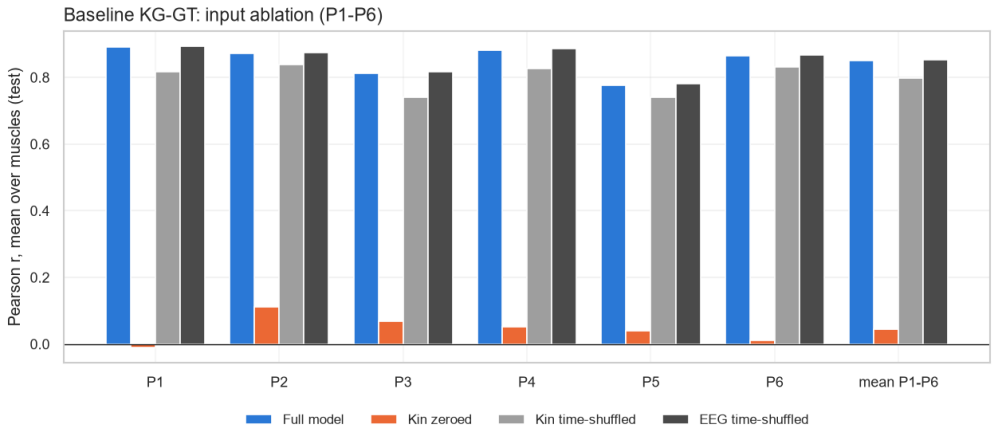
شکل ۵: دامنه‌ی پیش‌بینی مدل پایه برای شرکت‌کننده‌های P1 تا P6. چپ: height ratio هر عضله، یک ستون برای هر سری آزمون و یک ستون خاکستری برای همه‌ی سری‌ها (خط‌چین = ۱، یعنی دامنه‌ی درست). راست: سطح استراحت پیش‌بینی‌شده در برابر سطح واقعی. جدول ۲ همین اعداد را برای هر ۱۲ نفر دارد.

EEG در مدل پایه چه سهمی دارد؟

برای پاسخ، هر ورودی را جداگانه خراب می‌کنیم و می‌بینیم دقت چقدر پایین می‌آید (input ablation، جدول ۴). اگر سینماتیک صفر شود، r از ۰٫۸۵۱ به ۰٫۰۳۵ سقوط می‌کند؛ یعنی مدل بدون سینماتیک تقریباً هیچ پیش‌بینی‌ای ندارد. اما اگر EEG هر پنجره با EEG پنجره‌ی دیگری جابه‌جا شود، r پایین نمی‌آید و حتی کمی بالا می‌رود (۰٫۸۵۵). پس مدل پایه تقریباً همه‌ی پیش‌بینی‌اش را از سینماتیک می‌گیرد و EEG در عمل بی‌اثر است.

جدول ۴: input ablation در مدل پایه: ضریب همبستگی r وقتی یک ورودی صفر یا جابه‌جا می‌شود.

شرکت‌کننده	کامل	سینماتیک صفر	سینماتیک جابه‌جا	EEG جابه‌جا
P1	۰٫۸۹۱	-۰٫۰۱۰	۰٫۸۱۶	۰٫۸۹۴
P2	۰٫۸۷۲	۰٫۱۱۱	۰٫۸۳۸	۰٫۸۷۴
P3	۰٫۸۱۱	۰٫۰۶۸	۰٫۷۴۰	۰٫۸۱۶
P4	۰٫۸۸۰	۰٫۰۵۱	۰٫۸۲۶	۰٫۸۸۵
P5	۰٫۷۷۷	۰٫۰۳۹	۰٫۷۴۰	۰٫۷۸۰
P6	۰٫۸۶۵	۰٫۰۱۱	۰٫۸۳۲	۰٫۸۶۸
P7	۰٫۸۹۹	۰٫۱۶۹	۰٫۸۷۲	۰٫۹۰۲
P8	۰٫۷۶۴	۰٫۰۳۵	۰٫۶۶۳	۰٫۷۷۱
P9	۰٫۸۹۷	۰٫۰۰۶	۰٫۸۶۴	۰٫۸۹۹
P10	۰٫۸۷۱	-۰٫۰۹۶	۰٫۸۱۲	۰٫۸۷۷
P11	۰٫۸۵۸	۰٫۰۱۵	۰٫۸۳۰	۰٫۸۶۵
P12	۰٫۸۳۲	۰٫۰۱۹	۰٫۷۸۴	۰٫۸۳۴
میانگین	۰٫۸۵۱	۰٫۰۳۵	۰٫۸۰۱	۰٫۸۵۵



شکل ۶: input ablation در مدل پایه برای P1 تا P6: میانگین r روی پنج عضله برای مدل کامل، سینماتیک صفر، سینماتیک جابه‌جاشده در زمان و EEG جابه‌جاشده در زمان. جدول ۴ هر ۱۲ نفر را دارد.

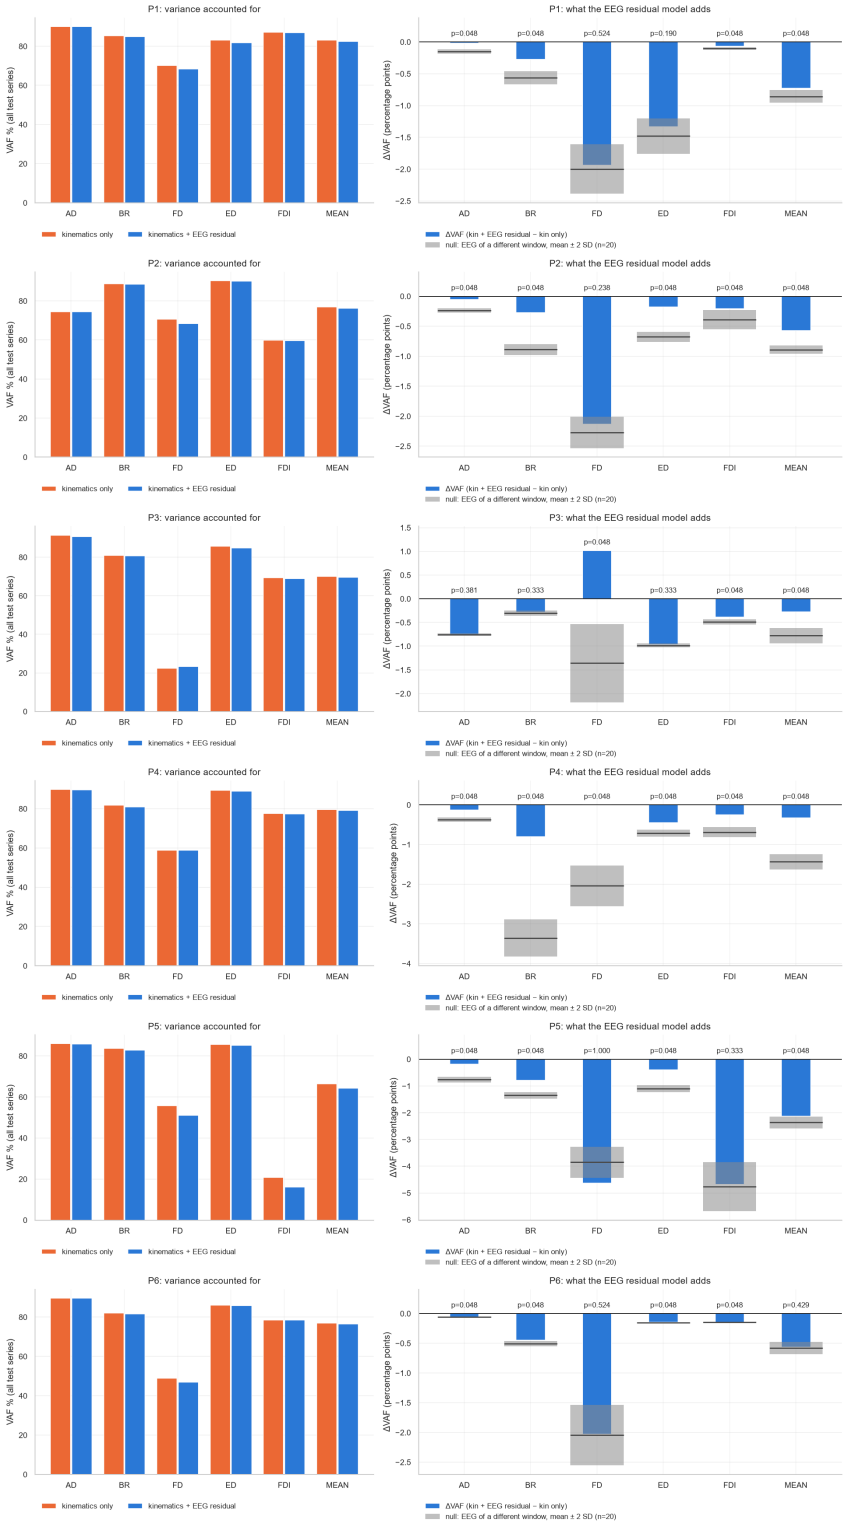
ممکن است این نتیجه فقط به ساختار مدل پایه مربوط باشد. برای اطمینان آزمایش جداگانه‌ای انجام شد (residual experiment، جدول ۵). اول مدلی فقط با سینماتیک آموزش دید. بعد از EEG فقط برای پیش‌بینی خطای باقی‌مانده‌ی آن مدل استفاده شد. اگر EEG اطلاعاتی داشته باشد که سینماتیک ندارد، باید این خطا را کم کند.

نتیجه منفی بود. مدل فقطسینماتیک به VAF ۷۵٫۵ درصد رسید که از مدل پایه‌ی کامل هم بیشتر است.

افزودن EEG آن را به‌طور میانگین ۰٫۷۴ واحد بدتر کرد. از ۶۰ ترکیب شرکت‌کننده و عضله، فقط ۴ مورد بهبود معنادار داشتند؛ اگر EEG هیچ اطلاعاتی نداشته باشد هم، فقط از روی شانس حدود ۳ مورد انتظار می‌رود.

جدول ۵: residual experiment روی مدل پایه (شاخه KG-GT-CUDA): مدل فقط‌سینماتیک در برابر مدلی که EEG را روی باقی‌مانده‌ی آن آموزش می‌دهد. ستون آخر: تعداد خانه‌های (سری × عضله) با p آزمون جابه‌جایی کمتر از ۰٫۰۵.

شرکت‌کننده	VAF فقط سینماتیک	VAF کامل	ΔVAF	r باقی‌مانده	خانه‌های معنادار
P1	۸۳٫۲	۸۲٫۴	-۰٫۷۳	۰٫۰۲۵	۰ از ۵
P2	۷۶٫۸	۷۶٫۳	-۰٫۵۷	۰٫۰۵۳	۰ از ۵
P3	۷۰٫۰	۶۹٫۷	-۰٫۲۸	۰٫۰۲۰	۱ از ۵
P4	۷۹٫۵	۷۹٫۲	-۰٫۳۳	۰٫۰۸۸	۰ از ۵
P5	۶۶٫۳	۶۴٫۲	-۲٫۱۴	۰٫۰۴۳	۰ از ۵
P6	۷۷٫۰	۷۶٫۵	-۰٫۵۶	۰٫۰۰۳	۰ از ۵
P7	۸۳٫۴	۸۳٫۱	-۰٫۲۸	۰٫۰۵۸	۱ از ۵
P8	۶۱٫۸	۶۰٫۷	-۱٫۱۱	۰٫۰۴۶	۱ از ۵
P9	۸۰٫۷	۸۰٫۱	-۰٫۶۸	۰٫۰۳۲	۰ از ۵
P10	۷۸٫۰	۷۷٫۹	-۰٫۱۳	۰٫۰۹۸	۱ از ۵
P11	۷۷٫۳	۷۵٫۷	-۱٫۵۹	۰٫۰۱۸	۰ از ۵
P12	۷۱٫۷	۷۱٫۲	-۰٫۴۹	۰٫۰۰۰	۰ از ۵
میانگین	۷۵٫۵	۷۴٫۷	-۰٫۷۴	۰٫۰۴۰	۴ از ۶۰



شکل ۷: residual experiment روی مدل پایه برای P1 تا P6. چپ: VAF هر عضله برای مدل فقط‌سینماتیک (نارنجی) و همان مدل به‌علاوه‌ی EEG روی خطای باقی‌مانده (آبی). راست: تغییر VAF (ستون آبی) در برابر null distribution، یعنی همان آزمون با EEG پنجره‌ای دیگر (نوار خاکستری، میانگین $\pm$ دو انحراف معیار)، و p تجربی. جدول ۵ هر ۱۲ نفر را دارد.

۴ کاستی‌های مدل پایه

سهم EEG را نمی‌توان اندازه گرفت. مدل پایه فقط یک خروجی دارد و EEG و سینماتیک درون همان گراف با هم مخلوط می‌شوند. سینماتیک به‌تنهایی پیش‌بینی بسیار خوبی می‌دهد، پس آموزش ساده‌ترین راه را انتخاب می‌کند: به سینماتیک تکیه می‌کند و EEG را نادیده می‌گیرد. نتیجه اینکه با این یک خروجی نمی‌توان هم دقت بالا گزارش کرد و هم پرسش علوم اعصاب («آیا EEG فعالیت عضله را رمز می‌کند؟») را آزمود.

مدل گذشته را نمی‌بیند. یک بلندکردن کامل چند ثانیه طول می‌کشد، اما مدل فقط یک ثانیه را می‌بیند. نمی‌داند جسم از کی در هوا است و نمی‌داند بلندکردن قبلی چقدر سنگین بود.

خطای دامنه به وزن جسم بستگی دارد. height ratio به‌طور میانگین درست است، اما وزن‌های سبک و متوسط ۴ تا ۱۱ درصد بیش‌برآورد می‌شوند. وقتی وزن ثابت است و فقط سطح فعالیت از یک بلندکردن به بعدی کمی فرق می‌کند، مدل این تفاوت را نمی‌بیند (برای AD همبستگی حدود ۰٫۰۷). این مشکل یک ضریب کلی نیست: اگر برای هر سری بهترین ضریب ثابت را پیدا کنیم، VAF فقط ۱٫۳ واحد بهتر می‌شود. مشکل این است که مدل هیچ اطلاعی از تاریخچه‌ی بلندکردن‌ها ندارد.

loss function پیچیده و یک‌طرفه است. وزن اضافه‌ی قله‌ها، گران‌تر بودن کم‌برآوردی و جزء استراحت، همه با هم مدل را به سمت بیش‌برآوردی هل می‌دهند؛ همین در نتایج هم دیده می‌شود. هشت جزء با هشت وزن هم باعث می‌شود نتوان گفت هر رفتار مدل از کدام جزء آمده است.

داده سقف دارد. اگر خود پوش واقعی را با فیلتر low-pass ۲ هرتز صاف کنیم، یک «پیش‌بین ایدئال هموار» به دست می‌آید. این پیش‌بین برای FD فقط به VAF ۷۴ درصد می‌رسد. پس بخشی از خطا در خود ثبت‌هاست و هیچ مدلی آن را جبران نمی‌کند (بخش ۷).

نمی‌توان دید مدل از کجا تصمیم می‌گیرد. در مدل پایه اطلاعات از چند راه مختلف بین لحظه‌ها جابه‌جا می‌شود: توجه تکه‌تکه، تأخیر آموختنی (که یک کانولوشن است)، میان‌بر سینماتیک و گراف. روش‌هایی مثل attention rollout و attention flow فقط وقتی کار می‌کنند که تنها راه جابه‌جایی اطلاعات، توجه باشد. علاوه بر این، لایه‌های گراف post-norm هستند و encoder هیچ recorder توجهی ندارد. در نتیجه نمی‌توان ردِ یک خروجی را تا ورودی دنبال کرد. شکل تفسیری مدل پایه (شکل ۴) فقط توجه muscle graph را نشان می‌دهد که درباره‌ی EEG چیزی نمی‌گوید.

۵ چرا v2

v2 برای رفع کاستی‌های بخش ۴ طراحی شد. مهم‌ترین تغییر این است که مدل به‌جای یک خروجی، سه خروجی جدا دارد:

- **K** فقط از سینماتیک و تاریخچه‌ی بلندکردن‌ها ساخته می‌شود. می‌گوید سینماتیک به‌تنهایی چقدر خوب پیش‌بینی می‌کند.
- **E** فقط از EEG ساخته می‌شود. می‌گوید EEG به‌تنهایی چه چیزی از فعالیت عضله را در خود دارد.

- **F** همان K است به‌علاوه‌ی یک اصلاح کوچک از EEG. اگر F از K بهتر شود، EEG چیزی دارد که سینماتیک ندارد.

با این سه خروجی، دو پرسشی که در مدل پایه با هم قاطی می‌شدند جدا می‌شوند. جدول ۶ بقیه‌ی تغییرها را کنار کاستی متناظر می‌گذارد.

جدول ۶: کاستی‌های مدل پایه و پاسخ v2 به هر کدام.

کاستی مدل پایه	تصمیم در v2
یک خروجی؛ سهم EEG را نمی‌توان جدا کرد	سه خروجی جدا: K (سینماتیک)، E (فقط EEG)، F (K به‌علاوه‌ی اصلاح gated از EEG)؛ K از E و F هیچ گرادیانی نمی‌گیرد
پنجره‌ی یک‌ثانیه‌ای	۵۰ tokens هرتز و پنجره‌ی ۸ ثانیه‌ای (۴۰۰ tokens)
بی‌خبری از بلندکردن‌های قبلی	هشت ویژگی تاریخچه از نیروها، فقط از گذشته و بدون EMG
loss function هشت‌جزئی و یک‌طرفه در حوزه‌ی z	حوزه‌ی جذر دامنه و loss function چهارجزئی، بدون وزن اضافه‌ی قله و جزء استراحت
EEG خام در حوزه‌ی زمان	band power در چهار باند برای هر الکترود، به‌صورت گرافی از الکترودها
اطلاعات از چند نوع لایه جابه‌جا می‌شود؛ rollout تعریف‌پذیر نیست	قاعده‌ی «یک مخلوط‌کننده»: فقط لایه‌های توجه اطلاعات را بین موقعیت‌ها جابه‌جا می‌کنند و همه‌شان ثبت می‌شوند
همه‌چیز با هم آموزش می‌بیند و با هم متوقف می‌شود	هر جریان optimizer و توقف خودش را دارد؛ جریانی که دیگر بهتر نمی‌شود در بهترین نقطه‌اش freeze می‌شود

v2 از سه جهت بهتر از مدل پایه است.

۱. **دقت.** K در هر ۱۲ شرکت‌کننده VAF بالاتری از مدل پایه دارد (بخش ۷).

۲. **پرسش علمی روشن.** «آیا EEG چیزی بیش از سینماتیک دارد؟» با مقایسه‌ی F و K و با residual test جواب می‌گیرد. «آیا EEG به‌تنهایی حرکت را رمز می‌کند؟» با E جواب می‌گیرد.

۳. **تفسیرپذیری.** برای هر عدد خروجی می‌توان دنبال کرد که از کدام ورودی‌ها و از کدام لایه‌ها آمده است.

۶ مدل v2

شکل ۸ کل مدل را نشان می‌دهد. مدل دو «جریان» مستقل دارد که هر کدام یک خروجی می‌سازند: جریان سینماتیک K را و جریان E EEG را. یک ماژول کوچک سوم (fusion) این دو را برای ساختن F به هم وصل می‌کند. در ادامه اول ورودی‌ها و خروجی‌ها، بعد اجزای مدل و در آخر نحوه‌ی آموزش توضیح داده می‌شود.

۱.۶ ورودی‌ها، tokens و خروجی‌ها

همه‌ی ورودی‌ها از پیش‌پردازش بخش ۵.۲ می‌آیند؛ اینجا فقط خلاصه‌شان آمده است.

نرخ token. مدل پایه با ۵۰۰ نمونه در ثانیه کار می‌کرد. برای اینکه v2 بتواند ۸ ثانیه را یک‌جا ببیند، همه‌ی سیگنال‌ها با فیلتر ضدتداخل به ۵۰ هرتز برده می‌شوند. هر token نماینده‌ی ۲۰ میلی‌ثانیه است و یک پنجره‌ی ۸ ثانیه‌ای ۴۰۰ token دارد.

سینماتیک $X^k \in \mathbb{R}^{T\times ۲۴}$. همان ۲۴ ویژگی مدل پایه (وضعیت دست، دو نیروی gated و سرعت‌هایشان)، استانداردشده با آماره‌های آموزش.

تاریخچه $X^h \in \mathbb{R}^{T\times ۸}$. این ویژگی‌ها به مدل می‌گویند تا این لحظه در سری چه گذشته است: آیا و چند بار جسم نگه داشته شده، چقدر از شروع سری و از آخرین نگه‌داشتن گذشته، و نیروهای آخرین نگه‌داشتن و میانگین همه‌ی نگه‌داشتن‌های قبلی. مدل فقط وقتی از یک نگه‌داشتن خبردار می‌شود که آن نگه‌داشتن تمام شده باشد؛ پس هیچ ویژگی‌ای از آینده خبر ندارد.

EEG $X^e \in \mathbb{R}^{T\times ۳۲\times ۴}$. به‌جای موج خام، برای هر الکترود لگاریتم توان در چهار باند: تتا (۴ تا ۸ هرتز)، آلفا (۸ تا ۱۳)، بتا (۱۳ تا ۳۰) و گامای پایین (۳۰ تا ۴۰)، استانداردشده و بریده در ± ۵.

هدف در حوزه‌ی جذر. برای هر عضله s_c صدک ۹۵ پوش در داده‌ی آموزش است. مدل به‌جای خود پوش، جذر پوش نرمال‌شده را پیش‌بینی می‌کند:

$$u = \sqrt{y/s_c}, \qquad \hat{y} = s_c\,\hat{u}^{۲}. \tag{۳}$$

جذر قله‌های بلند را کوتاه‌تر و سطح‌های پایین را بازتر می‌کند. در نتیجه خطای قله‌ها و خطای استراحت وزن نزدیک‌تری می‌گیرند و دیگر لازم نیست قله‌ها را جداگانه وزن بدهیم یا جزء جداگانه‌ای برای استراحت بگذاریم.

خروجی‌ها. مدل برای هر token و هر عضله سه عدد برمی‌گرداند:

$$K = K_{base} \odot g(X^h), \qquad E = \text{E-stream}(X^e), \qquad F = \text{relu}\big(K + F_{eeg}\big). \tag{۴}$$

K_{base} پیش‌بینی جریان سینماتیک است و g یک ضریب از تاریخچه که آن را کمی بزرگ یا کوچک می‌کند. F_{eeg} اصلاحی است که EEG به K اضافه می‌کند. مدل این اجزا را هم جداگانه برمی‌گرداند تا بتوان سهم هر کدام را دید.

۲.۶ بلوک توجه یکسان

همه‌ی لایه‌های توجه v2، چه روی زمان، چه روی الکترودها و چه روی عضله‌ها، یک شکل دارند. هر موقعیت (یک token، یک الکترود یا یک عضله) به بقیه‌ی موقعیت‌ها «نگاه می‌کند» و از هر کدام به اندازه‌ی وزن توجهش اطلاعات می‌گیرد. ماتریس توجه A همین وزن‌ها را نگه می‌دارد: سطر i موقعیتی است که اطلاعات می‌گیرد، ستون j موقعیتی است که اطلاعات می‌دهد و جمع هر سطر ۱ است. برای سر h:

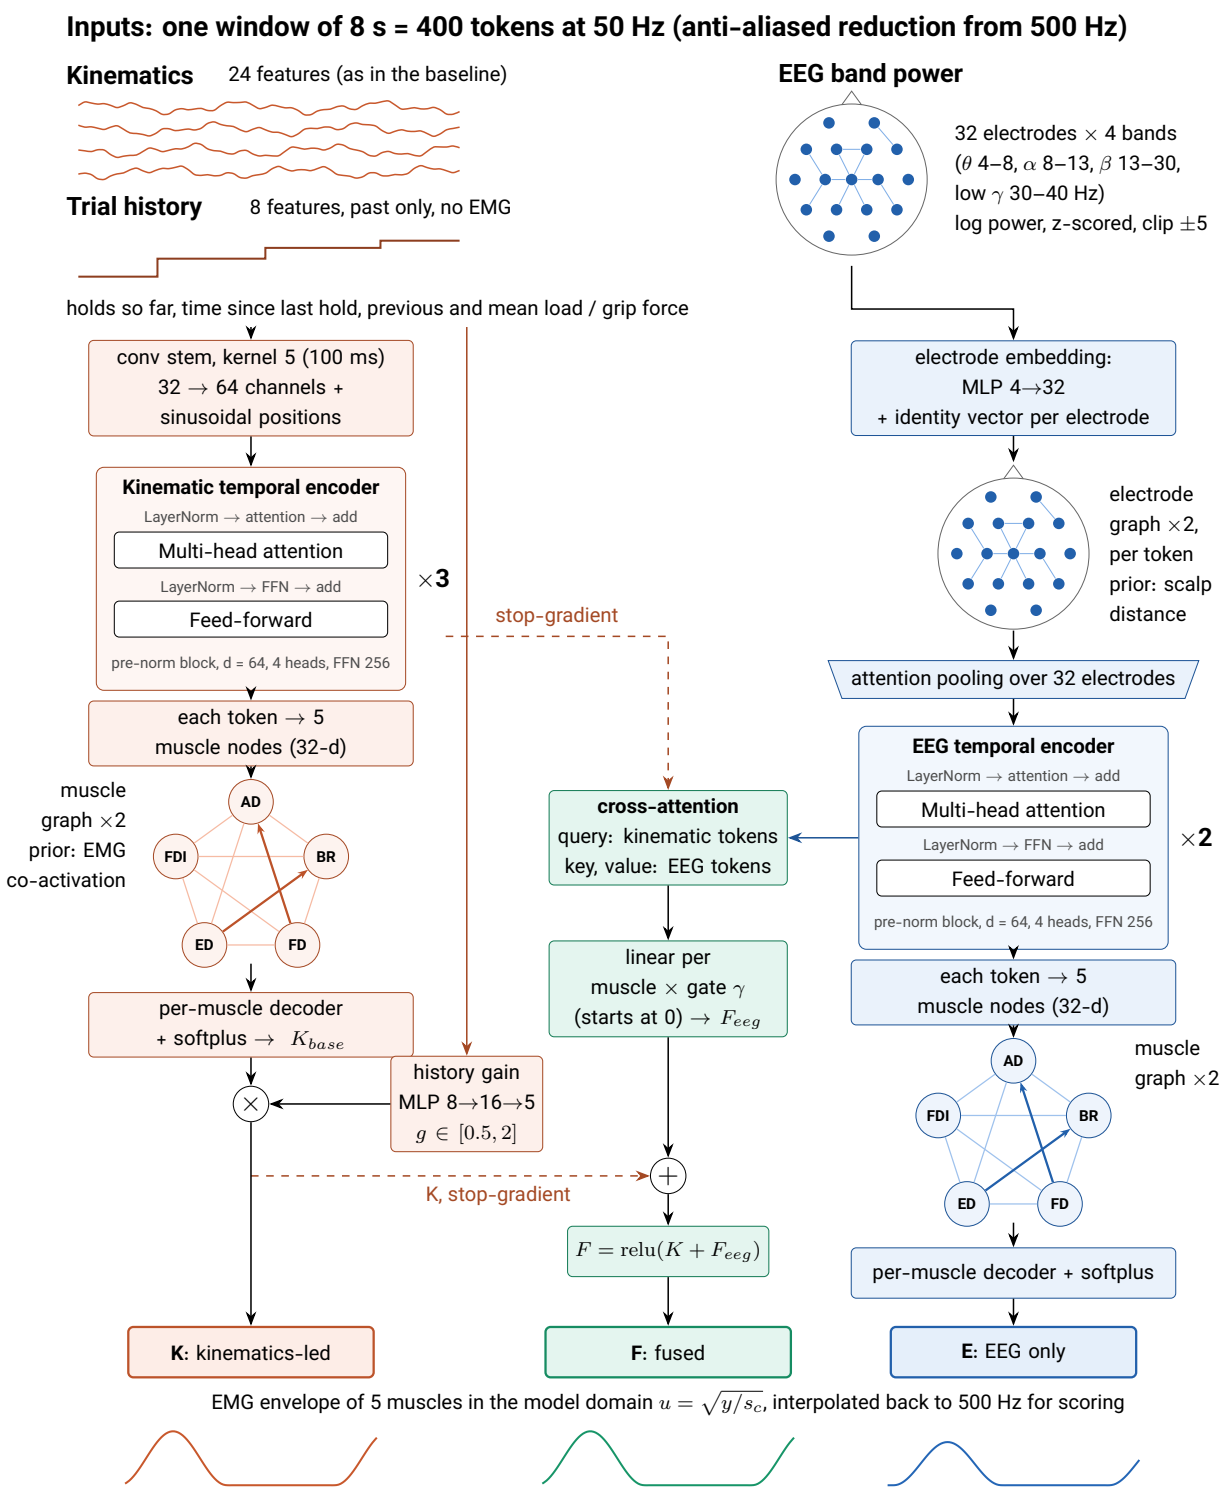
(۵)

$$A^h = \text{softmax}\Big(\frac{Q^h K^{h\top}}{\sqrt{d_h}} + M^h\Big), \qquad x \leftarrow x + W_o\big[A^{۱}V^{۱} \,\|\, \ldots \,\|\, A^H V^H\big], \qquad x \leftarrow x + \text{FFN}(\text{LN}(x)).$$

Q، K و V از $\text{LN}(x)$ ساخته می‌شوند (pre-norm). «$x \leftarrow x + \ldots$» یعنی خروجی هر بخش به ورودی‌اش اضافه می‌شود (residual connection)؛ پس اطلاعات هر موقعیت همیشه یک راه مستقیم هم به لایه‌ی بعد دارد.

M یک bias است که پیش از softmax اضافه می‌شود. در توجه زمانی $M = ۰$ است. در لایه‌های گرافی $M^h = B^h + \lambda P$ است: B^h یک bias آموختنی برای هر یال در هر سر، P یک ماتریس ثابت که دانش قبلی را وارد می‌کند (مثلاً اینکه الکترودهای نزدیک به هم مرتبط‌ترند) و λ ضریبی که مدل یاد می‌گیرد چقدر به این دانش تکیه کند. دو لایه residual connection ندارند: attention pooling الکترودها و cross-attention در fusion.

قاعده‌ی «یک مخلوط‌کننده». این قاعده v2 را تفسیرپذیر می‌کند. اطلاعات فقط از دو راه می‌تواند از یک موقعیت (زمان، الکترود، عضله یا جریان) به موقعیت دیگر برود: ماژول توجه بالا و ماژول attention pooling. همه‌ی لایه‌های دیگر هر موقعیت را جدا پردازش می‌کنند. پس اگر وزن‌های توجه همه‌ی لایه‌ها را داشته باشیم، کل مسیر اطلاعات را داریم.



Loss $L = L_K + L_E + L_F$, for each output: Huber ($\delta = 0.5$) + 0.3 $(1 - \mathrm{CCC})$ + 0.5 level error per detected hold + 0.1 temporal difference.
Training: one AdamW for the kinematic stream, one for the EEG stream and fusion (gate without weight decay); a stream with no improvement for 30 epochs returns to its best weights and is frozen, the other one goes on.
Attention recorder (outside the model): all 13 attention layers, per head and with gradients → rollout, attention flow, gradient-weighted rollout.

شکل ۸: نمای کلی v2 از ورودی تا سه خروجی. چپ: جریان سینماتیک (stem کانولوشنی، سه بلوک Transformer زمانی، گراف پنج عضله، decoder و history gain) که K را می‌سازد. راست: جریان EEG (embedding الکترودها، گراف ۳۲ الکترود روی سر، attention pooling، دو بلوک Transformer زمانی، muscle graph) که E را می‌سازد. وسط: fusion با cross-attention و یک gate که از صفر شروع می‌شود و F را می‌سازد. خط‌چین‌ها جاهایی‌اند که گرادیان قطع می‌شود: K fusion و tokens سینماتیک را می‌خواند اما به آن‌ها گرادیان نمی‌فرستد، پس K فقط با خطای خودش آموزش می‌بیند. کادر پایین loss function، آموزش و attention recorder را خلاصه می‌کند.

تنها استثنا کانولوشن ۵ضربه‌ای stem سینماتیک است. ردپای آن به‌صورت یک ماتریس S ثبت می‌شود: هر سطر جمع ۱ دارد و وزن هر جابه‌جایی برابر انرژی هسته‌ی کانولوشن در آن جابه‌جایی است.

وزن‌های توجه را یک ثبت‌کننده‌ی بیرونی (recorder) برمی‌دارد: with recording(model) as tape. این ثبت‌کننده توجه هر سر را پس از softmax و پیش از dropout نگه می‌دارد و در صورت نیاز گرادیان آن را هم نگه می‌دارد. ثبت کردن خروجی مدل را تغییر نمی‌دهد و لازم نیست به تابع forward هیچ آرگومان اضافه‌ای داده شود. فهرست ۱۳ لایه‌ی ثبت‌شده از model.attention_layers() می‌آید.

۳.۶ جریان سینماتیک

این جریان از سینماتیک و تاریخچه، K را می‌سازد:

۱. **stem.** یک کانولوشن یک‌بعدی با هسته‌ی ۵ روی سینماتیک و تاریخچه با هم (۳۲ ویژگی) که ۶۴ کانال می‌سازد. sinusoidal positional encoding جای هر token در پنجره را اضافه می‌کند.

۲. **temporal encoder.** ۳ بلوک توجه روی هر ۴۰۰ token پنجره، با ۴ سر، feed-forward ۲۵۶ و dropout ۰٫۲. اینجا هر token می‌تواند به هر لحظه‌ی دیگر پنجره نگاه کند.

۳. **سر عضله.** هر token به ۵ گره (یکی برای هر عضله، با عرض ۳۲) تبدیل می‌شود. دو بلوک توجه بین گره‌ها پیام جابه‌جا می‌کنند؛ ماتریس ثابت P این گراف از هم‌فعالی عضله‌ها در EMG آموزش ساخته شده است. در آخر یک decoder خطی برای هر عضله با خروجی softplus (که همیشه مثبت است) K_{base} را می‌دهد.

۴. **history gain.** یک شبکه‌ی کوچک ($۵ \to ۱۶ \to ۸$) روی ویژگی‌های تاریخچه، برای هر عضله یک ضریب $g = ۲^{\tanh(\cdot)}$ بین ۰٫۵ و ۲ می‌سازد. در شروع آموزش $g = ۱$ است. خروجی نهایی $K = K_{base} \odot g$ است. این ضریب به مدل اجازه می‌دهد مثلاً بعد از چند بلندکردن سنگین، سطح فعالیت را بالاتر پیش‌بینی کند.

۴.۶ جریان EEG

این جریان فقط از EEG، E را می‌سازد:

۱. **embedding الکترود.** یک MLP مشترک چهار band power هر الکترود را به یک بردار ۳۲ بعدی تبدیل می‌کند. یک بردار آموختنی هم به هر الکترود اضافه می‌شود تا مدل بداند این کدام الکترود است. در آموزش، هر الکترود با احتمال ۰٫۲ حذف می‌شود تا مدل به یک الکترود وابسته نشود.

۲. **electrode graph.** دو بلوک توجه بین ۳۲ الکترود، برای هر token جداگانه. ماتریس ثابت $P_{ij} = -d_{ij} / \operatorname{median}(d)$ است که d_{ij} فاصله‌ی دو الکترود روی سر (مختصات استاندارد ۱۰-۰۵) است. پس الکترودهای نزدیک به هم از ابتدا تمایل بیشتری به تبادل اطلاعات دارند.

۳. **attention pooling.** ۳۲ الکترود باید به یک بردار برای هر token تبدیل شوند. یک پرسش آموختنی به همه‌ی الکترودها نگاه می‌کند و میانگین وزن‌دار آن‌ها را می‌گیرد: $p_t = \sum_e \pi_{t,e}\, n_{t,e}$. وزن $\pi_{t,e}$ می‌گوید الکترود e در لحظه‌ی t چقدر در این بردار سهم دارد.

۴. **temporal encoder.** ۲ بلوک توجه روی ۴۰۰ token.

۵. **سر عضله.** مانند جریان سینماتیک ولی با وزن‌های جدا؛ خروجی E است.

fusion ۵.۶

fusion از EEG یک اصلاح کوچک برای K می‌سازد. tokens سینماتیک به‌عنوان پرسش به EEG tokens نگاه می‌کنند (cross-attention)؛ یعنی هر لحظه‌ی حرکت می‌پرسد «کدام لحظه‌های EEG برای من مهم است؟». سپس یک لایه‌ی خطی برای هر عضله یک عدد اصلاحی می‌سازد:

$$F_{eeg} = \gamma \odot W\,\mathrm{CrossAttn}\big(\mathrm{sg}[Z^k],\, Z^e\big), \qquad F = \mathrm{relu}\big(\mathrm{sg}[K] + F_{eeg}\big). \tag{۶}$$

sg (stop-gradient) یعنی fusion مقدار K و tokens سینماتیک را می‌خواند اما آن‌ها را تغییر نمی‌دهد؛ پس K فقط با خطای خودش آموزش می‌بیند. $\gamma \in \mathbb{R}^{۵}$ یک gate برای هر عضله است که از صفر شروع می‌شود و weight decay ندارد. اگر EEG چیز مفیدی به K اضافه نکند، γ نزدیک صفر می‌ماند و در نتیجه $F = K$. کل مدل ۷۱۲,۳۳۷ پارامتر دارد.

loss function ۶.۶

هر سه خروجی loss function یکسانی در حوزه‌ی جذر دارند و loss کل جمع آن‌هاست: $L = L_K + L_E + L_F$. برای هر خروجی o:

$$L_o = \underbrace{\mathrm{Huber}_{۰/۵}(\hat{u}_o, u)}_{\text{main},\,۱/۰} + ۰/۳\,\underbrace{\big(۱ - \mathrm{CCC}(\hat{u}_o, u)\big)}_{\text{ccc}} + ۰/۵\,\underbrace{\frac{۱}{|\mathcal{H}|}\sum_{k\in\mathcal{H}}\left|\overline{\hat{u}_{ok}} - \overline{u}_k\right|}_{\text{lift}} + ۰/۱\,\underbrace{\mathrm{mean}\,\big|\Delta\hat{u}_o - \Delta u\big|}_{\text{diff}}. \tag{۷}$$

- **main:** خطای نقطه‌به‌نقطه با تابع هوبر.
- **ccc:** شکل و اندازه‌ی کلی منحنی در پنجره.
- **lift:** برای هر نگه‌داشتن درون پنجره ($\mathcal{H}$، با دست‌کم ۵ token) میانگین پیش‌بینی را با میانگین واقعی مقایسه می‌کند. این جزء مستقیم همان خطایی را می‌سنجد که در مدل پایه به وزن جسم بستگی داشت.
- **diff:** تغییر لحظه‌به‌لحظه، تا بالا و پایین رفتن‌ها هم‌زمان باشند.

وزن اضافه‌ی قله، گران‌تر بودن کم‌برآوردی و جزء استراحت عمداً حذف شدند.

آموزش ۷.۶

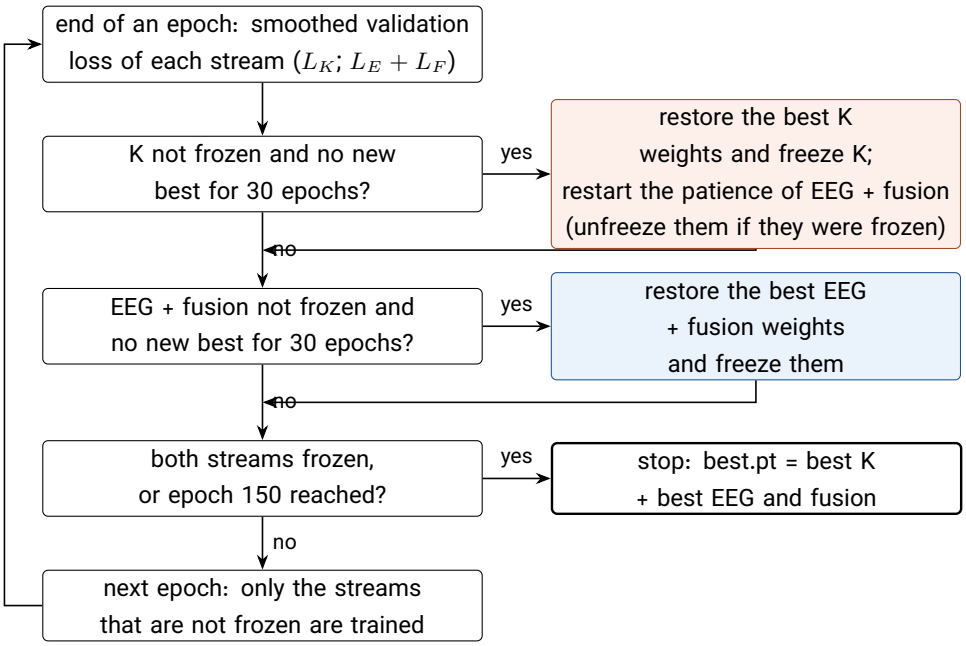
هر جریان optimizer خودش را دارد: یک AdamW برای پارامترهای *.kin و یکی برای *.eeg و *.fusion (gate بدون weight decay). تنظیم‌های مشترک: learning rate $۱۰^{-۳}$، weight decay ۰/۰۱، ۵ دوره warm-up و سپس cosine decay، gradient clipping ۱/۰ برای هر جریان جداگانه، batch size ۳۲ و حداکثر ۱۵۰ دوره. پنجره‌های آموزش ۸ ثانیه با فاصله‌ی ۲ ثانیه از هم هستند و جای شروعشان در هر دوره به‌طور تصادفی کمی جابه‌جا می‌شود.

پیش از آموزش، چند گام یک بار با mixed precision و یک بار بدون آن اجرا و زمان‌شان مقایسه می‌شود؛ هر کدام سریع‌تر بود انتخاب می‌شود. روی mixed precision GTX 1660 Ti حدود سه برابر کندتر بود و دقت کامل انتخاب شد.

freezing هر جریان. دو جریان با سرعت متفاوتی یاد می‌گیرند. اگر یکی زودتر به بهترین نقطه‌اش برسد و آموزش ادامه پیدا کند، ممکن است بدتر شود. برای جلوگیری از این، هر جریان جداگانه زیر نظر است. خطای validation هر جریان با میانگین سه‌دوره‌ای صاف می‌شود: L_K برای سینماتیک و $L_E + L_F$ برای EEG و fusion.

شکل ۹ قاعده را نشان می‌دهد. اگر خطای یک جریان در ۳۰ دوره‌ی پشت سر هم بهتر نشود، آن جریان به وزن‌های بهترین دوره‌اش برمی‌گردد و freeze می‌شود: دیگر loss برایش حساب نمی‌شود، optimizer آن را به‌روز نمی‌کند و در حالت ارزیابی می‌ماند. جریان دیگر به آموزش ادامه می‌دهد.

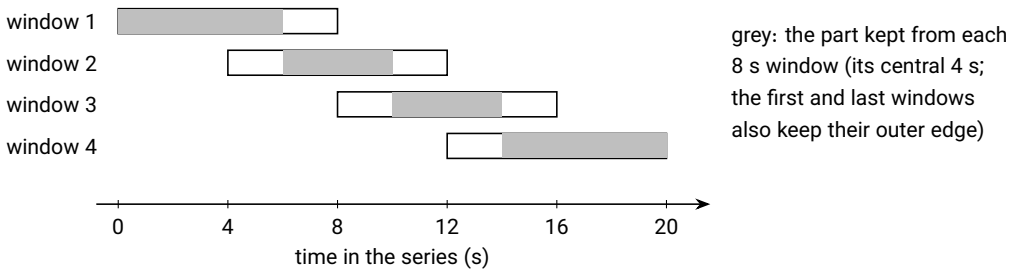
یک نکته‌ی ظریف: F روی K ساخته می‌شود. وقتی K freeze می‌شود و به وزن‌های قدیمی‌ترش برمی‌گردد، F هم کمی عوض می‌شود. برای همین شمارش صبر EEG و fusion از صفر شروع می‌شود تا بهترین دوره‌ی آن‌ها با همان K نهایی سنجیده شود. آموزش وقتی تمام می‌شود که هر دو جریان freeze شده باشند یا به ۱۵۰ دوره برسد.



شکل ۹: قاعده‌ی freezing در پایان هر دوره. وضعیت freezing در last.pt ذخیره می‌شود و اگر آموزش قطع و دوباره شروع شود، حفظ می‌شود.

۸.۶ پیش‌بینی روی یک سری کامل

مدل هر بار ۸ ثانیه را می‌بیند، اما یک سری چند دقیقه طول می‌کشد. برای پیش‌بینی کل سری، پنجره‌های ۸ ثانیه‌ای با فاصله‌ی ۴ ثانیه روی سری لغزانده می‌شوند و از هر پنجره فقط ۴ ثانیه‌ی وسطش نگه داشته می‌شود (شکل ۱۰). دلیلش این است که tokens نزدیک لبه‌ی پنجره بافت کمتری دارند و پیش‌بینی‌شان کم‌دقت‌تر است. اولین و آخرین پنجره لبه‌ی بیرونی‌شان را هم نگه می‌دارند تا هیچ بخشی از سری جا نماند. در آخر، tokens ۵۰ هرتز با درون‌یابی اسپلاین مکعبی به ۵۰۰ هرتز برمی‌گردند و با پوش واقعی ۵۰۰ هرتز مقایسه می‌شوند. همین تابع در ارزیابی، تفسیر و triptych figures به کار می‌رود.



شکل ۱۰: پیش‌بینی پیوسته روی یک سری: پنجره‌های ۸ ثانیه‌ای با فاصله‌ی ۴ ثانیه، و نگه‌داشتن ۴ ثانیه‌ی وسط هر پنجره.

۷ نتایج ارزیابی v2

همه‌ی اعداد این بخش روی همان سری‌های آزمونی است که مدل پایه با آن‌ها سنجیده شد، و با نرخ ۵۰۰ هرتز. پس مقایسه‌ی دو مدل منصفانه است. آموزش هر شرکت‌کننده روی GTX 1660 Ti بین ۱۷ تا ۳۱ دقیقه طول کشید (جدول ۹).

۱.۷ دقت K، E و F

جدول ۷ خلاصه‌ی اصلی نتایج است.

K از مدل پایه بهتر است. میانگین K VAF ۷۵٫۸ درصد و میانگین r آن ۰٫۸۷۲ است؛ مدل پایه ۷۲٫۲ درصد و ۰٫۸۵۱ داشت. این بهبود در هر ۱۲ شرکت‌کننده دیده می‌شود، نه فقط در میانگین. اندازه‌ی بهبود از ۰٫۳ واحد (P5) تا ۵٫۵ واحد (P4) است و میانه‌اش حدود ۴ واحد. K حتی از مدل فقط‌سینماتیکِ residual experiment (۷۵٫۵ درصد و ۰٫۸۶۹) هم کمی بهتر است. پس اولین معیار پذیرش v2 برآورده شد.

جدول ۷: نتایج v2 روی سری‌های آزمون در برابر مدل پایه. چهار ستون اول VAF (درصد) و چهار ستون بعد r، هر دو میانگین روی پنج عضله.

شرکت‌کننده	پایه	K	E	F	پایه	K	E	F
P1	۷۹٫۰	۸۳٫۶	۳۳٫۹	۸۳٫۸	۰٫۸۹۱	۰٫۹۱۴	۰٫۵۹۷	۰٫۹۱۵
P2	۷۵٫۲	۷۸٫۸	۵۸٫۳	۷۸٫۸	۰٫۸۷۲	۰٫۸۸۸	۰٫۷۶۶	۰٫۸۸۸
P3	۶۷٫۵	۶۹٫۸	۳۰٫۷	۷۰٫۲	۰٫۸۱۱	۰٫۸۳۷	۰٫۵۹۲	۰٫۸۳۶
P4	۷۶٫۰	۸۱٫۵	۵۷٫۷	۸۱٫۸	۰٫۸۸۰	۰٫۹۰۵	۰٫۷۵۹	۰٫۹۰۵
P5	۶۳٫۵	۶۳٫۸	۳۴٫۴	۶۴٫۰	۰٫۷۷۷	۰٫۷۹۵	۰٫۶۰۳	۰٫۷۹۳
P6	۷۴٫۷	۷۶٫۷	۳۵٫۸	۷۷٫۰	۰٫۸۶۵	۰٫۸۷۷	۰٫۶۲۶	۰٫۸۷۷
P7	۷۹٫۱	۸۲٫۶	۵۷٫۷	۸۲٫۵	۰٫۸۹۹	۰٫۹۱۰	۰٫۷۵۶	۰٫۹۱۱
P8	۵۴٫۳	۵۸٫۴	۳۲٫۷	۵۸٫۰	۰٫۷۶۴	۰٫۷۹۲	۰٫۵۸۲	۰٫۷۹۹
P9	۷۹٫۳	۸۳٫۵	۴٫۵	۸۳٫۵	۰٫۸۹۷	۰٫۹۱۸	۰٫۴۷۸	۰٫۹۱۸
P10	۷۴٫۹	۸۰٫۲	۵۳٫۶	۸۰٫۳	۰٫۸۷۱	۰٫۸۹۸	۰٫۷۲۵	۰٫۸۹۸
P11	۷۳٫۶	۷۸٫۱	۳۶٫۰	۷۸٫۱	۰٫۸۵۸	۰٫۸۸۴	۰٫۶۴۹	۰٫۸۸۴
P12	۶۹٫۸	۷۲٫۵	۳۴٫۴	۷۲٫۳	۰٫۸۳۲	۰٫۸۴۵	۰٫۶۰۴	۰٫۸۴۵
میانگین	۷۲٫۲	۷۵٫۸	۳۹٫۱	۷۵٫۹	۰٫۸۵۱	۰٫۸۷۲	۰٫۶۴۵	۰٫۸۷۲

E از EEG به‌تنهایی پیش‌بینی معناداری می‌سازد. E که فقط EEG می‌بیند به r ۰٫۶۴۵ و VAF ۳۹٫۱ درصد رسید. این از خروجی فقطEEG آزمایش‌های قبلی (r حدود ۰٫۴۷) بالاتر است.

آیا ممکن است این عدد تصادفی باشد؟ برای پاسخ، null test انجام شد: بلوک‌های EEG در زمان جابه‌جا می‌شوند تا رابطه‌اش با حرکت از بین برود، و دقت دوباره حساب می‌شود. E واقعی در هر ۱۲ شرکت‌کننده از این حالت جابه‌جاشده بهتر بود (جدول ۸). پس EEG به‌تنهایی اطلاعات واقعی درباره‌ی حرکت دارد.

F همان K است. میانگین F VAF ۷۵٫۹ و K ۷۵٫۸ است. بزرگ‌ترین قدرمطلق gate در هر شرکت‌کننده بین ۰٫۰۱ و ۰٫۰۴ ماند، و اصلاحی که EEG اضافه می‌کند حدود ۰٫۲ تا ۲ درصد اندازه‌ی K است (جدول ۱۴). فقط در یک نفر (P4) بهتر بودن F نسبت به K از null test گذشت؛ از ۱۲ آزمون، یک نتیجه‌ی معنادار همان چیزی است که از شانس انتظار می‌رود.

این یعنی EEG چیزی به سینماتیک اضافه نمی‌کند. ولی شاید مشکل از ماژول fusion باشد که نتوانسته اطلاعات موجود را یاد بگیرد. بخش ۱۲ این احتمال را جداگانه بررسی می‌کند و نشان می‌دهد این‌طور نیست.

جدول ۸: null tests: E در برابر EEG جابه‌جاشده بین بلوک‌ها، و بهره‌ی F نسبت به K. p هیچ‌گاه کمتر از یک‌تقسیم‌برتعداد بلوک‌ها گزارش نمی‌شود. ستون آخر بزرگ‌ترین قدرمطلق fusion gate بین پنج عضله است.

شرکت‌کننده	r خروجی E	p (جابه‌جایی)	ΔVAF (K−F)	p (جابه‌جایی)	بیشینه‌ی $\lvert g \rvert$
P1	۰٫۵۹۷	۰٫۰۱۲	+۰٫۱۹	۰٫۱۹	۰٫۰۱۵
P2	۰٫۷۶۶	۰٫۰۱۱	-۰٫۰۲	۰٫۸۵	۰٫۰۱۴
P3	۰٫۵۹۲	۰٫۰۱۳	+۰٫۳۷	۰٫۹۵	۰٫۰۱۷
P4	۰٫۷۵۹	۰٫۰۱۲	+۰٫۳۲	۰٫۰۱	۰٫۰۲۶
P5	۰٫۶۰۳	۰٫۰۱۱	+۰٫۲۵	۰٫۱۸	۰٫۰۲۶
P6	۰٫۶۲۶	۰٫۰۱۱	+۰٫۳۵	۰٫۲۶	۰٫۰۲۴
P7	۰٫۷۵۶	۰٫۰۱۱	-۰٫۰۲	۰٫۷۸	۰٫۰۱۸
P8	۰٫۵۸۲	۰٫۰۱۳	-۰٫۳۵	۰٫۳۴	۰٫۰۴۲
P9	۰٫۴۷۸	۰٫۰۱۲	+۰٫۰۳	۰٫۳۴	۰٫۰۱۲
P10	۰٫۷۲۵	۰٫۰۱۲	+۰٫۰۶	۰٫۴۰	۰٫۰۱۰
P11	۰٫۶۴۹	۰٫۰۱۱	+۰٫۰۱	۰٫۴۵	۰٫۰۱۵
P12	۰٫۶۰۴	۰٫۰۱۰	-۰٫۲۲	۰٫۸۲	۰٫۰۲۱

کی می‌توان به F اعتماد کرد. F روی K ساخته می‌شود، پس fusion ذخیره‌شده فقط وقتی معنا دارد که با همان K ذخیره‌شده آموزش دیده باشد. دفترچه‌ی آموزش این شرط را بررسی می‌کند. با قاعده‌ی freezing، بهترین دوره‌ی EEG و fusion همیشه بعد از freeze شدن K است (جدول ۹)، پس شرط در هر ۱۲ نفر برقرار است.

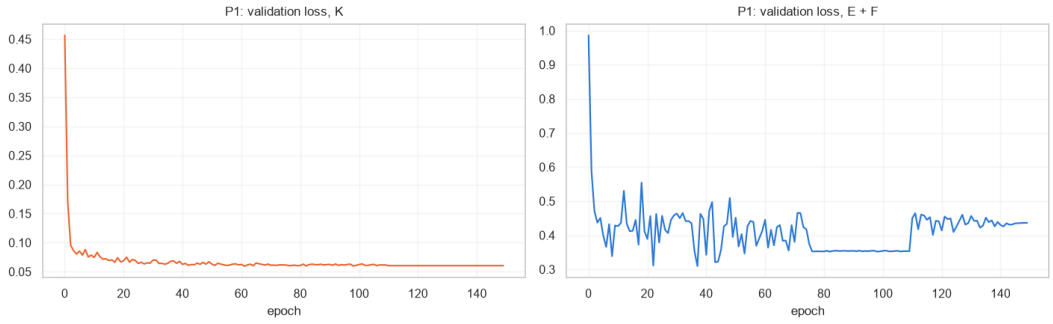
جدول حکم‌هایی که این گزارش از آن استفاده می‌کند پیش از اصلاح این بررسی ذخیره شده است. به همین دلیل برای ۹ نفر برچسب «غیرقابل‌تفسیر» دارد. اعداد جدول درست‌اند؛ اگر سلول ارزیابی دوباره اجرا شود، این برچسب‌ها به «EEG چیزی به سینماتیک اضافه نمی‌کند» تغییر می‌کنند (به‌جز P4).

۲.۷ هر عضله و سقف داده

جدول ۱۰ نشان می‌دهد K در همه‌ی پنج عضله از مدل پایه بهتر است.

جدول ۹: روند آموزش v2: شماره‌ی بهترین دوره و دوره‌ی freezing هر جریان. خط تیره یعنی جریان تا پایان (۱۵۰ دوره) منجمد نشد.

شرکت‌کننده	دوره‌ها	بهترین K	K freezing	بهترین E	E freezing	زمان (دقیقه)
P1	۱۵۰	۸۰	۱۱۰	۱۲۷	–	۲۴٫۱
P2	۱۵۰	۱۱۶	۱۴۶	۱۴۷	–	۳۰٫۸
P3	۱۰۵	۳۱	۶۱	۷۵	۱۰۵	۱۷٫۲
P4	۱۳۸	۵۵	۸۵	۱۰۸	۱۳۸	۲۳٫۹
P5	۱۵۰	۵۵	۸۵	۱۲۵	–	۲۷٫۹
P6	۱۲۲	۴۹	۷۹	۹۲	۱۲۲	۲۳٫۱
P7	۱۰۵	۳۸	۶۸	۷۵	۱۰۵	۲۱٫۹
P8	۱۳۸	۲۷	۵۷	۱۰۸	۱۳۸	۲۲٫۹
P9	۱۵۰	۷۳	۱۰۳	۱۲۰	۱۵۰	۲۴٫۶
P10	۱۱۰	۴۹	۷۹	۸۰	۱۱۰	۱۹٫۳
P11	۹۵	۳۳	۶۳	۶۵	۹۵	۱۷٫۸
P12	۹۰	۱۹	۴۹	۶۰	۹۰	۱۷٫۳



شکل ۱۱: خطای validation P1 در طول آموزش: چپ K، راست F+E. K در دوره‌ی ۸۰ بهترین بود و در دوره‌ی ۱۱۰ freeze شد؛ EEG و fusion تا دوره‌ی ۱۵۰ ادامه دادند.

ستون «سقف» جدول می‌گوید در بهترین حالت چه عددی ممکن است. این عدد VAF خود پوش واقعی پس از صاف کردن با low-pass ۲ هرتز است؛ یعنی دقت یک پیش‌بین هموار که همه‌چیز را درست می‌داند و فقط نوسان‌های سریع را نمی‌تواند بسازد. FD محدودترین عضله است: سقفش ۷۴ درصد است و فعالیتش تغییر کمی دارد (modulation depth کم: صدک ۸۰ فقط حدود دو برابر صدک ۲۰ است). برای AD، BR و ED فاصله‌ی K تا سقف حدود ۸ تا ۱۱ واحد است؛ یعنی هنوز جا برای بهتر شدن هست.

جدول ۱۰: VAF (درصد) برای هر عضله، میانگین روی ۱۲ شرکت‌کننده؛ VAF = smooth ceiling خودِ هدفِ هموارشده با low-pass ۲ هرتز؛ modulation depth = نسبت صدک ۸۰ به صدک ۲۰ هدف.

عضله	پایه	K	E	F	smooth ceiling	modulation depth
AD	۸۵٫۹	۸۸٫۶	۵۸٫۰	۸۸٫۷	۹۳٫۷	۱۲٫۲
BR	۷۹٫۶	۸۲٫۵	۴۴٫۴	۸۲٫۹	۹۰٫۵	۳٫۲
FD	۴۹٫۵	۵۳٫۰	۱۸٫۱	۵۲٫۷	۷۴٫۲	۲٫۰
ED	۸۲٫۴	۸۶٫۱	۵۲٫۴	۸۶٫۴	۹۳٫۳	۵٫۰
FDI	۶۳٫۷	۶۸٫۶	۲۲٫۷	۶۸٫۵	۸۷٫۱	۳٫۵

۳.۷ دامنه در هر وزن جسم

یکی از کاستی‌های مدل پایه این بود که خطای دامنه به وزن جسم بستگی داشت. جدول ۱۱ این را برای سه وزن مقایسه می‌کند. دو چیز سنجیده شده است: height ratio در زمان نگه‌داشتن، و همبستگی سطح فعالیت بین بلندکردن‌هایی که وزن یکسان دارند.

جزء lift در loss function و ویژگی‌های تاریخچه دقیقاً برای همین خطا طراحی شدند و اثرشان روشن است. مدل پایه وزن سبک را ۴٫۵ درصد و وزن متوسط را ۵٫۵ درصد بیش‌برآورد می‌کرد. K height ratio در هر سه وزن بین ۱٫۰۰۴ و ۱٫۰۰۹ است، یعنی خطای کمتر از یک درصد. معیار پذیرش دوم این بود که این عدد بین ۰٫۹۵ و ۱٫۰۵ باشد.

همبستگی سطح فعالیت بین بلندکردن‌های هم‌وزن هم در هر سه وزن بالا رفته است؛ مثلاً در وزن سبک از ۰٫۳۹ به ۰٫۵۳. یعنی K بهتر از مدل پایه تشخیص می‌دهد کدام بلندکردن کمی بیشتر یا کمتر از بقیه زور می‌خواهد.

جدول ۱۱: سطح فعالیت در مرحله‌ی نگه‌داشتن، برای هر وزن جسم (میانگین روی شرکت‌کننده‌ها، سری‌ها و عضله‌ها). height ratio = میانگین پیش‌بینی به میانگین هدف؛ مقدار مطلوب ۱.

وزن جسم	height ratio پایه	K height ratio	r بین بلندکردن‌ها پایه	r بین بلندکردن‌ها K
سبک	۱٫۰۴۵	۱٫۰۰۵	۰٫۳۹۱	۰٫۵۲۹
متوسط	۱٫۰۵۵	۱٫۰۰۴	۰٫۵۰۱	۰٫۵۷۰
سنگین	۱٫۰۲۴	۱٫۰۰۹	۰٫۳۹۴	۰٫۴۶۱

۴.۷ triptych figures

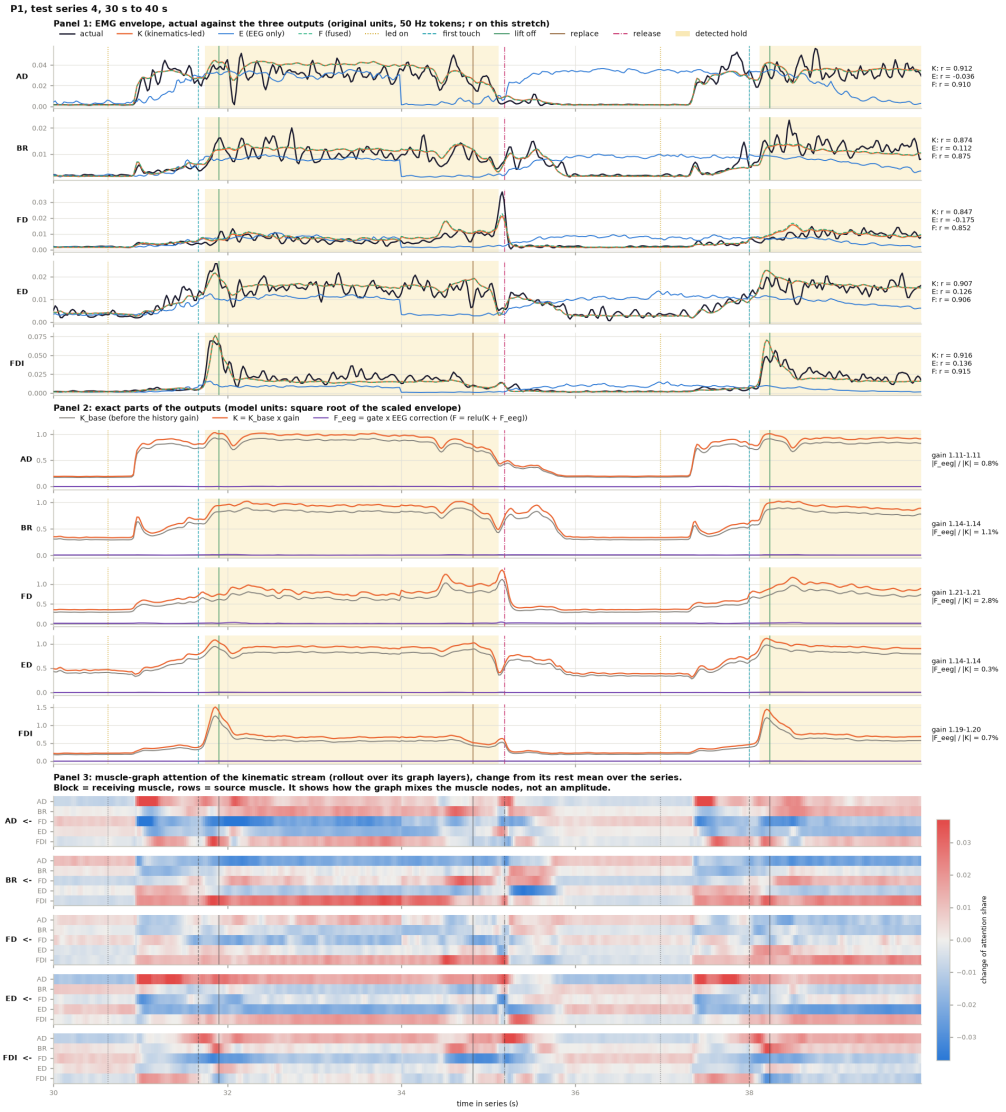
برای اینکه ببینیم مدل در عمل چه می‌کند، هر سری آزمون به تکه‌های ۱۰ ثانیه‌ای تقسیم و برای هر تکه یک شکل سه‌پنلی (triptych) ساخته شد. در ادامه برای شرکت‌کننده‌های ۱ تا ۴ و برای هر سری آزمون یک شکل آمده است (ثانیه‌ی ۳۰ تا ۴۰ هر سری).

- **پنل ۱: پیش‌بینی در برابر واقعیت.** پوش واقعی (سیاه) کنار K (نارنجی)، E (آبی) و F (سبز خط‌چین)، با واحد

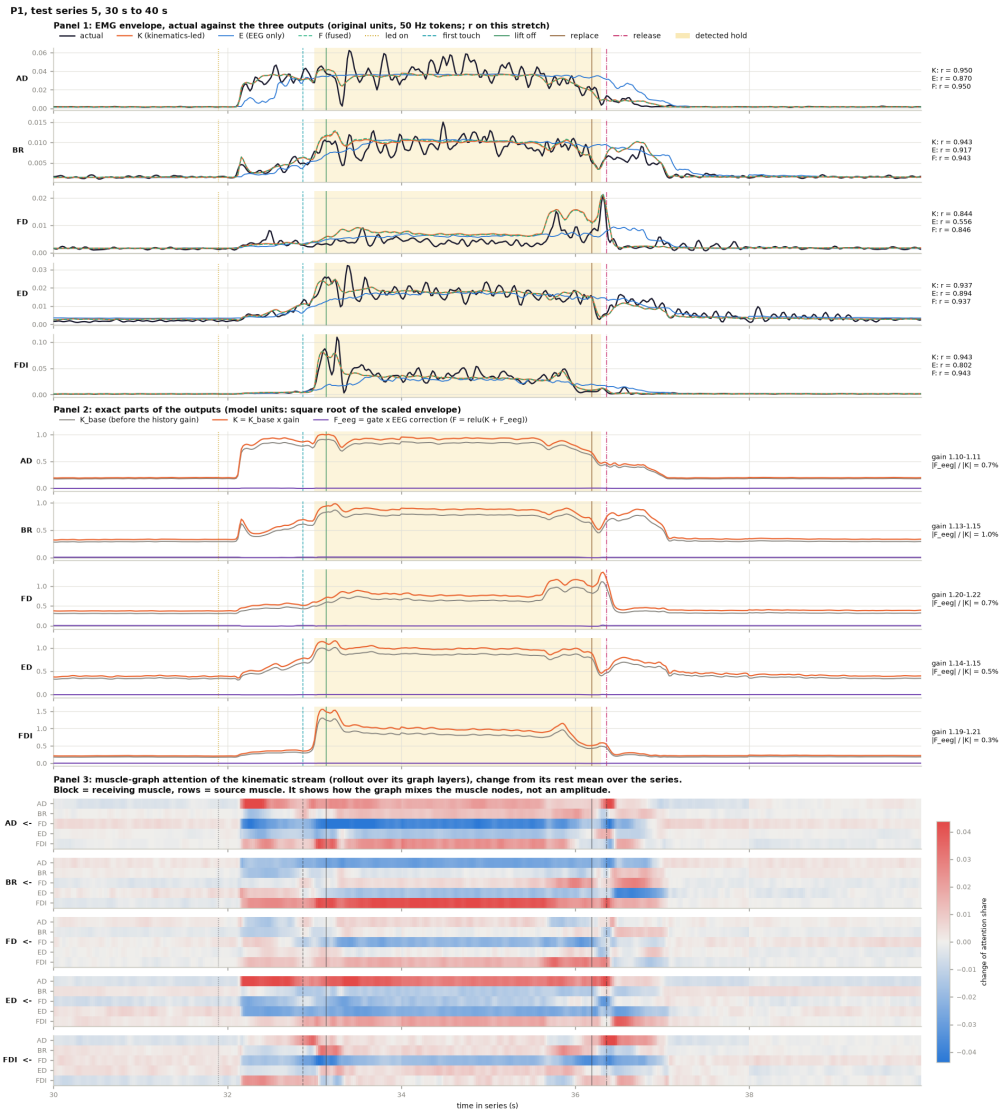
اصلی. خطوط عمودی رخدادهای آزمایش‌اند: روشن شدن چراغ، اولین تماس، جدا شدن جسم از سطح، گذاشتن و رها کردن. ناحیه‌ی زرد بازه‌ی نگه‌داشتن است. ستون راست r همین تکه را می‌دهد.

- **پنل ۲: اجزای خروجی.** K_{base} (خاکستری)، $K = K_{base} \cdot g$ (نارنجی) و اصلاح EEG، F_{eeg} (بنفش)، در حوزه‌ی جذر. ستون راست بازه‌ی ضریب تاریخچه و نسبت اندازه‌ی اصلاح EEG به K را می‌دهد.
- **پنل ۳: توجه بین عضله‌ها.** muscle graph attention rollout جریان سینماتیک، به‌صورت تغییر نسبت به میانگین استراحت همان سری. هر بلوک یک عضله‌ی گیرنده و هر سطر یک عضله‌ی فرستنده است.

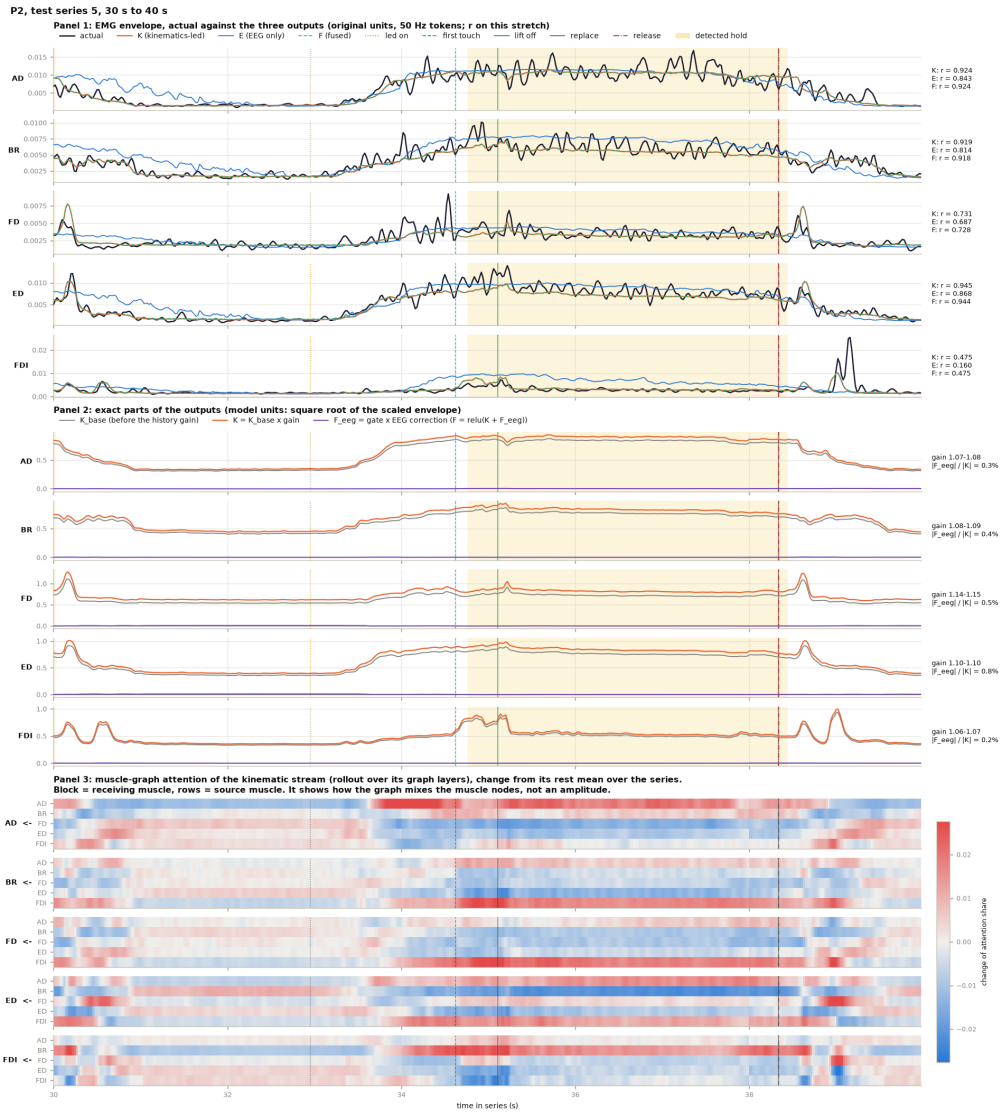
الگوی همه‌ی شکل‌ها یکی است. F دقیقاً روی K افتاده و F_{eeg} نزدیک صفر است. E زمان‌بندی کلی هر بلندکردن را درست دنبال می‌کند، اما جهش‌های کوتاه و تیز پوش را ندارد.



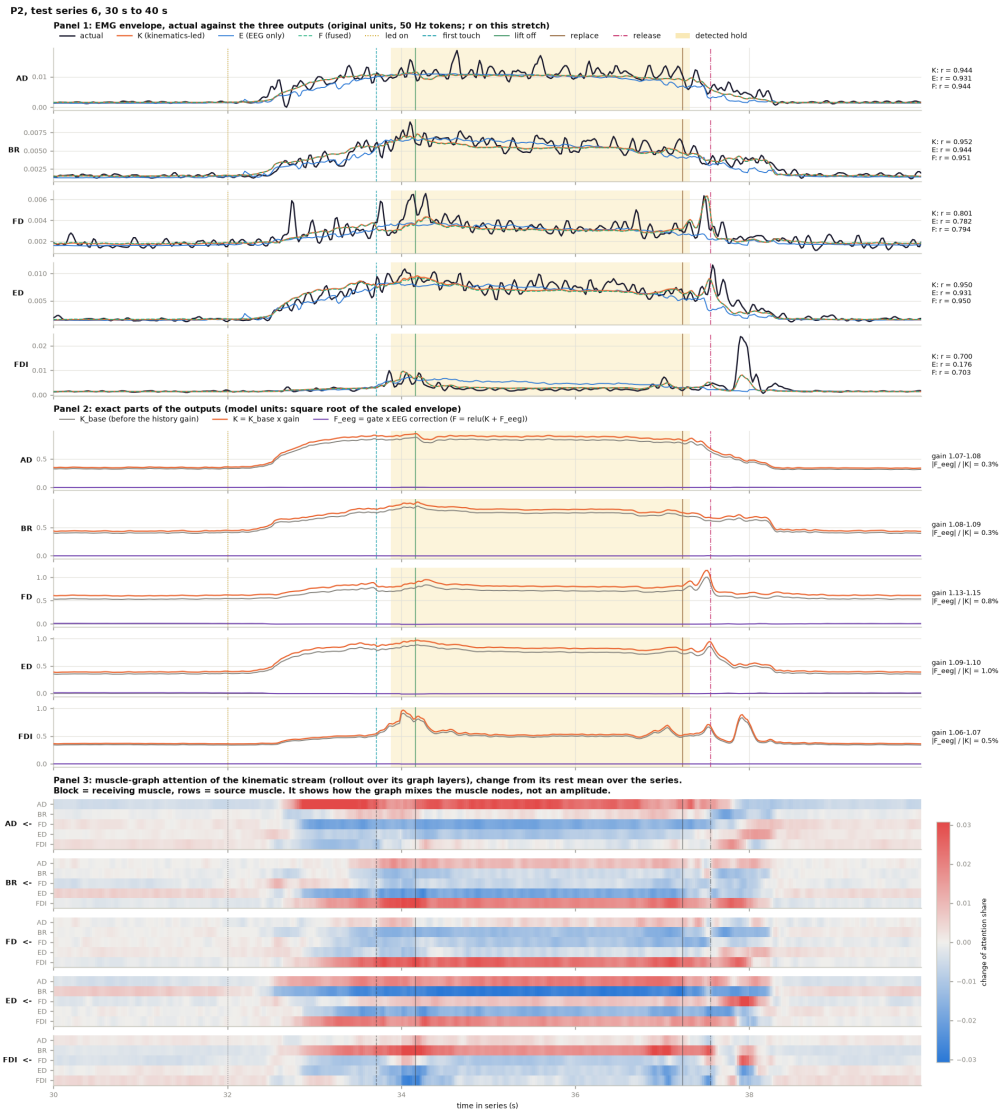
شکل ۱۲: P1، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰.



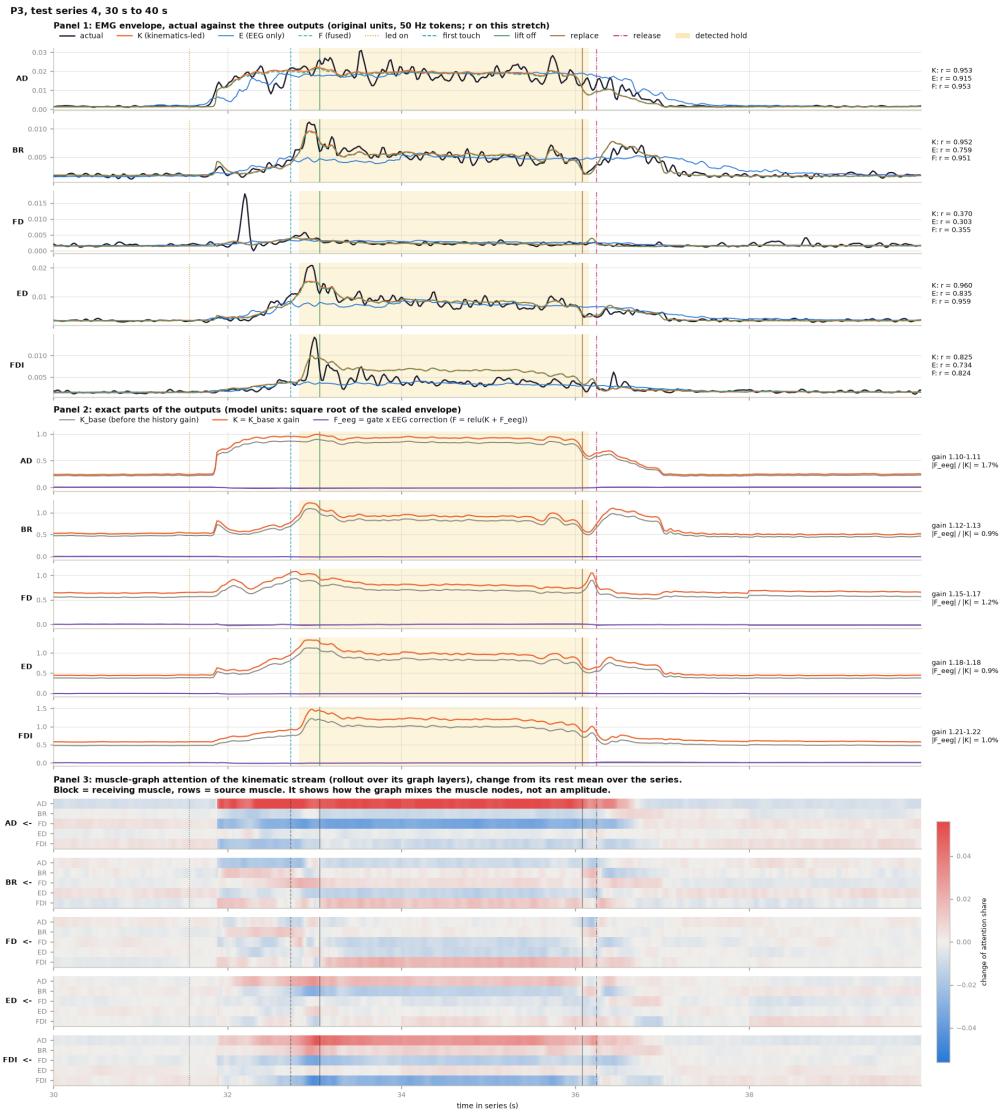
شکل ۱۳: P1، سری آزمون ۵، ثانیه‌ی ۳۰ تا ۴۰.



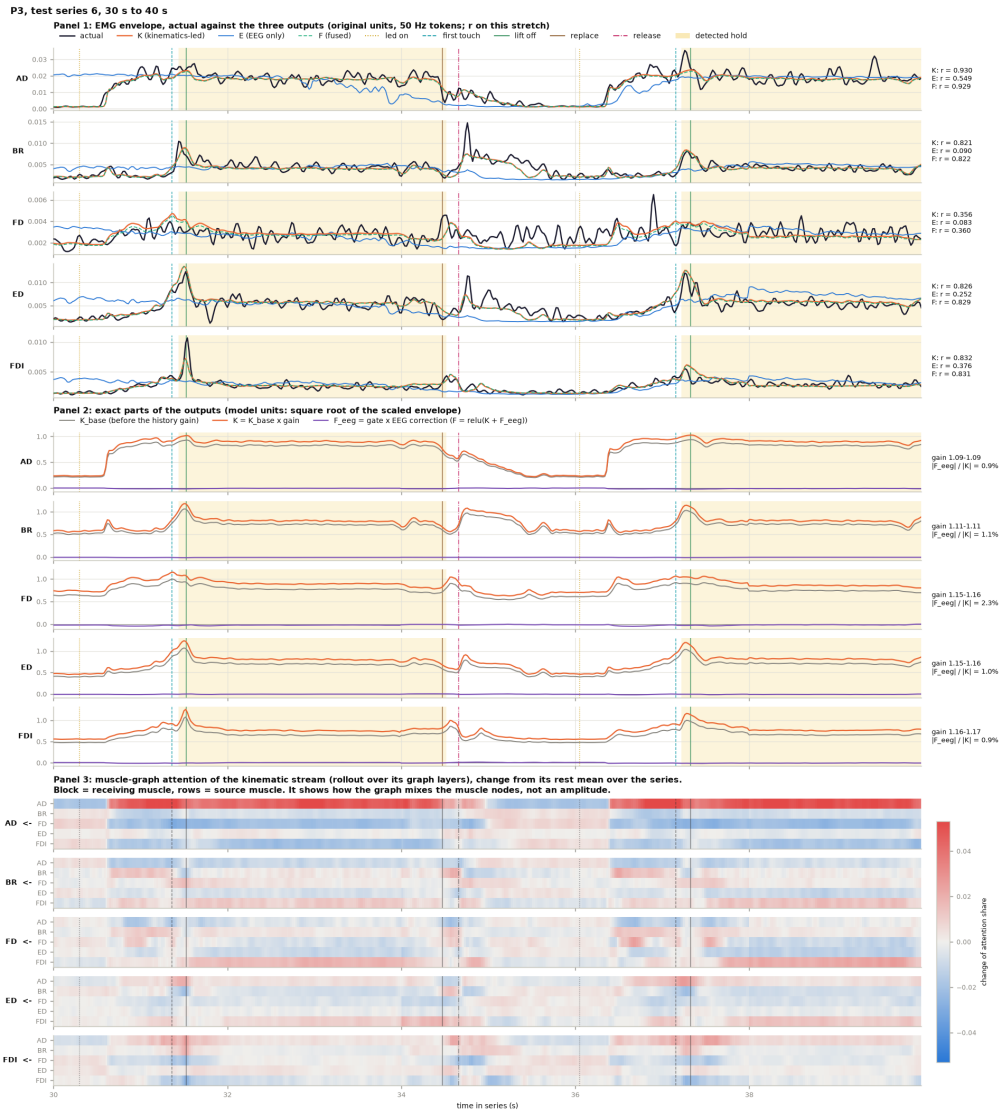
شکل ۱۴: P2، سری آزمون ۵، ثانیه‌ی ۳۰ تا ۴۰.



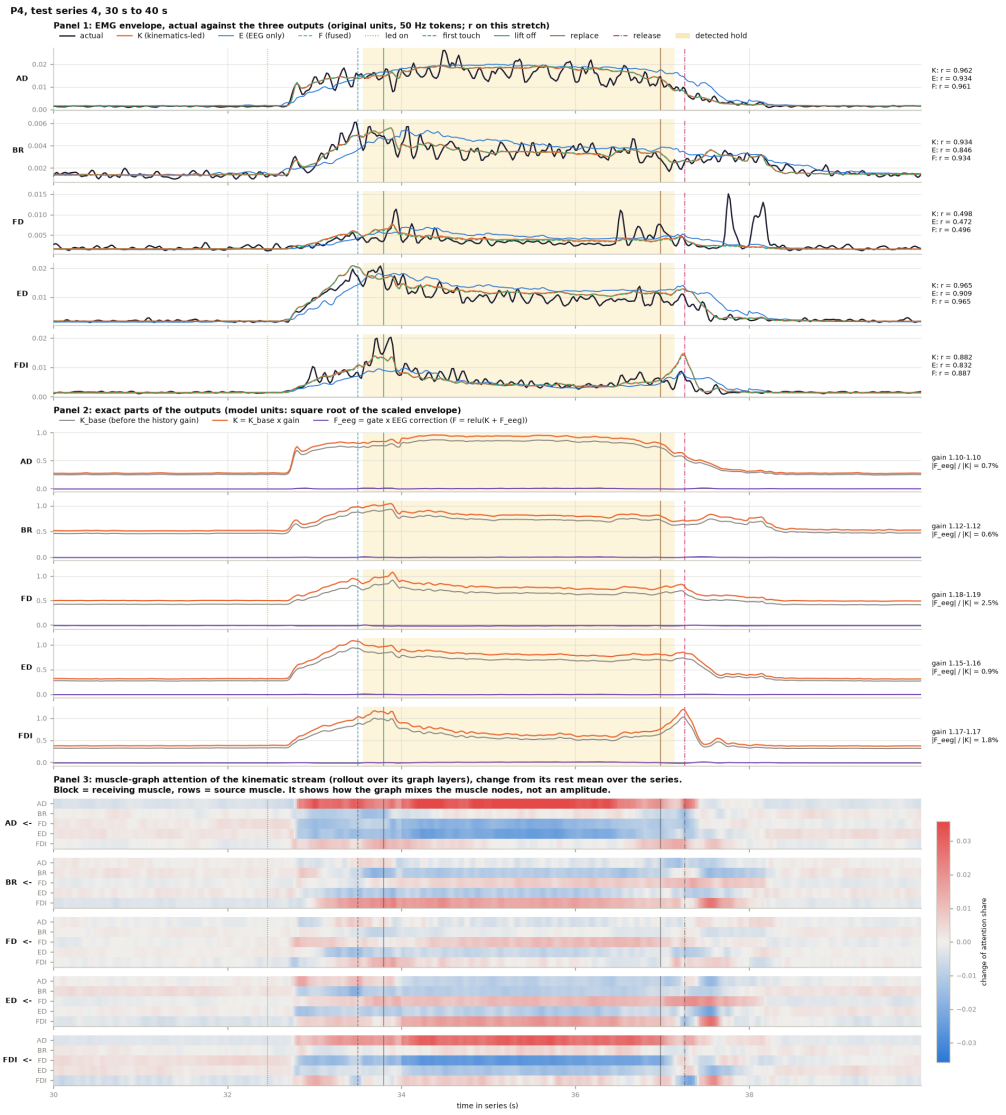
شکل ۱۵: P2، سری آزمون ۶، ثانیه‌ی ۳۰ تا ۴۰.



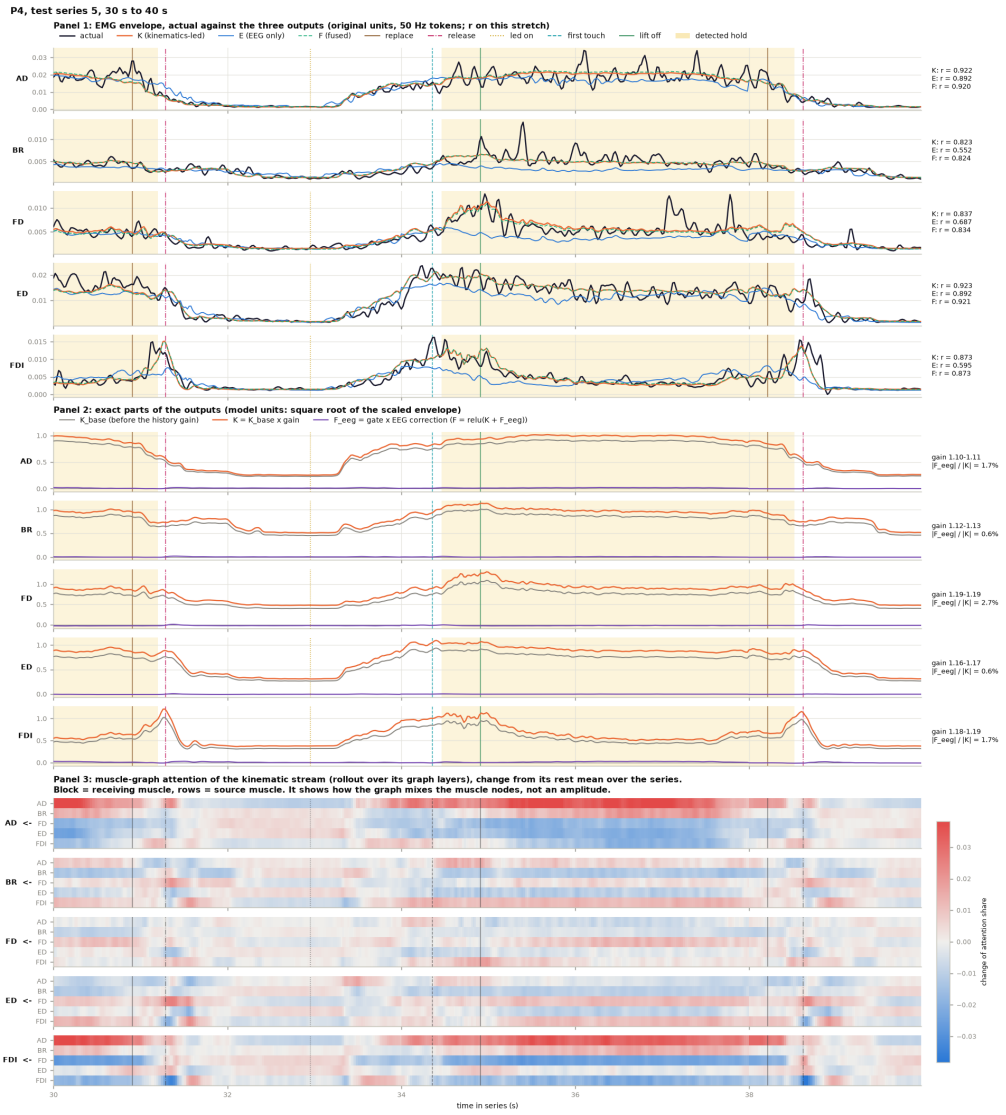
شکل ۱۶: P3، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰.



شکل ۱۷: P3، سری آزمون ۶، ثانیه‌ی ۳۰ تا ۴۰.



شکل ۱۸: P4، سری آزمون ۴، ثانیه‌ی ۳۰ تا ۴۰.



شکل ۱۹: P4، سری آزمون ۵، ثانیه‌ی ۳۰ تا ۴۰.

۸ تفسیرپذیری در v2

دقت به ما می‌گوید مدل چقدر خوب پیش‌بینی می‌کند. تفسیرپذیری می‌پرسد مدل برای این پیش‌بینی به کدام ورودی‌ها تکیه کرده است: کدام لحظه‌ها، کدام الکترودها، کدام باندها و کدام عضله‌ها. این بخش روش‌ها را توضیح می‌دهد، نشان می‌دهد چطور خودِ روش‌ها سنجیده شدند و نتایج را برای همه‌ی شرکت‌کننده‌ها و با جزئیات برای P1 و P2 می‌آورد.

۱.۸ چه چیزی توضیح داده می‌شود

هر توضیح درباره‌ی یک عدد مشخص است: خروجی o (یکی از K، E یا F_{eeg})، برای عضله‌ی c، در t token از یک پنجره‌ی ۸ ثانیه‌ای:

$$y = \mathrm{out}_o[t, c]. \tag{۸}$$

پنجره‌ها دور رخدادهای مهم آزمایش ساخته می‌شوند: «اولین تماس» (انگشت به جسم می‌رسد) و «جدا شدن» (lift-off، جسم از سطح بلند می‌شود). t وسط پنجره است، یعنی خودِ لحظه‌ی رخداد. پس پرسش این است: «مدل برای پیش‌بینی فعالیت عضله در لحظه‌ی رخداد، به کجای ورودی نگاه کرده است؟»

مسیری که هر خروجی از ورودی طی می‌کند:

- K: stem، سه لایه‌ی زمانی سینماتیک، دو لایه‌ی muscle graph؛
- E: دو لایه‌ی electrode graph، attention pooling، دو لایه‌ی زمانی EEG، دو لایه‌ی muscle graph؛
- F_{eeg}: electrode graph، attention pooling، لایه‌های زمانی EEG و cross-attention.

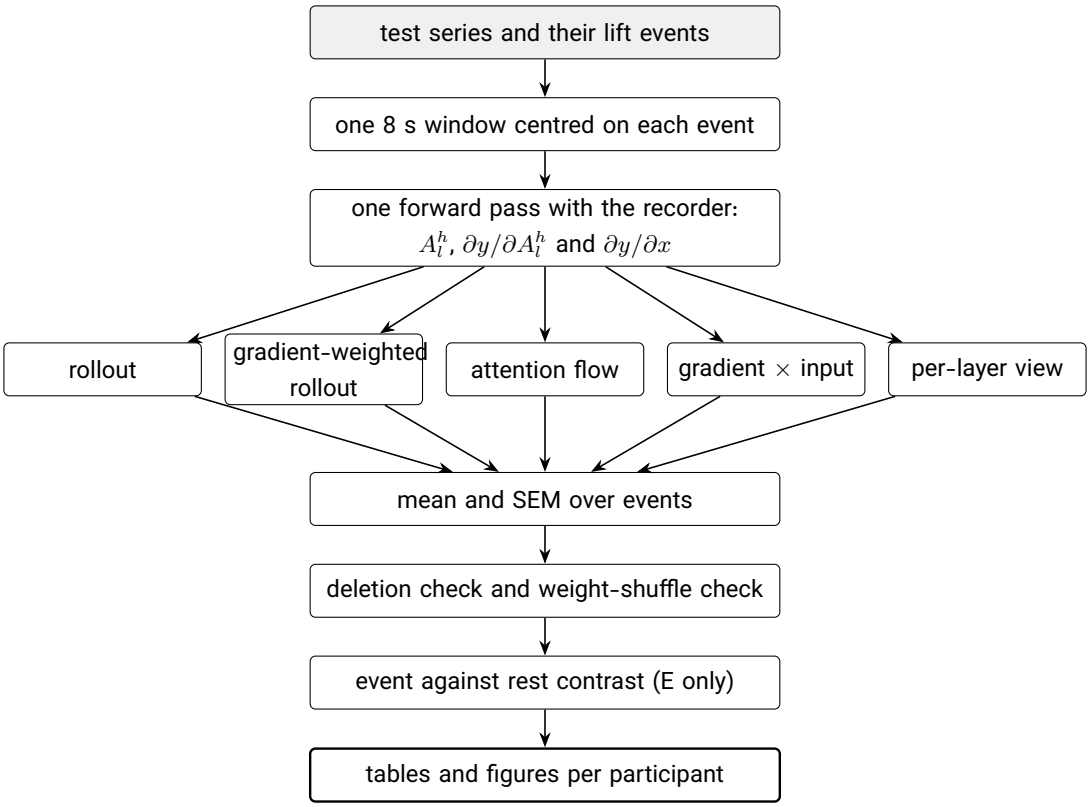
recorder در یک بار اجرای مدل، ماتریس توجه همه‌ی این لایه‌ها را برمی‌دارد: $A_l^h \in \mathbb{R}^{n \times n}$ برای لایه‌ی l و سر h. همه‌ی روش‌های زیر از همین ماتریس‌ها یا از گرادیان y نسبت به آن‌ها ساخته می‌شوند. شکل ۲۰ کل فرایند را نشان می‌دهد.

۲.۸ attention rollout و attention flow

این دو روش توجه همه‌ی لایه‌ها را پشت سر هم ترکیب می‌کنند تا از خروجی به ورودی برسند. چون پایه‌ی بیشتر نتایج این گزارش‌اند، بخش جداگانه‌ی ۹ آن‌ها را با جزئیات توضیح می‌دهد. برای این بخش همین کافی است: rollout در هر لایه ماتریس $\hat{A}_l = \frac{1}{2}\overline{A}_l + \frac{1}{2}I$ را می‌سازد (میانگین سرها، به‌علاوه‌ی راه مستقیم residual connection) و این ماتریس‌ها را در هم ضرب می‌کند: $R = \hat{A}_L \cdots \hat{A}_1$. نتیجه برای هر token ورودی یک سهم بین ۰ و ۱ است و جمع سهم‌ها ۱ می‌شود. این سهم برای هر پنج عضله‌ی یک جریان یکسان است، چون توجه زمانی بین عضله‌ها مشترک است.

۳.۸ gradient-weighted rollout

ایده. plain rollout همه‌ی توجه‌ها را به یک اندازه مهم می‌داند. اما ممکن است یک سر توجه، اطلاعاتی را جابه‌جا کند که برای عضله‌ی موردنظر اصلاً اهمیتی ندارد. gradient-weighted rollout [۵] این را اصلاح می‌کند: هر وزن توجه در گرادیان خروجی نسبت به همان وزن ضرب می‌شود. گرادیان می‌گوید اگر این وزن کمی بیشتر شود، خروجی چقدر و در کدام جهت تغییر می‌کند. فقط بخش مثبت نگه داشته می‌شود، یعنی توجه‌هایی که خروجی را بالا می‌برند. چون گرادیان برای هر عضله فرق می‌کند، نقشه هم برای هر عضله جداست.

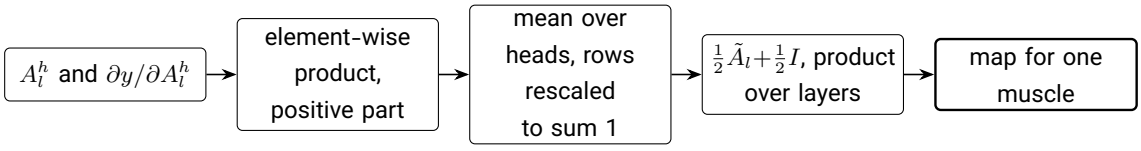


شکل ۲۰: فرایند تفسیر در v2: هر روش از یک اجرای ثبت‌شده ساخته می‌شود، روی رخدادها میانگین گرفته می‌شود و پیش از هر ادعا، خود روش سنجیده می‌شود.

ریاضی.

$$G_l = \frac{1}{H}\sum_h \Big(A_l^h \odot \frac{\partial y}{\partial A_l^h}\Big)^+, \qquad \tilde{A}_l = \frac{G_l}{G_l \mathbf{1}}, \qquad R^{\nabla} = \prod_{l=L}^{1}\Big(\tfrac{1}{2}\tilde{A}_l + \tfrac{1}{2}I\Big). \tag{۹}$$

$(\cdot)^+$ مقادیر منفی را صفر می‌کند. تقسیم بر $G_l\mathbf{1}$ هر سطر را دوباره به جمع ۱ می‌رساند؛ سطری که همه‌اش صفر شده همان I می‌ماند. بقیه‌ی کار دقیقاً مثل rollout است. گرادیان‌ها با recorder در حالت grad=True گرفته می‌شوند.



شکل ۲۱: gradient-weighted rollout.

۴.۸ نمای هر لایه

rollout لایه‌ها را با هم ترکیب می‌کند و نمی‌گوید کدام لایه چه کرده است. نمای هر لایه همین را نشان می‌دهد: توجه هر لایه و هر سر در لحظه‌ی رخداد، بدون ترکیب. برای لایه‌های زمانی سطر t از A_l^h، و برای electrode graph و muscle graph کل ماتریس رسم می‌شود.

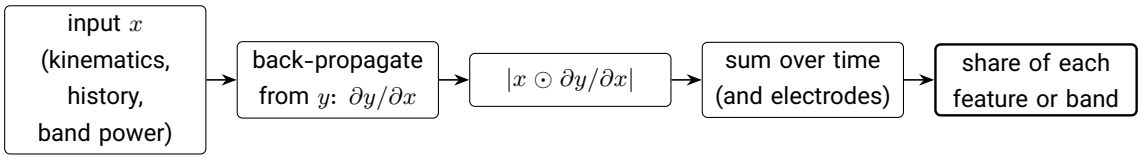
۵.۸ gradient × input

ایده. rollout فقط لایه‌های توجه را می‌بیند. لایه‌هایی مثل embedding، feed-forward و decoder در آن غایب‌اند، و rollout نمی‌تواند بگوید کدام ویژگی ورودی (مثلاً کدام باند EEG) مهم بوده است. gradient × input [۶] از کل مدل استفاده می‌کند: مقدار هر ورودی را در گرادیان خروجی نسبت به آن ضرب می‌کند. نتیجه تقریباً می‌گوید اگر این ورودی صفر شود، خروجی چقدر تغییر می‌کند.

ریاضی. برای ورودی x (سینماتیک، تاریخچه یا EEG band power):

$$s_i = \left| x_i \, \frac{\partial y}{\partial x_i} \right|. \tag{۱۰}$$

برای هر ویژگی سینماتیک، s روی زمان جمع زده می‌شود. برای هر باند EEG، روی زمان و همه‌ی الکترودها. سپس عددها به سهم (با جمع ۱) تبدیل می‌شوند.



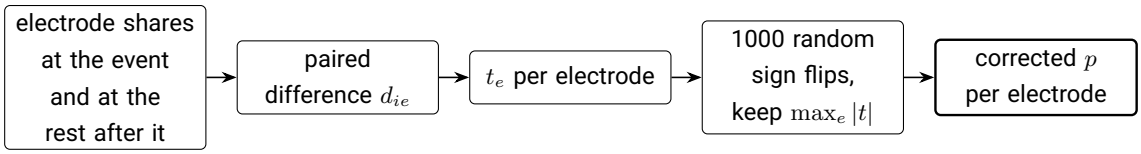
شکل ۲۲: gradient × input.

۶.۸ میانگین روی رخدادها و مقایسه با استراحت

میانگین روی رخدادها. نقشه‌ی یک پنجره‌ی تنها پرنویز است، پس هیچ نقشه‌ای از یک پنجره گزارش نمی‌شود. برای هر رخداد یک پنجره ساخته می‌شود، نقشه‌اش به سهم (جمع ۱) تبدیل می‌شود و سپس میانگین و خطای استاندارد ($\mathrm{SEM} = \sigma/\sqrt{n}$) روی همه‌ی رخدادها گرفته می‌شود. رخدادی که پنجره‌ی ۸ ثانیه‌ای‌اش در سری جا نشود کنار گذاشته می‌شود.

مقایسه با استراحت (فقط برای E). حتی اگر یک الکترود سهم بالایی داشته باشد، شاید همیشه سهم بالایی داشته باشد و ربطی به حرکت نداشته باشد. برای جدا کردن این دو، هر بلندکردن با یک پنجره‌ی استراحت بعد از آن (وسط فاصله‌ی دو بلندکردن) جفت می‌شود. برای هر الکترود e تفاوت سهم در رخداد و استراحت ($d_{ie} = a_{ie} - b_{ie}$) و آماره‌ی $t_e = \bar{d}_e/(s_e/\sqrt{n})$ حساب می‌شود. t بزرگ یعنی این الکترود در رخداد به‌طور پایدار سهم بیشتری دارد تا در استراحت.

برای p، علامت تفاوت هر جفت ۱۰۰۰ بار به‌طور تصادفی برگردانده می‌شود. هر بار بزرگ‌ترین $|t|$ روی همه‌ی ۳۲ الکترود نگه داشته می‌شود و p هر الکترود از مقایسه با این بیشینه‌ها به دست می‌آید (max-T، [۹]). این کار دو مزیت دارد. اول، خطای ناشی از آزمودن ۳۲ الکترود با هم را کنترل می‌کند. دوم، چون رخداد و استراحت از یک سری و یک مدل‌اند، هر اثری که در هر دو مشترک است (مثلاً ساختار خود پنجره) در تفاوت حذف می‌شود.



شکل ۲۳: مقایسه‌ی رخداد با استراحت.

۷.۸ سنجش خودِ روش‌ها

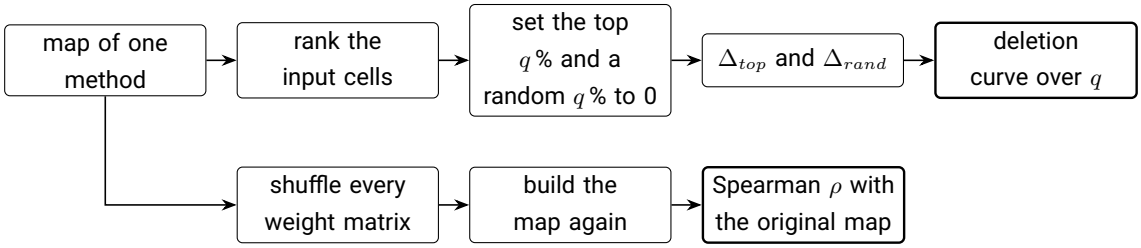
هر روش تفسیری یک نقشه می‌دهد، ولی این به معنای درست بودن نقشه نیست. دو آزمون می‌سنجند که نقشه‌ها واقعاً چیزی درباره‌ی مدل آموزش‌دیده می‌گویند.

deletion check [۷]. اگر یک روش درست بگوید کدام ورودی‌ها مهم‌اند، حذف همان ورودی‌ها باید خروجی را بیشتر از حذف ورودی‌های تصادفی تغییر دهد. «حذف» یعنی صفر کردن، که چون داده‌ها استانداردند برابر میانگین آموزش است. برای EEG هر خانه یک الکترود در یک token است (هر چهار باند با هم)، و برای سینماتیک همه‌ی ویژگی‌های یک token. ۵، ۱۰، ۲۰ و ۴۰ درصد از مهم‌ترین خانه‌ها حذف و با حذف همان تعداد خانه‌ی تصادفی (میانگین ۱۰ بار) مقایسه می‌شوند:

$$\Delta_{top}(q) = \big|\, y(x) - y(x_{\setminus \mathrm{top}(q)}) \,\big|, \qquad \Delta_{rand}(q) = \mathrm{mean}_{10} \big|\, y(x) - y(x_{\setminus \mathrm{rand}(q)}) \,\big|. \tag{۱۱}$$

$x_{\setminus \mathrm{top}(q)}$ ورودی بدون q درصد خانه‌های برتر است و $x_{\setminus \mathrm{rand}(q)}$ ورودی بدون همان تعداد خانه‌ی تصادفی. هر چه Δ_{top} یک روش بزرگ‌تر باشد، آن روش ورودی‌های واقعاً اثرگذار را بهتر پیدا کرده است.

weight-shuffle check [۸]. یک نسخه از مدل ساخته می‌شود که درایه‌های هر ماتریس وزن آن به‌هم ریخته شده است؛ یعنی مدلی با همان معماری که هیچ چیز یاد نگرفته. نقشه‌ها برای این مدل هم ساخته و با نقشه‌های مدل واقعی مقایسه می‌شوند (Spearman correlation). اگر نقشه‌ی مدل به‌هم‌ریخته هم همان شکل را داشته باشد، آن شکل از معماری آمده و نه از آنچه مدل یاد گرفته؛ پس درباره‌ی داده چیزی نمی‌گوید. همبستگی خوب نزدیک صفر است.



شکل ۲۴: deletion check (بالا) و weight-shuffle check (پایین).

۸.۸ نتایج برای همه‌ی شرکت‌کننده‌ها

کدام روش ورودی‌های مهم را بهتر پیدا می‌کند؟ جدول ۱۲ پاسخ deletion check است. برای E، gradient-weighted rollout با فاصله‌ی زیاد بهترین روش است: حذف خانه‌های برتر آن خروجی را ۰٫۲۰۵ تغییر می‌دهد، در حالی که این عدد برای روش‌های دیگر حدود ۰٫۰۹ و برای حذف تصادفی ۰٫۰۲۱ است. این روش در هر ۱۲ شرکت‌کننده اول است (جدول ۱۴). برای K، سه روش rollout، gradient-weighted rollout و gradient × input تقریباً برابرند و attention flow ضعیف‌تر است. همه‌ی روش‌ها از حذف تصادفی بهترند.

جدول ۱۲: deletion check، میانگین روی ۱۲ شرکت‌کننده، پنج عضله و چهار کسر حذف (۵، ۱۰، ۲۰ و ۴۰ درصد): تغییر خروجی (واحد مدل) وقتی ورودی‌هایی که هر روش مهم‌تر می‌داند حذف می‌شوند. بزرگ‌تر بهتر است.

خروجی	حذف تصادفی	rollout	attention flow	gradient-weighted rollout	gradient × input
E	۰٫۰۲۱	۰٫۰۹۸	۰٫۰۹۳	۰٫۲۰۵	۰٫۰۹۲
K	۰٫۰۳۷	۰٫۲۱۲	۰٫۱۱۸	۰٫۲۱۳	۰٫۲۱۱

کدام نقشه‌ها واقعاً از یادگیری می‌آیند؟ جدول ۱۳ یک هشدار دارد. K plain rollout برای مدل به‌هم‌ریخته هم شکل مشابهی دارد (همبستگی اسپیرمن ۰٫۴۷). دلیلش ساختار مدل است: residual connection و ردپای stem همیشه بیشترین سهم را به token خودِ رخداد و همسایه‌هایش می‌دهند، چه مدل آموزش دیده باشد چه نه. برای E، input × gradient کمترین وابستگی به یادگیری را دارد (۰٫۲۷). gradient-weighted rollout در هر دو خروجی نزدیک صفر است.

نتیجه‌ی این دو آزمون با هم: gradient-weighted rollout هم ورودی‌های مهم را بهتر پیدا می‌کند و هم کمتر از ساختار مدل اثر می‌گیرد. برای همین روش اصلی ادعاهای این گزارش است.

جدول ۱۳: weight-shuffle check: Spearman correlation بین نقشه‌ی مدل آموزش‌دیده و نقشه‌ی مدلی با ماتریس‌های وزنِ به‌هم‌ریخته (میانگین روی ۱۲ شرکت‌کننده). نزدیک صفر بهتر است: یعنی نقشه به آموخته‌های مدل وابسته است.

خروجی	rollout	attention flow	gradient-weighted rollout	gradient × input
E	۰٫۰۳۶	۰٫۰۷۵	۰٫۰۱۲	۰٫۲۷۱
K	۰٫۴۷۳	-۰٫۰۰۸	۰٫۰۷۰	۰٫۰۷۶

جدول ۱۴: اجزای دقیق خروجی در پنجره‌های رخداد و بهترین روش تفسیر برای E در هر شرکت‌کننده.

شرکت‌کننده	بازه‌ی history gain	$\lvert F_{eeg}\rvert/K$ (%)	بیشینه‌ی $\lvert g\rvert$	بهترین روش در deletion check (E)
P1	۱٫۰۹–۱٫۲۰	۰٫۶۹	۰٫۰۱۵	gradient-weighted rollout
P2	۱٫۰۶–۱٫۱۳	۰٫۱۵	۰٫۰۱۴	gradient-weighted rollout
P3	۱٫۱۰–۱٫۱۸	۱٫۰۱	۰٫۰۱۷	gradient-weighted rollout
P4	۱٫۱۰–۱٫۱۹	۰٫۶۰	۰٫۰۲۶	gradient-weighted rollout
P5	۱٫۰۴–۱٫۱۱	۰٫۵۷	۰٫۰۲۶	gradient-weighted rollout
P6	۱٫۰۸–۱٫۱۵	۱٫۱۴	۰٫۰۲۴	gradient-weighted rollout
P7	۱٫۱۱–۱٫۱۸	۰٫۹۱	۰٫۰۱۸	gradient-weighted rollout
P8	۱٫۰۸–۱٫۱۸	۲٫۲۲	۰٫۰۴۲	gradient-weighted rollout
P9	۱٫۰۸–۱٫۱۸	۰٫۶۵	۰٫۰۱۲	gradient-weighted rollout
P10	۱٫۰۹–۱٫۲۶	۰٫۸۳	۰٫۰۱۰	gradient-weighted rollout
P11	۱٫۰۸–۱٫۱۴	۱٫۰۹	۰٫۰۱۵	gradient-weighted rollout
P12	۱٫۰۹–۱٫۱۷	۱٫۰۶	۰٫۰۲۱	gradient-weighted rollout

۹.۸ نتایج P1 و P2: هر شکل چه می‌گوید

همه‌ی شکل‌های این بخش برای رخداد «جدا شدن» (lift_off) و میانگین روی همه‌ی بلندکردن‌های سری‌های آزمون هستند. شکل‌ها بر اساس نوعشان دسته‌بندی شده‌اند و از هر نوع، شکل P1 و P2 کنار هم آمده تا بتوان دو نفر را مقایسه کرد. برای هر نوع شکل سه چیز توضیح داده می‌شود: چه چیزی رسم شده، چطور خوانده می‌شود و چه نتیجه‌ای از آن می‌گیریم.

۱. شکل زمانی K: مدل سینماتیک به کدام لحظه‌ها نگاه می‌کند؟

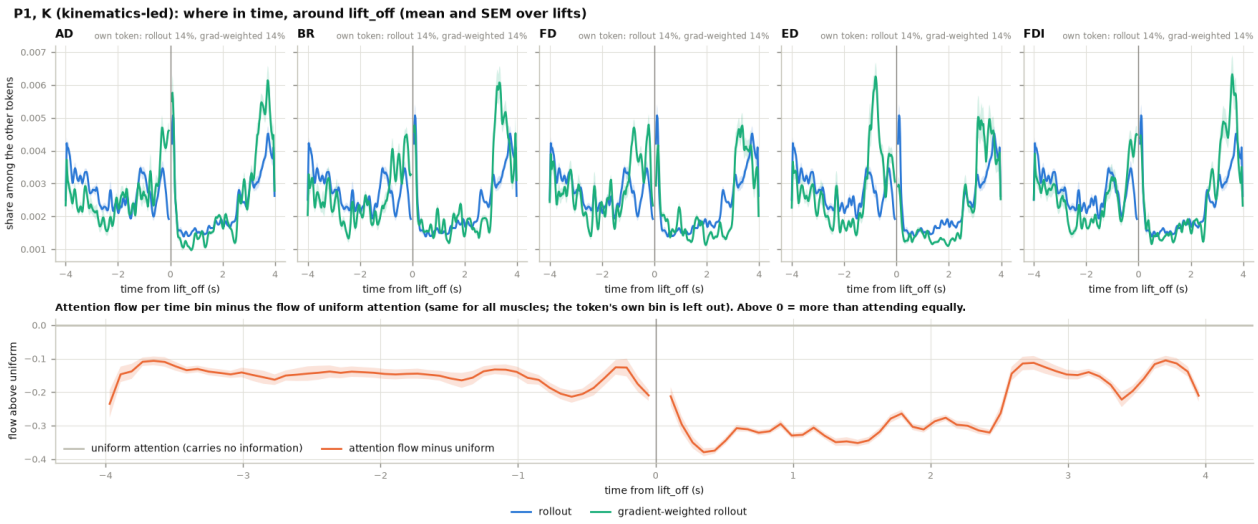
چه رسم شده. پنج پنل بالا یکی برای هر عضله است. محور افقی زمان نسبت به لحظه‌ی جدا شدن است، از ۴ ثانیه قبل تا ۴ ثانیه بعد (کل پنجره‌ی ۸ ثانیه‌ای مدل). محور عمودی سهم هر token ورودی در پیش‌بینی K در لحظه‌ی صفر است. آبی rollout و سبز gradient-weighted rollout است و نوار کم‌رنگ دور هر منحنی SEM روی بلندکردن‌هاست. سهم خودِ token رخداد و همسایه‌هایش بالای هر پنل به‌صورت عدد نوشته شده («own token: 14%») و منحنی سهم بقیه‌ی tokens است. پنل پایین attention flow منهای جریان توجه یکنواخت است؛ صفر یعنی «مثل مدلی که به همه‌جا یکسان نگاه می‌کند» و منفی یعنی مدل راه آن لحظه را تنگ کرده است.

چطور بخوانیم. جایی که منحنی بالاتر است، مدل برای پیش‌بینی فعالیت عضله در لحظه‌ی جدا شدن بیشتر از اطلاعات آن لحظه استفاده کرده است. اگر منحنی صاف بود، یعنی همه‌ی لحظه‌ها به یک اندازه مهم بودند و مدل جای خاصی را ترجیح نمی‌داد.

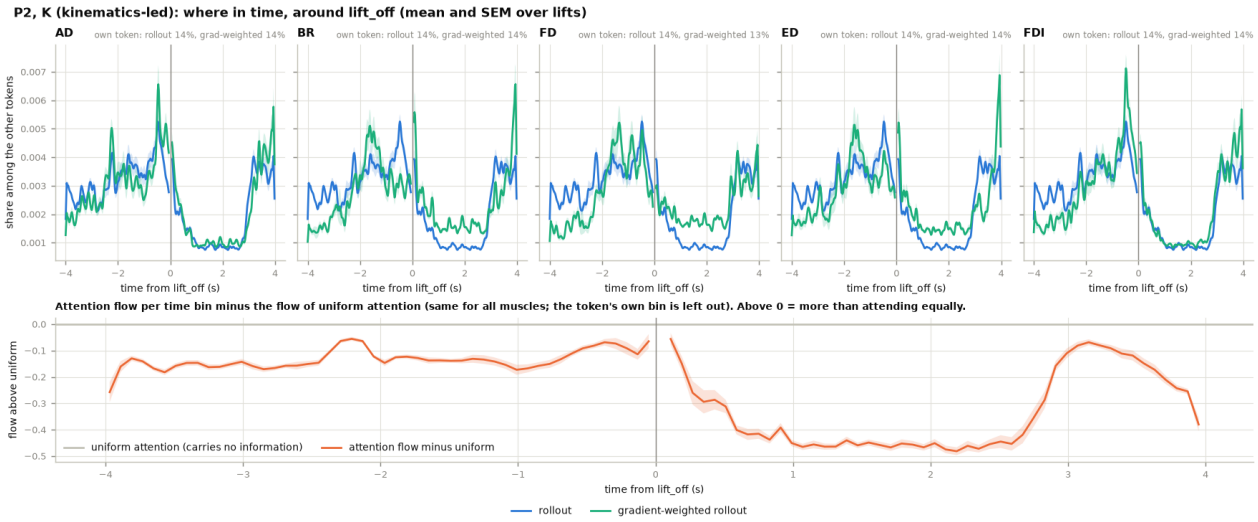
چه می‌فهمیم. در هر دو نفر الگو یکی است و سه بخش دارد:

- **پیش از رخداد (۴ ثانیه تا صفر):** سهم بالاست. در P2 از حدود ۲ ثانیه پیش از جدا شدن بالا می‌رود و درست پیش از صفر به اوج می‌رسد. این همان بازه‌ای است که دست به جسم می‌رسد، آن را می‌گیرد و نیروی بار را بالا می‌برد. پس K برای پیش‌بینی فعالیت عضله در لحظه‌ی جدا شدن، به حرکت و نیروی پیش از آن نگاه می‌کند.
- **۰ تا حدود ۲٫۵ ثانیه بعد:** سهم کمترین است و جریان هم بیشترین افت را دارد (در P2 تا ۰٫۴۵-). این بازه آغاز نگه‌داشتن است، اما آن لحظه‌ها هنوز بعد از رخدادند و برای توضیح فعالیت در لحظه‌ی جدا شدن اطلاعات تازه‌ای ندارند.
- **حدود ۳ تا ۴ ثانیه بعد:** سهم دوباره بالا می‌رود. بخشی از این افزایش اثر لبه‌ی پنجره است که در همه‌ی افراد دیده می‌شود (بخش ۱۰) و نباید آن را به رویداد حرکتی نسبت داد.

منحنی آبی در پنج پنل تقریباً یکی است، چون rollout زمانی به عضله بستگی ندارد. منحنی سبز برای هر عضله قله‌های خودش را دارد؛ مثلاً در ED P1 قله‌ی بلندی حدود ۰٫۸ ثانیه پیش از رخداد دارد. یعنی گرادیان نشان می‌دهد هر عضله به لحظه‌ی کمی متفاوتی از حرکت حساس است.



شکل ۲۵: P1، خروجی K: سهم هر token زمانی در اطراف جدا شدن جسم (بالا) و attention flow منهای uniform- attention flow (پایین).



شکل ۲۶: P2، خروجی K: سهم زمانی و attention flow منهای خط پایه. همان الگوی P1: سهم بالا پیش از رخداد، کمترین سهم در ۰ تا ۲٫۵ ثانیه بعد.

۲. شکل زمانی E: مدل EEG به کدام لحظه‌ها نگاه می‌کند؟

چه رسم شده. مثل شکل قبل، اما برای خروجی E که فقط EEG می‌بیند.

چه می‌فهمیم. سه تفاوت با K دارد:

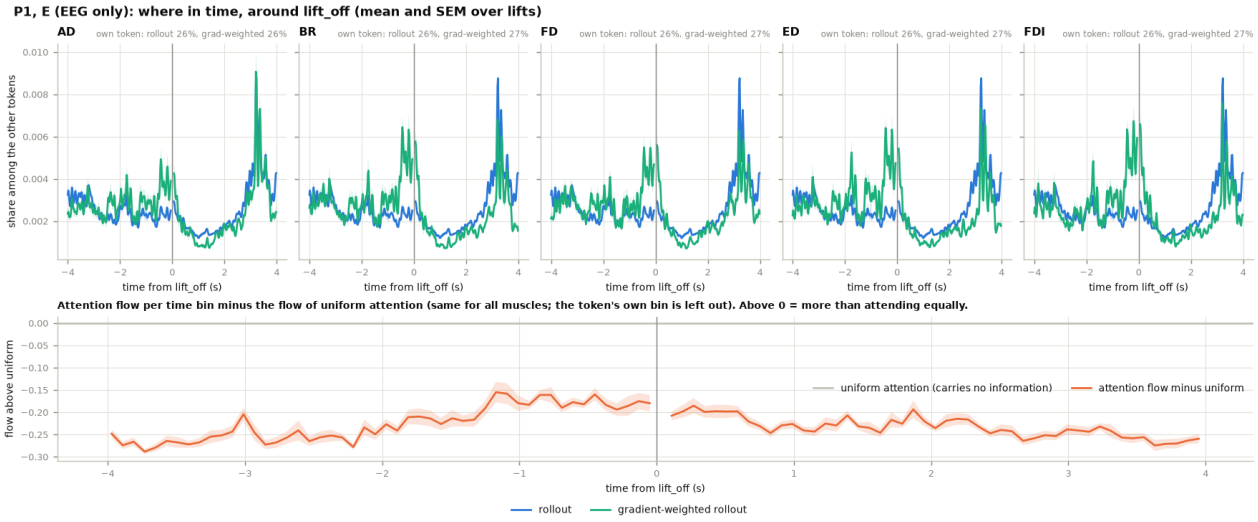
- **سهم خودِ لحظه بیشتر است:** در P1 حدود ۲۶ درصد در برابر ۱۴ درصد برای K. یعنی E بیشتر به توان باندهای EEG در همان لحظه تکیه می‌کند و کمتر به گذشته.
- **منحنی صاف‌تر است:** سهم لحظه‌های دیگر تقریباً یکسان است و ساختار زمانی روشنی مثل K ندارد. در P1 سبز کمی پیش از صفر بالا می‌رود که با زمان‌بندی ERD پیش از حرکت سازگار است. در P2 حتی این هم دیده نمی‌شود.
- **جهش‌های تیز در اواخر پنجره:** در P1 یک قله‌ی تیز حدود ۳٫۲ ثانیه بعد از رخداد هست و در P2 جهش در لبه‌ی پنجره. چون این قله‌ها در همه‌ی افراد در یک زمان نیستند (بخش ۱۰)، نمی‌توان آن‌ها را به یک رویداد حرکتی مشخص نسبت داد.

پنل جریان برای E تقریباً صاف و همه‌جا حدود ۰٫۲- است. یعنی جریان در مسیر EEG درباره‌ی زمان تقریباً چیزی نمی‌گوید.

۳. نقشه‌ی سر: E از کدام الکترودها اطلاعات می‌گیرد؟

چه رسم شده. هر دایره سر از بالاست (بینی بالا، گوش‌ها در دو طرف) و نقطه‌ها جای ۳۲ الکترود. رنگ سهم هر الکترود است: هر چه تیره‌تر، سهم بیشتر. سهم یکنواخت برای هر الکترود ۱/۳۲ ≈ ۰٫۰۳۱ است؛ پس رنگ‌های تیره‌تر از وسط نوار رنگ یعنی سهمی بیشتر از حالت یکنواخت. اولین دایره rollout است (برای همه‌ی عضله‌ها یکی) و پنج دایره‌ی بعد gradient-weighted rollout برای هر عضله. بین الکترودها درون‌یابی شده تا نقشه پیوسته دیده شود.

چطور بخوانیم. کانون‌های تیره جاهایی‌اند که E بیشترین اطلاعات را از آن‌ها گرفته است. ناحیه‌ی مرکزی چپ (C3، FC5، CP5) بالای قشر حرکتی دست راست است و انتظار داریم آنجا مهم باشد. پیشانی (Fp1، Fp2، F7، F8)



شکل ۲۷: P1، خروجی E: سهم زمانی و attention flow منهای خط پایه. سهم خودِ لحظه ۲۶ درصد است، بیشتر از K.

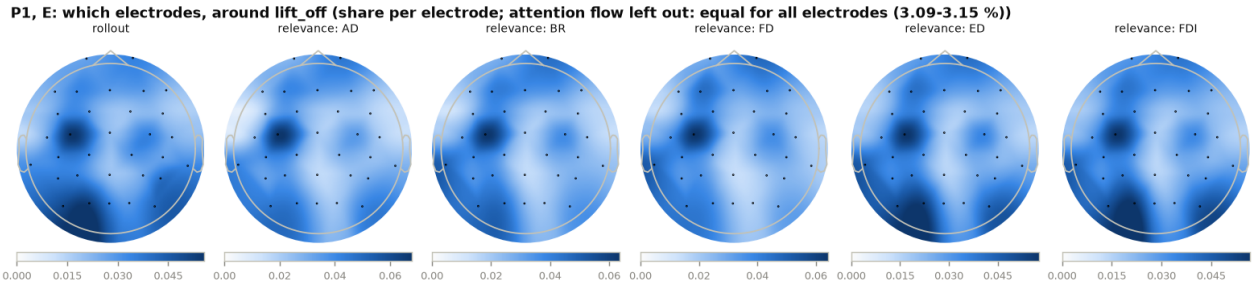


شکل ۲۸: P2، خروجی E: سهم زمانی و attention flow منهای خط پایه. منحنی تقریباً صاف است و فقط در لبه‌ی پنجره جهش دارد.

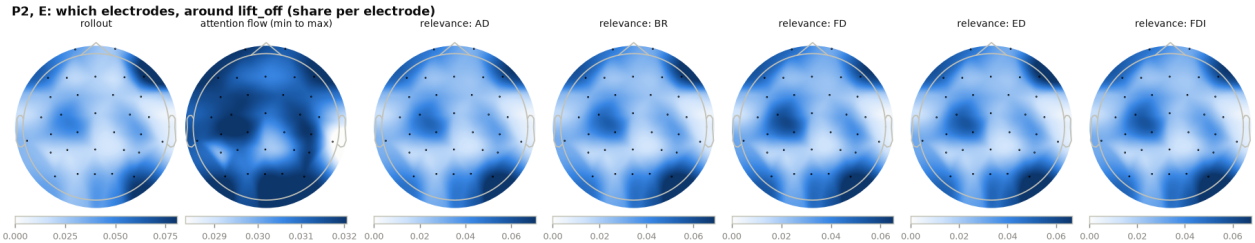
به حرکت چشم حساس است، و پس‌سری و گیجگاهی (O1، O2، PO9، PO10، TP9، TP10) به پردازش بینایی و فعالیت عضلات گردن.

چه می‌فهمیم.

- در P1 قوی‌ترین کانون روی مرکزی چپ است؛ یعنی همان جایی که از نظر فیزیولوژی انتظار داریم. کانون کوچک‌تری روی مرکزی راست (C4) و کانون قوی دیگری روی پس‌سری هم هست.
- در P2 کانون مرکزی چپ ضعیف‌تر است و بیشترین سهم روی لبه‌های سر، به‌خصوص پیشانی راست و پس‌سری، است. این نشانه‌ی احتمال artifact است.
- پنج نقشه‌ی عضله‌ها در هر نفر تقریباً یکسان‌اند. پس E برای همه‌ی عضله‌ها از یک جای سر می‌خواند و نقشه‌ی خاص هر عضله نمی‌سازد؛ این با خواندن «مرحله‌ی کلی حرکت» سازگار است، نه فرمان جداگانه برای هر عضله.
- در P1 نقشه‌ی attention flow رسم نشده، چون سهم همه‌ی الکترودها بین ۳٫۰۹ و ۳٫۱۵ درصد است و نقشه چیزی جز رنگ یکسان نشان نمی‌داد. در P2 رسم شده، اما نوار رنگش فقط از ۰٫۰۲۹ تا ۰٫۰۳۲ است؛ تفاوت‌ها بسیار کوچک‌اند.



شکل ۲۹: P1، خروجی E: سهم هر الکترود در rollout و در gradient-weighted rollout برای هر عضله. کانون اصلی روی مرکزی چپ (C3). نقشه‌ی attention flow رسم نشده، چون برای همه‌ی الکترودها تقریباً برابر است.



شکل ۳۰: P2، خروجی E: سهم هر الکترود. کانون مرکزی چپ ضعیف‌تر و سهم لبه‌های سر بیشتر است. جریان الکترودها کمی پراکندگی دارد (۱۱٫۵ درصد)، پس نقشه‌اش با رنگ از کمینه تا بیشینه رسم شده است.

۴. توجه هر لایه‌ی electrode graph: الکترودها از هم چه می‌خوانند؟

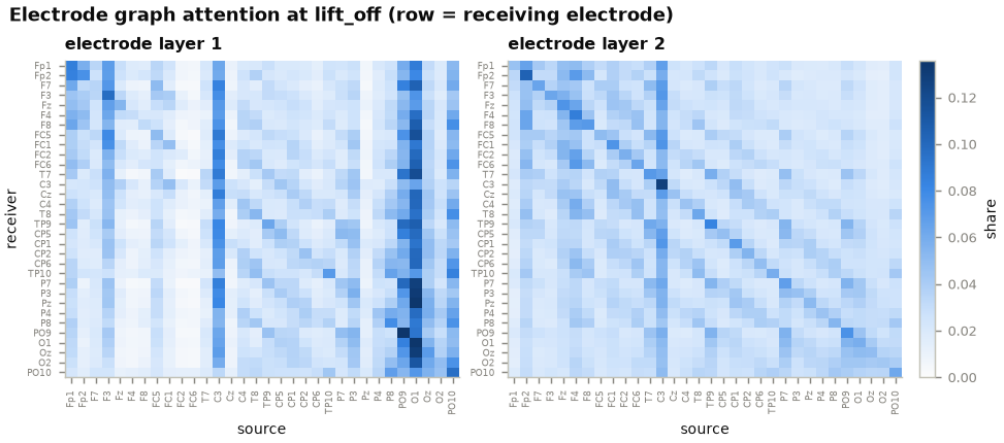
چه رسم شده. دو ماتریس ۳۲ × ۳۲، یکی برای هر لایه‌ی electrode graph، در لحظه‌ی جدا شدن و میانگین روی سرها. هر سطر الکترودی است که اطلاعات می‌گیرد و هر ستون الکترودی که اطلاعات می‌دهد. جمع هر سطر ۱ است.

چطور بخوانیم. یک ستون تیره که از بالا تا پایین ادامه دارد یعنی همه‌ی الکترودها از همان یک الکترود می‌خوانند؛ آن الکترود یک «مرکز پخش» است. قطر تیره یعنی هر الکترود بیشتر اطلاعات خودش را نگه می‌دارد.

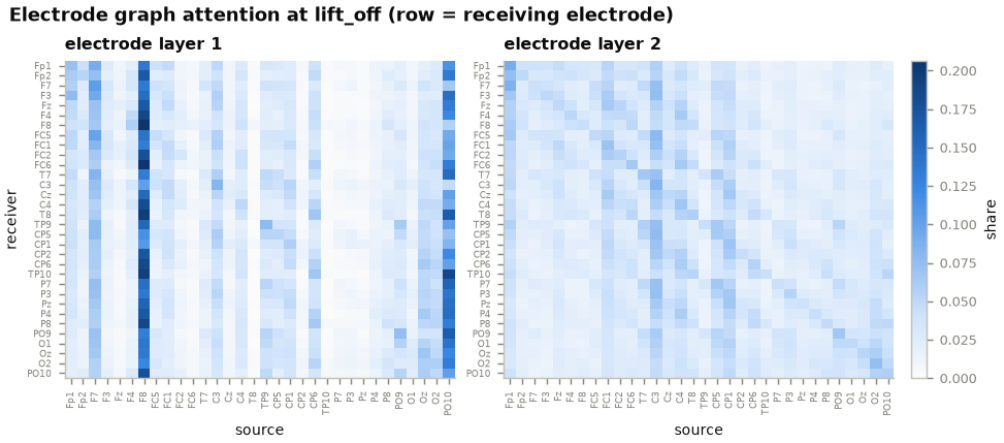
چه می‌فهمیم. لایه‌ی اول در هر دو نفر چند مرکز پخش دارد و لایه‌ی دوم بیشتر قطری است. یعنی لایه‌ی اول اطلاعات چند الکترود خاص را به همه می‌رساند و لایه‌ی دوم آن را با اطلاعات خود هر الکترود ترکیب می‌کند. نکته‌ی مهم این است که مرکزها کدام‌اند:

- در P1: C3 (قشر حرکتی چپ) و PO9/O1 (پس‌سری). C3 در لایه‌ی دوم هم یک ستون تیره دارد.
- در P2: F8 و F7 (پیشانی، نزدیک چشم‌ها) و TP10/PO10 (پشت گوش و گردن).

این شکل توضیح می‌دهد نقشه‌ی سر از کجا آمده است: نقشه‌ی P1 بیشتر از قشر حرکتی می‌آید و نقشه‌ی P2 بیشتر از الکترودهایی که به حرکت چشم و عضلات گردن حساس‌اند. پس اطلاعات E در P2 احتمالاً بیشتر از artifact است تا از قشر حرکتی.



شکل ۳۱: P1: توجه دو لایه‌ی electrode graph در لحظه‌ی جدا شدن (سطر = الکترود گیرنده). مرکزهای پخش در لایه‌ی اول: C3 و O1.



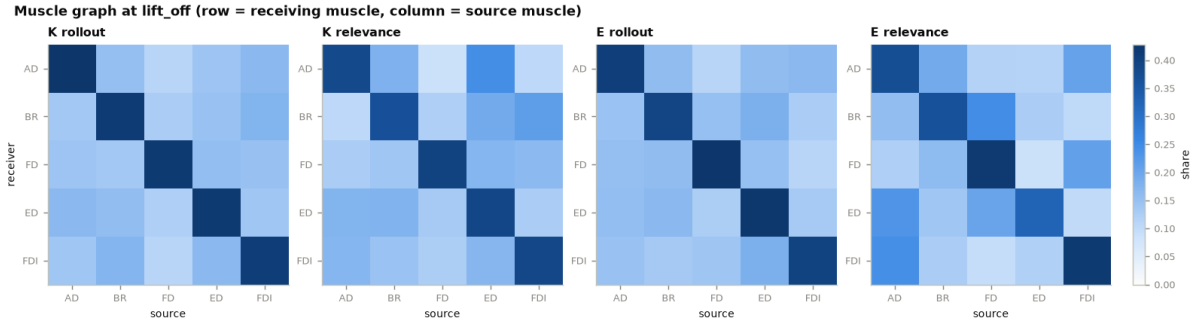
شکل ۳۲: P2: توجه دو لایه‌ی electrode graph در لحظه‌ی جدا شدن. مرکزهای پخش در لایه‌ی اول: F8، F7 و PO10.

۵. muscle graph: عضله‌ها از هم اطلاعات می‌گیرند؟

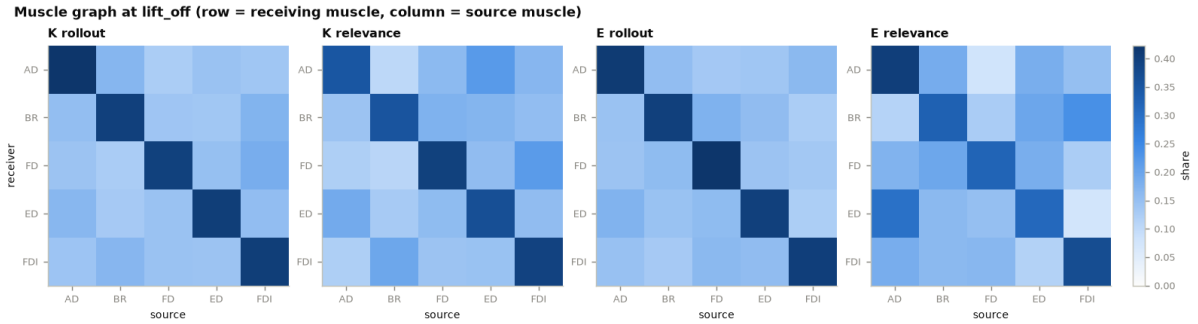
چه رسم شده. چهار ماتریس ۵ × ۵: rollout و gradient-weighted rollout (relevance) برای K و E. سطر عضله‌ی گیرنده و ستون عضله‌ی فرستنده است.

چطور بخوانیم. قطر تیره یعنی هر عضله پیش‌بینی‌اش را بیشتر از گره خودش می‌سازد. خانه‌ی تیره بیرون قطر، مثلاً سطر AD و ستون ED، یعنی پیش‌بینی AD از اطلاعات گره ED هم استفاده کرده است.

چه می‌فهمیم. در هر دو نفر و هر دو خروجی قطر غالب است؛ عضله‌ها بیشتر مستقل پیش‌بینی می‌شوند. در rollout خانه‌های بیرون قطر تقریباً یکسان‌اند و الگوی خاصی ندارند. در relevance چند خانه‌ی بیرون قطر برجسته می‌شوند؛ مثلاً در P1 AD از ED برای K، و BR از FD برای E. اما این رابطه‌ها از یک نفر به نفر دیگر عوض می‌شوند و بخش ۱۰ نشان می‌دهد در E یکسانی‌شان بین افراد کم است. پس نباید آن‌ها را هم‌کاری ثابت عضله‌ها تعبیر کرد.



شکل ۳۳: P1 muscle graph در لحظه‌ی جدا شدن برای K و E، با rollout و gradient-weighted rollout.



شکل ۳۴: P2 muscle graph در لحظه‌ی جدا شدن.

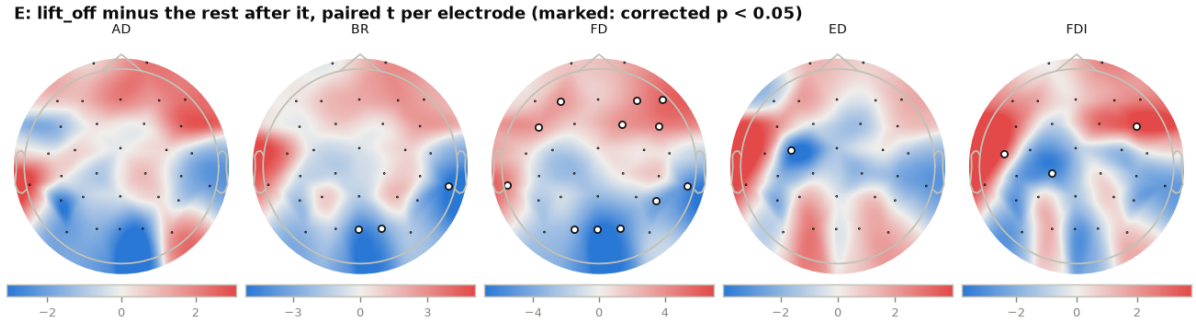
۶. مقایسه با استراحت: کدام الکترود فقط هنگام حرکت مهم می‌شود؟

چه رسم شده. برای هر عضله یک نقشه‌ی سر. رنگ آماره‌ی t جفت‌شده است: سهم الکترود در لحظه‌ی جدا شدن منهای سهمش در استراحت بعد از همان بلندکردن. قرمز یعنی در رخداد سهم بیشتری دارد، آبی یعنی در استراحت. دایره‌های توخالی الکترودهایی‌اند که اختلافشان پس از تصحیح برای ۳۲ الکترود معنادار است.

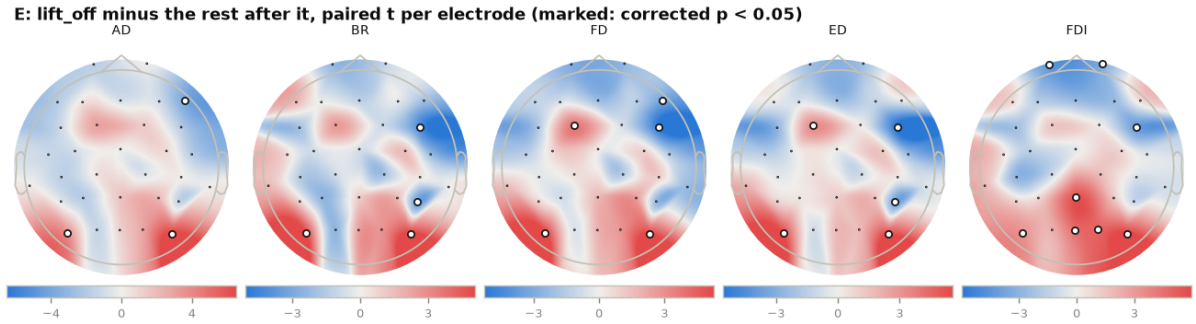
چطور بخوانیم. نقشه‌ی سر (شکل نوع ۳) فقط می‌گوید E از کجا می‌خواند؛ ممکن است همان الکترود در استراحت هم همان‌قدر مهم باشد. این شکل جواب می‌دهد کدام الکترودها **مخصوص لحظه‌ی حرکت** مهم می‌شوند.

چه می‌فهمیم. نتیجه بین دو نفر و حتی بین عضله‌های یک نفر بسیار متفاوت است. در P1 بیشترین الکترودهای معنادار برای FD است (پیشانی قرمز، پس‌سری آبی) و برای بقیه‌ی عضله‌ها چند الکترود پراکنده. در P2 برای همه‌ی عضله‌ها پس‌سری (O1، O2، P7، P8) قرمز و معنادار است و پیشانی راست آبی. افزایش سهم پس‌سری درست هنگام جدا شدن جسم با نگاه کردن به جسم و پردازش بینایی سازگار است، نه با فرمان حرکتی. بخش ۱۰ این را تأیید

می‌کند: این نقشه‌ها بین افراد تقریباً شبیه نیستند (pairwise ρ حدود ۰٫۰۶)، پس برای نتیجه‌گیری گروهی مناسب نیستند.



شکل ۳۵: P1: سهم الکترودها در E هنگام جدا شدن منهای استراحت بعد از آن؛ آماره‌ی t جفت‌شده. دایره‌ها الکترودهایی‌اند که p تصحیح‌شده‌شان کمتر از ۰٫۰۵ است.



شکل ۳۶: P2: مقایسه‌ی رخداد با استراحت برای E. پس‌سری در همه‌ی عضله‌ها هنگام جدا شدن سهم بیشتری دارد.

۷. سهم ورودی‌ها: کدام ویژگی‌ها و کدام باندها؟

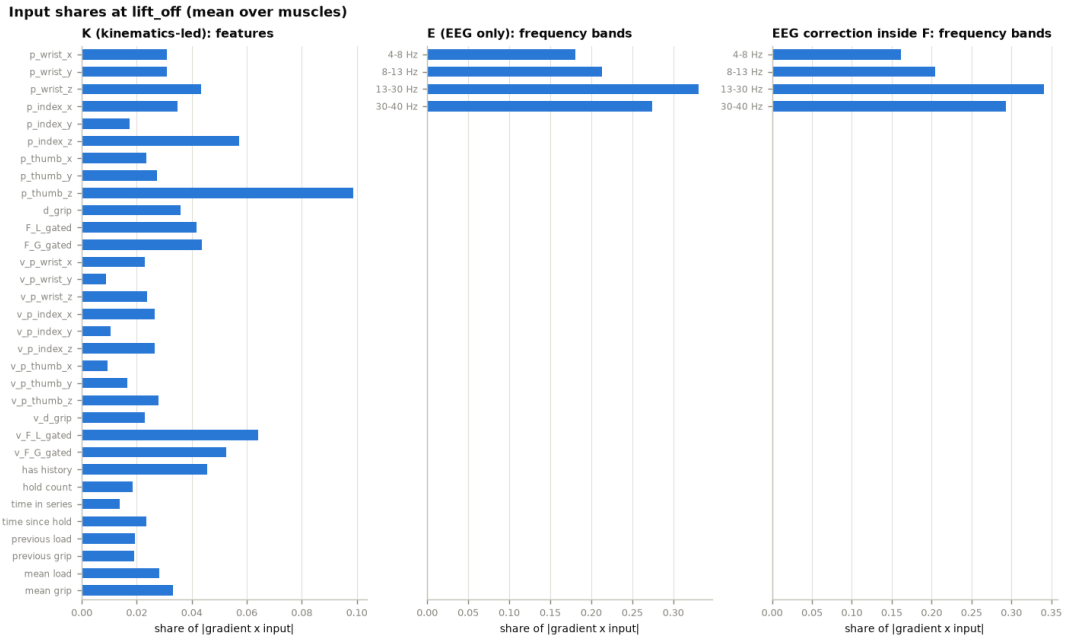
چه رسم شده. سه نمودار میله‌ای از input × gradient، میانگین روی پنج عضله. چپ: سهم هر یک از ۳۲ ویژگی K (۲۴ ویژگی سینماتیک و ۸ ویژگی تاریخچه، با نام‌های کد؛ پیشوند _v یعنی سرعت). وسط: سهم چهار باند EEG در E. راست: سهم همان چهار باند در اصلاح EEG درون F. سهم‌های هر نمودار جمع ۱ دارند.

چطور بخوانیم. این تنها شکلی است که درباره‌ی **نوع** ورودی می‌گوید، نه جای آن در زمان یا روی سر. میله‌ی بلندتر یعنی تغییر کوچک آن ویژگی خروجی را بیشتر تغییر می‌دهد.

چه می‌فهمیم.

- **K از فیزیک بلند کردن استفاده می‌کند.** در P1 بیشترین سهم با ارتفاع شست و انگشت اشاره (p_thumb_z، p_index_z) و سرعت نیروی بار و گرفتن (v_F_L_gated، v_F_G_gated) است. در P2 خود دو نیرو (F_G_gated، F_L_gated) و سرعت باز و بسته شدن دست (v_d_grip) جلوترند. لحظه‌ی جدا شدن دقیقاً جایی است که نیروی بار به وزن جسم می‌رسد و دست بالا می‌رود، پس این ویژگی‌ها همان چیزی‌اند که از فیزیک انتظار داریم.
- **تاریخچه کمک می‌کند ولی نقش اصلی ندارد.** هشت ویژگی تاریخچه (از has history تا mean grip) هر کدام ۱ تا ۵ درصد سهم دارند. has history از همه بیشتر است؛ یعنی مدل بلندکردن اول سری را از بقیه جدا می‌کند.

- **E باند بتا را ترجیح می‌دهد.** در هر دو نفر بتا (۱۳ تا ۳۰ هرتز) اول است و گامای پایین (۳۰ تا ۴۰ هرتز) دوم. بتا با پژوهش‌های قشر حرکتی می‌خواند. سهم بالای گامای پایین به artifact عضلات سر حساس است.
- **اصلاح EEG در F همان باندهای E را می‌خواند.** نمودار راست تقریباً تکرار نمودار وسط است. پس fusion اطلاعات دیگری از EEG نمی‌گیرد، فقط همان را با gate نزدیک صفر اضافه می‌کند.



شکل ۳۷: P1 سهم ویژگی‌های سینماتیک و تاریخچه در K و سهم باندهای EEG در E و در اصلاح EEG درون F (gradient × input).

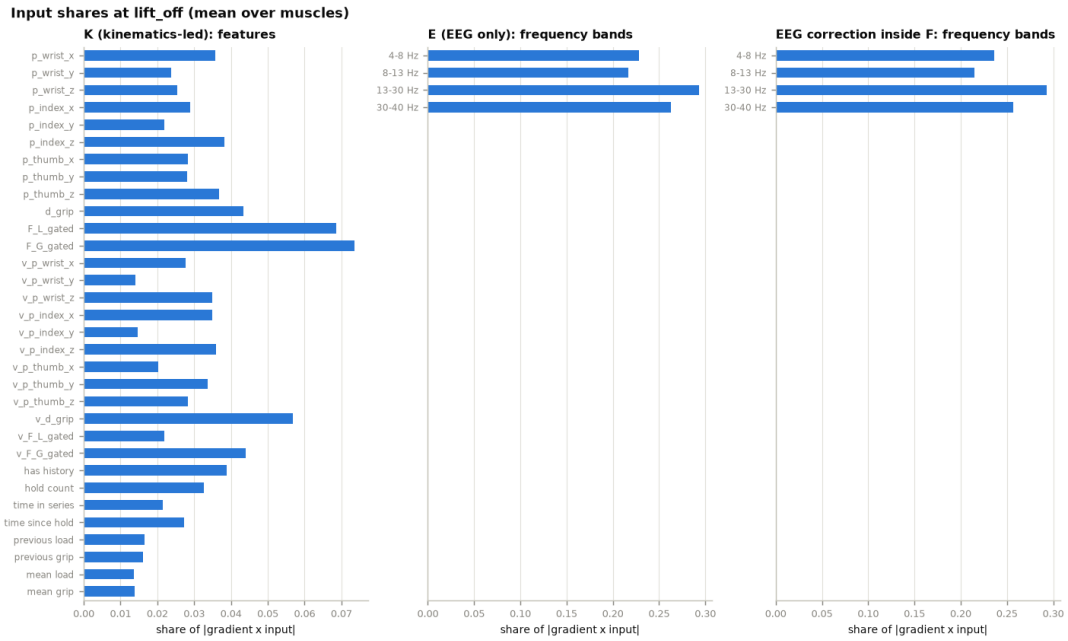
۸. deletion check: کدام روش تفسیر را باور کنیم؟

چه رسم شده. محور افقی درصد ورودی‌هایی است که حذف شده‌اند (۵، ۱۰، ۲۰ و ۴۰ درصد)، به ترتیبی که هر روش مهم‌تر می‌داند. محور عمودی تغییر خروجی مدل در اثر این حذف است. هر رنگ یک روش است و خاکستری حذف تصادفی. چپ E و راست K.

چطور بخوانیم. این شکل خود روش‌ها را می‌سنجد، نه مدل را. روشی که واقعاً ورودی‌های مهم را پیدا کرده باشد، با حذف همان ۵ درصد اول باید خروجی را بسیار تغییر دهد؛ یعنی منحنی‌اش از همان ابتدا بالا باشد. منحنی نزدیک خاکستری یعنی آن روش بهتر از انتخاب تصادفی نیست.

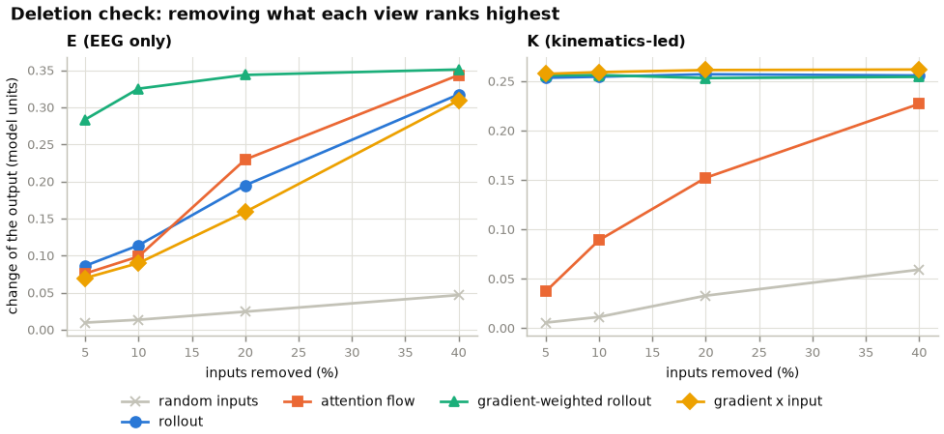
چه می‌فهمیم.

- **برای E:** سبز (gradient-weighted rollout) در هر دو نفر از همان ۵ درصد اول بسیار بالاتر از بقیه است (در P1 حدود ۰٫۲۸ در برابر حدود ۰٫۰۸). پس برای EEG فقط این روش ورودی‌های مهم را دقیق رتبه‌بندی می‌کند. در P2 سبز بعد از ۲۰ درصد کمی پایین می‌آید؛ احتمالاً با حذف ورودی‌های بیشتر، اثرهای مخالف هم حذف می‌شوند و یکدیگر را خنثی می‌کنند.
- **برای K:** سه روش rollout، gradient-weighted rollout و gradient × input تقریباً روی هم‌اند. در P1 منحنی آن‌ها از ۵ درصد صاف است؛ یعنی تقریباً همه‌ی اثر در همان ۵ درصد اول است (خودِ لحظه‌ی رخداد و همسایه‌هایش) و حذف بیشتر چیزی اضافه نمی‌کند. attention flow در P1 از ۵ درصد بسیار پایین شروع می‌شود، چون تقریباً به همه‌ی ورودی‌ها سهم برابر می‌دهد و نمی‌داند کدام را اول حذف کند.

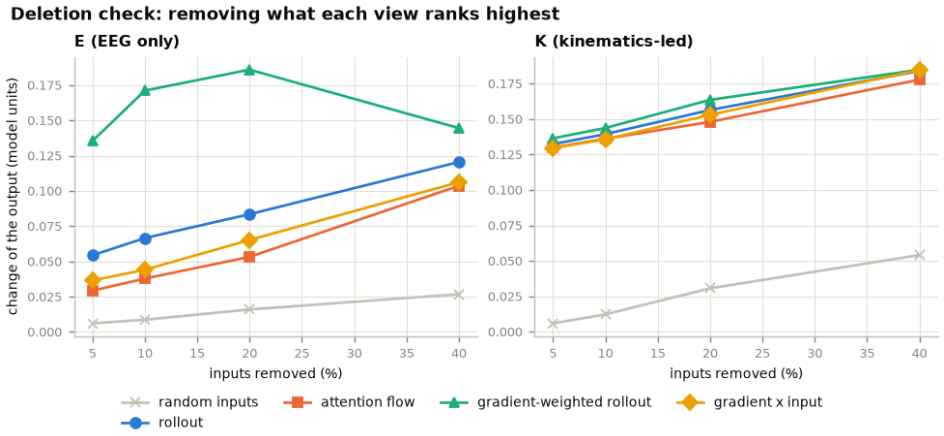


شکل ۳۸: P2: سهم ورودی‌ها (gradient × input).

- همه‌ی روش‌ها در هر دو نفر بالاتر از حذف تصادفی‌اند؛ پس هیچ‌کدام بی‌معنا نیستند، فقط دقتشان فرق دارد.



شکل ۳۹: P1: منحنی‌های deletion check. منحنی بالاتر در درصدهای کم یعنی روش دقیق‌تر.



شکل ۴۰: P2: منحنی‌های deletion check.

۹ attention rollout و attention flow

پرسش. یک عدد خروجی، مثلاً فعالیت AD در لحظه‌ی جدا شدن جسم، از کدام ورودی‌ها آمده است؟ اگر مدل فقط یک لایه‌ی توجه داشت، جواب ساده بود: سطر همان لحظه در ماتریس توجه. اما مدل چند لایه دارد. لایه‌ی آخر از tokens لایه‌ی قبل اطلاعات می‌گیرد، و هر کدام از آن‌ها خودشان مخلوطی از tokens لایه‌ی قبل‌ترند. باید این زنجیره را تا ورودی دنبال کرد.

attention rollout و attention flow [۴] دو راه برای دنبال کردن این زنجیره‌اند. هر دو از همان ماتریس‌های توجه ثبت‌شده استفاده می‌کنند و فقط در نحوه‌ی ترکیب لایه‌ها فرق دارند:

- **rollout** اطلاعات را مثل یک مخلوط در نظر می‌گیرد. در هر لایه، هر token درصدی از هر token قبلی را برمی‌دارد. درصدها در طول مسیر ضرب و روی مسیرها جمع می‌شوند.
- **attention flow** وزن‌های توجه را مثل ظرفیت لوله‌ها در نظر می‌گیرد و می‌پرسد حداکثر چقدر «آب» می‌تواند از یک ورودی به خروجی برسد.

هر دو روش فقط وقتی معنا دارند که توجه تنها راه جابه‌جایی اطلاعات بین موقعیت‌ها باشد. قاعده‌ی «یک مخلوط‌کننده» در v2 (بخش ۶) دقیقاً همین را تضمین می‌کند. تنها استثنا، stem سینماتیک، هم با ماتریس معلوم S وارد حساب می‌شود.

۱.۹ نمادها و layered graph

برای هر لایه‌ی l (از L لایه)، recorder ماتریس توجه $A_l^h \in \mathbb{R}^{n\times n}$ را برای هر سر $h = ۱, \dots, H$ برمی‌دارد. سطر i موقعیت گیرنده و ستون j موقعیت فرستنده است و جمع هر سطر ۱ است. دو کار روی آن انجام می‌شود: میانگین سرها گرفته می‌شود و راه مستقیم residual connection اضافه می‌شود:

$$\overline{A}_l = \frac{۱}{H}\sum_{h=۱}^{H} A_l^h, \qquad \hat{A}_l = \tfrac{۱}{۲}\,\overline{A}_l + \tfrac{۱}{۲} I. \tag{۱۲}$$

چرا $\frac{۱}{۲}I$؟ بلوک توجه به شکل $x + \mathrm{Attn}(\mathrm{LN}(x))$ است: هر موقعیت خودش را مستقیم نگه می‌دارد و چیزی از توجه به آن اضافه می‌شود. فرض می‌کنیم این دو سهم برابرند، پس نیمی از اطلاعات از راه توجه و نیمی از راه مستقیم می‌آید. این وزن ۰٫۵ یک قرارداد رایج است، نه چیزی که از مدل اندازه گرفته شده باشد.

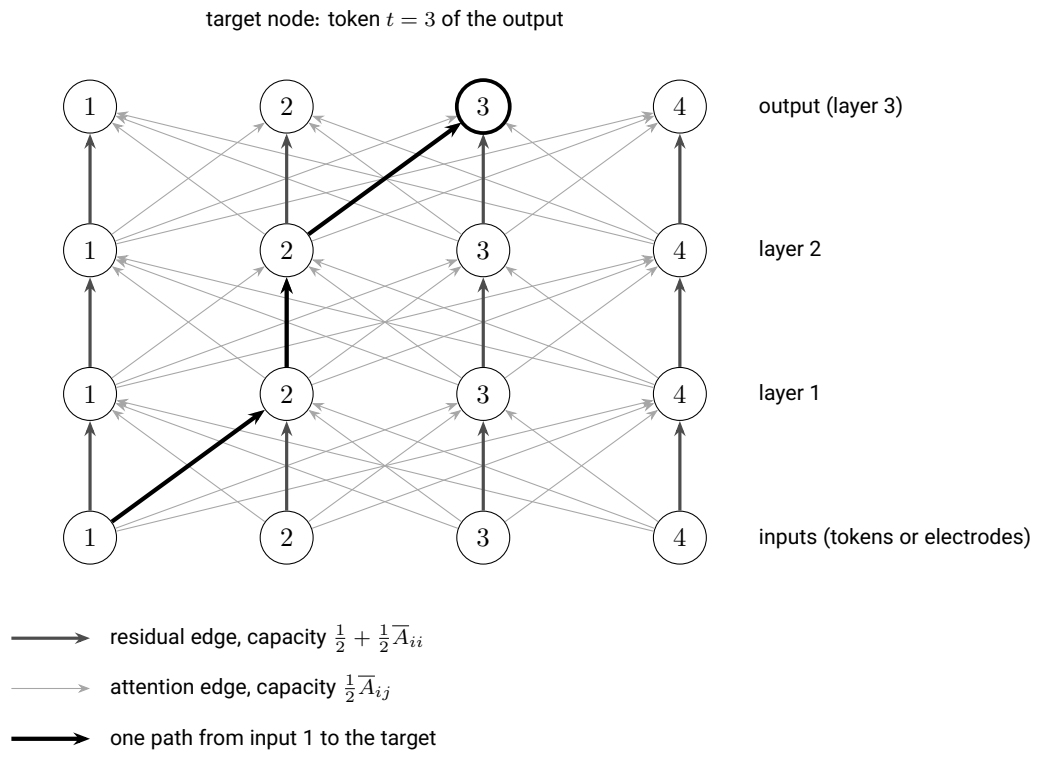
این ماتریس‌ها را می‌توان به شکل یک گراف لایه‌لایه (layered graph) دید (شکل ۴۱). گراف $L+۱$ ردیف گره دارد: ردیف ۰ ورودی‌ها و ردیف L خروجی‌ها. از گره j در ردیف $l-۱$ به گره i در ردیف l یک یال با وزن $\hat{A}_l[i,j]$ می‌رود. یال‌های افقی ($j \to j$) راه مستقیم residual connection و بقیه راه توجه‌اند.

۲.۹ attention rollout

تعریف

rollout ماتریس‌های لایه‌ها را از آخر به اول در هم ضرب می‌کند:

$$R = \hat{A}_L \hat{A}_{L-۱} \cdots \hat{A}_۱, \qquad R[t,\tau] = \sum_{\tau = i_۰ \to i_۱ \to \cdots \to i_L = t} \;\prod_{l=۱}^{L} \hat{A}_l[i_l, i_{l-۱}]. \tag{۱۳}$$



شکل ۴۱: layered graph که rollout و attention flow روی آن کار می‌کنند. وزن هر یال $\hat{A}_l[i,j]$ است. rollout روی همه‌ی مسیرها از ورودی به هدف، حاصل‌ضرب وزن‌های هر مسیر را جمع می‌زند. attention flow وزن‌ها را ظرفیت لوله می‌گیرد و بیشینه‌ی جریانی را که از یک ورودی به هدف می‌رسد حساب می‌کند.

سمت راست رابطه معنای این ضرب را می‌گوید. برای رسیدن از ورودی τ به خروجی t مسیرهای زیادی در گراف هست. سهم هر مسیر حاصل‌ضرب وزن‌های یال‌های آن است، و $R[t,\tau]$ جمع سهم همه‌ی این مسیرهاست. چون وزن‌ها ضرب می‌شوند، یک یال ضعیف کل مسیر را ضعیف می‌کند.

مثال کوچک. فرض کنید در لایه‌ی دوم، token t ۶۰ درصد از token a می‌گیرد، و در لایه‌ی اول a ۵۰ درصد از ورودی τ گرفته است. سهم این مسیر $۰٫۵ \times ۰٫۶ = ۰٫۳$ است. سهم نهایی τ جمع این عدد با سهم همه‌ی مسیرهای دیگر از τ به t است.

چرا جمع سهم‌ها ۱ است. همه‌ی $\hat{A}_l$ نامنفی‌اند و جمع هر سطرشان ۱ است. حاصل‌ضرب چنین ماتریس‌هایی هم همین ویژگی را دارد:

$$\hat{A}_l \mathbf{1} = \mathbf{1} \;\forall l \quad\Longrightarrow\quad R\mathbf{1} = \hat{A}_L \cdots \hat{A}_1 \mathbf{1} = \mathbf{1}, \qquad \sum_{\tau} R[t,\tau] = 1. \tag{۱۴}$$

پس سطر t از R یک توزیع روی ورودی‌هاست: هر عدد می‌گوید آن ورودی چه سهمی در خروجی token t دارد.

rollout در هر مسیر مدل

همین ضرب برای هر خروجی، روی لایه‌های همان مسیر:

- **K، زمان** (stem و سه لایه‌ی زمانی سینماتیک): $R_K = \hat{A}_3^{(k)} \hat{A}_2^{(k)} \hat{A}_1^{(k)}\, S$
- **E، زمان** (دو لایه‌ی زمانی EEG): $R_E = \hat{A}_2^{(t)} \hat{A}_1^{(t)}$
- **E، الکترودها در token** τ (دو لایه‌ی electrode graph و attention pooling): $e_\tau = \pi_\tau\, \hat{A}_2^{(e)}(\tau)\, \hat{A}_1^{(e)}(\tau) \in \mathbb{R}^{32}$

- **E، زمان و الکترود با هم:** $M_E[\tau, e] = R_E[t, \tau]\; e_\tau[e]$
- F_{eeg}: $R_F = c_t\, R_E$، که c_t سطر t cross-attention است (این لایه residual connection ندارد)
- **muscle graph** (دو لایه): $R_M = \hat{A}_۲^{(m)} \hat{A}_۱^{(m)} \in \mathbb{R}^{۵\times۵}$

S ردپای stem کانولوشنی K است: یک ماتریس نواری با پهنای ۵ که هر سطرش جمع ۱ دارد و وزن هر جابه‌جایی برابر انرژی هسته در آن جابه‌جایی است. π_τ وزن‌های attention pooling الکترودها در token τ است (جمع ۱).

سطر چهارم دو نقشه را ترکیب می‌کند. $R_E[t, \tau]$ می‌گوید لحظه‌ی τ چقدر در خروجی سهم دارد، و $e_\tau[e]$ می‌گوید در همان لحظه، الکترود e چه سهمی از آن لحظه دارد. حاصل‌ضرب آن‌ها سهم «الکترود e در لحظه‌ی τ» است. چون همه‌ی این عامل‌ها جمع سطری ۱ دارند، $\sum_{\tau,e} M_E[\tau, e] = ۱$ هم برقرار است.

نمایش

token خود رخداد و چهار همسایه‌اش (ردپای ۵تایی stem) همیشه بیشترین سهم را دارند، چون راه مستقیم residual connection در هر لایه سهم بزرگی به خود هر موقعیت می‌دهد. این سهم بزرگ بقیه‌ی منحنی را پنهان می‌کند. برای همین شکل‌ها سهم این tokens را جداگانه به‌صورت عدد می‌نویسند و منحنی سهم بقیه‌ی tokens را پس از نرمال کردن نشان می‌دهد:

$$\text{own} = \sum_{\tau \in \mathcal{O}} R[t, \tau], \qquad s(\tau) = \frac{R[t, \tau]}{۱ - \text{own}} \quad (\tau \notin \mathcal{O}), \tag{۱۵}$$

که $\mathcal{O}$ پنج token اطراف t است. نقشه برای هر رخداد جداگانه ساخته و سپس روی رخدادها میانگین و SEM گرفته می‌شود.

نسخه‌ی وزن‌دار با گرادیان

در gradient-weighted rollout (بخش ۸) فقط یک چیز عوض می‌شود: در رابطه‌ی (۱۲) به‌جای $\overline{A}_l$ از $\tilde{A}_l = \mathrm{rownorm}\big(\frac{۱}{H}\sum_h (A_l^h \odot \partial y/\partial A_l^h)^+\big)$ استفاده می‌شود. بقیه‌ی مراحل همین است. نتیجه برای هر عضله جداست.

محدودیت‌ها

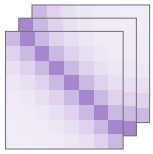
rollout فقط می‌بیند هر موقعیت چقدر به موقعیت دیگر نگاه کرده، نه اینکه چه اطلاعاتی منتقل شده است. ممکن است یک وزن توجه بزرگ، اطلاعات بی‌اهمیتی را جابه‌جا کند. لایه‌های بدون توجه (embedding، feed-forward، decoder) هم در حساب نیستند. وزن ۰٫۵ residual connection هم انتخاب ماست، نه چیزی که مدل یاد گرفته باشد.

۳.۹ attention flow

تعریف

در attention flow هر یال layered graph یک لوله است با ظرفیت $c_e = \hat{A}_l[i, j]$. پرسش این است: اگر از ورودی τ آب وارد کنیم، حداکثر چقدر آب می‌تواند به خروجی t برسد؟ آب می‌تواند هم‌زمان از چند مسیر برود، اما از هیچ

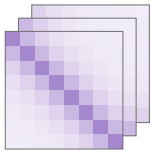
1 **Record every attention layer in one forward pass (after softmax, per head)**



layer 1: A_1^h, heads $h = 1..H$



layer 2: A_2^h, heads $h = 1..H$



layer 3: A_3^h, heads $h = 1..H$

row i = receiving token (query), column j = source

2 **Average the heads and add the residual path**



$\hat{A}_1 = \frac{1}{2}\overline{A}_1 + \frac{1}{2}I$



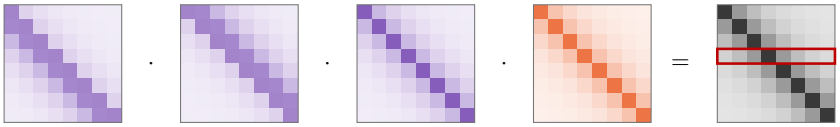
$\hat{A}_2 = \frac{1}{2}\overline{A}_2 + \frac{1}{2}I$



$\hat{A}_3 = \frac{1}{2}\overline{A}_3 + \frac{1}{2}I$

$\overline{A}_l = \frac{1}{H}\sum_h A_l^h$
rows still sum to 1
I: the skip connection

3 **Multiply the layers from the last to the first**

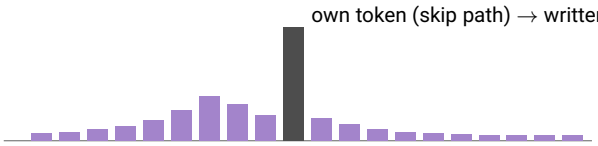


$\hat{A}_3$ · $\hat{A}_2$ · $\hat{A}_1$ · S (K only: stem) = R

row t = the explained token

$R[t,\tau] = \sum_{\text{paths } \tau \to t} \prod_l \hat{A}_l$
$\sum_\tau R[t,\tau] = 1$

4 **Read row t: the share of every input in the explained output**

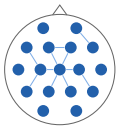


5 **The same product, stage by stage, for every output**

K: $R_K = \hat{A}_3\hat{A}_2\hat{A}_1 S$
time map, 400 tokens

E, time: $R_E = \hat{A}_2\hat{A}_1$
(EEG temporal layers)

E, electrodes at token τ:
$e_\tau = \pi_\tau \hat{A}_2^{(e)} \hat{A}_1^{(e)}$, π = pooling row

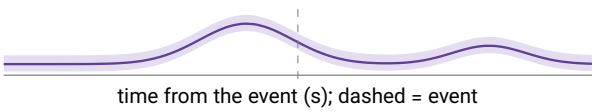


E, time × electrode:
$M_E[\tau, e] = R_E[t,\tau]\, e_\tau[e]$

F$_{eeg}$: cross-attention C last, no residual: $C\,R_E$

muscle graph: $\hat{A}_2^{(m)} \hat{A}_1^{(m)}$
5×5, row = receiving muscle

6 **One map per lift event, then mean ± SEM over events (never a single window)**



gradient-weighted variant: replace $\overline{A}_l$ by
$\tilde{A}_l = \text{rownorm}\left(\frac{1}{H}\sum_h \left(A_l^h \odot \frac{\partial y}{\partial A_l^h}\right)^+\right)$
and run steps 2–6 unchanged: one map per muscle.

شکل ۴۲: فرایند کامل attention rollout. (۱) recorder توجه هر لایه و هر سر را در یک بار اجرا برمی‌دارد. (۲) میانگین سرها گرفته و residual connection به‌صورت $\frac{1}{2}I$ اضافه می‌شود. (۳) ماتریس‌ها از لایه‌ی آخر به اول ضرب می‌شوند (برای K، ردپای stem S هم). (۴) سطر token موردنظر سهم هر ورودی است؛ سهم token خود رخداد جداگانه نوشته می‌شود. (۵) همین ضرب برای زمان، الکترودها، زمان و الکترود با هم، اصلاح EEG و muscle graph. (۶) نقشه‌ی هر رخداد ساخته و روی رخدادها میانگین گرفته می‌شود. کادر پایین: نسخه‌ی وزن‌دار با گرادیان.

لوله‌ای بیشتر از ظرفیتش رد نمی‌شود و در هیچ گره میانی جمع یا گم نمی‌شود:

(۱۶)

$$\text{flow}(\tau \to t) = \max_{f} \sum_{e \in \text{out}(\tau)} f_e \quad \text{s.t.} \quad ۰ \le f_e \le c_e, \qquad \sum_{e \in \text{in}(v)} f_e = \sum_{e \in \text{out}(v)} f_e \ \text{for every inner node } v.$$

طبق قضیه‌ی maximum flow و minimum cut، این مقدار برابر ظرفیت باریک‌ترین «گلوگاه» بین τ و t است؛ یعنی کمترین ظرفیت کل یال‌هایی که اگر بریده شوند، τ از t جدا می‌شود:

$$\text{flow}(\tau \to t) = \min_{(\mathcal{S},\mathcal{T}):\ \tau \in \mathcal{S},\ t \in \mathcal{T}} \sum_{e:\, \mathcal{S} \to \mathcal{T}} c_e. \tag{۱۷}$$

فرق با rollout. در rollout وزن‌ها در طول هر مسیر ضرب می‌شوند، پس مسیرهای طولانی سهم کوچکی می‌گیرند. در attention flow هر مسیر فقط با باریک‌ترین لوله‌اش محدود می‌شود و مسیرهای موازی با هم جمع می‌شوند. نتیجه اینکه جریان هیچ‌وقت از سهم rollout کمتر نیست، و وقتی توجه پخش است (همه به همه کمی نگاه می‌کنند) خیلی زود به سقف می‌رسد.

بازه‌بندی زمان

حل رابطه‌ی (۱۶) روی ۴۰۰ token، آن هم یک بار برای هر ورودی، بسیار پرهزینه است. برای همین زمان به بازه‌های ۴ توکنی (۸۰ میلی‌ثانیه) تقسیم می‌شود. سطرهای گیرنده‌ی هر بازه میانگین و ستون‌های فرستنده جمع زده می‌شوند:

$$\hat{A}^{bin}_{l}[a,b] = \frac{۱}{|a|} \sum_{i \in a} \sum_{j \in b} \hat{A}_l[i,j]. \tag{۱۸}$$

با این کار جمع هر سطر همچنان ۱ می‌ماند. برای K ماتریس stem S هم با همین قاعده بازه‌بندی و پیش از لایه‌ی اول گذاشته می‌شود. برای F_{eeg} سطر cross-attention لایه‌ی آخر است.

جریان الکترودها

برای E و F_{eeg}، در هر بازه‌ی زمانی τ یک گراف دیگر هم هست: دو لایه‌ی electrode graph (۳۲ $\to$ ۳۲ $\to$ ۳۲، با residual connection) و ردیف attention pooling (۱ $\to$ ۳۲ با ظرفیت $\pi_\tau[e]$ و بدون residual connection). $\text{flow}_{elec}(\tau, e)$ بیشینه‌ی جریان از الکترود e تا بردار poolشده است.

اطلاعات الکترودهای یک لحظه فقط از راه همین بردار poolشده به بقیه‌ی مدل می‌رسد. پس جریان یک الکترود در یک لحظه تا خروجی، با تنگ‌ترین مرحله از این دو محدود می‌شود:

$$\text{flow}(\tau, e) = \min\big(\text{flow}_{time}(\tau),\ \text{flow}_{elec}(\tau, e)\big). \tag{۱۹}$$

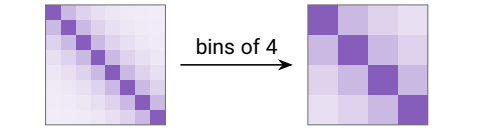
خط پایه‌ی توجه یکنواخت

عدد جریان به‌تنهایی معنای روشنی ندارد، چون حتی مدلی که هیچ چیز یاد نگرفته هم جریان زیادی می‌دهد. برای همین همان محاسبه برای یک مدل فرضی تکرار می‌شود که در هر لایه به همه‌ی n موقعیت به یک اندازه توجه می‌کند، با همان residual connection و همان stem:

$$\hat{A}^{u} = \tfrac{۱}{۲} \cdot \tfrac{۱}{n} J + \tfrac{۱}{۲} I, \qquad \text{excess}(\tau) = \text{flow}(\tau) - \text{flow}^{u}(\tau), \tag{۲۰}$$

که J ماتریسی است که همه‌ی درایه‌هایش ۱ است. فقط excess به آنچه مدل یاد گرفته مربوط است. مقدار مثبت یعنی مدل راه این ورودی را بازتر از توجه یکنواخت گذاشته، و مقدار منفی یعنی تنگ‌تر.

1 **Start from the same layer matrices $\hat{A}_l = \frac{1}{2}\overline{A}_l + \frac{1}{2}I$ and bin the time axis**

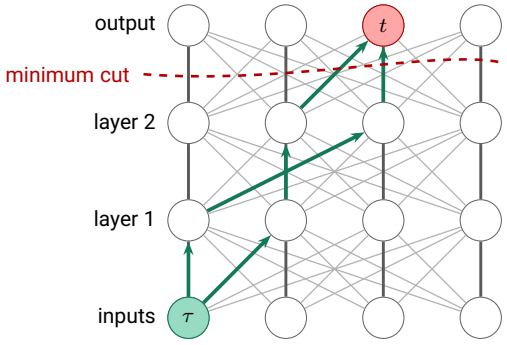


$\hat{A}_l$: 400 × 400 tokens — 100 × 100 bins (80 ms)

$$\hat{A}^{bin}[a,b] = \frac{1}{|a|}\sum_{i\in a}\sum_{j\in b}\hat{A}[i,j]$$

queries averaged, sources summed: rows still sum to 1, and the graph shrinks from $L \cdot 400^2$ to $L \cdot 100^2$ edges.

2 **Read the layers as a flow network: every edge is a pipe with capacity $\hat{A}_l[i,j]$**



source: input bin τ (one problem per source)

maximum flow from source τ to target t:

$$\text{flow}(\tau \to t) = \max_f \sum_{e \text{ out of } \tau} f_e$$

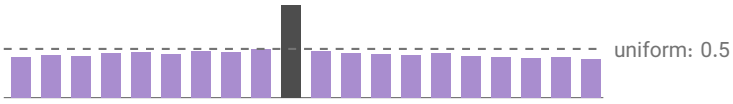
subject to $0 \le f_e \le c_e$ (capacity $c_e = \hat{A}_l[i,j]$) and inflow = outflow at every inner node.

max-flow = min-cut: the value equals the capacity of the cheapest set of pipes that separates τ from t.

Rollout multiplies along each path; flow adds parallel paths, each limited by its narrowest pipe.

3 **Solve one maximum-flow problem per source bin (100 per window)**

capacities $\times 10^6$, rounded to integers
`scipy...csgraph.maximum_flow`
result divided by 10^6



source bin τ (time); dark bar = the target's own bin

4 **Subtract the flow of a model that attends to everything equally**

uniform layers $\frac{1}{2}\frac{1}{n}J + \frac{1}{2}I$ (same residual, same stem)

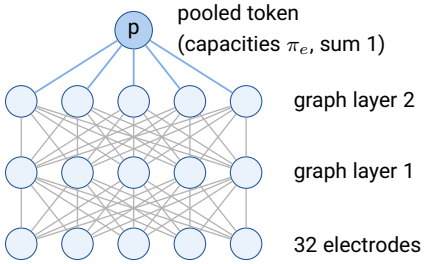
$$\text{excess}(\tau) = \text{flow}(\tau) - \text{flow}_{uniform}(\tau)$$

two uniform layers: every source gets exactly $\frac{1}{2}$



excess below 0: the learned attention is more concentrated than uniform

5 **Electrode flow (E and F_{eeg}): per time bin, through both electrode layers into the pooled token**



$\text{flow}_{elec}(\tau, e)$: maximum flow from electrode e to the pooled token of bin τ.

The pooled token is the only exit of a time step, so the input flow is $\text{flow}(\tau, e) = \min\left(\text{flow}_{time}(\tau),\ \text{flow}_{elec}(\tau, e)\right)$.

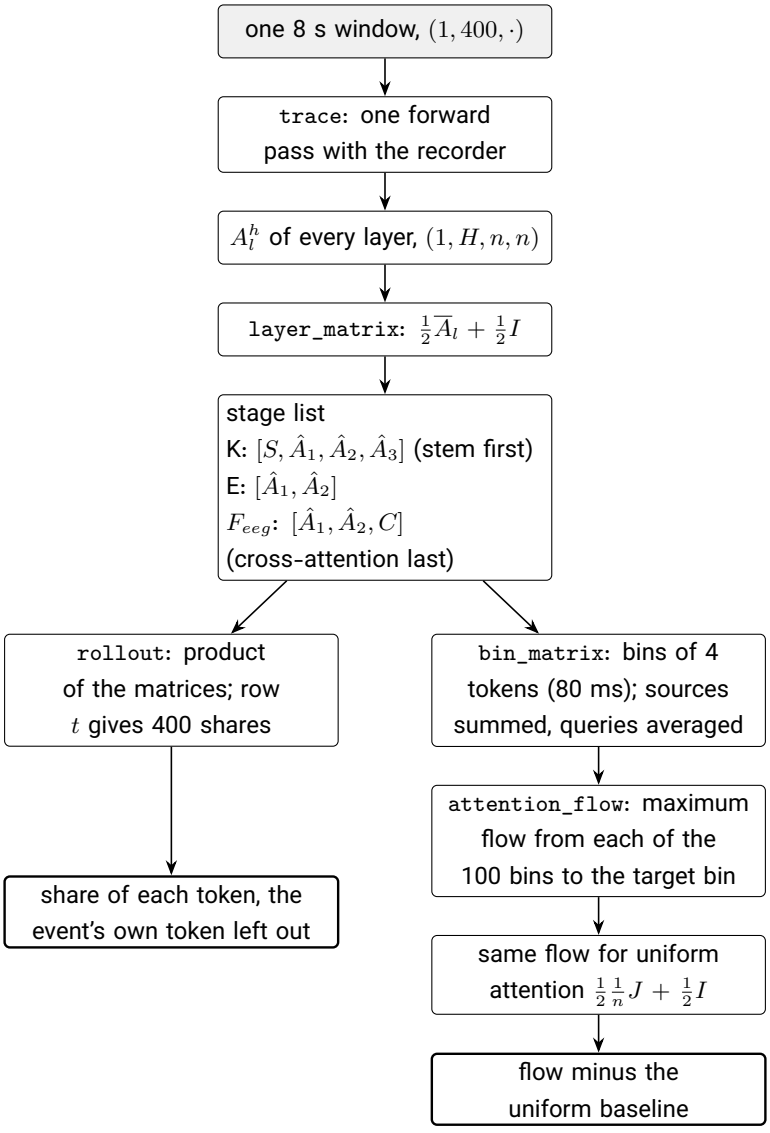
If $\max_e - \min_e < 10\,\%$ of the mean, every electrode reaches the same cap: the map carries no spatial information and is not drawn.

شکل ۴۳: فرایند کامل attention flow. (۱) همان ماتریس‌های لایه‌ها، با بازه‌بندی زمان به ۱۰۰ بازه‌ی ۸۰ میلی‌ثانیه‌ای. (۲) لایه‌ها به شکل شبکه‌ی لوله خوانده می‌شوند: هر یال لوله‌ای با ظرفیت $\hat{A}_l[i,j]$ است و بیشینه‌ی جریان از منبع τ تا هدف t برابر ظرفیت minimum cut است. (۳) برای هر بازه‌ی منبع یک مسئله‌ی maximum flow با ظرفیت‌های صحیح حل می‌شود. (۴) جریان مدل با توجه یکنواخت کم می‌شود؛ مقدار زیر صفر یعنی توجه آموخته‌شده متمرکزتر از یکنواخت است. (۵) جریان الکترودها از دو لایه‌ی electrode graph و attention pooling می‌گذرد و جریان نهایی هر ورودی کمینه‌ی جریان زمانی و جریان الکترود است.

۴.۹ پیاده‌سازی

تابع trace مدل را یک بار با recorder اجرا می‌کند و برای هر لایه تنسوری به شکل (B, H, n, n) برمی‌دارد. تابع layer_matrix رابطه‌ی (۱۲) را می‌سازد و تابع rollout ماتریس‌ها را از لایه‌ی آخر به اول ضرب می‌کند. نتیجه‌ی rollout روی ماتریس‌های ساختگی با تابع rollout مدل پایه مقایسه و یکسان بودنشان بررسی شده است.

برای جریان، تابع bin_matrix بازه‌بندی را انجام می‌دهد و تابع attention_flow برای هر منبع یک مسئله‌ی maximum flow را با SciPy حل می‌کند. الگوریتم SciPy فقط ظرفیت عدد صحیح می‌پذیرد؛ پس ظرفیت‌ها در $۱۰^۶$ ضرب و گرد می‌شوند و جواب دوباره بر $۱۰^۶$ تقسیم می‌شود. هر پنجره ۱۰۰ مسئله دارد، پس جریان برای هر خروجی و هر نوع رخداد فقط روی حداکثر ۶ رخداد حساب می‌شود. پیاده‌سازی روی گراف‌های ساده با گلوگاه معلوم آزموده شده و جریان در هیچ آزمونی از rollout کمتر نشده است.



شکل ۴۴: پیاده‌سازی rollout (چپ) و attention flow (راست) برای مسیر زمانی.

۵.۹ چرا attention flow در این مدل به سقف می‌رسد

یک مثال ساده: دو لایه با توجه کاملاً یکنواخت روی n موقعیت (مثل مسیر زمانی E). ظرفیت یال از ورودی j به گره میانی i برابر $\frac{۱}{۲n} + \frac{۱}{۲}\delta_{ij}$ است (δ_{ij} یعنی ۱ اگر $i = j$ و ۰ در غیر این صورت)، و از i به هدف t برابر $\frac{۱}{۲n} + \frac{۱}{۲}\delta_{it}$. برای

هر ورودی $j \neq t$، آب از n مسیر جدا می‌گذرد (یکی از هر گره میانی) و هر مسیر با یال کوچک‌ترش محدود می‌شود:

$$\text{flow}(j \to t) = \sum_{i=۱}^{n} \min\Big(\tfrac{۱}{۲n} + \tfrac{۱}{۲}\delta_{ij},\ \tfrac{۱}{۲n} + \tfrac{۱}{۲}\delta_{it}\Big) = n \cdot \tfrac{۱}{۲n} = \tfrac{۱}{۲}. \tag{۲۱}$$

برای خود هدف ($j = t$) جریان نزدیک ۱ است. یعنی در مدلی که هیچ چیز یاد نگرفته، همه‌ی ورودی‌ها جریان ۰٫۵ دارند و فقط token خود رخداد به ۱ می‌رسد. با stem و سه لایه (مسیر K) این عدد برای همه‌ی ورودی‌ها حدود ۱ می‌شود.

دلیل اصلی این است که وقتی توجه پخش است، تعداد بسیار زیادی مسیر موازی کوچک وجود دارد و جمع آن‌ها به سقف می‌رسد. در این حالت جریان بیشتر نشان می‌دهد توجه چقدر پخش است، نه اینکه اطلاعات از کجا آمده است.

در الکترودها وضع بدتر است. جریان هر الکترود باید از ردیف attention pooling بگذرد که ظرفیت کل آن ۱ است، و ظرفیت خروجی هر الکترود در لایه‌ی اول دست‌کم ۰٫۵ است. اگر توجه لایه‌ی دوم هم نسبتاً پخش باشد، تقریباً همه‌ی الکترودها به یک سقف می‌رسند. در P1 سهم جریان همه‌ی ۳۲ الکترود بین ۳٫۰۹ و ۳٫۱۵ درصد است، در حالی که سهم کاملاً یکنواخت ۳٫۱۲۵ درصد است. در این حالت شکل‌ها نقشه‌ی جریان الکترود را رسم نمی‌کنند و دلیلش را در عنوان می‌نویسند.

۶.۹ نتایج

جدول ۱۵ و شکل ۴۵ جریان را در برابر خط پایه‌ی یکنواخت برای هر ۱۲ شرکت‌کننده نشان می‌دهند.

مدل راه بیشتر ورودی‌ها را تنگ می‌کند. جریان واقعی همه‌جا **کمتر** از جریان مدل یکنواخت است: به‌طور میانگین ۰٫۱۵- برای K، ۰٫۲۱- برای E و ۰٫۲۴- برای F_{eeg}. یعنی توجه آموخته‌شده متمرکزتر از یکنواخت است و راه بسیاری از ورودی‌ها را تنگ می‌کند.

K در همه‌ی افراد به گذشته نگاه می‌کند. الگوی زمانی K در همه‌ی شرکت‌کننده‌ها یکی است: ورودی‌های ۰ تا ۳ ثانیه بعد از جدا شدن کمترین جریان را دارند و ورودی‌های پیش از رخداد بیشترین. این با rollout هم می‌خواند: K برای پیش‌بینی فعالیت عضله در لحظه‌ی جدا شدن، به حرکت دست پیش از آن نگاه می‌کند.

جریان الکترودها تقریباً اطلاعات مکانی ندارد. پراکندگی جریان الکترودها در ۱۰ نفر از ۱۲ نفر کمتر از ۱۰ درصد میانگین است؛ فقط P2 (۱۲ درصد) از این مرز می‌گذرد. پس نقشه‌ی جریان الکترود در این مدل تقریباً صاف است.

جمع‌بندی. در deletion check (جدول ۱۲)، جریان برای K ضعیف‌ترین روش است (۰٫۱۱۸ در برابر حدود ۰٫۲۱ برای بقیه). برای E هم‌تراز plain rollout و بسیار ضعیف‌تر از gradient-weighted rollout است. پس attention flow در این معماری درست محاسبه می‌شود، اما برای پیدا کردن جای اطلاعات به کار نمی‌آید. روش اصلی gradient-weighted rollout است و جریان فقط به‌صورت «فاصله از خط پایه‌ی یکنواخت» گزارش می‌شود.

شکل ۴۵ را چطور بخوانیم.

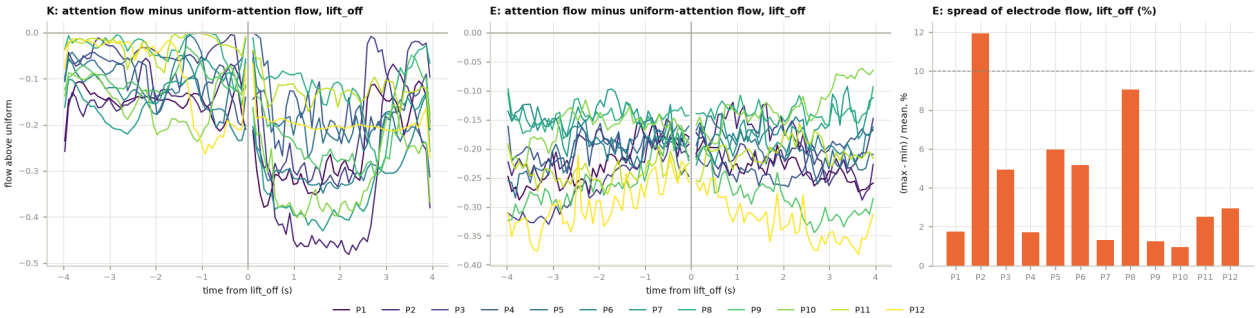
- **چه رسم شده.** دو پنل چپ «attention flow منهای جریان توجه یکنواخت» را در اطراف جدا شدن جسم نشان می‌دهند، برای K و E؛ هر خط یک شرکت‌کننده است. خط صفر یعنی «مثل مدلی که به همه‌جا یکسان

نگاه می‌کند». پنل راست برای هر شرکت‌کننده پراکندگی جریان بین ۳۲ الکترود را نشان می‌دهد: (بیشینه منهای کمینه) تقسیم بر میانگین، به درصد.

- **پنل K.** همه‌ی ۱۲ خط زیر صفرند و یک شکل مشترک دارند: پیش از رخداد کمی زیر صفر (حدود ۰٫۰۵- تا ۰٫۲-، بسته به شرکت‌کننده)، یک افت ناگهانی درست بعد از صفر (تا ۰٫۲۵- تا ۰٫۴۸-) و برگشت بعد از حدود ۳ ثانیه. معنی‌اش این است که مدل K در همه‌ی افراد راه اطلاعات ۳ ثانیه‌ی بعد از رخداد را بیشتر از بقیه می‌بندد و از لحظه‌های پیش از رخداد بیشتر استفاده می‌کند. این همان پیام شکل زمانی rollout است، این بار با روشی دیگر و برای همه‌ی افراد.
- **پنل E.** خط‌ها همه زیر صفرند (بین ۰٫۱- و ۰٫۳۷-) اما شکل مشترکی ندارند و در زمان رخداد هیچ تغییر روشنی دیده نمی‌شود. جریان در مسیر EEG فقط می‌گوید توجه کمی متمرکزتر از یکنواخت است، نه اینکه کدام لحظه مهم بوده است.
- **پنل پراکندگی الکترودها.** اگر جریان الکترودها اطلاعات مکانی داشت، بعضی الکترودها جریان خیلی بیشتری از بقیه می‌داشتند و این عدد بزرگ می‌شد. در ۱۰ نفر از ۱۲ نفر کمتر از ۱۰ درصد (خط‌چین) است و در بیشتر آن‌ها کمتر از ۳ درصد. فقط P2 از مرز می‌گذرد و P8 نزدیک آن است. نتیجه: نقشه‌ی جریان الکترود را تقریباً در هیچ فردی نمی‌توان برای پیدا کردن الکترودهای مهم به کار برد.

جدول ۱۵: attention flow در برابر خط پایه‌ی توجه یکنواخت: میانگین «جریان منهای جریانِ توجه یکنواخت» روی همه‌ی بازه‌های زمانی، و پراکندگی جریان بین الکترودها (بیشینه منهای کمینه، تقسیم بر میانگین). منفی یعنی جریان از حالت یکنواخت کمتر است.

شرکت‌کننده	جریان اضافه K	جریان اضافه E	جریان اضافه F_eeg	پراکندگی جریان الکترودها (%)
P1	۰٫۱۵۷-	۰٫۲۲۸-	۰٫۲۴۶-	۱٫۷
P2	۰٫۲۴۰-	۰٫۲۰۳-	۰٫۲۰۴-	۱۱٫۵
P3	۰٫۱۱۶-	۰٫۲۴۲-	۰٫۲۰۲-	۴٫۵
P4	۰٫۱۳۲-	۰٫۲۱۶-	۰٫۲۱۷-	۱٫۶
P5	۰٫۱۴۱-	۰٫۱۹۵-	۰٫۱۸۶-	۶٫۳
P6	۰٫۱۸۳-	۰٫۱۷۹-	۰٫۱۹۱-	۵٫۶
P7	۰٫۱۸۸-	۰٫۱۶۸-	۰٫۲۱۶-	۱٫۴
P8	۰٫۰۷۶-	۰٫۱۴۸-	۰٫۲۷۵-	۸٫۸
P9	۰٫۱۲۱-	۰٫۲۷۰-	۰٫۲۴۳-	۱٫۳
P10	۰٫۲۰۶-	۰٫۱۵۶-	۰٫۳۹۱-	۰٫۹
P11	۰٫۰۷۷-	۰٫۲۲۳-	۰٫۲۴۰-	۲٫۴
P12	۰٫۱۲۸-	۰٫۳۰۰-	۰٫۲۵۸-	۲٫۸



شکل ۴۵: attention flow منهای uniform-attention flow برای K (چپ) و E (وسط) در اطراف جدا شدن جسم؛ هر خط یک شرکت‌کننده است و بازه‌ی token خود رخداد حذف شده است. راست: پراکندگی جریان الکترودها برای E؛ خط‌چین مرز ۱۰ درصد است که زیر آن نقشه‌ی جریان رسم نمی‌شود.

۱۰ یکسانی نتایج rollout و attention flow بین شرکت‌کننده‌ها

چرا یکسانی مهم است. هر ۱۲ نفر یک کار را با یک دست انجام داده‌اند، و برای هر کدام یک مدل با معماری یکسان جداگانه آموزش دیده است. اگر نقشه‌های تفسیر چیزی واقعی درباره‌ی رابطه‌ی مغز و عضله نشان دهند، باید در افراد مختلف کم‌وبیش شبیه باشند. اگر نقشه در هر نفر شکل کاملاً متفاوتی داشته باشد، یا از نویز آمده یا از جزئیات تصادفی آموزش همان مدل. در هر دو حالت نمی‌توان از آن نتیجه‌ی علمی گرفت.

این بخش یکسانی را برای همه‌ی نقشه‌های ذخیره‌شده اندازه می‌گیرد. هیچ مدلی دوباره اجرا نشده است؛ همه‌ی اعداد از جدول‌های بخش ۸ و ۹ می‌آیند (اسکریپت v2-report/analysis/consistency.py).

۱.۱۰ معیارها

برای هر نوع نقشه یک ماتریس $X \in \mathbb{R}^{12 \times n}$ ساخته می‌شود. هر سطر نقشه‌ی یک شرکت‌کننده است (میانگین روی رخدادها) و n تعداد خانه‌ها: ۳۲ الکترود، یا نقاط زمانی، یا ۲۰ درایه‌ی غیرقطری muscle graph. پنج معیار، هر کدام از یک زاویه:

- ρ **pairwise: دو نفر چقدر شبیه‌اند؟** نقشه‌ی هر دو نفر با همبستگی اسپیرمن مقایسه و میانگین روی هر ۶۶ جفت گرفته می‌شود (برای منحنی‌های زمانی همبستگی پیرسون). اسپیرمن فقط ترتیب را می‌سنجد: آیا الکترودی که در یک نفر مهم است، در نفر دیگر هم مهم است؟
- ρ **leave-one-out (LOO): هر نفر چقدر شبیه بقیه‌ی گروه است؟** نقشه‌ی هر نفر با میانگین ۱۱ نفر دیگر مقایسه و نتیجه روی ۱۲ نفر میانگین گرفته می‌شود. میانگین گروه نویز کمتری از یک نفر دارد، پس این عدد معمولاً از pairwise بزرگ‌تر است.
- **split-half reliability: اگر آزمایش را با ۱۲ نفر دیگر تکرار کنیم، همین نقشه‌ی گروهی را می‌گیریم؟** شرکت‌کننده‌ها به‌طور تصادفی به دو گروه ۶ نفری تقسیم می‌شوند و همبستگی میانگین دو گروه حساب می‌شود. چون هر نیمه فقط ۶ نفر است، عدد با فرمول اسپیرمن-براون، $2r/(1+r)$، به اندازه‌ی ۱۲ نفر تصحیح می‌شود. این کار ۵۰۰ بار تکرار و میانگین گرفته می‌شود.
- **Kendall's W: ۱۲ نفر چقدر در رتبه‌بندی توافق دارند؟** هر شرکت‌کننده مثل یک داور خانه‌ها را رتبه‌بندی می‌کند. W بین ۰ (هیچ توافقی) و ۱ (همه رتبه‌بندی یکسان) است. معناداری با آزمون $\chi^2 = m(n-1)W$ سنجیده

می‌شود:

$$W = \frac{۱۲ \sum_{j=۱}^{n} \left(R_j - \bar{R}\right)^{۲}}{m^{۲}(n^{۳} - n)}, \qquad R_j = \sum_{i=۱}^{m} \mathrm{rank}_i(j). \tag{۲۲}$$

- **null: اگر هیچ الگوی مشترکی نبود، چه عددی می‌گرفتیم؟** برچسب الکترودها در هر شرکت‌کننده به‌طور مستقل به‌هم ریخته و pairwise ρ دوباره حساب می‌شود (برای منحنی‌های زمانی، منحنی هر نفر به‌طور دایره‌ای در زمان جابه‌جا می‌شود). این کار ۵۰۰ بار تکرار می‌شود. 95% null صدک ۹۵ این توزیع است. p سهم دفعاتی است که عدد به‌هم‌ریخته از عدد واقعی بزرگ‌تر شده؛ کمترین p ممکن ۰٫۰۰۲ است.

۲.۱۰ نقشه‌ی الکترودها

جدول ۱۶: یکسانی نقشه‌ی الکترودها بین ۱۲ شرکت‌کننده. pairwise ρ: میانگین همبستگی اسپیرمن روی ۶۶ جفت؛ LOO: هر نفر در برابر میانگین ۱۱ نفر دیگر؛ split-half: همبستگی میانگین دو نیمه‌ی تصادفی با تصحیح اسپیرمن-براون؛ null 95% و p: در برابر جابه‌جایی برچسب الکترودها در هر شرکت‌کننده.

نقشه	pairwise ρ	LOO ρ	split-half	Kendall's W	null 95%	p
E, first-touch, rollout	۰٫۲۱	۰٫۳۶	۰٫۷۰	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
E, first-touch, gradient-weighted rollout	۰٫۲۲	۰٫۳۶	۰٫۶۸	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
E, first-touch, attention flow	۰٫۲۳	۰٫۳۷	۰٫۷۰	۰٫۲۹	۰٫۰۴	۰٫۰۰۲
E, lift-off, rollout	۰٫۲۲	۰٫۳۶	۰٫۶۹	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
E, lift-off, gradient-weighted rollout	۰٫۲۱	۰٫۳۶	۰٫۶۸	۰٫۲۸	۰٫۰۳	۰٫۰۰۲
E, lift-off, attention flow	۰٫۲۰	۰٫۳۴	۰٫۶۷	۰٫۲۶	۰٫۰۳	۰٫۰۰۲
F-eeg, first-touch, rollout	۰٫۲۲	۰٫۳۵	۰٫۶۷	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
F-eeg, first-touch, gradient-weighted rollout	۰٫۱۹	۰٫۳۱	۰٫۶۲	۰٫۲۶	۰٫۰۴	۰٫۰۰۲
F-eeg, first-touch, attention flow	۰٫۲۴	۰٫۴۰	۰٫۷۵	۰٫۳۱	۰٫۰۴	۰٫۰۰۲
F-eeg, lift-off, rollout	۰٫۲۲	۰٫۳۶	۰٫۶۸	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
F-eeg, lift-off, gradient-weighted rollout	۰٫۱۹	۰٫۳۱	۰٫۶۳	۰٫۲۶	۰٫۰۴	۰٫۰۰۲
F-eeg, lift-off, attention flow	۰٫۲۳	۰٫۳۹	۰٫۷۴	۰٫۳۰	۰٫۰۴	۰٫۰۰۲

جدول ۱۶ نتیجه‌ی اصلی است و دو پیام دارد.

یکسانی واقعی است. هر ۱۲ نقشه‌ی الکترود (دو خروجی، دو رخداد، سه روش) بین شرکت‌کننده‌ها بسیار بیشتر از null شبیه‌اند؛ p در همه کمترین مقدار ممکن است.

اما اندازه‌اش متوسط است. pairwise ρ حدود ۰٫۲۰ تا ۰٫۲۴، LOO ρ حدود ۰٫۳۱ تا ۰٫۴۰ و Kendall's W حدود ۰٫۲۶ تا ۰٫۳۱ است. یعنی نقشه‌ی دو نفر تصادفی فقط کمی شبیه هم است. با این حال split-half reliability بین ۰٫۶۲ و ۰٫۷۵ است. پس نقشه‌ی میانگین گروه تکرارپذیر است، حتی اگر نقشه‌ی هر فرد پرنویز باشد؛ مثل یک نظرسنجی که پاسخ تک‌تک افراد پراکنده است ولی میانگین آن پایدار.

سه روش تقریباً به یک اندازه یکسانی دارند. نقشه‌ی attention flow با اینکه تقریباً صاف است (بخش ۹)، باز هم ترتیب یکسانی بین افراد دارد؛ چون همان تفاوت‌های کوچکش از توجه لایه‌ی اول می‌آید.

نقشه‌ی جداگانه‌ی هر عضله (جدول ۱۷) هم همین اندازه یکسانی را دارد و فرق معناداری بین عضله‌ها دیده نمی‌شود. این با بخش ۸ می‌خواند: در هر شرکت‌کننده، نقشه‌های gradient-weighted rollout پنج عضله بسیار شبیه هم‌اند و هیچ عضله‌ای الگوی مکانی خاص خودش را ندارد.

جدول ۱۷: همان معیارها برای نقشه‌ی gradient-weighted rollout هر عضله در خروجی E.

نقشه	pairwise ρ	LOO ρ	split-half	Kendall's W	null 95%	p
E, first-touch, AD	۰٫۲۱	۰٫۳۴	۰٫۶۷	۰٫۲۷	۰٫۰۴	۰٫۰۰۲
E, first-touch, BR	۰٫۲۱	۰٫۳۵	۰٫۶۸	۰٫۲۷	۰٫۰۴	۰٫۰۰۲
E, first-touch, FD	۰٫۲۱	۰٫۳۳	۰٫۶۶	۰٫۲۷	۰٫۰۴	۰٫۰۰۲
E, first-touch, ED	۰٫۲۲	۰٫۳۷	۰٫۶۹	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
E, first-touch, FDI	۰٫۲۱	۰٫۳۴	۰٫۶۸	۰٫۲۷	۰٫۰۴	۰٫۰۰۲
E, lift-off, AD	۰٫۲۲	۰٫۳۵	۰٫۶۶	۰٫۲۹	۰٫۰۴	۰٫۰۰۲
E, lift-off, BR	۰٫۲۰	۰٫۳۴	۰٫۶۵	۰٫۲۷	۰٫۰۳	۰٫۰۰۲
E, lift-off, FD	۰٫۱۸	۰٫۳۲	۰٫۶۲	۰٫۲۵	۰٫۰۴	۰٫۰۰۲
E, lift-off, ED	۰٫۲۲	۰٫۳۸	۰٫۶۹	۰٫۲۸	۰٫۰۴	۰٫۰۰۲
E, lift-off, FDI	۰٫۲۰	۰٫۳۵	۰٫۶۹	۰٫۲۶	۰٫۰۳	۰٫۰۰۲

کدام الکترودها در همه مشترک‌اند؟ جدول ۱۸ و شکل ۴۶ نقشه‌ی گروه را نشان می‌دهند. فقط دو الکترود در سطح گروه به‌طور معنادار سهمی بیشتر از سهم یکنواخت دارند (با تصحیح max-T روی ۳۲ الکترود): C3 و CP1. هر دو بالای قشر حسی-حرکتی نیمکره‌ی چپ‌اند که دست راست را کنترل می‌کند. C3 در ۸ تا ۹ نفر از ۱۲ نفر و CP1 در ۷ تا ۸ نفر جزو سه الکترود اول‌اند. C4 در نیمکره‌ی راست سومین الکترود گروه است، اما معنادار نیست. این الگو در هر دو رخداد و هر دو روش rollout یکی است.

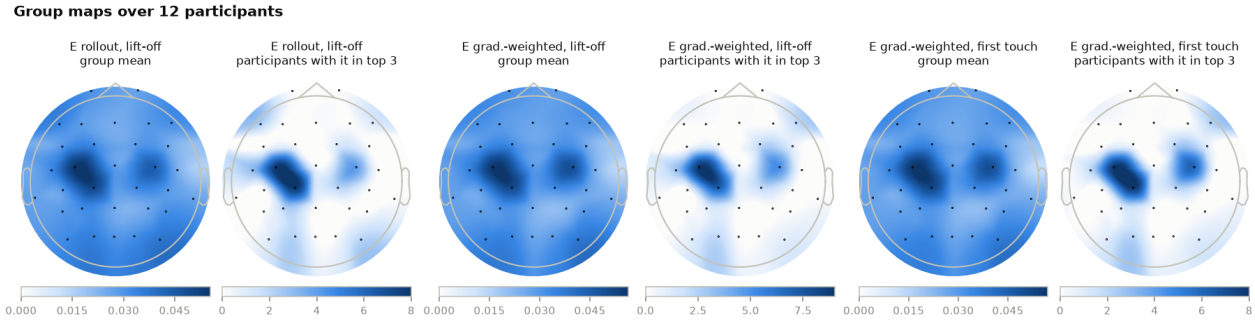
جدول ۱۸: هشت الکترود با بیشترین سهم میانگین در gradient-weighted rollout خروجی E هنگام lift-off. آزمون t تک‌نمونه‌ای سهم هر الکترود در برابر سهم یکنواخت (۳٫۱۲۵ درصد) با تصحیح max-T روی ۳۲ الکترود.

electrode	میانگین گروه (درصد)	t در برابر یکنواخت	p (max-T)	شمار افراد با آن در سه الکترود اول
C3	۵٫۶۴	۴٫۷۴	۰٫۰۲۵	9 / 12
CP1	۵٫۰۲	۵٫۶۸	۰٫۰۰۶	7 / 12
C4	۴٫۸۵	۲٫۹۶	۰٫۳۲۵	5 / 12
PO10	۳٫۷۰	۱٫۶۶	۰٫۹۹۲	1 / 12
T7	۳٫۵۳	۱٫۰۷	۱٫۰۰۰	3 / 12
PO9	۳٫۴۰	۰٫۹۱	۱٫۰۰۰	1 / 12
O1	۳٫۳۵	۰٫۷۶	۱٫۰۰۰	2 / 12
CP2	۳٫۲۵	۰٫۳۸	۱٫۰۰۰	2 / 12

شکل نقشه‌ی گروه (شکل ۴۶). سه جفت نقشه‌ی سر دارد: rollout هنگام جدا شدن، gradient-weighted rollout هنگام جدا شدن، و gradient-weighted rollout هنگام اولین تماس. نقشه‌ی اول هر جفت میانگین سهم الکترودها روی ۱۲ نفر است. نقشه‌ی دوم می‌شمارد هر الکترود در چند نفر جزو سه الکترود اول بوده است (از ۰ تا ۱۲).

- **چطور بخوانیم.** نقشه‌ی میانگین ممکن است با چند نفر که سهم خیلی زیادی دارند تیره شود. نقشه‌ی شمارش این مشکل را ندارد: کانون تیره در آن یعنی این الکترود در **تعداد زیادی** از افراد مهم بوده است. اگر دو نقشه یک کانون داشته باشند، آن کانون واقعاً مشترک است.
- **چه می‌فهمیم.** در هر سه جفت، قوی‌ترین کانون روی مرکزی چپ (C3 و CP1) است و یک کانون ضعیف‌تر روی مرکزی راست (C4). در نقشه‌ی شمارش، مرکزی چپ تا ۸ نفر می‌رسد و بقیه‌ی سر تقریباً سفید است. پس با

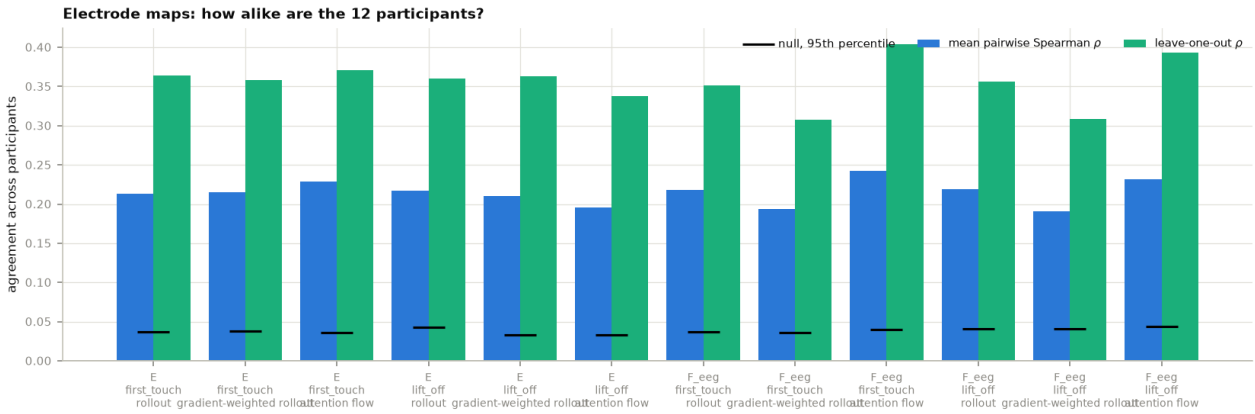
وجود اینکه نقشه‌ی هر فرد پرنویز است و در بعضی افراد لبه‌های سر هم مهم‌اند، تنها جایی که در اکثر افراد تکرار می‌شود قشر حسی-حرکتی مقابل دست است. این نتیجه به روش (rollout یا gradient-weighted) و به رخداد (تماس یا جدا شدن) بستگی ندارد. سهم لبه‌ی سر در نقشه‌های میانگین در نقشه‌های شمارش تقریباً دیده نمی‌شود؛ یعنی هر بار در افراد مختلف جای متفاوتی دارد.



شکل ۴۶: نقشه‌ی گروه (میانگین ۱۲ شرکت‌کننده) و تعداد شرکت‌کننده‌هایی که هر الکترود را جزو سه الکترود اول خود دارند، برای E با rollout و gradient-weighted rollout.

شکل میزان یکسانی (شکل ۴۷). هر جفت ستون یک نوع نقشه‌ی الکترود است (خروجی، رخداد، روش). ستون آبی میانگین شباهت دو نفر (pairwise ρ) و ستون سبز شباهت هر نفر به میانگین بقیه (LOO ρ) است. خط سیاه کوتاه حدی است که اگر هیچ الگوی مشترکی نبود، فقط از شانس به آن می‌رسیدیم (صدک ۹۵ null).

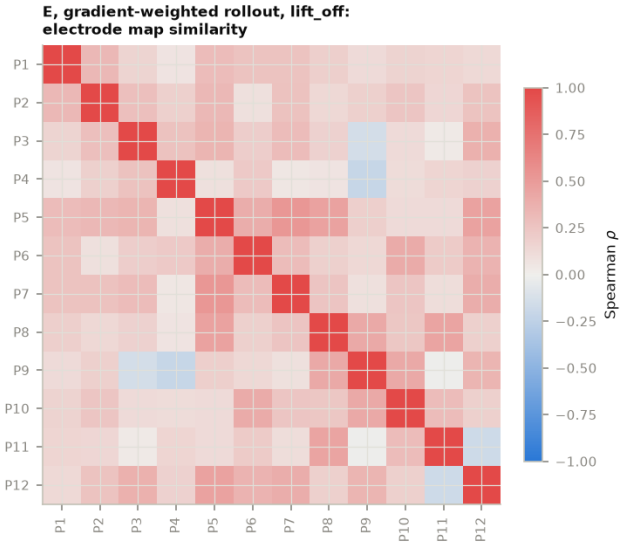
- **چطور بخوانیم.** هر چه ستون از خط سیاه بالاتر باشد، شباهت واقعی‌تر است. فاصله‌ی ستون سبز از آبی نشان می‌دهد میانگین گروه چقدر تمیزتر از یک نفر است.
- **چه می‌فهمیم.** همه‌ی ۱۲ نوع نقشه پنج تا شش برابر بالاتر از خط شانس‌اند؛ پس شباهت تصادفی نیست. اما مقدار آبی فقط حدود ۰٫۲ است؛ یعنی دو نفر تصادفی فقط کمی شبیه‌اند. سبز تقریباً دو برابر آبی است، پس هر نفر به میانگین گروه شبیه‌تر است تا به یک نفر دیگر. این الگوی «یک نقشه‌ی مشترک به‌علاوه‌ی نویز فردی زیاد» است. ستون‌ها تقریباً هم‌قدند؛ هیچ روش یا رخدادی یکسانی خیلی بهتری نمی‌دهد.



شکل ۴۷: یکسانی نقشه‌ی الکترودها بین شرکت‌کننده‌ها: pairwise ρ (آبی) و LOO ρ (سبز) در برابر صدک ۹۵ null (خط سیاه). ستون بالاتر از خط یعنی یکسانی بیشتر از شانس.

ماتریس شباهت دوبه‌دو (شکل ۴۸). هر خانه همبستگی اسپیرمن نقشه‌ی الکترود دو نفر است؛ قرمز یعنی شبیه، آبی یعنی برعکس و سفید یعنی بی‌ربط. قطر همیشه ۱ است.

- **چطور بخوانیم.** اگر افراد چند گروه با نقشه‌های متفاوت بودند، در ماتریس بلوک‌های قرمز جدا از هم دیده می‌شد. اگر یک یا دو نفر نقشه‌ی بسیار متفاوتی داشتند، سطر و ستون آن‌ها سفید یا آبی بود.
- **چه می‌فهمیم.** تقریباً همه‌ی خانه‌ها قرمز کم‌رنگ‌اند (حدود ۰٫۱ تا ۰٫۴) و هیچ بلوک یا گروهی دیده نمی‌شود. فقط چند جفت کمی آبی‌اند (مثلاً P3 و P4 با P9، و P11 با P12). پس افراد زیرگروه ندارند و هیچ‌کس نقشه‌ی کاملاً متفاوتی ندارد. یک الگوی مشترک ضعیف در همه هست و میانگین گرفتن روی گروه کار درستی است.



شکل ۴۸: همبستگی اسپیرمن نقشه‌ی الکترود E (gradient-weighted rollout، lift-off) برای هر جفت شرکت‌کننده.

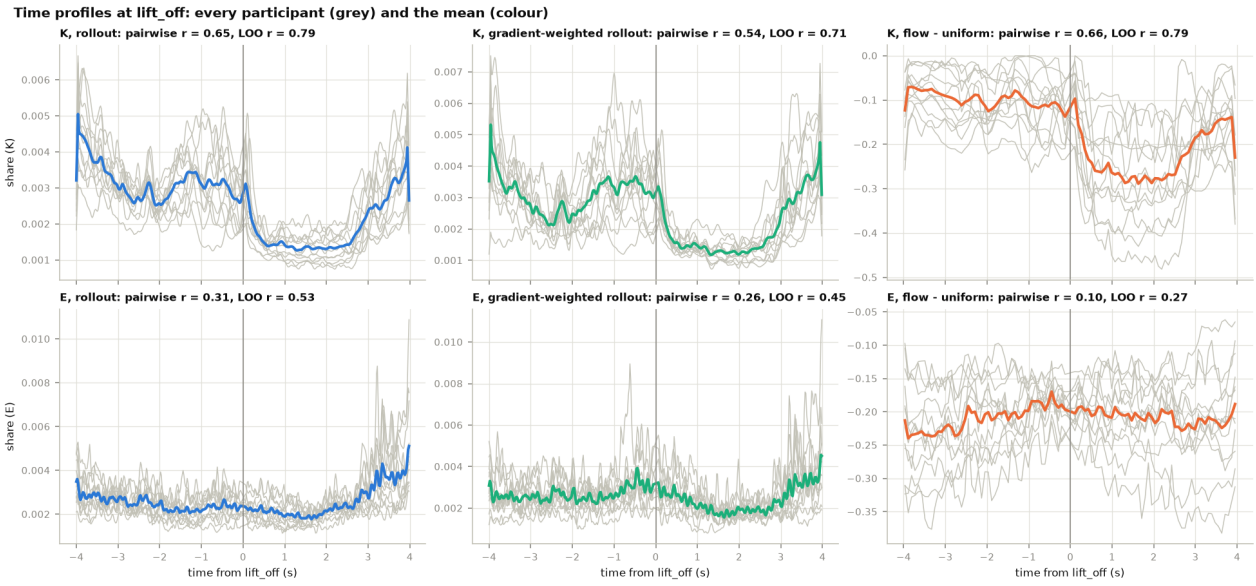
۳.۱۰ منحنی‌های زمانی

شکل منحنی‌های زمانی (شکل ۴۹). شش پنل دارد: ردیف بالا K و ردیف پایین E؛ ستون‌ها از چپ rollout، gradient-weighted rollout و «flow منهای یکنواخت». هر خط خاکستری منحنی یک شرکت‌کننده است و خط رنگی میانگین ۱۲ نفر. شباهت دوبه‌دو و شباهت هر نفر به بقیه بالای هر پنل نوشته شده است.

- **چطور بخوانیم.** اگر خط‌های خاکستری یک دسته‌ی باریک دور خط رنگی بسازند، همه‌ی افراد یک الگوی زمانی دارند. اگر پخش باشند و قله‌هایشان در جاهای مختلف باشد، میانگین چیزی را نشان می‌دهد که در هیچ فردی به آن شکل وجود ندارد.
- **چه می‌فهمیم.** در ردیف بالا خط‌های خاکستری دسته‌ی باریکی دارند و یک شکل را تکرار می‌کنند: بالا پیش از رخداد، افت تند درست بعد از آن، کف از ۰ تا ۲٫۵ ثانیه و بالا رفتن در انتهای پنجره. این مطمئن‌ترین نتیجه‌ی تفسیری کل گزارش است: K در همه‌ی افراد از حرکت پیش از جدا شدن استفاده می‌کند. در ردیف پایین خط‌ها پخش‌اند، شکل مشترک کمرنگ است و بیشترین ویژگی مشترک بالا رفتن در لبه‌ی پنجره است که به رخداد ربطی ندارد. پس الگوی زمانی E را نمی‌توان مثل K به همه‌ی افراد تعمیم داد.

جدول ۱۹: یکسانی منحنی‌های زمانی بین شرکت‌کننده‌ها (همبستگی پیرسون؛ توکن خودِ رخداد کنار گذاشته شده). null: جابه‌جایی دایره‌ای منحنی هر شرکت‌کننده. ستون آخر: زمان قله نسبت به رخداد، میانگین ± انحراف معیار بین شرکت‌کننده‌ها.

peak (s)	p	null 95%	Kendall's W	split-half	LOO ρ	pairwise ρ	نقشه
۰٫۸۴ ± -۰٫۷۷	۰٫۰۰۲	۰٫۱۲	۰٫۷۵	۰٫۹۶	۰٫۸۱	۰٫۶۹	K, first-touch, rollout
۰٫۵۳ ± -۰٫۴۶	۰٫۰۰۲	۰٫۰۸	۰٫۶۷	۰٫۹۵	۰٫۷۴	۰٫۵۸	K, first-touch, gradient-weighted rollout
۰٫۵۹ ± -۰٫۵۶	۰٫۰۰۲	۰٫۰۹	۰٫۶۹	۰٫۹۶	۰٫۷۹	۰٫۶۵	K, lift-off, rollout
۱٫۲۵ ± -۰٫۴۴	۰٫۰۰۲	۰٫۰۹	۰٫۶۷	۰٫۹۴	۰٫۷۱	۰٫۵۴	K, lift-off, gradient-weighted rollout
–	۰٫۰۰۲	۰٫۱۳	۰٫۷۳	۰٫۹۷	۰٫۸۳	۰٫۷۱	K, first-touch, flow - uniform
–	۰٫۰۰۲	۰٫۱۰	۰٫۶۱	۰٫۹۶	۰٫۷۹	۰٫۶۶	K, lift-off, flow - uniform
۲٫۱۹ ± ۰٫۲۳	۰٫۰۰۲	۰٫۰۸	۰٫۲۸	۰٫۸۸	۰٫۴۸	۰٫۲۶	E, first-touch, rollout
۱٫۲۲ ± -۰٫۵۱	۰٫۰۰۲	۰٫۰۷	۰٫۳۳	۰٫۸۰	۰٫۴۵	۰٫۲۵	E, first-touch, gradient-weighted rollout
۲٫۳۶ ± -۰٫۰۳	۰٫۰۰۲	۰٫۰۸	۰٫۳۱	۰٫۹۱	۰٫۵۳	۰٫۳۱	E, lift-off, rollout
۱٫۵۶ ± -۰٫۸۱	۰٫۰۰۲	۰٫۰۶	۰٫۳۳	۰٫۷۹	۰٫۴۵	۰٫۲۶	E, lift-off, gradient-weighted rollout
–	۰٫۰۲۰	۰٫۰۷	۰٫۱۸	۰٫۶۹	۰٫۲۸	۰٫۱۱	E, first-touch, flow - uniform
–	۰٫۰۲۰	۰٫۰۷	۰٫۱۸	۰٫۶۵	۰٫۲۷	۰٫۱۰	E, lift-off, flow - uniform



شکل ۴۹: منحنی‌های زمانی در اطراف lift-off برای هر ۱۲ شرکت‌کننده (خاکستری) و میانگین آن‌ها (رنگی). بالا: K؛ پایین: E.

K: بسیار یکسان. منحنی‌های زمانی K در افراد مختلف شکل تقریباً یکسانی دارند (جدول ۱۹، شکل ۴۹): pairwise r بین ۰٫۵۴ و ۰٫۷۱، LOO r تا ۰٫۸۳ و split-half بالای ۰٫۹۳. در همه‌ی افراد ورودی‌های پیش از رخداد سهم زیادی دارند و دو ثانیه‌ی بعد از آن کمترین سهم را. قله (در بازه‌ی ۳± ثانیه) به‌طور میانگین ۰٫۴ تا ۰٫۸ ثانیه پیش از رخداد است، با انحراف معیار ۰٫۵ تا ۱٫۳ ثانیه بین افراد.

E: یکسانی کمتر. منحنی‌های E شباهت کمتری دارند (pairwise r حدود ۰٫۲۵ تا ۰٫۳۱) و زمان قله‌شان بین افراد بیشتر جابه‌جا می‌شود (انحراف معیار ۱٫۲ تا ۲٫۴ ثانیه).

attention flow. منحنی «flow منهای یکنواخت» برای K همان‌قدر یکسان است که rollout. اما برای E کمترین یکسانی را دارد (pairwise r حدود ۰٫۱۰)، که با به سقف رسیدن attention flow در جریان EEG می‌خواند.

اثر لبه‌ی پنجره. در همه‌ی افراد و هر دو خروجی، سهم tokens نزدیک دو لبه‌ی پنجره‌ی ۸ ثانیه‌ای (۴± ثانیه) بالا می‌رود. این ربطی به رخداد ندارد. دلیلش positional encoding و این است که tokens لبه همسایه‌ی کمتری دارند. چون این الگو در همه مشترک است، بخشی از شباهت منحنی‌ها هم از همین می‌آید. برای همین قله فقط در بازه‌ی ۳± ثانیه جست‌وجو شده است.

۴.۱۰ muscle graph، باندهای EEG و مقایسه با استراحت

جدول ۲۰: یکسانی muscle graph (۲۰ درایه‌ی غیرقطری ماتریس ۵×۵) بین شرکت‌کننده‌ها.

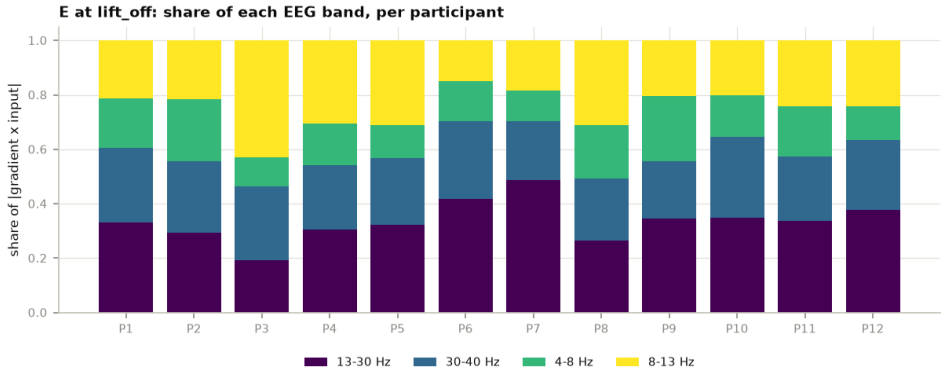
نقشه	pairwise ρ	LOO ρ	split-half	Kendall's W	null 95%	p
K, first-touch, rollout	۰٫۳۸	۰٫۵۸	۰٫۹۰	۰٫۴۳	۰٫۰۵	۰٫۰۰۲
K, first-touch, gradient-weighted rollout	۰٫۵۰	۰٫۶۷	۰٫۹۳	۰٫۵۴	۰٫۰۴	۰٫۰۰۲
K, lift-off, rollout	۰٫۴۱	۰٫۶۲	۰٫۹۲	۰٫۴۶	۰٫۰۵	۰٫۰۰۲
K, lift-off, gradient-weighted rollout	۰٫۳۹	۰٫۵۷	۰٫۸۶	۰٫۴۴	۰٫۰۵	۰٫۰۰۲
E, first-touch, rollout	۰٫۴۷	۰٫۶۳	۰٫۸۹	۰٫۵۱	۰٫۰۵	۰٫۰۰۲
E, first-touch, gradient-weighted rollout	۰٫۱۸	۰٫۲۹	۰٫۵۸	۰٫۲۵	۰٫۰۵	۰٫۰۰۲
E, lift-off, rollout	۰٫۴۶	۰٫۶۰	۰٫۸۶	۰٫۵۱	۰٫۰۵	۰٫۰۰۲
E, lift-off, gradient-weighted rollout	۰٫۱۹	۰٫۳۴	۰٫۶۳	۰٫۲۶	۰٫۰۵	۰٫۰۰۲

جدول ۲۱: سهم هر باند EEG در خروجی E هنگام lift-off (gradient × input). Kendall's W روی ترتیب باندها: ۰٫۵۹ (p = ۰٫۰۰۱>).

band	سهم میانگین (درصد)	انحراف معیار	شمار افراد با بیشترین سهم
13-30 Hz	۳۳٫۵	۷٫۴	9 / 12
30-40 Hz	۲۵٫۲	۲٫۷	0 / 12
4-8 Hz	۱۶٫۲	۴٫۴	0 / 12
8-13 Hz	۲۵٫۱	۷٫۶	3 / 12

شکل باندها (شکل ۵۰). هر ستون یک شرکت‌کننده است و چهار رنگ آن سهم چهار باند EEG در E هنگام جدا شدن (gradient × input). جمع هر ستون ۱ است.

- **چطور بخوانیم.** اگر همه‌ی باندها یک‌چهارم سهم داشتند، هر رنگ ۰٫۲۵ ستون را می‌گرفت. رنگی که در بیشتر ستون‌ها بزرگ‌تر از یک‌چهارم است، باندی است که مدل در بیشتر افراد ترجیح می‌دهد.
- **چه می‌فهمیم.** بتا (رنگ تیره، پایین هر ستون) در بیشتر افراد بزرگ‌ترین بخش است؛ در P6 و P7 به ۰٫۴ تا ۰٫۵ می‌رسد. استثنای روشن P3 است که آلفا (زرد، بالای ستون) در آن حدود ۰٫۴ سهم دارد. ترتیب باندها از فردی به فرد دیگر کمتر عوض می‌شود تا نقشه‌ی الکترودها؛ یعنی «کدام باند» پایدارتر از «کدام الکترود» است.



شکل ۵۰: سهم هر باند EEG در خروجی E هنگام lift-off برای هر شرکت‌کننده.

جدول ۲۲: یکسانی نقشه‌های t مقایسه‌ی رخداد با استراحت بین شرکت‌کننده‌ها.

نقشه	pairwise ρ	LOO ρ	Kendall's W	null 95%	p	الکترودهای معنادار (میانگین)
E, first-touch, event - rest t	۰٫۰۶	۰٫۱۸	۰٫۱۴	۰٫۰۴	۰٫۰۰۶	۹٫۹
E, lift-off, event - rest t	۰٫۰۶	۰٫۱۷	۰٫۱۳	۰٫۰۴	۰٫۰۱۴	۱۱٫۲

muscle graph. درایه‌های غیرقطری rollout (یعنی هر عضله چقدر از عضله‌ی دیگر اطلاعات می‌گیرد) در K و E یکسانی متوسط تا خوبی دارند (جدول ۲۰، pairwise ρ حدود ۰٫۳۸ تا ۰٫۵۰). نسخه‌ی gradient-weighted برای E یکسانی کمتری دارد (حدود ۰٫۱۸).

باندهای EEG. باند بتا (۱۳ تا ۳۰ هرتز) با میانگین حدود ۳۴ درصد بیشترین سهم را دارد و در ۹ نفر از ۱۲ نفر اول است؛ در ۳ نفر دیگر آلفا اول است (جدول ۲۱). توافق افراد روی ترتیب چهار باند خوب است (Kendall's W حدود ۰٫۵۵ تا ۰٫۶۰).

مقایسه‌ی رخداد با استراحت. نقشه‌های t بین افراد تقریباً شبیه هم نیستند (جدول ۲۲، pairwise ρ حدود ۰٫۰۶)، هرچند هنوز از null بیشترند. یعنی اینکه «کدام الکترود در رخداد بیشتر از استراحت سهم دارد» در هر نفر فرق می‌کند. این نقشه‌ها برای ادعای گروهی مناسب نیستند.

۵.۱۰ جمع‌بندی

- **قوی و تکرارپذیر.** الگوی زمانی K: همه‌ی افراد به حرکت پیش از رخداد نگاه می‌کنند. همچنین نقشه‌ی گروهی الکترودهای E با دو کانون C3 و CP1 (split-half حدود ۰٫۷).

- **معنادار ولی ضعیف در سطح فرد.** نقشه‌ی الکترود هر شرکت‌کننده (pairwise ρ حدود ۰٫۲). ادعا درباره‌ی الکترودها باید درباره‌ی گروه باشد، نه یک نفر.
- **قابل اتکا نیست.** نقشه‌های مقایسه‌ی رخداد با استراحت، و «flow منهای یکنواخت» برای E.
- **دیده نشد.** هیچ روشی الگوی خاص هر عضله را به‌طور تکرارپذیر بین افراد نشان نمی‌دهد.

۱۱ مقایسه‌ی نقشه‌های rollout با پژوهش‌های پیشین

بخش ۱۰ نشان داد کدام بخش‌های نقشه‌ها بین شرکت‌کننده‌ها تکرار می‌شوند. اما تکرارپذیر بودن یعنی پایدار بودن، نه درست بودن. این بخش می‌پرسد: آیا همین بخش‌های تکرارپذیر با آنچه پژوهش‌های قبلی درباره‌ی رابطه‌ی EEG و فعالیت عضله یافته‌اند می‌خوانند؟

دو دسته پژوهش مرجع.

- **corticomuscular coherence (CMC).** این روش اصلی ساختن نقشه‌ی «از عضله به مغز» است. CMC می‌سنجد نوسان‌های یک کانال EEG (یا MEG) و نوسان‌های EMG یک عضله در یک فرکانس خاص چقدر با هم هماهنگ‌اند. اگر یک ناحیه‌ی قشر و یک عضله هم‌آهنگ نوسان کنند، احتمالاً آن ناحیه فرمان عضله را می‌فرستد.
- **event-related desynchronization (ERD).** این پژوهش‌ها تغییر توان باندهای EEG را در اطراف حرکت می‌سنجند. مثلاً توان باند بتا روی قشر حرکتی کمی پیش از شروع حرکت پایین می‌آید.

یک تفاوت مهم در روش. مدل v2 توان باندهای EEG را می‌بیند، یعنی اینکه نوسان در هر باند چقدر بزرگ است (با هموارسازی ۵ هرتز)، نه فاز آن. CMC اما به هم‌فازی نوسان‌های قشر و عضله در ۱۵ تا ۳۰ هرتز بستگی دارد. هدف مدل هم پوش EMG با low-pass ۸ هرتز است که این نوسان‌های سریع را ندارد. پس مدل اصلاً نمی‌تواند CMC را یاد بگیرد و آنچه یاد می‌گیرد به ERD نزدیک‌تر است. در نتیجه مقایسه با CMC فقط درباره‌ی این است که اطلاعات «کجا» است، نه اینکه «چه» اطلاعاتی است.

۱.۱۱ مکان: کدام الکترودها

پژوهش‌های پیشین. CMC در باند بتا بیشترین مقدار را روی قشر حسی-حرکتی نیمکره‌ی مقابل دست دارد. برای گرفتن دقیق با دست راست، [۱۲] CMC معنادار را روی M1 نیمکره‌ی چپ و روی ناحیه‌ی حرکتی مکمل (SMA) گزارش کرده‌اند. روی همین داده (WAY-EEG-GAL)، [۱۳] CMC را بین C3 و هر پنج عضله حساب کرده‌اند؛ البته فقط برای یک شرکت‌کننده (P7) و با C3 که از پیش انتخاب شده بود. در پژوهشی با ۳۳ نوع گرفتن [۱۴]، EEG ناحیه‌ی آهیانه‌ای نیمکره‌ی مقابل در باند mu در مرحله‌های پایانی گرفتن و نگه‌داشتن با فعالیت عضله رابطه داشت.

نتیجه‌ی ما. تنها الکترودهایی که در سطح گروه به‌طور معنادار سهمی بیشتر از یکنواخت دارند C3 و CP1 هستند (جدول ۱۸). این دو دقیقاً روی قشر حسی-حرکتی و حسی-آهیانه‌ای نیمکره‌ی چپ‌اند، یعنی نیمکره‌ی مقابل دست راست. این با هر سه گزارش بالا سازگار است. C4 در نیمکره‌ی هم‌سمت دست سوم است ولی معنادار نیست؛ پژوهش‌های CMC هم سازمان دوطرفه با برتری نیمکره‌ی مقابل دیده‌اند. ناحیه‌ی SMA (اطراف Cz و FCz) در نقشه‌ی ما برجسته نیست.

آنچه با پژوهش‌ها نمی‌خواند. در بسیاری از افراد، الکترودهای پس‌سری (O1، PO9، PO10)، گیجگاهی و پیشانی هم سهم بالایی دارند. این نواحی در پژوهش‌های CMC دست جایی ندارند. به احتمال زیاد این سهم از پردازش بینایی (دیدن چراغ شروع و جسم)، حرکت چشم یا فعالیت عضلات سر و گردن می‌آید، نه از فرمان حرکتی.

۲.۱۱ فرکانس: کدام باندها

پژوهش‌های پیشین. CMC در باند بتا (۱۵ تا ۳۰ هرتز) هنگام انقباض پایدار و نگه‌داشتن بیشترین است و با شروع حرکت کم می‌شود [۱۱]. روی همین داده، طیف CMC بین C3 و عضله‌ها قله‌هایی در حدود ۱۰، ۲۰ و ۳۰ هرتز داشت [۱۳]. در ERD، توان mu و بتا روی قشر حسی-حرکتی مقابل از حدود یک ثانیه پیش از حرکت کم می‌شود، و پس از پایان حرکت توان بتا حتی از حالت پایه بالاتر می‌رود [۱۵].

نتیجه‌ی ما. در input × gradient، باند بتا (۱۳ تا ۳۰ هرتز) با میانگین ۳۳٫۵ درصد بیشترین سهم را دارد و در ۹ نفر از ۱۲ نفر اول است. در ۳ نفر دیگر آلفا (۸ تا ۱۳ هرتز) اول است (جدول ۲۱). این ترتیب با هر دو دسته پژوهش سازگار است. سهم گامای پایین (۳۰ تا ۴۰ هرتز، حدود ۲۵ درصد) بیشتر از انتظار است. این باند به artifact عضلات سر حساس است.

۳.۱۱ زمان: پیش یا پس از رخداد

پژوهش‌های پیشین. ERD بتا حدود یک ثانیه پیش از شروع حرکت آغاز می‌شود [۱۵]. CMC برعکس، در نگه‌داشتن پایدار بیشترین و در حین حرکت کمترین است [۱۱].

نتیجه‌ی ما. قله‌ی gradient-weighted rollout خروجی E به‌طور میانگین ۰٫۵ تا ۰٫۸ ثانیه پیش از اولین تماس و lift-off است (جدول ۱۹). این با زمان‌بندی ERD پیش از حرکت می‌خواند. اما دو نکته با CMC نمی‌خواند. اول، زمان این قله بین افراد خیلی جابه‌جا می‌شود (انحراف معیار ۱٫۲ تا ۱٫۶ ثانیه). دوم، E در دو ثانیه‌ی پس از lift-off کمترین سهم را به tokens می‌دهد؛ درست همان آغاز نگه‌داشتن که CMC در پژوهش‌ها بیشترین است. پس مدل بیشتر از تغییرهای اطراف رویدادهای حرکتی استفاده می‌کند تا از هماهنگی پایدار مغز و عضله در نگه‌داشتن.

۴.۱۱ عضله: کدام عضله‌ها

پژوهش‌های پیشین. CMC برای عضله‌های انتهایی دست (مثل FDI) قوی و شناخته‌شده است. روی همین داده، بهترین طبقه‌بندی وزن جسم با CMC از BR، FDI و FD به دست آمد و AD ضعیف‌ترین بود [۱۳].

نتیجه‌ی ما. ترتیب برعکس است. E برای AD (عضله‌ی شانه، نزدیک تنه) بهترین پیش‌بینی را دارد (r میانگین ۰٫۷۸) و برای عضله‌های انگشت، FD و FDI، ضعیف‌ترین (r حدود ۰٫۵۰). نقشه‌های الکترود پنج عضله هم تقریباً یکسان‌اند (جدول ۱۷).

این دو نتیجه با هم نشان می‌دهند که E بیشتر مرحله‌ی کلی حرکت بازو را از EEG می‌خواند (دست در حال رفتن است، جسم را گرفته، بلندش کرده یا در استراحت است)، نه فرمان قشری خاص هر عضله را. احتمالاً AD که بازو را بالا می‌برد بیشترین تغییر را بین این مرحله‌ها دارد و برای همین با این اطلاعات بهتر از همه پیش‌بینی می‌شود. همین توضیح می‌دهد چرا EEG تقریباً چیزی به K اضافه نمی‌کند (بخش ۱۲): مرحله‌ی حرکت در سینماتیک هم هست.

۵.۱۱ تفاوت بین افراد

پژوهش‌های CMC تفاوت زیادی بین افراد گزارش می‌کنند. حتی در جوانان سالم، اندازه‌ی CMC از فردی به فرد دیگر بسیار فرق می‌کند و در برخی افراد اصلاً معنادار نیست [۱۶، ۱۷]. نتیجه‌ی ما هم همین تصویر را دارد: نقشه‌ی هر فرد فقط کمی شبیه دیگران است (ρ pairwise حدود ۰٫۲)، ولی نقشه‌ی گروه تکرارپذیر است (split-half حدود ۰٫۷). پس ادعاهای مکانی باید درباره‌ی گروه باشند.

۶.۱۱ مقایسه با Pinto Neto (2026) روی همین داده

نزدیک‌ترین پژوهش به کار ما [۱۸] است. آن پژوهش روی همین ۱۲ شرکت‌کننده‌ی WAY-EEG-GAL ده مدل را آزموده است، از جمله یک graph attention network روی گرافی از ۳۲ کانال EEG و ۵ کانال EMG و یک Transformer چهارلایه. تفسیر مدل‌ها هم با feature importance، فیلترهای EEGNet و attention rollout انجام شده است.

مسئله‌ی آن پژوهش با ما فرق دارد. آن‌ها از یک پنجره‌ی یک‌ثانیه‌ای در زمان نگه‌داشتن، وزن و جنس سطح جسم را طبقه‌بندی می‌کنند و مدل را روی هر نفر با مدلی که روی ۱۱ نفر دیگر آموزش دیده می‌سنجند (leave-one-subject-out). ما پوش پیوسته‌ی EMG را برای هر نفر جداگانه از سینماتیک و EEG پیش‌بینی می‌کنیم. با این حال چند نتیجه‌ی آن‌ها مستقیم با نتایج ما قابل مقایسه است (جدول ۲۳).

جدول ۲۳: مقایسه با Pinto Neto (2026) روی WAY-EEG-GAL.

جنبه	Pinto Neto (2026)	این گزارش
سهم EEG	EEG به‌تنهایی نزدیک شانس (دقت ۰٫۳۴ تا ۰٫۳۸، شانس ۰٫۳۳)؛ افزودن EEG به EMG دقت را کم می‌کند	F برابر K؛ EEG حدود ۰٫۵ درصد واریانس باقی‌مانده را توضیح می‌دهد (بخش ۱۲)
کنار گذاشتن EEG	graph attention با کم کردن وزن کانال‌های کم‌اطلاعات در برابر افزودن EEG مقاوم است	gate نزدیک صفر می‌ماند؛ همان سازوکار به شکل صریح
EEG به‌تنهایی	در نگه‌داشتن پایدار، وزن و سطح از EEG قابل خواندن نیست	E با r ۰٫۶۴۵ مرحله‌ی حرکت را در طول کل سری می‌خواند
الکترودها	بیشترین EEG importance برای سطح روی FC1، Cz، C3، FC2 و C4؛ به گفته‌ی خودشان نشانه‌ی هم‌تغییری با EMG، نه رمزگشایی مستقل	کانون گروهی C3 و CP1، سپس C4؛ همان نوار حسی-حرکتی
فرکانس	فیلترهای EEGNet در بتا و گامای بالا؛ برترین ویژگی‌های EEG گامای بالا در Fp1، FC5 و O2	بتا اول؛ گامای پایین حدود ۲۵ درصد؛ سهم پیشانی و پس‌سری
عضله	برترین ویژگی وزن: توان گامای بالای EMG عضله‌ی AD	E بهترین برای AD
attention rollout	توجه دریافتی گره‌های EMG بیشتر از گره‌های EEG؛ میانگین روی همه‌ی foldها، بدون سنجش یکسانی بین افراد	سنجش یکسانی بین ۱۲ نفر (بخش ۱۰)

کجا هم‌نظریم. دو پژوهش با مدل‌ها و مسئله‌های متفاوت به یک نتیجه می‌رسند: در WAY-EEG-GAL اطلاعات اصلی در سیگنال‌های بدن است (EMG در آن پژوهش، سینماتیک در ما)، و EEG سطح سر چیز قابل‌اندازه‌گیری‌ای به آن اضافه نمی‌کند. رفتار مدل‌ها هم شبیه است: graph attention آن‌ها به کانال‌های EEG توجه کمی می‌کند و gate ما نزدیک صفر می‌ماند. نقشه‌ی الکترود هر دو کار روی نوار حسی-حرکتی است و C3 و C4 در هر دو دیده می‌شوند.

کجا فرق داریم. E ما با $r \approx 0/645$ از هر ۱۲ null test گذشت، اما EEG آن پژوهش نزدیک شانس بود. این تناقض نیست. پنجره‌ی آن‌ها فقط زمان نگه‌داشتن است و می‌پرسند جسم سنگین است یا سبک. در این بازه دست ثابت است و تفاوت شرایط بسیار کوچک است. E ما در طول کل سری تفاوت مرحله‌های حرکت را می‌خواند (رسیدن، گرفتن، بلند کردن، استراحت) که تفاوت‌های بسیار بزرگ‌تری‌اند. این با نتیجه‌ی بخش‌های قبل هم می‌خواند: E بیشتر مرحله‌ی کلی حرکت را از EEG می‌گیرد تا فرمان خاص عضله را.

چه چیزی اضافه می‌کنیم. Pinto Neto نقشه‌های توجه را فقط توصیفی و به‌صورت میانگین روی همه‌ی foldها گزارش کرده و سنجش پایداری آن‌ها بین افراد را به کار آینده سپرده است. بخش ۱۰ دقیقاً همین را برای نقشه‌های ما انجام می‌دهد: نقشه‌ی گروه تکرارپذیر است (split-half حدود ۰/۷) و نقشه‌ی یک نفر پرنویز.

یک تفاوت در پیش‌پردازش هم هست. آن پژوهش عمداً ICA انجام نداده و EMG را یکسوسازی نکرده است؛ در خط پایه‌ی ما ICA انجام شده و هدف پوش هموار است. پس سهم بالای گامای پیشانی و پس‌سری در آن پژوهش ممکن است بیشتر از نتایج ما از artifact اثر گرفته باشد.

۷.۱۱ جمع‌بندی و محدودیت‌ها

جدول ۲۴: خلاصه‌ی مقایسه‌ی نتایج rollout با پژوهش‌های پیشین.

جنبه	پژوهش‌های پیشین	نتیجه‌ی ما	سازگاری
مکان	قشر حسی-حرکتی مقابل (M1)، SMA، آهیانه‌ای مقابل	C3 و CP1 معنادار؛ C4 سوم؛ SMA برجسته نیست	بله، با یک استثنا
artifact	–	سهم پس‌سری، گیجگاهی و پیشانی در بسیاری از افراد	هشدار
فرکانس	بتا (و mu)	بتا اول در ۹ نفر از ۱۲، آلفا در ۳ نفر	بله
زمان	ERD از حدود ۱ ثانیه پیش از حرکت؛ CMC بیشینه در نگه‌داشتن	قله حدود ۰/۵ تا ۰/۸ ثانیه پیش از رخداد؛ کمترین سهم در آغاز نگه‌داشتن	با ERD بله، با CMC نه
عضله	CMC قوی در عضله‌های انتهایی دست	E بهترین برای AD، ضعیف برای FD و FDI؛ نقشه‌ی خاص هر عضله نیست	نه
تفاوت افراد	زیاد	متوسط در سطح فرد، تکرارپذیر در سطح گروه	بله

جدول ۲۴ نتیجه را خلاصه می‌کند. نقشه‌های rollout در مکان و فرکانس با دانش موجود سازگارند: کانون تکرارپذیرشان روی قشر حسی-حرکتی مقابل دست است و باند بتا را ترجیح می‌دهند. در زمان و در خاص بودن برای هر عضله با CMC نمی‌خوانند، و به ERD و خواندن مرحله‌ی کلی حرکت نزدیک‌ترند.

این مقایسه کیفی است، نه عددی. هیچ‌کدام از این پژوهش‌ها نقشه‌ی عددی‌ای برای WAY-EEG-GAL با ۱۲ شرکت‌کننده منتشر نکرده‌اند که بتوان مستقیم با آن همبستگی گرفت. پژوهش CMC روی همین داده [۱۳] فقط یک نفر و یک الکترود را بررسی کرده است. نقشه‌های Pinto Neto [۱۸] هم برای مسئله‌ی دیگری (طبقه‌بندی وزن و سطح در نگه‌داشتن) و فقط به‌صورت میانگین گروه گزارش شده‌اند.

گام بعدی منطقی ساختن نقشه‌های مرجع روی خود داده‌ی ماست: CMC (از EMG خام، چون پوش هموار باند بتا ندارد) و ERD، برای همین ۱۲ شرکت‌کننده و همین رخدادها. سپس می‌توان همبستگی مکانی این نقشه‌ها با نقشه‌های rollout را برای هر فرد اندازه گرفت.

۱۲ residual test: آیا EEG چیزی بیش از سینماتیک دارد؟

۱.۱۲ پرسش

F با K برابر ماند و gate نزدیک صفر. این دو توضیح ممکن دارد:

۱. EEG واقعاً اطلاعاتی درباره‌ی خطای K ندارد؛

۲. دارد، ولی ماژول fusion نتوانسته آن را یاد بگیرد.

residual test این دو را بدون استفاده از fusion از هم جدا می‌کند. مستقیم می‌پرسد: آیا از EEG می‌توان خطای K را پیش‌بینی کرد؟ اگر جواب منفی باشد، توضیح اول درست است. اگر مثبت باشد و fusion آن را پیدا نکرده باشد، توضیح دوم.

۲.۱۲ روش

باقی‌مانده. خطای K در حوزه‌ی جذر و با نرخ token: $\varepsilon = u - \hat{u}_K$، که $u = \sqrt{y/s_c}$ هدف و $\hat{u}_K$ خروجی K است. این همان بخشی از فعالیت عضله است که سینماتیک توضیح نداده است.

ویژگی‌ها. دو مجموعه ویژگی EEG، هر کدام برای هر token:

- **tokens:** خروجی temporal encoder جریان EEG (۶۴ بعد)، یعنی دقیقاً همان چیزی که fusion می‌خواند.
- **band power:** ۱۲۸ ویژگی ورودی مدل (۳۲ الکترود × ۴ باند) با moving average یک‌ثانیه‌ای. این مجموعه به جریان EEG آموزش‌دیده وابسته نیست و بررسی مستقلی است.

برازش. یک ridge regression خطی، با ورودی استانداردشده و عرض از مبدأ، باقی‌مانده را از ویژگی‌ها پیش‌بینی می‌کند:

$$\hat{W} = \arg\min_{W} \; \|\varepsilon - ZW\|^2 + \alpha\, N\, \|W\|^2. \tag{۲۳}$$

جمله‌ی دوم وزن‌ها را کوچک نگه می‌دارد تا مدل نویز را حفظ نکند. α از میان $10^{-2}, \ldots, 10^{4}$ با cross-validation روی پنج بلوک پیوسته‌ی زمانی انتخاب می‌شود.

ridge روی سری‌های validation برازش می‌شود، نه آموزش. دلیلش این است که K داده‌ی آموزش را تا حدی حفظ کرده و خطایش روی آن کوچک‌تر از واقع است. اما K روی سری‌های validation آموزش ندیده، پس خطایش آنجا شبیه خطایش روی سری‌های آزمون است.

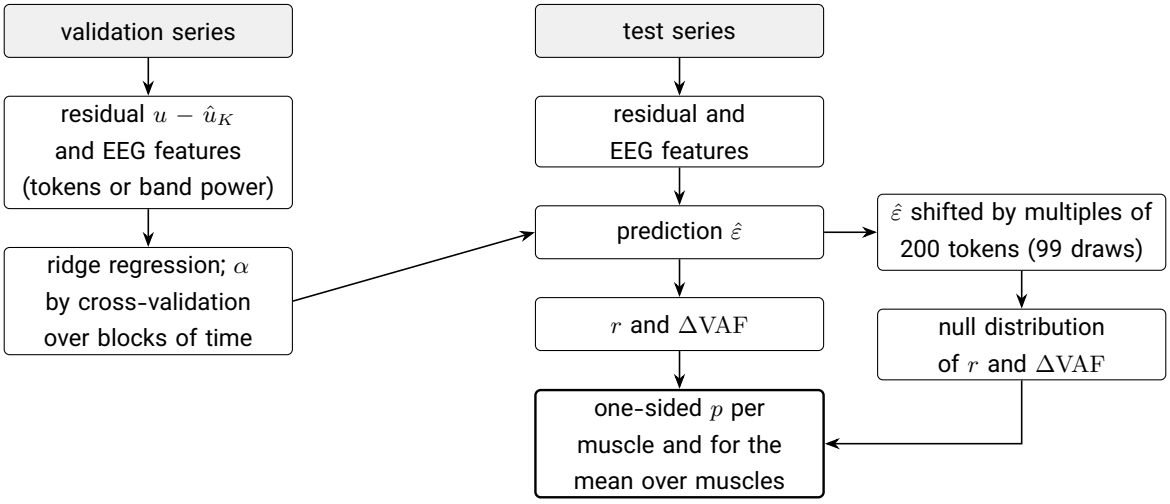
سنجش روی سری‌های آزمون. برای هر عضله دو عدد:

$$r = \mathrm{corr}(\hat{\varepsilon}, \varepsilon), \qquad \Delta\mathrm{VAF} = \mathrm{VAF}\big(s_c\, \mathrm{relu}(\hat{u}_K + \hat{\varepsilon})^2,\; y\big) - \mathrm{VAF}\big(s_c\, \hat{u}_K^2,\; y\big). \tag{۲۴}$$

r می‌گوید پیش‌بینی خطا چقدر با خطای واقعی هم‌جهت است. $\Delta\mathrm{VAF}$ می‌گوید اگر این پیش‌بینی را به K اضافه کنیم، دقت چقدر بهتر می‌شود.

null distribution. برای اینکه بدانیم r از شانس بیشتر است یا نه، پیش‌بینی $\hat{\varepsilon}$ به‌طور دایره‌ای در زمان جابه‌جا و دوباره سنجیده می‌شود (۹۹ بار). جابه‌جایی رابطه‌ی واقعی با زمان را از بین می‌برد ولی شکل کلی سیگنال را نگه می‌دارد. اندازه‌ی جابه‌جایی همیشه مضربی از گام پیش‌بینی (۲۰۰ token، یعنی ۴ ثانیه) و دست‌کم یک پنجره است؛ دلیلش در بخش بعد آمده است. p یک‌طرفه است و هیچ‌وقت کمتر از یک‌تقسیم‌برتعداد جابه‌جایی‌های ممکن گزارش نمی‌شود (۱۵۲ تا ۱۹۰ جابه‌جایی در شرکت‌کننده‌های مختلف). آزمون اصلی روی میانگین پنج عضله است.

مقایسه با مدل. همبستگی اصلاحی که خود مدل ساخته $(F - K)$ با باقی‌مانده هم گزارش می‌شود: r_{model}. اگر r_{model} هم‌اندازه‌ی r ridge باشد، fusion همان چیزی را یافته که در EEG هست.



شکل ۵۱: residual test.

۳.۱۲ یک دام: موقعیت درون پنجره

encoderهای زمانی به هر sinusoidal positional encoding token اضافه می‌کنند. پس EEG tokens می‌دانند در کجای پنجره‌ی ۸ ثانیه‌ای هستند. از طرف دیگر، پیش‌بینی پیوسته‌ی K از پنجره‌هایی ساخته شده که هر ۴ ثانیه یک بار شروع می‌شوند، پس ممکن است خطای کوچکی با همین دوره‌ی ۴ ثانیه‌ای داشته باشد.

یک ridge روی tokens می‌تواند این دو الگوی دوره‌ای را به هم ربط دهد، بی آنکه EEG واقعاً اطلاعاتی داشته باشد. این اتفاق در آزمون روی داده‌ی کاملاً تصادفی دیده شد: با جابه‌جایی‌های دلخواه، r حدود ۰٫۱ و «معنادار» شد.

راه حل: اگر جابه‌جایی همیشه مضربی از ۴ ثانیه باشد، این الگوی دوره‌ای در داده‌ی جابه‌جاشده هم سر جایش می‌ماند. پس این اثر در null distribution هم هست و فقط اطلاعاتی شمرده می‌شود که به زمان واقعی بسته است. ویژگی‌های band power اصلاً اطلاعات موقعیت ندارند و از این نظر بررسی تمیزتری هستند.

۴.۱۲ نتایج

اثر واقعی است. با tokens میانگین r ۰٫۰۷۳ است، در حالی که در null distribution ۰٫۰۰۱- است. در ۱۰ شرکت‌کننده از ۱۲ نفر $p \leq$ ۰٫۰۵ است؛ از شانس کمتر از یک مورد انتظار می‌رود. با band power میانگین r ۰٫۰۴۰ است و در ۶ نفر معنادار.

اما اثر بسیار کوچک است. $r =$ ۰٫۰۷ یعنی حدود ۰٫۵ درصد از واریانس باقی‌مانده. اضافه کردن این پیش‌بینی به K، VAF را به‌طور میانگین ۰٫۱۰ واحد (با tokens) بهتر و ۰٫۱۳ واحد (با band power) بدتر می‌کند. فقط در ۷ نفر (tokens) و ۲ نفر (band power) بهره‌ی VAF هم مثبت و هم معنادار است.

استثنا: P8. با tokens VAF ۲٫۴ واحد بهتر می‌شود و r برای BR، FD و ED تا ۰٫۲۹ می‌رسد. P8 ضعیف‌ترین K را دارد (VAF ۵۸ درصد)، پس خطای بیشتری برای توضیح دادن باقی مانده است.

جدول ۲۵: residual test، ردیف میانگین روی پنج عضله برای هر شرکت‌کننده. r: همبستگی باقی‌مانده‌ی پیش‌بینی‌شده و واقعی روی سری‌های آزمون؛ p: در برابر همان پیش‌بینی با جابه‌جایی زمانی؛ VAF∆: بهره‌ی K به‌علاوه‌ی باقی‌مانده‌ی پیش‌بینی‌شده نسبت به K (واحد درصد)؛ ستون آخر همبستگی اصلاحِ خودِ مدل (F_{eeg}) با باقی‌مانده.

شرکت‌کننده	tokens r	p	VAF∆	band power r	p	VAF∆	اصلاح مدل r
P1	۰٫۰۵۵	۰٫۰۱	-۰٫۰۳	۰٫۰۴۱	۰٫۰۳	-۰٫۰۶	۰٫۰۹۲
P2	۰٫۰۸۵	۰٫۰۱	+۰٫۰۳	۰٫۰۸۳	۰٫۰۱	-۰٫۰۰	۰٫۰۰۴
P3	۰٫۱۴۱	۰٫۰۱	+۰٫۲۴	۰٫۱۰۴	۰٫۰۱	-۰٫۴۸	۰٫۰۸۴
P4	۰٫۰۸۸	۰٫۰۱	+۰٫۰۶	۰٫۰۰۶	۰٫۳۶	-۰٫۱۹	۰٫۰۶۴
P5	۰٫۰۶۵	۰٫۰۱	+۰٫۱۹	۰٫۰۳۰	۰٫۲۴	-۰٫۲۳	۰٫۰۸۸
P6	۰٫۰۵۹	۰٫۰۱	-۰٫۹۷	۰٫۰۶۲	۰٫۰۳	-۰٫۶۳	۰٫۱۲۲
P7	۰٫۰۰۱	۰٫۶۰	-۰٫۰۸	-۰٫۰۴۶	۱٫۰۰	-۰٫۰۸	۰٫۱۲۲
P8	۰٫۲۲۶	۰٫۰۱	+۲٫۳۷	۰٫۱۲۲	۰٫۰۱	+۰٫۴۷	۰٫۱۵۲
P9	۰٫۰۷۸	۰٫۰۱	+۰٫۱۶	۰٫۰۴۲	۰٫۰۱	+۰٫۲۳	۰٫۱۴۷
P10	-۰٫۰۵۵	۱٫۰۰	-۰٫۸۶	-۰٫۰۱۲	۰٫۸۱	-۰٫۵۹	-۰٫۰۰۱
P11	۰٫۰۳۹	۰٫۰۱	-۰٫۱۰	۰٫۰۱۷	۰٫۱۸	+۰٫۰۳	-۰٫۰۰۴
P12	۰٫۱۰۱	۰٫۰۱	+۰٫۱۵	۰٫۰۳۶	۰٫۰۸	-۰٫۰۴	۰٫۰۳۷
میانگین	۰٫۰۷۳		+۰٫۱۰	۰٫۰۴۰		-۰٫۱۳	۰٫۰۷۶

جدول ۲۶: residual test برای هر عضله، میانگین روی ۱۲ شرکت‌کننده؛ ستون‌های تعداد از ۱۲ شمرده شده‌اند.

عضله	tokens r	تعداد p≤۰۵٫۰	VAF∆	band power r	تعداد p≤۰۵٫۰	VAF∆
AD	۰٫۰۵۶	۷	+۰٫۰۴	۰٫۰۳۵	۴	+۰٫۰۲
BR	۰٫۰۷۹	۷	+۰٫۱۶	۰٫۰۲۱	۶	-۰٫۱۳
FD	۰٫۱۱۸	۸	+۰٫۱۴	۰٫۰۵۲	۷	-۰٫۴۶
ED	۰٫۰۷۸	۷	+۰٫۰۸	۰٫۰۵۱	۴	-۰٫۰۳
FDI	۰٫۰۳۶	۵	+۰٫۰۷	۰٫۰۴۲	۴	-۰٫۰۵

fusion همان چیزی را یاد گرفته که هست. r_{model}، یعنی همبستگی اصلاح خود مدل با باقی‌مانده، به‌طور میانگین ۰٫۰۷۶ است؛ هم‌اندازه‌ی ridge. پس fusion جهت درست را پیدا کرده است. ولی چون اطلاعات این‌قدر کم است، آموزش gate را نزدیک صفر نگه داشته است.

۵.۱۲ بحث

EEG در این داده سیگنالی کوچک اما پایدار درباره‌ی آنچه سینماتیک توضیح نمی‌دهد دارد. ارزش پیش‌بینی این سیگنال کمتر از نیم واحد VAF است. پس $F \approx K$ نتیجه‌ی درست این داده است، نه نقص fusion.

آیا آموزش جداگانه‌ی fusion کمکی می‌کرد؟ مثلاً یک مرحله‌ی اضافه فقط برای fusion، با هر دو جریان freezeشده و انتخاب بهترین دوره بر اساس خطای F. بر اساس اعداد بالا، در بهترین حالت حدود ۰٫۱ واحد به میانگین و حدود ۲ واحد به P8 اضافه می‌شد. این بهره هزینه‌ی آموزش دوباره‌ی ۱۲ نفر را توجیه نمی‌کند.

یک احتیاط. tokens بهتر از band power عمل کردند. اما tokens برای پیش‌بینی EMG آموزش دیده‌اند، پس می‌دانند حرکت در چه مرحله‌ای است. ممکن است بخشی از این سیگنال کوچک، زمان‌بندی حرکت یا artifact حرکت در EEG باشد و نه فرمان قشر حرکتی. پس r معنادار در اینجا **ثابت نمی‌کند** که EEG اطلاعات عصبی فراتر از سینماتیک دارد. آزمون بعدی می‌تواند همین ridge روی باندها یا الکترودهایی باشد که کمتر در معرض artifact حرکت‌اند.

۱۳ جمع‌بندی و محدودیت‌ها

آنچه به دست آمد. مدل پایه سه پرسش را در یک خروجی با هم قاطی می‌کرد. v2 با سه خروجی جدا به هر کدام جداگانه جواب داد.

۱. **سینماتیک چقدر خوب پیش‌بینی می‌کند؟** K با VAF ۷۵٫۸ درصد و r ۰٫۸۷۲ در هر ۱۲ شرکت‌کننده از مدل پایه بهتر است و دامنه را در هر سه وزن جسم با خطای کمتر از یک درصد پیش‌بینی می‌کند. چهار تغییر پشت این بهبودند: پنجره‌ی ۸ ثانیه‌ای، ویژگی‌های تاریخچه، حوزه‌ی جذر و جزء lift در loss function.

۲. **آیا EEG به‌تنهایی چیزی از حرکت می‌داند؟** بله. E با r ۰٫۶۴۵ در هر ۱۲ نفر از null test گذشت. اما آنچه می‌خواند بیشتر مرحله‌ی کلی حرکت است (رسیدن، گرفتن، بلند کردن، استراحت)، نه فرمان خاص هر عضله.

۳. **آیا EEG چیزی بیش از سینماتیک دارد؟** تقریباً نه. F با K برابر است. residual test سیگنالی واقعی ولی بسیار کوچک یافت (r حدود ۰٫۰۷، کمتر از نیم واحد VAF)، و fusion هم همین را یافته بود.

تفسیرپذیری. قاعده‌ی «یک مخلوط‌کننده» و recorder بیرونی باعث شدند rollout، attention flow، gradient-weighted rollout و نمای هر لایه برای هر خروجی و در همه‌ی لایه‌ها بدون حالت خاص کار کنند. آزمون‌های روی خودِ روش‌ها نشان دادند gradient-weighted rollout قابل‌اعتمادترین است: در deletion check بهترین است و کمترین شباهت را با مدل به‌هم‌ریخته دارد. attention flow در این معماری به سقف می‌رسد و فقط در مقایسه با خط پایه‌ی توجه یکنواخت معنا دارد.

در سطح گروه، نقشه‌ی الکترود E کانون تکرارپذیری روی C3 و CP1 دارد، بالای قشر حسی-حرکتی نیمکره‌ی مقابل دست، و باند بتا را ترجیح می‌دهد؛ هر دو با پژوهش‌های پیشین می‌خوانند. نقشه‌ی هر فرد جداگانه پرنویز است. سهم الکترودهای پیشانی و پس‌سری هشدار می‌دهد که بخشی از اطلاعات E ممکن است از artifact باشد.

محدودیت‌ها.

- rollout و attention flow فقط وزن‌های توجه را می‌بینند، و وزن residual connection ۰٫۵ یک قرارداد است. روش‌های گرادیانی فقط رفتار مدل را در نزدیکی ورودی فعلی و به‌صورت خطی می‌سنجند.
- K plain rollout برای مدل به‌هم‌ریخته هم شکل مشابهی دارد (همبستگی ۰٫۴۷)؛ پس شکل آن بیشتر از ساختار مدل می‌آید تا از یادگیری.
- پنجره‌های رخدادهای نزدیک به هم هم‌پوشانی دارند، پس p مقایسه‌ی رخداد با استراحت تقریبی است.
- هر مدل برای یک شرکت‌کننده آموزش دیده است؛ پیش‌بینی برای فرد تازه آزموده نشده است.
- پیش‌بینی برون‌خط است: هر token از کل پنجره‌ی ۸ ثانیه‌ای، از جمله لحظه‌های بعد از خودش، استفاده می‌کند.
- سقف داده (به‌ویژه برای FD) هر بهبود بیشتری را محدود می‌کند.

بازتولید. کد در شاخه‌ی KG-GT-v2 است (بسته‌ی v2/ و دفترچه‌ی main_v2.ipynb). جدول‌ها و شکل‌های فصل یکسانی بین شرکت‌کننده‌ها را اسکریپت v2-report/analysis/consistency.py از نتایج ذخیره‌شده می‌سازد و هیچ مدلی را اجرا نمی‌کند.

مراجع

[۱] M. D. Luciw, E. Jarocka, B. B. Edin. Multi-channel EEG recordings during 3,936 grasp and lift trials with varying weight and friction. Scientific Data, 1:140047, 2014.

[۲] A. Vaswani et al. Attention is all you need. NeurIPS, 2017.

[۳] P. Veličković et al. Graph attention networks. ICLR, 2018.

[۴] S. Abnar, W. Zuidema. Quantifying attention flow in transformers. ACL, 2020.

[۵] H. Chefer, S. Gur, L. Wolf. Generic attention-model explainability for interpreting bi-modal and encoder-decoder transformers. ICCV, 2021.

[۶] A. Shrikumar, P. Greenside, A. Shcherbina, A. Kundaje. Not just a black box: learning important features through propagating activation differences. arXiv:1605.01713, 2016.

[۷] W. Samek, A. Binder, G. Montavon, S. Lapuschkin, K.-R. Müller. Evaluating the visualization of what a deep neural network has learned. IEEE TNNLS, 28(11), 2017.

[۸] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, B. Kim. Sanity checks for saliency maps. NeurIPS, 2018.

[۹] T. E. Nichols, A. P. Holmes. Nonparametric permutation tests for functional neuroimaging: a primer with examples. Human Brain Mapping, 15(1), 2002.

[۱۰] L. I. Lin. A concordance correlation coefficient to evaluate reproducibility. Biometrics, 45(1), 1989.

[۱۱] J. M. Kilner, S. N. Baker, S. Salenius, R. Hari, R. N. Lemon. Human cortical muscle coherence is directly related to specific motor parameters. J. Neurosci., 20(23):8838–8845, 2000.

[۱۲] S. Chen, J. Entakli, M. Bonnard, E. Berton, J. B. De Graaf. Functional corticospinal projections from human supplementary motor area revealed by corticomuscular coherence during precise grip force control. PLOS ONE, 8(3):e60291, 2013.

[۱۳] G. Cisotto, A. V. Guglielmi, L. Badia, A. Zanella. Classification of grasping tasks based on EEG-EMG coherence. IEEE Healthcom, 2018 (arXiv:1809.03300).

[۱۴] A. I. Sburlea, G. R. Müller-Putz. Exploring representations of human grasping in neural, muscle and kinematic signals. Sci. Rep., 8:16669, 2018.

[۱۵] G. Pfurtscheller, F. H. Lopes da Silva. Event-related EEG/MEG synchronization and desynchronization: basic principles. Clin. Neurophysiol., 110(11):1842–1857, 1999.

[۱۶] J. Ushiyama et al. Between-subject variance in the magnitude of corticomuscular coherence during tonic isometric contraction of the tibialis anterior muscle in healthy young adults. J. Neurophysiol., 106(3):1379–1388, 2011.

[۱۷] R. Matsuya, J. Ushiyama, J. Ushiba. Inhibitory interneuron circuits at cortical and spinal levels are associated with individual differences in corticomuscular coherence during isometric voluntary contraction. Sci. Rep., 7:44417, 2017.

[۱۸] O. Pinto Neto. Architecture-data matching for EEG-EMG decoding: compact deep models match classical spectral decoders on the WAY-EEG-GAL grasp-and-lift dataset. Front. Neurosci., 20:1874302, 2026.